SQL 구원의 기술

똑똑하게 코딩하는 법

Effective SQL

존 비아시에스, 더글러스 스틸,
벤 클로디어 지음 | 홍형경 옮김

인천광역시미추홀도서관
123001KM0000406152

데이터베이스의 동작과 성능에 영향을 주는 61가지 SQL 기법을 다양한 예제로 설명한다!

길벗

지은이

존 비아시에스

45년 이상의 경력을 가진 데이터베이스 컨설턴트로, 시스템 분석가에서 시작해 IBM 메인프레임 시스템용 대규모 데이터베이스 애플리케이션을 설계했다. 응용데이터연구소에서 30명이 넘는 인원을 이끌며 6년간 IBM 메인프레임 컴퓨터용 데이터베이스 제품을 개발하고 연구하며 고객 지원을 했다.

더글러스 스틸

45년이 넘게 메인프레임과 PC를 넘나들며 전문가로 활동하고 있다. 2012년 퇴직 전까지 31년 동안 글로벌 정유 회사에서 일했다. 주로 데이터베이스와 데이터 모델링을 했으며, 말년에는 10만 대가 넘는 컴퓨터를 윈도우 7으로 올리는 SCCM 태스크 시퀀스를 개발했다.

벤 클로디어

IT Impact, Inc.에서 솔루션 아키텍트로 일하며 프리미어 액세스와 SQL Server 개발 숍을 운영한다. J Street Technology와 Advisicon 등 유명한 회사에서 프리랜서 컨설턴트를 겸하고 있다. 1인 솔루션부터 회사 전체 LOB 애플리케이션까지 많은 마이크로소프트 액세스 프로젝트를 수행했다. Microsoft SQL Server 2012 Solution Associate 인증을 보유하고 있으며, MySQL 5.0 인증 개발자이자 2009년부터 마이크로소프트 MVP다.

옮긴이

홍형경

치열한 회사 생활에서 빠져 나와 현재 프리랜서 프로그래머로 일하고 있다. 아직은 IT 분야에서 프리랜서란 직업이 외국에서의 그것처럼 인식되지는 않지만, 나름대로 나아가야 할 올바른 방향을 찾고 있는 중이다. Head First 시리즈를 비롯해 다수의 책을 번역했고 〈오라클 SQL과 PL/SQL을 다루는 기술〉을 집필했다.

표지 디자인 • 길벗 디자인실 박상희, 장기춘

EFFECTIVE SQL: 61 SPECIFIC WAYS TO WRITE BETTER SQL

Authorized translation from the English language edition, entitled EFFECTIVE SQL: 61 SPECIFIC WAYS TO WRITE BETTER SQL, 1st Edition by VIESCAS, JOHN; STEELE, DOUGLAS; CLOTHIER, BEN; WICKERATH, TOM, published by Pearson Education, Inc, publishing as Addison-Wesley Professional, Copyright © 2017 EFFECTIVE SQL: 61 SPECIFIC WAYS TO WRITE BETTER SQL.

All rights reserved. No part of this book may be reproduced or transmitted in any form or by any means, electronic or mechanical, including photocopying, recording or by any information storage retrieval system, without permission from Pearson Education, Inc. KOREAN language edition published by GILBUT PUBLISHING CO., LTD., Copyright © 2017.

이 책의 한국어판 저작권은 대니홍 에이전시를 통한 저작권사와의 독점 계약으로 (주)도서출판 길벗에 있습니다. 신저작권법에 의해 한국 내에서 보호를 받는 저작물이므로 무단전재와 무단복제를 금합니다.

SQL 코딩의 기술

초판 발행 · 2017년 11월 30일

지은이 · 존 비아시에스, 더글러스 스틸, 벤 클로디어
옮긴이 · 홍형경
발행인 · 이종원
발행처 · (주)도서출판 길벗
출판사 등록일 · 1990년 12월 24일
주소 · 서울시 마포구 월드컵로 10길 56(서교동)
대표 전화 · 02)332-0931 | **팩스** · 02)323-0586
홈페이지 · www.gilbut.co.kr | **이메일** · gilbut@gilbut.co.kr

기획 및 책임편집 · 안윤경(yk78@gilbut.co.kr) | **디자인** · 장기춘 | **제작** · 이준호, 손일순, 이진혁
영업마케팅 · 임태호, 전선하, 지운집 | **영업관리** · 김명자 | **독자지원** · 송혜란, 정은주

교정교열 · 김솔 | **전산편집** · 남은순 | **출력 및 인쇄** · (주)상지사P&B | **제본** · 신정문화사

▸ 잘못된 책은 구입한 서점에서 바꿔 드립니다.
▸ 이 책에 실린 모든 내용, 디자인, 이미지, 편집 구성의 저작권은 (주)도서출판 길벗과 지은이에게 있습니다. 허락 없이 복제하거나 다른 매체에 옮겨 실을 수 없습니다.

ISBN 979-11-6050-342-5 93000
(길벗 도서번호 006882)

정가 28,000원

독자의 1초를 아껴주는 정성 길벗출판사
(주)도서출판 길벗 | IT실용, IT전문서, IT/일반수험서, 경제경영, 취미실용, 인문교양(더퀘스트) www.gilbut.co.kr
길벗이지톡 | 어학단행본, 어학수험서 www.eztok.co.kr
길벗스쿨 | 국어학습, 수학학습, 어린이교양, 주니어 어학학습, 교과서 www.gilbutschool.co.kr

페이스북 · www.facebook.com/gbitbook
예제 소스 · https://github.com/gilbutITbook/006882

지은이의 말

SQL(Structured Query Language)(구조화된 질의 언어)은 대부분의 데이터베이스 시스템과 소통하는 데 사용되는 표준 언어다. 여러분은 지금 SQL을 사용해 데이터베이스에서 정보를 가져와야 하기에 이 책을 보고 있을 것이다.

이 책의 독자층은 애플리케이션 개발자와 정기적으로 SQL을 사용해 작업 일부를 처리하는 중급 데이터베이스 관리자(DBA)다. 여러분이 기본 SQL 문법은 이미 안다는 가정하에 SQL 언어를 최대한 활용할 수 있는 유용한 팁을 담았다. 필자들은 컴퓨터 프로그래밍 작업과는 완전히 다른 접근법이 필요함을 발견했다. 즉, 문제를 해결하려면 절차적 기반의 접근법에서 벗어나 집합적 기반으로 접근하는 사고방식이 필요하다.

관계형 데이터베이스 관리 시스템(RDBMS)은 관계형 데이터베이스를 생성·관리·수정·조작하는 데 사용하는 소프트웨어다. 많은 RDBMS가 데이터베이스에 저장된 데이터와 상호 작용하는 최종 사용자 애플리케이션을 생성하는 데 필요한 도구를 제공한다. RDBMS 프로그램은 처음 세상에 선보인 이후로 계속 진화해 왔는데, 하드웨어 기술과 운영 환경의 발전에 발맞춰 좀 더 강력하고 기능적인 완벽함을 추구해 나간다.

간략히 알아보는 SQL의 역사

에드거 커드 박사(Edgar Codd, 1923~2003년)는 IBM 연구원으로 1969년에 최초로 관계형 데이터베이스 개념을 고안했다. 그는 1960년대 후반 많은 양의 데이터를 처리할 수 있는 새로운 방법을 찾고 있었는데, 자신에게 닥친 무수한 문제에 수학적 원리를 적용해서 해결하는 방법을 모색하기 시작했다.

커드 박사가 1970년에 관계형 데이터베이스 모델을 세상에 선보인 이래, 대학교와 연구소 같은 조직은 관계형 모델을 지원하는 데이터베이스 시스템에서 사용 가능한 언어를 개발하려고 노력했다. 이들의 노력으로 1970년대 초에서 중반까지 몇 가지 언어를 개발하기 시작했는데, 그러다 캘리포니아 주 산호세에 있는 IBM 산타테레사연구소의 실험실에서 결실을 맺었다.

IBM은 관계형 모델의 생존 능력을 증명하고, 관계형 데이터베이스를 설계·구현하는 경험을 쌓으려고 1970년대 초에 System/R이라는 연구 프로젝트를 시작했다. 이들은 1974년부터 1975년까지 그동안의 노력을 성공적으로 증명해 관계형 데이터베이스의 최소화된 프로토타입을 만들었다.

이와 동시에 연구원들은 관계형 데이터베이스는 물론 데이터베이스 언어도 개발하고 있었다. 1974년 도널드 챔버린 박사와 동료들은 명료한 영어 문장을 사용해 관계형 데이터베이스를 질의할 수 있는 구조화된 영어 질의 언어(Structured English QUEry Language, SEQUEL)를 개발했다. 이들의 프로토타입 데이터베이스인 SEQUEL-XRM의 초기 성공으로 챔버린 박사와 동료들은 연구를 계속할 수 있는 계기를 마련했다. 1976년과 1977년에 걸쳐 SEQUEL을 SEQUEL/2로 개정했는데, 법적인 이유(이미 누군가가 SEQUEL이란 약어를 사용하고 있었다)로 SEQUEL을 SQL로 변경했다. 널리 퍼진 '공식' 발음은 에스큐엘(ess-cue-el)임에도 여전히 많은 사람이 SQL을 시퀄(SEQUEL)로 발음한다.

IBM의 System/R과 SQL은 관계형 데이터베이스가 현실성이 있다고 증명했지만, 당시 하드웨어 기술은 비즈니스에 적용할 만한 제품을 만들 정도로 강력하다는 것을 충분히 보여 주지 못했다.

1977년 캘리포니아 주 멘로 파크에서 한 무리의 엔지니어가 SQL에 기반한 새로운 관계형 데이터베이스를 만들려는 목적에서 Relational Software, Inc.를 설립했는데, 자신들이 만든 제품을 오라클(Oracle)이라고 불렀다. 1979년에는 이 제품을 상용화했고, 오라클은 최초의 상용 RDBMS 제품이 되었다. 오라클의 장점 중 하나는 비싼 IBM 메인프레임이 아닌 Digital의 VAX 미니 컴퓨터에서 작동한다는 것이다. Relational Software는 Oracle Corporation으로 사명을

변경하고 RDBMS 소프트웨어 벤더의 선두 주자가 되었다.

거의 동시에 마이클 스톤브레이커와 유진 웅, 캘리포니아 주 버클리대학교 컴퓨터연구소의 몇몇 교수는 관계형 데이터베이스 기술을 연구하고 있었다. 이들은 Ingres라는 이름으로 관계형 데이터베이스 프로토타입을 개발했다. Ingres는 데이터베이스 언어인 QUEL(QUEry Language)(질의 언어)을 포함하고 있었는데, SQL보다 훨씬 더 구조적이었음에도 영어와 유사한 문장 사용 비율은 현저히 떨어졌다. 하지만 SQL이 표준 데이터베이스 언어로 가시화되면서 Ingres는 결국 SQL 기반의 RDBMS로 변환되었다. 버클리대학교에 남은 몇몇 교수는 1980년에 Relational Technology, Inc.를 설립해 1981년에 Ingres의 첫 번째 상용 버전을 출시했다. Relational Technology는 몇 번의 격동을 거친 후 Computer Associates International, Inc. 소유가 되었고, 현재는 Actian의 자회사다. Ingres는 지금도 여전히 이 분야의 선두 데이터베이스 제품 중 하나다.

한편 IBM은 1981년에 SQL/Data System(SQL/DS)이라는 RDBMS를 발표했고, 1982년에는 제품으로 출시했다. 1983년에는 IBM 메인스트림 MVS 운영체제를 사용한 메인프레임에서 구동되는 DB2(DataBase2)라는 새로운 RDBMS를 선보였다. 1985년에 첫 제품을 납품한 이후 DB2는 IBM 최고의 RDBMS가 되었으며, 이 기술은 IBM 전체의 제품 라인을 통합해 버렸다.

데이터베이스 언어 개발을 둘러싼 많은 활동을 전개하던 와중에 데이터베이스 커뮤니티 내부에서 표준화 필요성이 대두되었다. 하지만 누가 표준을 제정하고 어떤 유형의 언어를 기반으로 해야 하는지 등 서로 합의된 사항이나 협정은 없었다. 결국 각 벤더는 자신이 사용하는 SQL 형태가 산업 표준이 될 것이라는 희망을 품고 독자적으로 데이터베이스 제품을 개발하고 개선하는 작업을 이어갔다.

고객의 피드백과 요구는 SQL의 특정 요소를 포함하도록 많은 벤더를 움직이게 했고, 결국 제때에 비공식 표준이 출현했다. 다양한 형태의 SQL 중에서 유사한 부분만 추려냈기에 오늘날의 표준과 비교하면 상대적으로 작은 규격이다. 하지만 이 규격은 데이터베이스 고객에게 시장에 나온 다양한 데이터베이스 프로그

램 중 어떤 것을 선택해야 하는지 일련의 핵심 기준을 제공했다. 또 한 데이터베이스 프로그램에서 다른 데이터베이스 프로그램으로 쉽게 이동할 수 있는 지식도 제공했다.

공식적인 관계형 데이터베이스 언어 표준이 필요하다는 요구가 늘어나면서 1982년에 미국 국립표준협회(ANSI)는 내부 X3 기구의 데이터베이스 기술위원회인 X3H2에 표준 제안서를 만들도록 함으로써 드디어 응답을 했다. 많은 노력(SQL의 많은 개선을 포함해)을 기울인 끝에 이 위원회는 자신들의 새로운 표준이 당시의 주요 SQL과는 맞지 않음을 알게 되었다. 그리고 SQL에 가해진 변경 사항이 이런 비호환성을 보증할 정도로 충분히 만족할 만큼 개선되지 못했음을 깨달았다. 결국 위원회는 어떤 데이터베이스 벤더든 수용할 수 있도록 요구 사항의 '최소 공통분모'에 해당하는 최소 내용만 반영하도록 했다.

ANSI는 SQL/86으로 알려진 "ANSI X3.135-1986 데이터베이스 언어 SQL" 표준안을 1982년 승인했다. 이는 다양한 SQL 중 비슷한 요소와 많은 데이터베이스 벤더가 이미 구현한 요소에 공식적인 지위를 부여한 셈이다. 위원회도 물론 단점을 인지하고 있었는데, 이 새로운 표준은 최소한 SQL과 향후 어떤 식으로 개발해 구현해야 하는지 구체적인 기반을 제공했다.

국제표준협회(ISO)는 1987년 국제 표준으로 자신들의 문서(ANSI SQL/86과 정확히 대응되는)를 승인했고 "ISO 9075: 1987 데이터베이스 언어 SQL"을 발표했다(이 두 표준은 여전히 SQL/86으로 언급된다). 국제 데이터베이스 벤더 커뮤니티는 미국 벤더들과 동일한 표준을 따르며 작업했다. SQL이 공식적인 표준의 위상을 얻기는 했지만 완전한 모습을 갖추기까지 아직 갈 길이 멀었다.

얼마 지나지 않아 SQL 구문 안의 중복적 성격(같은 쿼리를 구현하는 방법은 많다), 특정 관계 연산자 지원 부족, 참조 무결성 부족 등의 이유로 정부와 C. J. Date 같은 산업계 강성론자 측에서는 SQL/86을 공개적으로 비판했다.

이런 비판, 특히 참조 무결성 비판에 대응할 목적으로 ISO와 ANSI는 자신의 표준을 개정한 버전을 채택했다. 1989년 중반에 ISO는 "ISO 9075: 무결성이 향상된 1989 데이터베이스 언어 SQL"을 발표했고, 같은 해 말에 ANSI는 "X3.135-

무결성이 향상된 1989 데이터베이스 언어 SQL"(SQL/89)을 채택했다.

일반적으로 SQL/86과 SQL/89는 성공적으로 데이터베이스를 하는 데 필요한 기반이 되는 특징 중 일부가 부족하다고 인식했다. 예를 들어 한 번 정의한 데이터베이스 구조는 어떤 식으로 변경을 가해야 하는지 알려 주는 표준이 없었다. 모든 벤더가 자신의 상용 제품에서 구현할 수 있는 방법을 제공하고 있었음에도, 표준에는 임의의 구조적인 구성 요소를 수정하거나 삭제하거나 데이터베이스 보안에 변경을 가하는 내용이 없었다(예를 들어 데이터베이스 객체를 생성하는 구문은 있었지만 수정이나 삭제하는 구문은 없었다).

또 다른 최소 공통분모에 해당하는 표준을 제공하는 것을 원하지는 않았지만, ANSI와 ISO는 SQL을 완전하고 강력한 언어로 만들려고 주요 개정 작업을 계속 이어갔다. 새로운 버전(SQL/92)에는 주요 데이터베이스 벤더 대부분이 이미 폭넓게 구현하던 기능이 포함되어 있었다. 게다가 아직 폭넓게 수용되지 않은 기능뿐만 아니라 현재 구현된 기능을 뛰어넘는 기능까지도 포함하려고 했다.

ANSI와 ISO는 자신들의 새로운 SQL 표준인 X3.135-1992 데이터베이스 언어 SQL과 ISO/IEC 9075:1992 데이터베이스 언어 SQL을 발표했다. 이 SQL/92는 SQL/89에 비해 문서량이 상당히 방대했으며, 훨씬 넓은 범위를 다루었다. 예를 들어 이미 정의된 데이터베이스 구조를 수정할 방법을 제공했고, 문자와 날짜, 시간 데이터를 조작하는 추가적인 연산을 지원했으며, 추가적인 보안 특성을 정의했다. SQL/92는 이전 버전의 표준보다 큰 진전을 이루었다.

데이터베이스 벤더들은 SQL/92에 명시된 기능을 구현함과 동시에 자체 기능을 개발하고 구현했으며 이 SQL 표준을 '확장' 형태로 추가했다. 이 확장 버전은 기존 제품에 더 많은 기능을 제공하므로(SQL/92에 명시된 여섯 가지 기능보다 많은 데이터 타입을 제공한다) 각 벤더는 다른 벤더와 차별화할 수 있었다. 물론 이에 따른 문제점도 있었다. 확장 버전을 추가하면서 일어나는 주요 문제점은 각 벤더가 구현한 SQL 형태가 원래 표준에서 많이 벗어났다는 것이다. 이것은 오히려 SQL 데이터베이스에 관계없이 구동할 수 있는 휴대용 애플리케이션을 개발하는 데이터베이스 개발자의 일만 방해하는 셈이었다.

1997년 ANSI의 X3는 정보기술표준국제협회(NCITS)로 명칭을 변경하고 SQL 표준을 담당하는 기술위원회인 ANSI NCITS-H2를 발족했다. ANSI와 ISO 표준위원회는 SQL 표준이 복잡해지고 많아지면서 표준을 12개의 독립된 부분과 SQL3(표준의 세 번째 주요 개정이라서 이렇게 이름을 붙였다)라는 하나의 부가 조항으로 분리해 부분별로 병렬로 진행하는 데 합의했다. 1997년 이후 추가로 두 가지 부분을 정의했다.

이 책의 모든 내용은 SQL 데이터베이스 언어인 SQL/Foundation(문서 번호 ISO/IEC 9075-2:2011)의 현재 ISO 표준을 따른다. 이것은 유명한 상용 데이터베이스 시스템이 현재까지 구현한 내용이다. ANSI 또한 이 ISO 문서를 채택했는데, 이것으로 진정한 국제 표준이 되었다. 이 책은 또한 DB2, 액세스, SQL Server, MySQL, 오라클, PostgreSQL에서 제공하는 최신 버전 문서들을 참고했고, 필요하다면 각 제품에 특화된 내용도 담았다. 여기서 소개된 SQL은 특정 소프트웨어 제품에 특화된 것은 아니지만, 필요에 따라서 제품에 특화된 예제도 수록했다.

데이터베이스 시스템

앞에서 SQL 표준이 있다고 했는데, 그렇다고 모든 DBMS가 동일한 것은 아니다. DB-Engines 웹 사이트(http://db-engines.com/en/ranking/relational+dbms)에서는 DBMS 정보를 수집해 월별로 현재 인기 순위를 발표한다.

다음은 몇 달간 지속적으로 인기가 있었던 DBMS 여섯 개를 나열한 것이다(괄호 안의 버전은 이 책에서 테스트한 버전이다).

1. DB2(리눅스, 유닉스, 윈도우용 DB2 v10.5.700.368)
2. 액세스(액세스 2007 - 2010, 2013, 2016)
3. SQL Server(SQL Server 2012 - 11.0.5343.0)
4. MySQL(MySQL Community Server 5.7.11)

5. 오라클 데이터베이스(오라클 데이터베이스 11g Express Edition Release 11.2.0.2.0)
6. PostgreSQL(PostgreSQL 9.5.2)

그렇다고 책에서 다루는 예제가 이 DBMS들에서만 작동하는 것은 아니다. 다른 DBMS나 앞에서 나열한 DBMS들의 다른 버전에서는 테스트하지 않았을 뿐이다. 이 책을 학습하다 뭔가 변경이 필요할 때는 Note로 권고 내용을 정리했다. Note는 앞에서 나열한 DBMS 여섯 개에만 적용된다. 다른 DBMS를 사용한다면 예제를 실행하면서 문제를 일으킬 경우 해당 DBMS 문서를 참고한다.

샘플 데이터베이스

이 책의 콘셉트는 여러 샘플 데이터베이스를 사용한다는 것이다.

1. **맥주 스타일**(Beer Styles) : 마이클 라슨이 쓴 〈Beer: What to Drink Next〉(Sterling Epicure, 2014)에 나온 정보를 바탕으로 서로 스타일이 다른 89가지 맥주 정보를 상세하게 분류했다.
2. **엔터테인먼트 에이전시**(Entertainment Agency) : 연주단, 에이전트, 고객, 예약을 관리할 목적으로 설계된 데이터베이스다. 이벤트 예약이나 호텔 예약 업무를 처리하려면 이를 이용해 설계하면 된다.
3. **요리법**(Recipes) : 우리나 여러분이 좋아하는 요리법을 관리하고 저장하는 데 이 데이터베이스를 사용할 수 있다.
4. **판매 주문**(Sales Orders) : 자전거, 스케이트보드, 관련 부속품을 판매하는 가게에서 사용하는 전형적인 주문 목록이다.
5. **학생 성적**(Student Grades) : 이 데이터베이스는 학생과 수업, 성적을 관리한다.

또 특정 BETTER WAY에 특화된 수많은 샘플 데이터베이스도 제공하는데, 그 중 일부는 코드로 실었다. 샘플 스키마와 데이터는 이 책의 깃허브 리포지터리에서 내려받을 수 있다.

샘플 데이터베이스와 소스 코드 내려받기

샘플 데이터베이스와 소스 코드는 다음 깃허브 리포지터리에서 얻을 수 있다.

https://github.com/gilbutITbook/006882

리포지터리는 DBMS별로 최상위 폴더를 구성했다. 각 폴더에는 각 장에 대응하는 하위 폴더가 열 개 있으며, Sample Databases라는 폴더도 한 개 있다.

각 장 폴더 안에는 해당 장에 속한 BETTER WAY별로 마련된 파일이 있다. 모든 소스 코드를 DBMS에 다 적용할 수 있는 것은 아니다. 장별 README 파일에 차이점을 적어 놓았다. 예를 들어 액세스는 README 파일을 보면 각 장에 있는 코드를 포함한 샘플 데이터베이스가 어떤 것인지 알 수 있다.

리포지터리 루트에는 각 코드가 어떤 데이터베이스에 포함되어 있는지 나열한 Listings.xlsx 파일이 있다. 이 파일에는 데이터베이스 시스템 여섯 개에 각각 적용 가능한 SQL 샘플 정보가 들어 있다.

각 DBMS의 Sample Databases 폴더에는 여러 SQL 파일이 들어 있고, 마이크로소프트 액세스 폴더에는 .accdb 파일이 2007 포맷으로 들어 있다. 2007 포맷을 사용한 이유는 액세스 12(2007) 버전 이상은 모든 버전과 호환되기 때문이다. 이 파일들의 한 세트에는 각 샘플 데이터베이스에 대한 객체 생성 구문이 들어 있고, 다른 세트에는 데이터 입력 구문이 포함되어 있다. (BETTER WAY 일부는 특정 유형의 데이터에 특화되었다. 이런 BETTER WAY에서 다루는 객체와 데이터는 각 장 소스 코드에 포함할 때도 있다.)

장별 요약

책 제목에서도 알 수 있듯이 특화된 BETTER WAY가 무려 61개나 수록되어 있다. 각각은 독립된 주제를 다루므로 한 BETTER WAY에 나온 자료를 사용하려고 다른 BETTER WAY를 볼 필요는 없다. 물론 특정 BETTER WAY에 있는 자료를 다른 BETTER WAY의 자료를 기준으로 만들기도 한다. 이때는 가능하면 관련 배경 내용을 설명하려고 했다. 하지만 관련된 BETTER WAY와 상호

참조할 수 있는 정보도 제공했으므로 해당 내용만 봐도 문제가 없을 것이다.

앞에서 언급했듯이 각각을 독립적으로 만들고 주제별로 자연스럽게 묶어 정리했다. 각 장의 내용을 정리하면 다음과 같다.

1. **데이터 모델 설계** : 잘못 설계된 데이터 모델로는 효율적으로 SQL을 작성할 수 없으므로 이 장에는 올바른 관계형 모델을 설계하는 기본 내용을 담았다. 여러분의 데이터베이스 설계가 여기 나온 규칙을 위반한다면 잘못된 점이 무엇인지 파악해서 수정해야 한다.

2. **인덱스 설계와 프로그램적 처리** : 단순히 논리적인 데이터 모델의 설계가 좋다고 해서 효율적으로 SQL을 작성할 수 있는 것은 아니다. 설계된 내용을 올바른 방법으로 구현했는지 확인해야 한다. 그렇지 않으면 SQL을 효율적인 방식으로 사용해 데이터에서 의미 있는 정보를 추출하는 능력이 손상될 수 있다. 이 장에서 소개한 내용은 인덱스의 중요성과 인덱스를 적절하게 구현하는 방법을 이해하는 데 도움이 될 것이다.

3. **데이터 모델 설계를 변경할 수 없는 경우** : 가끔씩 많은 노력을 기울였음에도 제어할 수 없는 외부 데이터를 사용해야 할 때가 있다. 이 장에서는 이런 상황에 대처하는 데 도움이 되는 방법을 설명한다.

4. **데이터 필터링과 검색** : 관심 있는 데이터를 찾거나 걸러 내는 능력은 SQL로 수행할 수 있는 중요한 작업 중 하나다. 이 장에서는 정확히 원하는 데이터만 추출해 낼 수 있는 여러 기법을 알아볼 것이다.

5. **집계** : SQL 표준은 항상 데이터의 집계와 관련된 내용을 담고 있다. '고객별 합계', '일별 주문 개수', '카테고리별 월간 평균 매출' 같은 자료를 뽑아야 할 때가 많다. '~별' 자료를 뽑아낼 때는 좀 더 주의를 기울여야 한다. 이 장에서는 집계를 수행할 때 최고 성능을 낼 수 있는 기법을 소개한다. 또 윈도우 함수를 사용해 좀 더 복잡한 집계를 할 수 있는 방법도 소개한다.

6. **서브쿼리** : 서브쿼리를 사용하는 방법은 매우 다양하다. 이 장에서는 서브쿼리를 사용해 SQL에서 추가적인 유연성을 확보하는 다양한 방법을 보여

주는 데 초점을 맞추었다.

7. **메타데이터 획득 및 분석** : 가끔 데이터만으로는 충분하지 않을 때가 있다. 데이터에 관한 데이터가 필요하다. 심지어 데이터를 가져오는 방법과 관련된 데이터가 필요할 때도 있다. 몇몇 경우에는 SQL을 사용해 메타데이터를 가져오는 것이 더 편리하다. 이 장의 내용은 특정 데이터베이스에 특화되어 있기는 하지만, 충분한 정보를 제공하므로 여러분이 사용하는 DBMS에 이 원리들을 적용할 수 있기 바란다.

8. **카티전 곱** : 카티전 곱은 한 테이블의 모든 로우와 두 번째 테이블의 모든 로우를 조합한 결과다. 다른 조인 유형처럼 일반적이지는 않지만, 이 장에서는 카티전 곱을 사용하지 않고는 주요 문제에서 답을 얻는 것이 불가능한 상황을 보여 준다.

9. **탤리 테이블** : 또 다른 유용한 도구로 탤리 테이블이 있다. 이것은 연속된 숫자나 연속된 날짜로 된 컬럼으로 구성된 테이블 또는 일련의 합계 집합을 피버팅하는 데 도움을 주는 좀 더 복잡한 데이터가 있는 테이블이다. 카티전 곱이 주요 테이블의 실제 값에 의존하는 반면, 탤리 테이블은 가능한 모든 조합을 처리할 수 있다. 이 장에서는 탤리 테이블만 사용해서 해결할 수 있는 다양한 문제 사례를 보여 준다.

10. **계층형 데이터 모델링** : 관계형 데이터베이스에서 계층 구조의 데이터를 모델링하는 일은 흔하지 않다. 불행히도 이 부분은 SQL의 취약 부분 중 하나다. 이 장은 데이터 정규화, 메타데이터 관리 및 질의의 용이성 사이에서 균형을 맞추는 데 도움이 되는 내용으로 구성했다.

각 데이터베이스 시스템은 날짜와 시간의 값을 계산하고 조작하는 여러 유형의 함수를 제공한다. 또 데이터 타입, 날짜와 시간 연산과 관련된 자체적인 규칙이 있다. 이런 차이점 때문에 여러분의 데이터베이스 시스템에서 날짜와 시간 데이터를 처리하는 데 도움을 줄 수 있는 '부록. 날짜와 시간 타입, 연산, 함수'를 실었다. 부록에 데이터베이스별로 지원하는 데이터 타입과 연산을 정확히 요약했

다고 믿지만, 각 함수의 확실한 문법은 사용하는 데이터베이스 관련 문서를 참고한다.

감사의 말

어느 유명한 정치가는 이렇게 말했다. "어린 아이 하나를 키우려면 사회 전체가 연대해야 합니다." 여러분이 기술서나 다른 분야의 책을 집필해 왔다면 '아이(작품)'를 성공적인 책으로 만드는 데 훌륭한 팀이 필요하다는 사실을 이미 알고 있을 것이다.

먼저 기획 편집자이자 프로젝트 매니저인 트리나 맥도널드에게 깊은 감사를 전한다. 존의 성공작인 이펙티브 소프트웨어 개발 시리즈 중 하나와 〈SQL Queries for Mere Mortals, Third Edition〉(Addison-Wesley, 2014)이 출간되기까지 열심히 지원했으며, 이 프로젝트의 여러 면을 잘 살펴주었다. 존은 이 책을 출간하는 데 많은 도움을 준 국제적인 팀을 구성했다. 열심히 노력한 그들에게 개인적으로 감사의 마음을 전한다. 프로젝트 초창기는 물론 이후 기술 리뷰 때도 큰 도움을 준 톰 위커라스에게 특히 감사한다.

트리나가 소개한 원고 개발 편집자인 송린 치우는 이 시리즈를 만들면서 세부적인 내용을 이해하는 데 도움을 주었다. 송린의 지도력에 크게 감사한다.

또 트리나는 훌륭한 테크니컬 에디터를 모아 이 책에서 다룬 예제 수백 개를 성심성의껏 테스트하고 디버그한 후 피드백을 주었다. MySQL의 모건 토커와 데이브 스토크스, PostgreSQL의 리처드 앤소니 브로어스마, DB2의 크레이그 멀린스, 오라클의 비빅 샤마에게도 감사한다.

더불어 이 시리즈 편집자이자 베스트셀러 〈Effective C++: 55 Specific Ways to Improve Your Programs and Designs, Third Edition〉(Addison-Wesley, 2005)의 저자 스콧 마이어스는 이 책을 어떻게 하면 진정으로 효과적인 내용으로 바꿀 수 있는지 소중한 조언을 해 주었다. 시리즈의 아버지인 그가 이 책을 자랑스럽게 여기면 좋겠다.

줄리 나힐, 안나 파픽, 바바라 우드로 구성된 프로덕션 팀이 이 책을 마지막까지 완성하는 데 도움을 주었다. 당신들이 없었으면 해내지 못했을 것이다.

마지막으로 원고를 집필하고 예제를 만들면서 수많은 밤을 지새웠는데, 곁에서 이를 지켜봐 준 가족에게도 감사한다. 가족의 인내심에 정말 감사한다.

- 존 비아시에스 / 프랑스 파리

- 더글러스 스틸 / 캐나다 온타리오 주 세인트캐서린스

- 벤 클로더어 / 미국 텍사스 주 컨버스

옮긴이의 말

IT 프로그래밍 기술은 종류도 매우 많고 변화도 매우 빠른 분야에 속한다. 돌이켜 보면 당시에는 유망했던 기술도 점차 시간이 지나면서 역사 저편으로 사라졌으며, 새롭게 주목받는 기술이 등장하기도 했다. 이런 점 때문에 프로그래머로 산다는 것은 타 직업에 비해 상당히 고단하다. 이미 알고 있는 기술도 계속해서 갈고 닦아야 하고, 남들보다 뒤처지지 않으려면 신기술이 등장할 때마다 학습해야 하기 때문이다. 어느 분야에서나 사용할 수 있음에도 그 중요성과 가치가 상대적으로 저평가된 프로그래밍 언어 기술이 하나 있는데, 바로 SQL이다. 대부분의 시스템에서 데이터를 사용하는데, 이런 데이터를 관리하려면 SQL을 반드시 알아야 한다. 하지만 다른 프로그래밍 언어와 비교했을 때 SQL은 상대적으로 간단해 보이고 배우기도 쉬워서인지 많은 개발자가 어느 정도까지 학습한 후에는 더는 배우지 않는 듯하다. 그래서인지 SQL을 어느 정도 수준으로 구사하는 개발자는 많아도, 효율적이고 성능이 좋은 SQL을 작성할 수 있는 개발자는 상대적으로 적다. 프로젝트 현장에서도 마찬가지다.

하지만 SQL을 효율적으로 잘 작성하면 이와 연동된 프로그래밍을 할 때 많은 도움이 된다. 예를 들어 좀 까다로운 데이터를 처리한다고 하자. 기본적인 SQL 문 구사 능력만 사용하면 이후에 가져온 데이터를 처리할 때는 해야 할 프로그래밍 작업이 많아진다. 반면에 복잡하고 까다로운 작업을 모두 SQL로 깔끔하게 처리해 버린다면 이후 작업은 간단히 끝낼 수 있다. 다른 프로그래밍 언어 학습에 들이는 시간과 노력을 약간만 SQL에 투자한다면 어느 순간 자신의 능력이 눈에 띄게 향상되어 있을 것이다. 한마디로 SQL은 '가성비'가 좋은 언어라고 할 수 있다.

이 책은 SQL 입문서가 아니다. 어느 정도 SQL을 사용한 경험이 있는 사람을 대상으로 한다. SQL을 사용하면서 어려움에 부딪힐 수 있는 여러 상황을 주제별로 정리해 총 61개 항목으로 구성했고, 각 상황에 맞는 설명과 이를 해결하는

방법을 수록했다. 단순히 SQL 학습서가 아닌 문제 해결에 초점을 맞추고 있다. 사실 SQL로 원하는 결과를 산출하는 방법은 매우 많다. 하지만 이 책에서는 좀 더 효율적인 방식으로 빠르게 결과를 가져오는 여러 방법과 장단점을 소개해 어떤 방법을 선택할지 독자에게 올바른 방향을 제시한다. 특정 DBMS가 아닌 주요 DBMS(DB2, 액세스, SQL Server, MySQL, 오라클, PostgreSQL)를 모두 다루고 DBMS별 소스 코드를 제공하는 것은 이 책만의 장점이다. 동일한 처리를 하는 DBMS별 SQL 문을 보는 것도 흥미로울 것이다.

다른 IT 책과는 달리 이 책은 처음부터 끝까지 순서대로 읽을 필요가 없다. 주제별로 정리해 놓았으므로 목차를 살펴보고 관심 있는 주제부터 보면 된다. 주제별로 상세한 설명보다는 어떤 식으로 문제를 해결할지에 초점을 맞추고 있으므로 이를 참고해서 보자. 어떤 주제는 상대적으로 설명이 빈약하기도 하다. 예를 들어 처리되는 SQL 문의 실행 계획을 다룬 부분이 있는데, 이 부분의 내용만으로는 실행 계획을 자세히 파악하기가 쉽지 않다. 하지만 이것은 어쩔 수 없다. 실행 계획은 DBMS별로 다르게 처리하므로 자세히 설명하려면 실행 계획 하나만으로도 책 한 권 분량은 되기 때문이다. 따라서 이 책에서 부족하게 다룬 주제는 다른 책이나 관련 DBMS 문서를 참고한다. 이런 단점에도 이 책은 소장할 만한 가치가 있다. 이 책에서 제시한 해결책에만 의지하지 말고 내용을 완전히 이해한 후 더 나은 해결책을 여러분 스스로 찾아내어 보자. 이것이 이 책의 진정한 집필 의도가 아닐까 생각한다.

끝으로 이 책을 번역하기까지 수고해 주신 (주)도서출판 길벗의 관계자 여러분께 감사한다. 특히 IT 전문서팀 서형철 팀장님, 담당자 안윤경 님께 깊은 감사를 전한다. 그리고 가까이에서 많은 응원을 하면서 직장 일과 육아를 병행하며 고생하는 아내와 어머님께 진심으로 감사의 마음을 전하고 싶다.

2017년 10월

홍형경

목차

추천사 4 • 지은이 소개 6 • 테크니컬 에디터 소개 9 • 지은이의 말 11 • 옮긴이의 말 23

1장 ▸ 데이터 모델 설계 031

BETTER WAY 1 모든 테이블에 기본키가 있는지 확인하자 032

BETTER WAY 2 중복으로 저장된 데이터 항목을 제거하자 037

BETTER WAY 3 반복 그룹을 제거하자 041

BETTER WAY 4 컬럼당 하나의 특성만 저장하자 044

BETTER WAY 5 왜 계산 데이터를 저장하면 좋지 않은지 이해하자 049

BETTER WAY 6 참조 무결성을 보호하려면 외래키를 정의하자 055

BETTER WAY 7 테이블 간 관계를 명확히 하자 059

BETTER WAY 8 제3정규화로도 부족하다면 더 정규화하자 064

BETTER WAY 9 데이터 웨어하우스에는 역정규화를 사용하자 072

2장 ▸ 인덱스 설계와 프로그램적 처리 077

BETTER WAY 10 인덱스를 만들 때는 널을 고려하자 078

DB2 079

액세스 080

SQL Server 081

MySQL 082

오라클 083

PostgreSQL 084

BETTER WAY 11 인덱스와 데이터 스캔을 최소화하도록 인덱스는 신중히 만들자 085

BETTER WAY 12 인덱스를 단순 필터링 이상의 목적으로 사용하자 090

BETTER WAY 13 트리거를 남발하지 말자 096

BETTER WAY 14 데이터의 부분 집합을 포함하거나 제외하려면 필터링된 인덱스를 사용하자 101

BETTER WAY 15 프로그래밍으로 검사하는 대신 선언적 제약 조건을 사용하자 105

BETTER WAY 16 자신이 사용하고 작성하는 SQL의 종류를 파악하자 108

결과 집합 정렬 108

반환 결과 집합의 개수 제한 109

BOOLEAN 데이터 타입 110

SQL 함수 110

UNIQUE 제약 조건 111

BETTER WAY 17 인덱스에서 계산 결과를 사용할 시기를 파악하자 112

3장 ▸ 데이터 모델 설계를 변경할 수 없는 경우 117

BETTER WAY 18 설계를 변경할 수 없을 때는 뷰로 데이터를 간소화하자 118

BETTER WAY 19 비관계형 데이터를 정보성 데이터로 변환할 때는 ETL을 사용하자 124

BETTER WAY 20 요약 테이블을 만들어 관리하자 130

BETTER WAY 21 비정규화된 데이터를 '언피벗'하려면 UNION 문을 사용하자 134

4장 ▸ 데이터 필터링과 검색 141

BETTER WAY 22 관계 대수와 이를 SQL로 구현하는 방법을 이해하자 141

선택(제한) 142

추출 143

조인 143

교집합 145

카티전 곱 147

합집합 147

나누기 148
차집합 148
BETTER WAY 23 일치하지 않거나 누락된 레코드를 찾아내자 150
BETTER WAY 24 CASE로 문제를 해결해야 할 때를 파악하자 153
BETTER WAY 25 다중 조건 문제를 해결하는 기법을 파악하자 159
BETTER WAY 26 완전히 일치하는 데이터가 필요할 때는 데이터를 분할하자 166
BETTER WAY 27 날짜와 시간을 모두 포함하는 컬럼에서 날짜 범위를 올바르게 검색하는 방법을 알아 두자 170
BETTER WAY 28 데이터베이스 엔진이 인덱스를 사용하도록 사거블 쿼리를 작성하자 175
BETTER WAY 29 LEFT 조인의 오른쪽 데이터를 올바르게 걸러 내자 181

5장 ▸ 집계 185

BETTER WAY 30 GROUP BY 절의 작동 원리를 이해하자 186
BETTER WAY 31 GROUP BY 절은 간단하게 만들자 194
BETTER WAY 32 복잡한 문제를 해결하려면 GROUP BY나 HAVING 절을 사용하자 197
BETTER WAY 33 GROUP BY 절 없이 최댓값, 최솟값을 찾자 203
BETTER WAY 34 OUTER JOIN에서는 잘못된 결과를 내는 COUNT() 함수를 사용하지 말자 210
BETTER WAY 35 'HAVING COUNT(x) < 숫자'를 검사할 때는 제로 값을 가진 로우를 포함하자 214
BETTER WAY 36 겹치지 않는 개수를 얻으려면 DISTINCT를 사용하자 219
BETTER WAY 37 윈도우 함수 사용법을 알아 두자 223
BETTER WAY 38 로우 번호를 만들어 다른 로우 대비 순위를 매기자 227
BETTER WAY 39 이동 집계를 만들자 230

6장 ▸ 서브쿼리 239

BETTER WAY 40 서브쿼리를 어디에 사용할 수 있는지 알아 두자 239

테이블 서브쿼리 240

단일 컬럼 테이블 서브쿼리 243

스칼라 서브쿼리 244

BETTER WAY 41 연관성 있는 서브쿼리와 연관성 없는 서브쿼리의 차이점을 파악하자 246

연관성 없는 서브쿼리 247

연관성 있는 서브쿼리 249

BETTER WAY 42 가능하면 서브쿼리 대신 공통 테이블 표현식을 사용하자 253

CTE로 쿼리를 단순하게 만들기 255

재귀 CTE 사용하기 258

BETTER WAY 43 서브쿼리 대신 조인을 사용해 더 효율적인 쿼리를 작성하자 262

7장 ▸ 메타데이터 획득 및 분석 267

BETTER WAY 44 사용 중인 시스템의 쿼리 분석기 사용법을 파악하자 268

DB2 268

액세스 270

SQL Server 272

MySQL 274

오라클 275

PostgreSQL 277

BETTER WAY 45 데이터베이스 관련 메타데이터를 수집하는 방법을 배우자 280

BETTER WAY 46 실행 계획의 작동 원리를 이해하자 287

8장 ▸ 카티전 곱 299

BETTER WAY 47 두 테이블에서 로우 조합을 만들어 한 테이블과 간접적으로 관련된 다른 테이블 로우에 표시를 남기자 300

BETTER WAY 48 등분위로 로우 순위를 매기는 방법을 이해하자 303

BETTER WAY 49 한 테이블에서 각 로우와 다른 모든 로우를 쌍으로 만드는 방법을 알아 두자 309

BETTER WAY 50 카테고리별 목록을 만들어 첫 번째, 두 번째, 세 번째 순위의 정보를 참조하는 방법을 파악하자 315

9장 ▸ 탤리 테이블 323

BETTER WAY 51 매개변수를 기준으로 널 로우를 만들려면 탤리 테이블을 사용하자 324

BETTER WAY 52 순번을 생성할 때는 탤리 테이블과 윈도우 함수를 사용하자 329

BETTER WAY 53 탤리 테이블에 있는 범위 값을 기준으로 여러 로우를 만들자 335

BETTER WAY 54 탤리 테이블에 있는 값 범위를 기준으로 한 테이블에 있는 값을 변환하자 340

BETTER WAY 55 날짜 계산을 쉽게 하려면 날짜 테이블을 사용하자 348

BETTER WAY 56 특정 범위에 있는 모든 날짜를 나열한 일정 달력을 만들자 356

BETTER WAY 57 탤리 테이블로 데이터를 피벗하자 360

10장 ▸ 계층형 데이터 모델링 369

BETTER WAY 58 인접 리스트 모델을 시작점으로 사용하자 370

BETTER WAY 59 자주 갱신되지 않는 데이터의 쿼리 성능을 빠르게 하려면 중첩 집합을 사용하자 373

BETTER WAY 60 제한된 검색과 간단한 설정에는 구체화된 경로를 사용하자 377

BETTER WAY 61 복잡한 검색에는 계통 순회 폐쇄 구조를 사용하자 380

부록 ▸ 날짜와 시간 타입, 연산, 함수 387

DB2 388

데이터 타입 388

산술 연산 388

함수 388

액세스 **392**

데이터 타입 392

산술 연산 392

함수 393

SQL Server **395**

데이터 타입 395

산술 연산 395

함수 396

MySQL **398**

데이터 타입 398

산술 연산 398

함수 399

오라클 **403**

데이터 타입 403

산술 연산 403

함수 403

PostgreSQL **405**

데이터 타입 405

산술 연산 405

함수 405

찾아보기 **407**

CHAPTER

1

데이터 모델 설계

"암퇘지 귀로는 비단 주머니를 만들 수 없다." 1579년 영국 풍자가 스티븐 고슨이 한 이 유명한 말은 데이터베이스에도 그대로 적용된다. 데이터 모델을 잘못 설계하면 '효율적'인 SQL 작성은 시작도 할 수 없다. 데이터 모델이 제대로 된 정규화를 거쳐 올바른 관계로 정의되어 있지 않으면 SQL로 데이터에서 의미 있는 정보를 뽑아내기가 (가능하다고 해도) 어렵다. 이 장은 좋은 관계형 모델을 설계하는 기초 내용을 다룬다. 여러분이 설계한 데이터베이스가 여기서 다루는 규칙 중 어느 하나라도 위반한다면 잘못된 점을 찾아 수정해야 한다.

데이터 모델 설계를 손댈 수 없다면 적어도 의미 있는 정보를 추출하기가 왜 어려운지 그 이유라도 이해해서 설계 담당자에게 가능한 해결책을 제시할 수 있어야 한다. 이 장에서 알려 준 정보를 활용하면 필요한 정보를 추출할 SQL을 작성하는 것이 왜 어렵거나 불가능한지 설명할 수 있을 것이다. 설계 내용을 손볼 수 없더라도 SQL로 일부 문제점을 우회하는 방법이 몇 가지 있다. 실제로 이런 상황에 직면한다면 '3장. 데이터 모델 설계를 변경할 수 없는 경

우'를 읽고 통찰하기 바란다.

이 장에서는 데이터베이스 설계와 관련된 미묘한 내용까지 모두 다루기보다는 기본 내용만 다룬다. 관계형 모델을 따르는 설계 방법을 좀 더 깊게 알고 싶다면 마이클 헤르난데즈(Michael Hernandez)가 쓴 〈Database Design for Mere Mortals, Third Edition〉(Addison-Wesley, 2013) 같은 책을 참고하자.

BETTER WAY 1 모든 테이블에 기본키가 있는지 확인하자

관계형 모델을 따르려면 데이터베이스 시스템이 한 테이블에 있는 특정 로우와 나머지 로우를 구별할 수 있어야 하므로, 모든 테이블에는 컬럼 한 개 이상으로 구성된 기본키(Primary Key)가 있어야 한다. 기본키는 로우마다 유일해야 하며 널(Null) 값을 가질 수 없다(더 자세한 내용은 'BETTER WAY 10. 인덱스를 만들 때는 널을 고려하자'를 참고한다). 기본키가 없으면 데이터를 걸러 낼 때 일치하는 로우가 없거나 딱 한 개인 조건은 보장할 수 없다. 하지만 기본키가 없는 테이블을 만든다고 규칙에 어긋나지는 않는다. 사실 단순히 널이 아니고 로우마다 유일하다고 해서 데이터베이스 엔진이 컬럼 한 개나 일련의 컬럼을 항상 효율적으로 사용할 수 있는 것은 아니다. 따라서 컬럼 한 개 이상을 기본키로 정의해 컬럼을 효율적으로 사용하라고 데이터베이스 엔진에 명시적으로 통보해야 한다. 게다가 기본키가 없는 테이블 간의 관계를 모델링하는 것은 일반적으로 불가능하다.

테이블에 기본키가 없으면 반복적이고 일관성 없는 데이터가 쌓여 쿼리 수행 속도가 느리고, 부정확한 정보를 조회하는 등 모든 종류의 문제를 일으킬 수 있다. 그림 1-1에 있는 주문 테이블을 살펴보자.

▼ 그림 1-1 일관성 없는 데이터

Orders
Customer
John A. Smith
Smith, John A.
John Smith
John A Smith
Smith, John

컴퓨터 관점에서 그림 1-1을 본다면 모든 값이 유일한 것은 분명한 사실이지만, 이들은 모두 같은 사람이거나 적어도 첫 빈째와 두 번째, 네 번째 로우는 동일한 사람(John A. Smith)일 수 있다. 컴퓨터는 사람보다 훨씬 빠르게 데이터를 처리할 수 있지만, 상당한 양의 프로그래밍 없이는 언제 특징 데이터를 동일한 것으로 간주해야 할지 판단하는 작업은 잘 처리하지 못한다. 따라서 이 테이블에서는 Customer 컬럼을 기본키로 정의할 수 있는데, 유일한 값을 가져야 한다는 요구 사항을 만족시키더라도 바람직한 선택은 아니다.

그렇다면 무엇이 기본키의 좋은 후보 자격이 될 수 있을까? 다음 특성을 따르는 컬럼을 후보군으로 삼으면 된다.

- 유일한 값을 가져야 한다.
- 널 값을 가질 수 없다.
- 안정적인 값이어야 한다(즉, 값을 갱신할 필요가 없다).
- 가능한 한 간단한 형태여야 한다(예를 들어 문자나 부동소수점보다는 정수형이 낫고, 여러 컬럼보다는 단일 컬럼이 낫다).

이런 목표를 달성하는 일반적인 방법은 의미 없는 숫자 데이터로 자동 생성되는 컬럼을 기본키로 만드는 것이다. 관계형 데이터베이스 관리 시스템(Relational DataBase Management System, RDBMS) 소프트웨어에 따라 이 컬럼은 여러 이름으로 칭하는데 DB2, SQL Server, 오라클 12c에서는 IDENTITY, 액

세스에서는 AutoNumber, MySQL에서는 AUTO_INCREMENT, PostgreSQL에서는 serial 컬럼이라고 한다. 오라클 12c 이전 버전에서는 동일한 기능을 구현하려면 컬럼 속성이 아닌 독립적인 시퀀스(Sequence) 객체를 사용해야 했다. DB2, SQL Server, PostgreSQL에서도 시퀀스 객체를 지원한다.

관계형 데이터베이스에서 참조 무결성(Reference Integrity, RI) 개념은 매우 중요하다. 참조 무결성을 준수한다는 것은 널이 아닌 외래키(Foreign Key)가 설정된 자식 테이블의 각 레코드와 일치하는 레코드가 부모 테이블에 존재한다는 것을 의미한다.

잘 설계된 Orders 테이블이라면 고객 정보 컬럼에 외래키를 설정해 Customers 테이블의 기본키와 연결되어 있을 것이다. 따라서 John Smith라는 고객이 실제로 여러 명이더라도 Customers 테이블의 각 로우는 유일한 키를 가지므로 각 주문에 대응하는 오직 하나의 고객만 쉽게 식별할 수 있다.

테이블 간에 참조 무결성을 유지하려면 변경된 기본키 값을 이와 관련 있는 테이블과 모든 자식 레코드에 전파해야 한다. 이렇게 갱신이 전파되면 관련 테이블에 잠금(Lock)이 설정되어 높은 동시성을 지원하는 다중 사용자 데이터베이스에서 심각한 문제를 일으킬 수 있다. 그림 1-2는 액세스 2003에서 샘플로 제공하는 Northwind 데이터베이스의 Customers 테이블에서 추출한 예제이다. 한번 살펴보자.

그림 1-2 Customers 테이블 샘플 데이터

Results | Messages

	CustomerID	CompanyName	ContactName	ContactTitle
1	ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative
2	ANATR	Ana Trujillo Emparedados y helados	Ana Trujillo	Owner
3	ANTON	Antonio Moreno Taquería	Antonio Moreno	Owner
4	AROUT	Around the Horn	Thomas Hardy	Sales Representative
5	BERGS	Berglunds snabbköp	Christina Berglund	Order Administrator
6	BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative

이 예제에서 텍스트 기반 기본키인 CustomerID는 회사 이름(CompanyName)과 연관된다는 것이 비즈니스 규칙이라고 가정한다. 어느 한 회사 이름을 변경하려면 키 값을 결정하는 비즈니스 규칙을 반영해 CustomerID도 갱신해야 한다. 기본키 값이 변경되므로 관련된 테이블에도 변경이 전파되어야 한다. 의미 없는 값을 키로 사용한다면 CustomerID 값을 변경하거나 갱신할 필요가 없지만, 비즈니스 규칙을 준수하는 값을 표시하려면 텍스트 기반 컬럼을 유지해야 한다.

텍스트 기반 컬럼을 기본키로 사용하는 이유는 중복 값 입력을 막을 수 있기 때문이라는 의견이 일반적이다. 예를 들어 CompanyName을 기본키로 만든다면 회사 이름은 중복되지 않아야 한다. 하지만 Customers 테이블의 CompanyName에 유일 인덱스를 추가해 이름이 중복되지 않게 하는 것이 더 쉽다. 이렇게 하면 무결성을 확보하면서 여전히 자동 생성된 숫자 값을 기본키로 사용할 수 있다. 여기에 'BETTER WAY 2. 중복으로 저장된 데이터 항목을 제거하자'와 'BETTER WAY 4. 컬럼당 하나의 특성만 저장하자'에서 권고하는 내용을 적용한다면 더욱 잘 작동할 것이고, 그림 1-1에서 지적한 문제점을 피하는 데도 도움이 된다. 반면에 텍스트 기반 기본키를 사용하면 숫자키로 연결된 값(그림 1-2에서 CompanyName)을 가져오려고 참조 테이블과 조인할 필요가 없으므로 SQL 문이 좀 더 간략하다.

기본키로 숫자가 나은지 텍스트 기반이 나은지는 데이터베이스 전문가 사이에서도 큰 이견이 있다. 책에서는 이런 논쟁에서 어느 한쪽만 편을 들지는 않을 것이다. 핵심은 기본키로 사용하는 컬럼은 반드시 유일한 값을 가져야 한다는 점이기 때문이다.

또 복합 기본키(Compound Primary Key)는 다음 두 가지 이유에서 효율성이 떨어지므로 사용하지 않는 것이 좋다.

1. 기본키를 정의할 때 대부분의 데이터베이스 시스템은 해당 컬럼에 유일 인덱스를 같이 만든다. 컬럼 두 개 이상에 유일 인덱스를 만들면 데이터베이스 시스템이 할 일만 더 많아진다.
2. 일반적으로 기본키로 조인을 수행하는데, 기본키가 여러 컬럼으로 구성되어 있으면 쿼리가 좀 더 복잡하고 느려진다.

하지만 특정한 상황에서는 여러 컬럼을 기본키로 사용하는 것이 마땅하다. 제품과 판매회사를 연결하는 테이블이 있고, 이 테이블은 관련된 테이블의 기본키를 가리키는 ProductID와 VendorID 컬럼으로 구성되어 있다고 하자. 이 테이블에는 특정 판매회사가 해당 제품의 주 공급처인지 부 공급처인지 나타내는 컬럼, 판매회사가 부과하는 제품 가격 컬럼 같은 다른 컬럼도 포함되어 있을 수 있다.

자동 생성되는 숫자 컬럼을 추가로 만들어서 인위적으로 기본키를 생성할 수 있지만, ProductID와 VendorID 컬럼을 조합해서 기본키로 사용할 수도 있다. 항상 개별 컬럼을 사용해 이 테이블에 연결하므로 추가로 만든 숫자 컬럼을 키로 사용하기보다는 이 두 컬럼으로 구성된 복합 기본키를 정의하는 것이 더 효율적이다. 또 두 컬럼을 합쳐 유일한 값이 되기를 원할 것이므로 추가 컬럼을 사용하지 않고 이 두 컬럼을 복합 기본키로 정의하면 더 좋다. 자세한 복합 기본키의 장점과 예제는 'BETTER WAY 8. 제3정규화로도 부족하다면 더 정규화하자'를 참고한다.

핵심 정리

- 모든 테이블에는 하나 또는 일련의 컬럼으로 구성된 기본키가 있어야 한다.
- 키가 아닌 컬럼에 중복 값이 들어갈까 봐 걱정이 된다면, 해당 컬럼에 유일 인덱스를 정의해 무결성을 확보할 수 있다.
- 형태가 가능한 간단하고 값을 갱신할 필요가 없는 컬럼을 키로 사용한다.

BETTER WAY 2 중복으로 저장된 데이터 항목을 제거하자

데이터를 중복으로 저장하면 일관되지 않은 데이터, 비정상적인 삽입 · 갱신 · 삭제 처리, 디스크 공간 낭비 등 많은 문제를 일으킨다. 정규화(Normalization)는 중복 데이터를 저장하면서 일으키는 문제점을 없애려고 정보를 주제(Subject)별로 분할하는 프로세스를 의미한다. 여기서 말하는 '중복'은 어느 한 테이블의 기본키 값을 다른 테이블의 외래키로 사용하는 것이 아니다. 그보다는 사용자가 동일한 데이터를 한 군데 이상에서 입력하는 상황에 더 가깝다. 전자의 중복 데이터는 테이블 간 연결을 유지하는 데 필요하다.

이 책에서는 지면이 부족한 관계로 데이터베이스 정규화를 깊게 파고들 수 없지만, 데이터베이스를 다루는 사람이라면 정규화를 철저히 이해해야 한다. 자세한 정규화 내용은 웹이나 다른 책에서 많이 구할 수 있다.

정규화의 한 가지 목표는 한 데이터베이스에서 동일한 테이블이든 다른 테이블이든 반복되는 데이터를 최소화하는 것이다. 그림 1-3에서는 CustomerSales 데이터베이스에서 데이터 중복 저장의 몇 가지 예제를 소개한다.

❮ 그림 1-3 단일 테이블의 중복 데이터

CustomerSales

SalesID	CustFirstName	CustLastName	Address	City	Phone	
1	Amy	Bacock	111 Dover Lane	Chicago	312-222-1111	...
2	Tom	Frank	7453 NE 20th St.	Bellevue	425-888-9999	...
3	Debra	Smith	3223 SE 12th Pl.	Seattle	206-333-4444	...
4	Barney	Killjoy	4655 Rainier Ave.	Auburn	253-111-2222	...
5	Homer	Tyler	1287 Grady Way	Renton	425-777-8888	...
6	Tom	Frank	7435 NE 20th St.	Bellevue	425-888-9999	...

	PurchaseDate	ModelYear	Model	SalesPerson
...	2/14/2016	2016	Mercedes R231	Mariam Castro
...	3/15/2016	2016	Land Rover	Donald Ash
...	1/20/2016	2016	Toyota Camry	Bill Baker
...	12/22/2015	2016	Subaru Outback	Bill Baker
...	11/10/2015	2016	Ford Mustang GT Convertible	Mariam Castro
...	5/25/2015	2015	Cadillac CT6 Sedan	Jessica Robin

Tom Frank의 주소(Address) 데이터가 일관되지 않은 데이터 예제다. 이 사람의 주소에 있는 숫자 값이 두 번째 레코드에서는 7453인 반면, 여섯 번째 레코드에서는 7435다. 이런 형태의 데이터 불일치는 어느 컬럼에서나 나타날 수 있다.

고객 레코드와 함께 판매 정보가 입력되기 전까지는 주어진 자동차 모델(Model 컬럼) 정보를 입력할 수 없으므로 비정상적인 데이터 입력이 존재한다. 또 이런 형태로 설계한다면 고객이 자동차를 추가로 구매할 때 대부분의 데이터가 반복될 수밖에 없다. 불필요한 데이터 입력은 디스크 공간, 메모리, 네트워크 리소스 낭비는 물론, 심지어 데이터를 입력하는 사람의 시간까지도 낭비한다. 게다가 데이터 입력을 반복하다 보면 그림 1-3의 예제에서 주소에 있는 숫자를 바꾸는 것처럼 데이터 입력 오류가 발생할 위험이 커진다.

또 판매원(SalesPerson)이 결혼해서 이름을 바꾼다고 하자. 이 사람의 이름과 일치하는 모든 데이터를 갱신하는 UPDATE 쿼리를 수행해야 하므로 비정상적으로 데이터를 갱신할 때도 있다. 이것은 많은 사람이 동시에 사용하는 데이터베이스에서 레코드의 개수가 아주 많을 때 큰 문제를 일으킬 수 있다. 게다가 이런 형태의 갱신 작업은 해당 판매원의 이름이 모두 정확히 입력되어 있고(일관성 없는 데이터가 없음을 의미) 이름이 동일한 사람이 없을 때만 성공할 수 있다.

로우가 한 개 삭제될 때 데이터베이스에서 제거하려고 하지 않은 데이터를 잃을 수도 있기 때문에 비정상적으로 데이터를 삭제할 때도 있다.

그림 1-3의 고객 판매 데이터는 논리적으로 다음 테이블 네 개로 분할할 수 있다.

1. Customers 테이블(이름, 주소 등)
2. Employees 테이블(판매원 이름, 입사 일자 등)

3. AutomobileModels 테이블(모델, 출시 연도 등)
4. SalesTransactions 테이블

이렇게 설계하면 고객, 직원, 자동차 모델 정보는 각 테이블에서 한 번만 입력해도 된다. 이 모든 테이블에는 기본키로 설정할 수 있는 유일한 식별자가 포함되어 있다. SalesTransactions 테이블은 각 판매 거래의 내용을 상세하게 저장하려고 외래키를 사용한다. 그림 1-4를 보자.

그림 1-4 주제별로 데이터를 테이블에서 분리

Customers

CustomerID	CustFirstName	CustLastName	Address	City	Phone
1	Amy	Bacock	111 Dover Lane	Chicago	312-222-1111
2	Tom	Frank	7453 NE 20th St.	Bellevue	425-888-9999
3	Debra	Smith	3223 SE 12th Pl.	Seattle	206-333-4444
4	Barney	Killjoy	4655 Rainier Ave.	Auburn	253-111-2222
5	Homer	Tyler	1287 Grady Way	Renton	425-777-8888

Employees

EmployeeID	SalesPerson
1	Mariam Castro
2	Donald Ash
3	Bill Baker
4	Jessica Robin

AutomobileModels

ModelID	ModelYear	Model
1	2016	Mercedes R231
2	2016	Land Rover
3	2016	Toyota Camry
4	2016	Subaru Outback
5	2016	Ford Mustang GT Convertible
6	2015	Cadillac CT6 Sedan

SalesTransactions

SalesID	CustomerID	ModelID	SalesPersonID	PurchaseDate
1	1	1	1	2/14/2016
2	2	2	2	3/15/2016
3	3	3	3	1/20/2016
4	4	4	3	12/22/2015
5	5	5	1	11/10/2015
6	2	6	4	5/25/2015

눈치 빠른 독자라면 이 과정을 거쳐 Customers 테이블에서 중복 데이터를 한 개 제거한 것을 눈치챘을 것이다. 즉, Tom Frank 주소 중 올바른 레코드만 남은 것이다.

그림 1-5와 같이 부모 테이블 세 개(Customers, AutomobileModels, Employees)의 기본키와 자식 테이블 SalesTransactions의 외래키를 사용해 관계를 맺을 수 있다(이것을 외래키 제약 조건이라고도 한다). 이 그림은 액세스에 있는 관계 도구를 사용해 만든 것이다. 관계형 데이터베이스 제품에 따라 테이블 간 관계를 표현하는 방법은 조금씩 다르다.

▼ 그림 1-5 외래키 컬럼과 조인한 기본키를 사용해 서로 관계를 맺은 테이블들

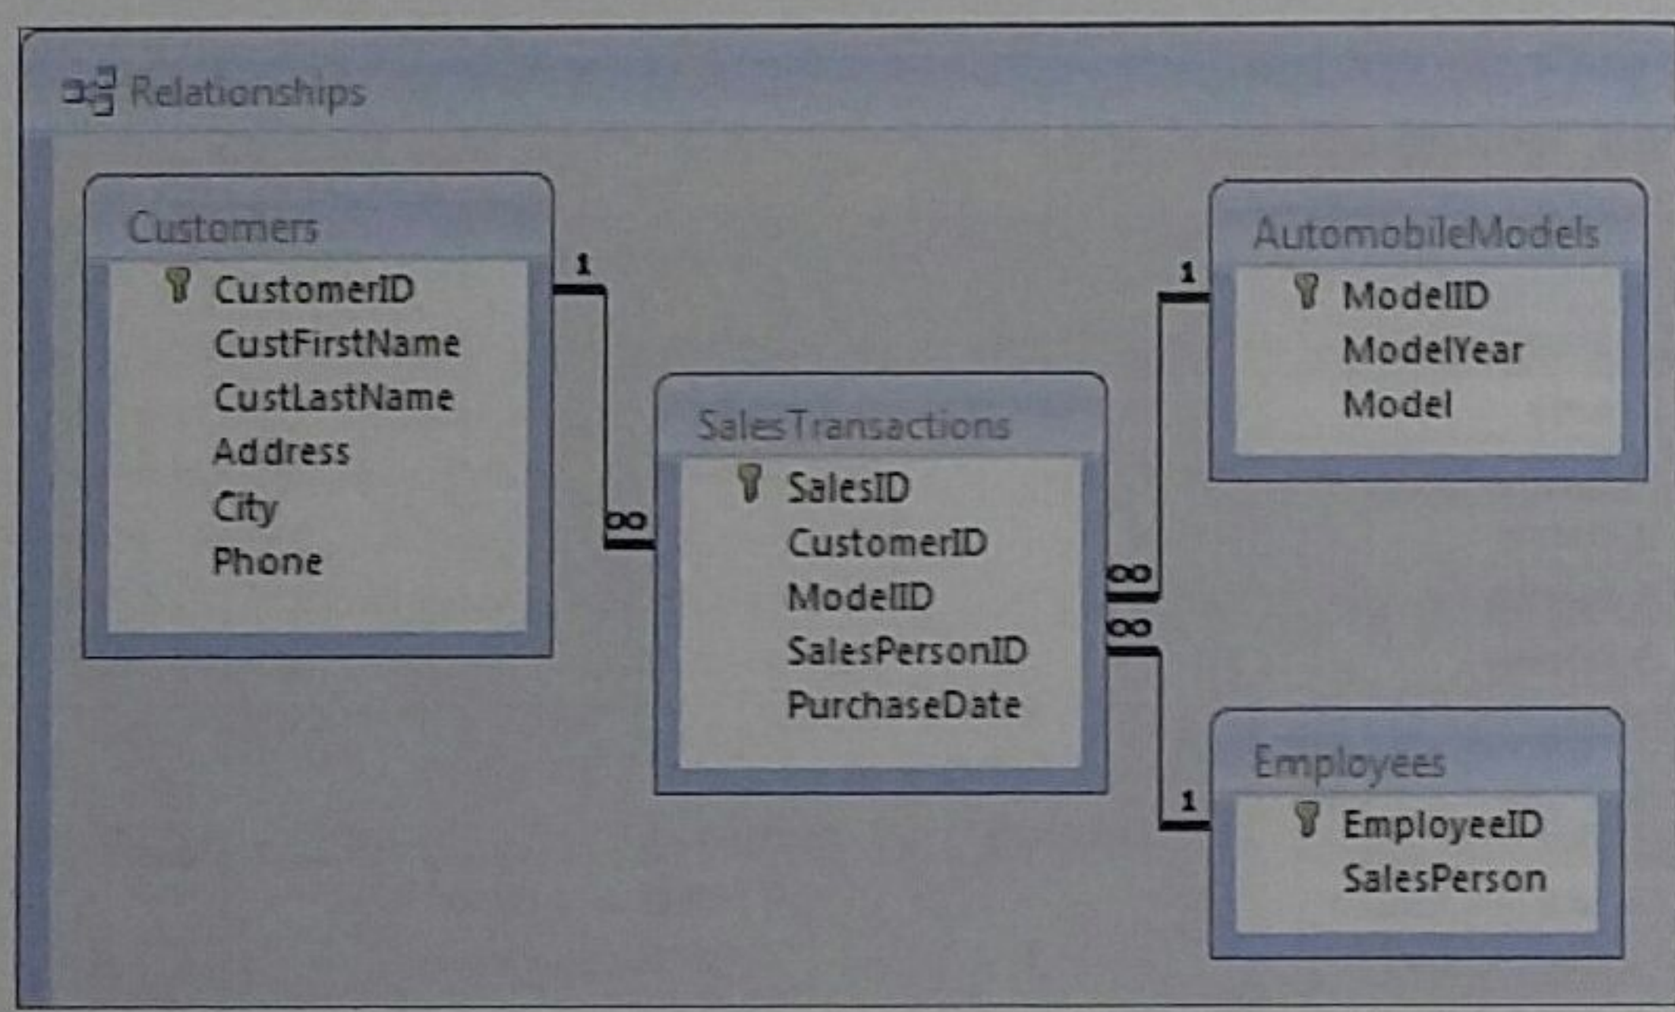

코드 1-1과 같이 가상 테이블(쿼리)을 만들면 중복 데이터를 저장하면서 발생하는 단점 없이 그림 1-3에 있는 원래 데이터를 쉽게 재생성할 수 있다('BETTER WAY 42. 가능하면 서브쿼리 대신 공통 테이블 표현식을 사용하자'에서처럼 가상 테이블은 공통 테이블 표현식(Common Table Expression, CTE)을 이용해 생성할 수 있다).

코드 1-1 원래 데이터를 반환하는 SQL

```
SELECT st.SalesID, c.CustFirstName, c.CustLastName, c.Address,
  c.City, c.Phone, st.PurchaseDate, m.ModelYear, m.Model,
  e.SalesPerson
FROM SalesTransactions st
  INNER JOIN Customers c
    ON c.CustomerID = st.CustomerID
```

```
INNER JOIN Employees e
  ON e.EmployeeID = st.SalesPersonID
INNER JOIN AutomobileModels m
  ON m.ModelID = st.ModelID;
```

핵심 정리

- 데이터베이스 정규화의 목표는 중복 데이터를 제거해 데이터를 처리할 때 사용되는 자원을 최소화하는 것이다.
- 중복 데이터를 제거하면 비정상적인 삽입, 갱신, 삭제를 막을 수 있다.
- 중복 데이터를 제거하면 일관성 없는 데이터 발생을 최소화할 수 있다.

참고문헌

관계형 데이터베이스를 올바르게 설계하는 방법을 찾고 있다면 다음 책 두 권을 추천한다. 첫 번째 책은 초급자의 눈높이에 맞춰져 있다.

- 〈가장 쉬운 데이터베이스 설계 책 : 적절한 데이터베이스 디자인을 위한 지침서〉(비제이 퍼블릭, 2014)
  〈Database Design for Mere Mortalsz〉(Addison-Wesley, 2013)
- 〈Handbook of Relational Database Design〉(Addison-Wesley, 1989)

BETTER WAY 3 반복 그룹을 제거하자

스프레드시트에서는 비슷한 데이터가 반복적으로 그룹을 이루는 것을 흔히 볼 수 있다. 정보 처리 작업자가 데이터베이스 정규화를 염두에 두지 않고 단순히 이런 데이터를 새 데이터베이스에 밀어 넣는 일도 다반사다. 그림 1-6은 데이터의 반복 그룹 예제다. 여기서는 DrawingNumber(도면 번호)가 Predecessor(선행 번호) 다섯 개와 관련되어 있다. 이 테이블은 도면 번호와 선행 번호 값 사이가 일대다(One-to-many) 관계다.

❮ 그림 1-6 단일 테이블에 있는 데이터의 반복 그룹

Assignments

ID	DrawingNumber	Predecessor_1	Predecessor_2	Predecessor_3	Predecessor_4	Predecessor_5
1	LO542B2130	LS01847409	LS02390811	LS02390813	LS02390817	LS02390819
2	LO426C2133	LS02388410	LS02495236	LS02485238	LS02495241	LS02640008
3	LO329W2843-1	LS02388418	LS02640036	LS02388418		
4	LO873W1842-1	LS02388419	LS02741454	LS02741456	LS02769388	
5	LO690W1906-1	LS02742130				
6	LO217W1855-1	LS02388421	LS02769390			

그림 1-6의 예제는 Predecessor란 단일 속성(Attribute)이 반복 그룹임을 보여 준다. 또 ID가 3인 레코드에는 의도하지 않은 중복 값이 들어 있다. 반복 그룹의 또 다른 예로 1월, 2월, 3월 등 월을 컬럼으로 하는 것을 들 수 있다. 하지만 반복 그룹이 단일 속성에만 국한되는 것은 아니다. 예를 들어 Quantity1, ItemDescription1, Price1, Quantity2, ItemDescription2, Price2, … QuantityN, ItemDescriptionN, PriceN이라는 컬럼이 있는 테이블을 보았다면, 이 역시 반복 그룹 패턴임을 알아챌 수 있어야 한다.

반복 그룹은 쿼리를 만들어 속성별로 묶은 보고서를 생성하기가 어렵다. 그림 1-6에서 나중에 Predecessor 값을 추가하거나 이미 있는 Predecessor를 제거할 일이 발생한다면 지금 설계로는 컬럼을 추가하거나 제거해야 한다. 또 이 테이블의 데이터를 기준으로 만든 모든 쿼리(뷰), 보고서의 설계도 수정해야 한다. 이 시점에서 기억할 유용한 공식은 다음과 같다.

영향도(비용) 측면에서 컬럼은 비싸고 로우는 싸다.

향후 입력될 유사한 데이터로 컬럼을 추가하거나 제거하도록 테이블을 설계했다면 마음속으로 적색 경보를 울려야 한다. 그보다는 필요할 때 로우를 추가하거나 제거하도록 설계하는 것이 훨씬 바람직하다. 이 예제에서는 ID 값을 외래키로 사용하는 Predecessors 테이블을 생성하면 좋다. 또 혼란스러울 수 있으니 그림 1-7과 같이 기존 ID 컬럼을 DrawingID로 바꾼다.

그림 1-7 일대다 관계를 수용하도록 정규화를 적용한 설계

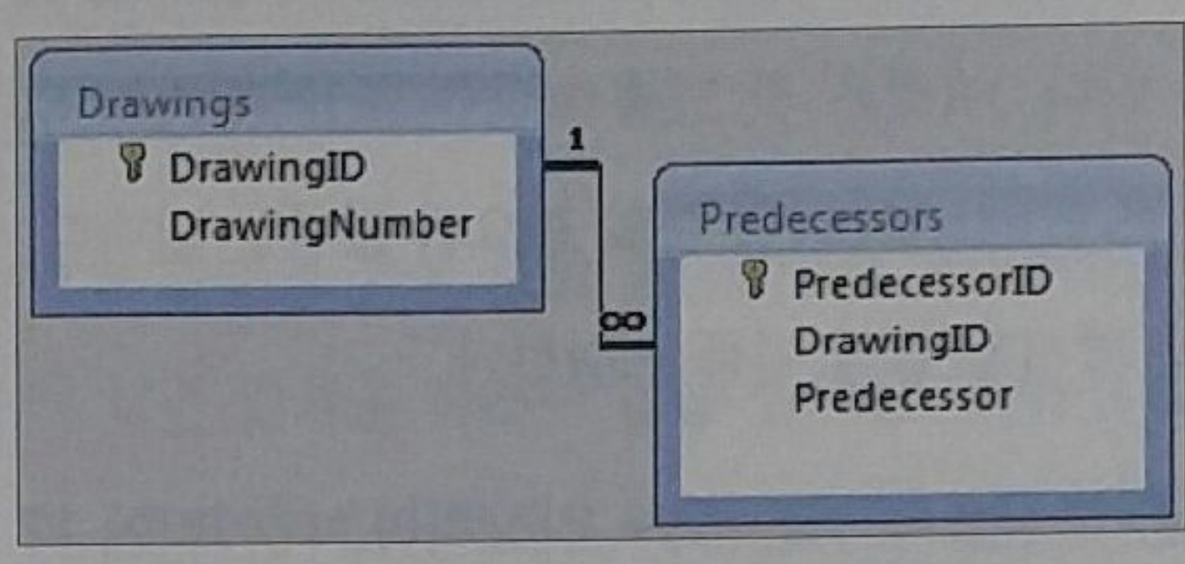

반복 그룹을 처리할 때는 UNION 쿼리를 사용한다. 이런저런 이유로 적절하게 정규화를 적용한 설계를 할 수 없다면, UNION을 사용해 읽기 전용 뷰를 만들어 데이터를 '정규화'할 수 있다. 또 코드 1-2와 같이 UNION으로 쿼리를 덧붙여 Predecessors 테이블에 레코드를 추가하는 효과도 낼 수 있다.

코드 1-2 데이터를 정규화하는 UNION 쿼리

```
SELECT ID AS DrawingID, Predecessor_1 AS Predecessor
FROM Assignments WHERE Predecessor_1 IS NOT NULL
UNION
SELECT ID AS DrawingID, Predecessor_2 AS Predecessor
FROM Assignments WHERE Predecessor_2 IS NOT NULL
UNION
SELECT ID AS DrawingID, Predecessor_3 AS Predecessor
FROM Assignments WHERE Predecessor_3 IS NOT NULL
UNION
SELECT ID AS DrawingID, Predecessor_4 AS Predecessor
FROM Assignments WHERE Predecessor_4 IS NOT NULL
UNION
SELECT ID AS DrawingID, Predecessor_5 AS Predecessor
FROM Assignments WHERE Predecessor_5 IS NOT NULL
ORDER BY DrawingID, Predecessor;
```

Note ≡ 한 로우에 있는 중복 데이터를 포함해 모든 데이터를 가져와야 한다면 UNION에 ALL 키워드를 붙인 UNION ALL을 사용한다. 하지만 이 예제에서는 ID가 3인 로우에 중복된 Predecessor 값을 제거하는 것이 목적이다.

UNION을 사용하려면 각 SELECT 문에서 사용되는 컬럼의 데이터 타입이 동일해야 하며 나열 순서도 같아야 한다. 이것은 첫 번째 SELECT 문 이후에는 코드 1-2와 같이 AS DrawingID나 AS Predecessor를 붙일 필요가 없다는 의미다. UNION은 맨 첫 번째 SELECT 문에 명시된 컬럼 이름을 취한다.

각 SELECT 문의 WHERE 절에 다른 조건을 붙이는 것도 가능하다. 데이터에 따라 길이가 0인 문자열(Zero-Length String, ZLS)이나 스페이스(' ')처럼 출력이 필요 없는 값을 제외해야 할 수도 있다.

UNION 쿼리에서 ORDER BY 절은 마지막 SELECT에서만 사용할 수 있다. 또 ORDER BY 1, 2 형태로 정렬 순서를 지정할 수도 있다. 코드 1-2에서는 ORDER BY DrawingID, Predecessor로 정렬 순서를 지정했다.

핵심 정리

- 데이터베이스 정규화의 목표는 데이터의 반복 그룹을 제거하고 스키마 변경을 최소화하는 것이다.
- 데이터의 반복 그룹을 제거하면 인덱싱을 사용해 데이터 중복을 방지할 수 있고 쿼리도 간소화할 수 있다.
- 데이터의 반복 그룹을 제거하면 테이블 설계가 더 유연해진다. 새로운 그룹을 추가할 때 테이블 설계를 바꿔서 새 컬럼을 추가하는 것이 아니라 단순히 또 다른 로우만 추가하면 되기 때문이다.

BETTER WAY 4 컬럼당 하나의 특성만 저장하자

관계형 용어에서 관계(테이블)는 오직 한 주제나 액션만 기술해야 한다. 속성(컬럼)은 관계로 정의된 주제를 기술하는 유일한 특성(종종 '원자성' 데이터라고도 한다)과 관련된 데이터를 포함한다. 또 속성은 다른 관계의 속성을

포함하는 외래키가 될 수 있고, 이 외래키는 다른 관계에 있는 일부 튜플(로우)과 연관성을 제공한다.

단일 컬럼에 특성 값을 두 개 이상 저장하는 것은 좋은 생각이 아니다. 이렇게 하면 검색을 하거나 값을 집계할 때 특성 값을 분리하기가 어렵기 때문이다. 중요한 개별 특성은 자체 컬럼에 넣는 것을 고려해야 한다. 표 1-1은 컬럼에 여러 특성이 포함된 테이블의 예를 보여 준다(이 샘플 데이터에 있는 주소는 실제 주소지만, 저자들의 주소는 아니다).

표 1-1 여러 컬럼에 여러 속성이 있는 테이블

AuthID	AuthName	AuthAddress
1	John L. Viescas	144 Boulevard Saint-Germain, 75006, Paris, France
2	Douglas J. Steele	555 Sherbourne St., Toronto, ON M4X 1W6, Canada
3	Ben Clothier	2015 Monterey St., San Antonio, TX 78207, USA
4	Tom Wickerath	2317 185th Place NE, Redmond, WA 98052, USA

이런 테이블에는 몇 가지 문제점이 있다.

- 불가능하지는 않지만 성(姓)을 찾기가 어렵다. 이 테이블에 로우가 네 개 이상 있다고 할 때, 성이 Smith인 사람을 찾으려고 LIKE 연산자와 와일드카드 %를 사용하면 성이 Smithson이나 Blacksmith인 사람도 검색될 수 있다.
- 이름을 검색할 때 효율성이 떨어지는 LIKE나 substring 연산자를 사용해 이름을 추출해야 한다. LIKE 연산자로 검색할 문자 끝에 %를 넣으면 효율적으로 처리할 수도 있지만, 이름에 Mr. 같은 문자가 포함되어 있다면 %를 검색어 앞에 붙여야 하는데 전체 데이터를 스캔하는 비효율성을 야기한다.
- 거리 이름, 도시, 주(州), 우편번호를 쉽게 찾을 수 없다.
- 데이터를 그룹으로 묶으면(예를 들어 책의 각 장(章)과 페이지 정보가 있는 다른 테이블과 조인하는 경우), 그루핑된 데이터에서 우편번호, 주, 국가를 추출하기가 매우 어렵다.

스프레드시트 같은 외부 데이터 소스에서 데이터를 가져올 때 이런 유형의 데이터를 볼 가능성이 크다. 실제 사용되는 데이터베이스에서도 이처럼 잘못 설계된 테이블을 어렵지 않게 볼 수 있다.

좀 더 올바른 해결책은 코드 1-3과 비슷한 형태로 테이블을 생성하는 것이다.

코드 1-3 속성을 분할한 Authors 테이블을 생성하는 SQL

```
CREATE TABLE Authors (
  AuthorID int IDENTITY (1, 1),
  AuthFirst varchar(20),
  AuthMid varchar(15),
  AuthLast varchar(30),
  AuthStNum varchar(6),
  AuthStreet varchar(40),
  AuthCity varchar(30),
  AuthStProv varchar(2),
  AuthPostal varchar(10),
  AuthCountry varchar(35)
);
INSERT INTO Authors (AuthFirst, AuthMid, AuthLast, AuthStNum,
    AuthStreet, AuthCity, AuthStProv, AuthPostal, AuthCountry)
  VALUES ('John', 'L.', 'Viescas', '144',
    'Boulevard Saint-Germain', 'Paris', ' ', '75006', 'France');
INSERT INTO Authors (AuthFirst, AuthMid, AuthLast, AuthStNum,
    AuthStreet, AuthCity, AuthStProv, AuthPostal, AuthCountry)
  VALUES ('Douglas', 'J.', 'Steele', '555',
    'Sherbourne St.', 'Toronto', 'ON', 'M4X 1W6', 'Canada');
--  ... 로우 삽입 생략
```

거리 번호(AuthStNum)를 문자 데이터 타입으로 사용한 점에 주목하자. 거리 '번호'에는 문자나 특수 문자가 포함되는 경우가 흔하기 때문이다. 예를 들어 일부 거리 번호는 1/2을 포함한다. 또 프랑스에서는 거리 번호에 bis*를 붙

* 역주 번지가 동일할 때 이것을 구분하려고 붙인다.

인다. 미국에서는 우편 번호가 숫자 형태이지만 캐나다와 영국에서는 문자와 공백이 포함되어 있다.

여기서 제안한 테이블 형태로 설계하면 표 1-2와 같이 한 컬럼당 특성 하나로 데이터를 분리할 수 있다.

표 1-2 컬럼당 특성을 한 개 갖도록 제대로 설계한 Authors 테이블

AuthID	AuthFirst	AuthMid	AuthLast	AuthStNum	AuthStreet	...
1	John	L.	Viescas	144	Boulevard Saint-Germain	...
2	Douglas	J.	Steele	555	Sherbourne St.	...
3	Ben		Clothier	2015	Monterey St.	...
4	Tom		Wickerath	2317	185th Place NE	...

...	AuthCity	AuthStProv	AuthPostal	AuthCountry
...	Paris		75006	France
...	Toronto	ON	M4X 1W6	Canada
...	San Antonio	TX	78207	USA
...	Redmond	WA	98052	USA

이제 컬럼당 특성이 한 개만 있으므로 하나 이상의 개별 특성에서 검색이나 그루핑을 쉽게 할 수 있다.

특성들을 재결합해야 할 때, 예를 들어 메일링 리스트를 만들 때는 SQL의 문자 연결 기능을 이용하면 쉽게 원래 데이터를 얻을 수 있다. 방법은 코드 1-4와 같다.

코드 1-4 SQL의 문자 연결 기능을 이용해 원래 데이터 생성

```
SELECT AuthorID AS AuthID, CONCAT(AuthFirst,
  CASE
    WHEN AuthMid IS NULL
    THEN ' '
    ELSE CONCAT(' ', AuthMid, ' ')
  END, AuthLast) AS AuthName,
  CONCAT(AuthStNum, ' ', AuthStreet, ' ',
      AuthCity, ', ', AuthStProv, ' ',
      AuthPostal, ', ', AuthCountry)
    AS AuthAddress
FROM Authors;
```

Note ≡ DB2, SQL Server, MySQL, 오라클, PostgreSQL 모두 CONCAT() 함수를 지원하는데, DB2와 오라클은 매개변수를 두 개만 받으므로 여러 문자를 연결하려면 CONCAT() 함수를 중첩해서 사용해야 한다. ISO 표준은 문자열 연결에서 || 연산자만 정의해 놓았다. DB2, 오라클, PostgreSQL은 || 연산자를 지원하지만, MySQL은 서버의 sql_mode 설정 값에 PIPE_AS_CONCAT를 포함할 때만 지원한다. 액세스는 CONCAT() 함수를 지원하지 않지만 &나 +로 문자열을 붙일 수 있다.

코드 1-3은 '좀 더 바른' 몇 가지 설계 후보 중 하나인데, 거리 주소에서 거리 번호를 분리하라고 권고한 이유가 무엇인지 궁금할 것이다. 사실 대부분의 애플리케이션에서는 거리 주소가 포함된 거리 이름을 사용하는 데 별 무리가 없다. 따라서 해당 애플리케이션의 요구 사항에 따라 신중히 고려해야 한다. 토지 조사용 데이터베이스에서는 거리 이름(그리고 '거리' 또는 '가(街)' 또는 '대로' 같은 지명)에서 거리 번호를 분리하는 것이 중요할 수 있다. 또 일부 애플리케이션에서는 국가 코드, 지역 코드, 전화번호에서 지역 번호 부분을 분리하는 것이 중요할 수도 있다. 따라서 속성을 식별할 때는 어느 부분을 미세하게 쪼갤 것인지 신중히 검토해서 결정한다.

특성들을 개별 컬럼으로 분할하면 개별 데이터 검색이나 그루핑을 수행하기

가 쉽다는 것은 자명하다. 보고서나 목록이 필요할 때도 간단히 분할된 데이터 조각들을 재결합할 수 있다.

핵심 정리

- 올바른 테이블 설계는 개별 특성을 자체 컬럼에 할당한다. 한 컬럼에 여러 특성이 포함되어 있으면 검색이나 그루핑 작업이 가능하다고 해도 어렵기 때문이다.
- 일부 애플리케이션에서는 주소나 전화번호 같은 컬럼의 데이터 일부를 걸러 내려면 최소 수준의 데이터 조각으로 분할해야 한다.
- 보고서나 목록을 뽑으려고 특성들을 재결합할 때는 SQL의 문자열 연결 기능을 사용한다.

BETTER WAY 5 왜 계산 데이터를 저장하면 좋지 않은지 이해하자

가끔씩 자동 계산되는 데이터를 저장하고 싶은 유혹에 빠질 것이다. 특히 이 데이터가 관련 테이블에 있는 데이터를 기준으로 할 때는 더욱 그럴 것이다. 코드 1-5를 살펴보자.

코드 1-5 예제 테이블 생성 SQL

```
CREATE TABLE Orders (
  OrderNumber int NOT NULL,
  OrderDate date NULL,
  ShipDate date NULL,
  CustomerID int NULL,
  EmployeeID int NULL,
  OrderTotal decimal(15,2) NULL
);
```

얼핏 보면 Orders 테이블에 OrderTotal 컬럼(모르긴 해도 Order_Details 테이블의 수량 * 가격의 합일 것이다)을 두는 것이 좋은 생각인 것 같다. 모든 주문과 주문 금액을 원할 때마다 관련 로우를 가져와서 계산할 필요가 없

기 때문이다. 하지만 이런 계산 필드는 데이터 웨어하우스 시스템에서는 좋을지 몰라도 운영 중인 데이터베이스 성능에는 심각한 영향을 미칠 수 있다('BETTER WAY 9. 데이터 웨어하우스에는 역정규화를 사용하자'를 참고한다). 또 Order_Details 테이블의 로우가 변경·삽입·삭제될 때마다 값을 재계산해야 하므로 데이터 무결성을 유지하기가 어렵다는 사실을 알게 될 것이다. 좋은 소식은 요즘에는 많은 데이터베이스 시스템이 필드를 관리하는 방법을 제공하므로 서버에서 수행되는 코드가 이런 계산을 대신한다는 것이다. 계산 컬럼을 현행화하는 가장 원시적인 방법은 계산에 사용되는 원천 컬럼이 있는 테이블에 트리거를 추가하는 것이다. 트리거는 대상 테이블에 데이터가 입력·갱신·삭제될 때 수행하는 코드다. 코드 1-5의 예제에 적용한다면, OraderTotal 컬럼 값을 재계산할 때는 Order_Details 테이블에 트리거가 필요하다. 하지만 트리거는 정확하게 작성하기가 어렵고 비용도 비싸다('BETTER WAY 13. 트리거를 남발하지 말자'를 참고한다).

잠재적으로 트리거보다 나은 선택으로 몇몇 데이터베이스 시스템에서는 테이블을 생성할 때 계산 컬럼을 정의하는 방법을 제공한다. 트리거보다 낫다고 한 이유는 테이블 정의의 일부로 계산 컬럼을 정의하면 트리거를 작성할 때 종종 필요한 복잡한 코드를 작성하지 않아도 되기 때문이다. 몇몇 RDBMS, 특히 최신 버전에서는 이미 계산 컬럼을 정의해 사용하는 기능을 지원한다. 예를 들어 SQL Server에서는 AS 키워드 다음에 수행할 계산을 정의하는 표현식을 붙일 수 있다. 동일한 테이블에 있는 컬럼만으로 계산하려면, 단순히 계산 컬럼을 정의할 때 다른 계산 대상 컬럼을 표현식에 추가한다. 관련된 다른 테이블에 있는 값으로 계산하고 이 계산을 수행하는 함수를 만들 수 있는 시스템이라면, 대상 테이블을 생성하거나 변경할 때 AS 절에서 함수를 호출해 해당 컬럼을 정의한다. 코드 1-6에서는 SQL Server의 예제

함수와 테이블 정의 내용을 보여 준다. 주의할 점은 해당 함수가 다른 테이블에 있는 데이터에 의존하고 비결정적 함수이므로 계산 컬럼에 인덱스를 만들 수 없다는 것이다.

코드 1-6 SQL Server의 함수와 테이블 정의

```
CREATE FUNCTION dbo.getOrderTotal(@orderId int)
RETURNS money
AS
BEGIN
  DECLARE @r money
  SELECT @r = SUM(Quantity * Price)
  FROM Order_Details WHERE OrderNumber = @orderId
  RETURN @r;
END;
GO

CREATE TABLE Orders (
  OrderNumber int NOT NULL,
  OrderDate date NULL,
  ShipDate date NULL,
  CustomerID int NULL,
  EmployeeID int NULL,
  OrderTotal money AS dbo.getOrderTotal(OrderNumber)
);
```

이런 식으로 처리하는 것은 매우 좋지 않은 생각이다. 이 함수는 비결정적 함수이고, 이 계산 컬럼은 테이블의 다른 실제 컬럼처럼 값이 지속되지 않기 때문이다. 또 이 컬럼으로는 인덱스를 만들 수 없고, 컬럼을 참조할 때마다 각 로우에 대해 서버가 함수를 호출해야 하므로 서버에 매우 많은 부하가 걸린다. 차라리 결과가 필요할 때마다 OrderID 컬럼을 기준으로 집계해 계산하는 서브쿼리로 해당 테이블을 조인하는 것이 훨씬 더 효율적이다.

결정적 함수와 비결정적 함수

결정적(Deterministic) 함수는 특정 값 집합이 입력되면 언제나 동일한 결과를 반환한다. 비결정적(Nondeterministic) 함수는 특정 값 집합이 입력되더라도 매번 다른 값을 반환할 수도 있다. 예를 들어 SQL Server의 내장 함수인 DATEADD()는 매개변수 세 개를 받는데, 주어진 값에서 동일한 결과를 반환하므로 결정적 함수다. 반면에 GETDATE() 함수는 실행할 때마다 매번 다른 값을 반환하므로 비결정적 함수다. (여기서는 DATEADD() 함수의 매개변수 값이 세 개 결정되었다고 가정한다. 예를 들어 GETDATE() 함수를 DATEADD() 함수의 매개변수로 사용할 수 없다고 가정한다.) '부록. 날짜와 시간 타입, 연산, 함수'에서 데이터베이스 시스템별로 제공되는 날짜와 시간 함수를 소개한다.

DB2에서는 GENERATED 키워드를 사용해 비슷한 기능을 구현할 수 있다. 하지만 DB2는 쿼리를 호출하는 함수로 계산 컬럼을 생성하는 것을 허용하지 않는데 비결정적 함수이기 때문이다. 하지만 결정적 함수 호출이나 표현식을 사용하는 컬럼은 정의할 수 있다. 코드 1-7은 수량 * 금액을 계산해 총 금액을 반환하는 표현식을 정의하고 Order_Details 테이블에 컬럼을 생성하는 방법을 보여 준다.

코드 1-7 DB2에서 표현식을 사용한 테이블 컬럼 정의

```
-- 테이블을 변경하려고 INTEGRITY 옵션을 끔
SET INTEGRITY FOR Order_Details OFF;
-- 표현식을 사용해 계산 컬럼을 생성함
ALTER TABLE Order_Details
  ADD COLUMN ExtendedPrice decimal(15,2)
    GENERATED ALWAYS AS (QuantityOrdered * QuotedPrice);
-- INTEGRITY 옵션을 다시 켬
SET INTEGRITY FOR Order_Details
IMMEDIATE CHECKED FORCE GENERATED;
-- 계산 컬럼에 인덱스를 생성함
CREATE INDEX Order_Details_ExtendedPrice
  ON Order_Details (ExtendedPrice);
```

이 표현식에는 결정적 특성이 있으므로 테이블에 컬럼을 생성하고 인덱스도 만들 수 있다. 코드 1-7은 DB2용 예제이지만 다른 데이터베이스에서 처리한 예제도 깃허브 리포지터리에서 찾아볼 수 있다(https://github.com/gilbutITbook/006882에서 〈데이터베이스 이름〉/Listing 1.007.sql 파일을 참고한다).

오라클에서 계산 컬럼(가상 컬럼이라고도 한다)을 만들려면 GENERATED [ALWAYS] AS 구문을 이용한다. 코드 1-8은 Order_Details 테이블에 총 금액 컬럼을 생성하는 오라클 SQL이다.

코드 1-8 오라클에서 인라인 표현식을 사용한 테이블 정의

```
CREATE TABLE Order_Details (
  OrderNumber int NOT NULL,
  OrderNumber int NOT NULL,
  ProductNumber int NOT NULL,
  QuotedPrice decimal(15,2) DEFAULT 0 NULL,
  QuantityOrdered smallint DEFAULT 0 NULL,
  ExtendedPrice decimal(15,2)
    GENERATED ALWAYS AS (QuotedPrice * QuantityOrdered)
);
```

이 시점에서 이런 의문이 들 것이다. 지금까지 많은 지면을 할애해 계산 컬럼을 사용하는 방법을 설명했는데, 도대체 이 BETTER WAY 제목은 '왜 계산 데이터를 저장하면 좋지 않은지 이해하자'일까? 아쉽게도 나쁜 소식을 전해야겠다. 대용량 온라인 데이터 입력용 테이블에서 이런 식으로 계산 컬럼을 추가하는 것은 서버에 심각한 부하가 걸려 응답 시간이 현저히 느려진다.

DB2, SQL Server, 오라클을 사용한다면 계산 컬럼에 인덱스를 만들 수 있고, 보통은 인덱스 덕분에 계산된 결과에 의존하는 쿼리가 빨리 수행될 것이다. 코드 1-6의 SQL Server 예제(다른 데이터베이스 시스템에서도 마찬가

지다)는 다른 테이블에 있는 컬럼에 의존하는 비결정적 함수를 사용했기 때문에 인덱스를 만들 수 없었음을 기억하자('BETTER WAY 17. 인덱스에서 계산 결과를 사용할 시기를 파악하자'를 참고한다).

SQL Server에서는 표현식에 PERSISTED 키워드를 추가로 명시해야 하는 반면, DB2에서는 일단 표현식에 인덱스를 만들어 놓으면 자동으로 유지된다.

코드 1-7에서는 호출된 함수 값이 변할 때마다, 즉 Order_Details 테이블의 로우를 갱신·삭제·삽입할 때마다 부하가 걸린다. 누군가가 주문 정보를 많이 입력하면 이 함수가 계산을 수행하고 인덱스 값을 저장해야 하기 때문에 응답 시간은 현저히 느려질 것이다. 코드 1-6과 코드 1-8에서는 Orders 테이블에 있는 컬럼을 가져올 때마다 부하가 걸리므로, SELECT를 수행할 때 테이블에 계산 컬럼을 포함하고 가져올 로우의 개수가 많다면 응답 시간은 참기 힘들 정도로 느릴 것이다.

핵심 정리

- 많은 시스템에서 테이블을 정의할 때 계산 컬럼을 정의할 수 있지만 성능을 고려해야 한다. 특히 비결정적 표현식이나 함수를 사용할 때는 더욱 그렇다.
- 트리거를 사용해 계산 컬럼을 일반 컬럼처럼 정의할 수 있지만 작성해야 할 코드가 복잡하다.
- 계산 컬럼은 데이터베이스 시스템에 추가적인 부하를 일으키므로 계산 컬럼으로 얻는 혜택이 부하를 일으키는 비용보다 클 때만 사용한다.
- 대부분의 경우 저장 공간이 증가하고 데이터 갱신이 느린 대신 일부 혜택을 보려고 계산 컬럼에 인덱스를 만들고 싶을 것이다.
- 인덱스 적용이 어려울 때는 테이블에 계산 결과를 저장해 놓는 방법 대신 뷰를 이용해 수행할 계산을 정의하는 방법을 종종 사용한다.

BETTER WAY 6 참조 무결성을 보호하려면 외래키를 정의하자

데이터베이스 스키마를 제대로 설계하려면 관련된 부모 테이블의 기본키 값을 포함하도록 테이블에 외래키를 정의하는 것이 좋다. 예를 들어 판매 주문 데이터베이스의 Orders 테이블은 Customers 테이블의 기본키를 가리키는 CustomerID나 CustomerNumber 컬럼을 정의해 이 컬럼으로 각 주문 고객 정보를 식별할 수 있게 해야 한다.

그림 1-8은 '전형'적인 판매 주문 데이터베이스의 모델링을 보여 준다.

그림 1-8 전형적인 Sales Orders 데이터베이스의 테이블 설계

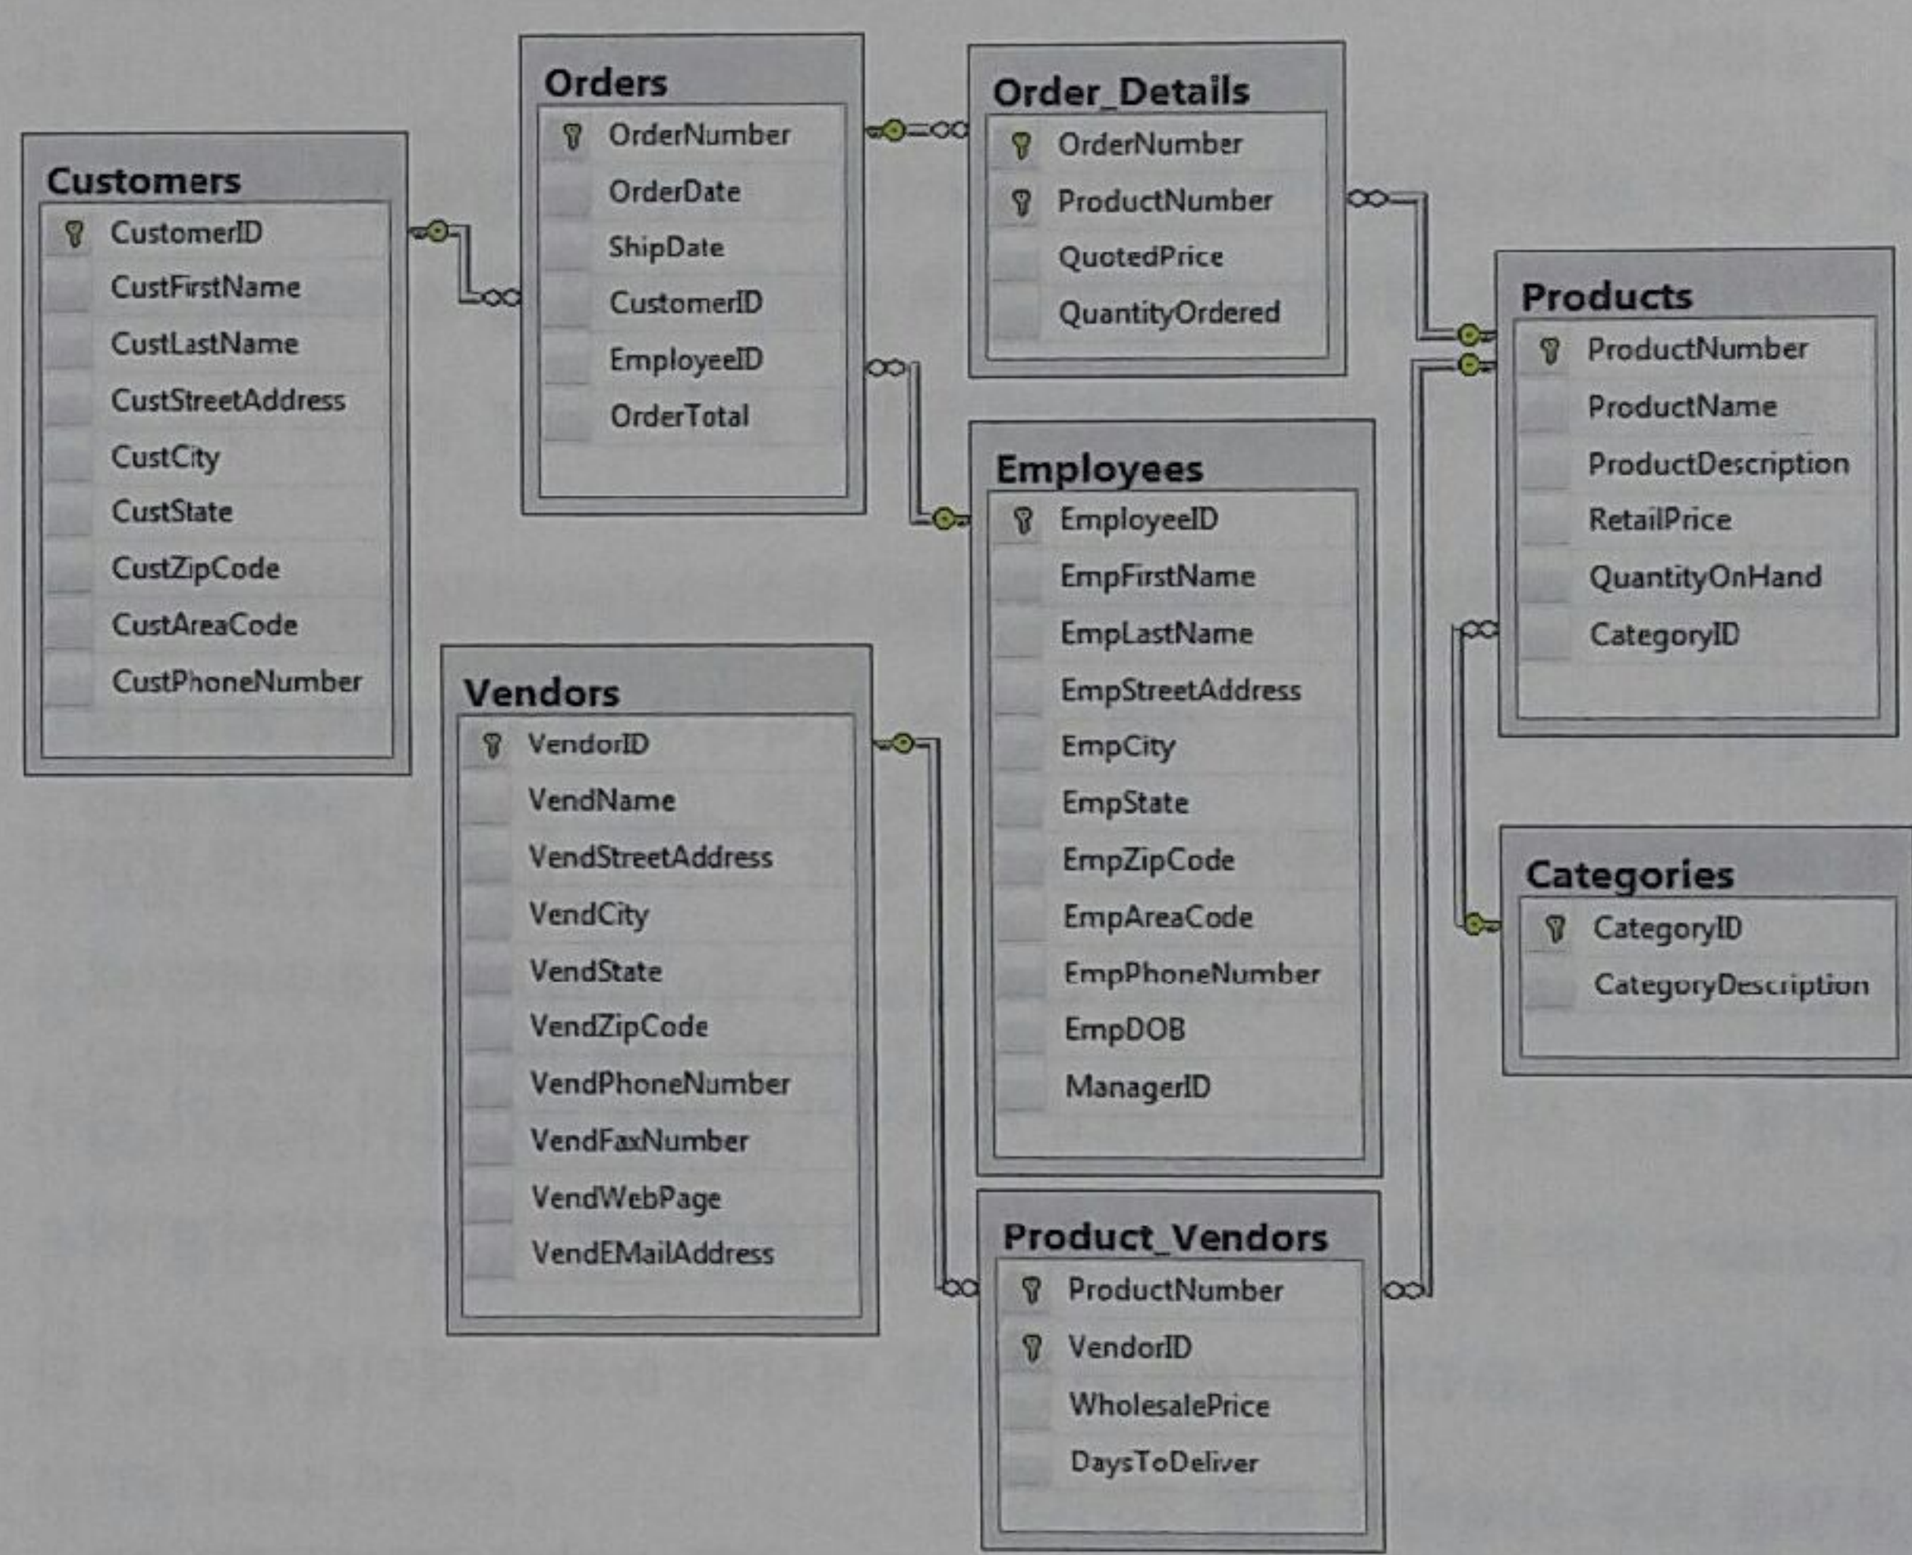

이 다이어그램은 여러 테이블 간의 관계를 분명하게 보여 준다. 각 관계선 끝에 위치한 열쇠 기호는 한 테이블의 기본키와 관계를 맺고 있음을 의미하며, 반대편 끝에 있는 무한대 기호는 두 번째 테이블의 외래키와 '일대다' 관계를 맺고 있음을 의미한다.

Note ≡ 그림 1-8은 SQL Server Management Studio의 다이어그램 도구로 만들었다. DB2, 액세스, MySQL, 오라클, Erwin, Idera ER/Studio 같은 모델링 도구에도 비슷한 도구가 있다.

선언적 참조 무결성(Declarative Referential Integrity, DRI)을 정의했기 때문에 데이터베이스 시스템은 테이블 간의 관계를 알고 있다. 이런 관계를 정의하는 목적은 두 가지다.

1. 그래픽 쿼리 디자이너를 사용하면 데이터베이스에서 새로운 뷰나 저장 프로시저를 생성할 때 쿼리 디자이너가 JOIN 절을 올바르게 만들 수 있도록 도와준다.
2. 일대다 관계에서 '다'에 해당하는 테이블에 데이터를 입력하고 변경하거나 '일'에 해당하는 테이블의 데이터를 변경하고 삭제할 때 데이터베이스 시스템이 데이터 무결성을 강화하는 데 도움을 준다.

이 중 두 번째 목적이 더 중요하다. 예를 들어 Orders 테이블에 누락되거나 엉뚱한 CustomerID 값을 가진 로우를 입력하지 않도록 해야 하기 때문이다. Customers 테이블에서 CustomerID 값을 변경할 수 있다면, (ON UPDATE CASCADE 키워드를 명시해) 변경된 값이 Orders 테이블의 관련 로우에도 모두 전파되게 하고 싶을 것이다. 그리고 사용자가 Orders 테이블의 로우와 관련된 Customers 테이블의 로우를 삭제하려고 시도한다면, 이 삭제 작업을 허용하지 않거나 (ON DELETE CASCADE 키워드를 명시해) Orders 테이블에 있는 관련 로우를 모두 삭제하기 원할 것이다.

여러분의 데이터베이스 시스템에서 이런 주요 기능을 사용하려면 '다' 관계에 있는 테이블을 생성할 때 CREATE TABLE 구문이나 ALTER TABLE 구문으로 FOREIGN KEY 제약 조건을 추가해야 한다. Customers와 Orders 테이블을 예로 처리 방법을 살펴보자.

먼저 코드 1-9와 같이 Customers 테이블을 만들어 보자.

코드 1-9 Customers 테이블 생성

```
CREATE TABLE Customers (
  CustomerID int NOT NULL PRIMARY KEY,
  CustFirstName varchar(25) NULL,
  CustLastName varchar(25) NULL,
  CustStreetAddress varchar(50) NULL,
  CustCity varchar(30) NULL,
  CustState varchar(2) NULL,
  CustZipCode varchar(10) NULL,
  CustAreaCode smallint NULL DEFAULT 0,
  CustPhoneNumber varchar(8) NULL
);
```

다음으로 Orders 테이블을 생성한 후 ALTER TABLE 문을 실행해서 두 테이블 간의 연관 관계를 정의해 보자. 코드 1-10에 해당 소스가 있다.

코드 1-10 Orders 테이블을 생성한 후 두 테이블의 연관 관계 정의

```
CREATE TABLE Orders (
  OrderNumber int NOT NULL PRIMARY KEY,
  OrderDate date NULL,
  ShipDate date NULL,
  CustomerID int NOT NULL DEFAULT 0,
  EmployeeID int NULL DEFAULT 0,
  OrderTotal decimal(15,2) NULL DEFAULT 0
);

ALTER TABLE Orders
  ADD CONSTRAINT Orders_FK99
    FOREIGN KEY (CustomerID)
    REFERENCES Customers (CustomerID);
```

이 두 테이블을 생성하고 데이터를 입력한 후 FOREIGN KEY 제약 조건을 추가하기로 결정했다면, Orders 테이블에 입력된 데이터가 참조 무결성을 위반할 때 Orders 테이블의 ALTER TABLE 구문은 실패할 것이다. 일부 데이터베이스 시스템에서는 성공할 수 있지만, 이때도 데이터베이스 옵티마이저는 이 제약 조건을 신뢰할 수 없다고 판단해 더는 사용하지 않을 것이다. 단순히 이 제약 조건을 정의하는 것만으로는 이전에 입력된 데이터에 대한 참조 무결성이 꼭 보장된다고 장담할 수 없다.

코드 1-11과 같이 자식 테이블(Orders)을 생성할 때 FOREIGN KEY 제약 조건을 정의할 수도 있다.

코드 1-11 테이블을 생성할 때 FOREIGN KEY 제약 조건 정의

```
CREATE TABLE Orders (
  OrderNumber int NOT NULL PRIMARY KEY,
  OrderDate date NULL,
  ShipDate date NULL,
  CustomerID int NOT NULL DEFAULT 0
    CONSTRAINT Orders_FK98 FOREIGN KEY
      REFERENCES Customers (CustomerID),
  EmployeeID int NULL DEFAULT 0,
  OrderTotal decimal(15,2) NULL DEFAULT 0
);
```

일부 데이터베이스 시스템(대표적으로 액세스)에서는 참조 무결성 제약 조건을 정의하면 자동으로 외래키 컬럼에 인덱스를 만드므로, 조인을 수행할 때 성능 향상 효과가 있을 수 있다. DB2처럼 외래키 컬럼에 자동으로 인덱스를 만들지 않는 데이터베이스 시스템은 이 제약 조건을 검증하고 최적화 차원에서 외래키 컬럼에 인덱스를 만들면 좋다.

핵심 정리

- 명시적으로 외래키를 만들면 부모 테이블에 없는 로우를 가리키는 자식 테이블 로우가 없음을 보장할 수 있으므로 관련된 테이블 간에 데이터 무결성을 확인하는 데 좋다.
- 이미 데이터가 있는 테이블에 FOREIGN KEY 제약 조건을 추가할 때 이 제약 조건을 위반하는 데이터가 있다면 제약 조건을 생성하는 작업은 실패할 것이다.
- 일부 시스템에서는 FOREIGN KEY 제약 조건을 정의하면 자동으로 인덱스를 만들어 주므로 조인 성능이 향상될 수 있다. 다른 시스템은 FOREIGN KEY 제약 조건이 걸린 컬럼에서 수동으로 인덱스를 만들어야 한다. 일부 시스템은 인덱스 없이도 옵티마이저가 해당 컬럼을 특별 취급해 더 나은 쿼리 실행 계획을 세우기도 한다.

BETTER WAY 7 테이블 간 관계를 명확히 하자

이론적으로는 관련 컬럼의 데이터 타입이 같으면 테이블 간에 어떤 관계든 맺을 수 있다. 하지만 뭔가 할 수 있다는 이유만으로 반드시 해야 하는 것은 아니다. 그림 1-9에서 판매 주문 정보를 담는 데이터베이스의 스키마 다이어그램을 살펴보자.

언뜻 보았을 때 특별히 이상한 점은 없다. 테이블이 여러 개 있고 각 테이블은 단일 주제를 포함한다. Employees, Customers, Vendors 테이블에 집중해 보자. 이 세 테이블을 유심히 보면 테이블 간에 비슷한 컬럼이 많음을 알 수 있다. 이 세 테이블에 있는 데이터 자체는 유일하므로 비슷한 컬럼이 있다고 해서 문제가 되지는 않는다.

하지만 고객 일부가 공급처이거나 이 회사의 임직원이라면, 이 모델은 'BETTER WAY 2. 중복으로 저장된 데이터 항목을 제거하자'에서 살펴본 중복 데이터 규칙을 위반하게 된다. 모든 종류의 연락처 정보를 담은 Contacts 라는 단일 테이블을 생성해서 이 난관을 극복할 수 있다고 생각하는 사람도

있을 것이다. 하지만 이 방법도 문제가 있다. 하나만 예를 들면 EmployeeID, CustomerID, VendorID는 이제 단일 기본키인 ContactID로 통합될 텐데, 해당 ID가 실제로는 고객이자 공급처인지 판별할 방법이 없다.

❮ 그림 1-9 판매 주문 정보 데이터베이스의 스키마 다이어그램

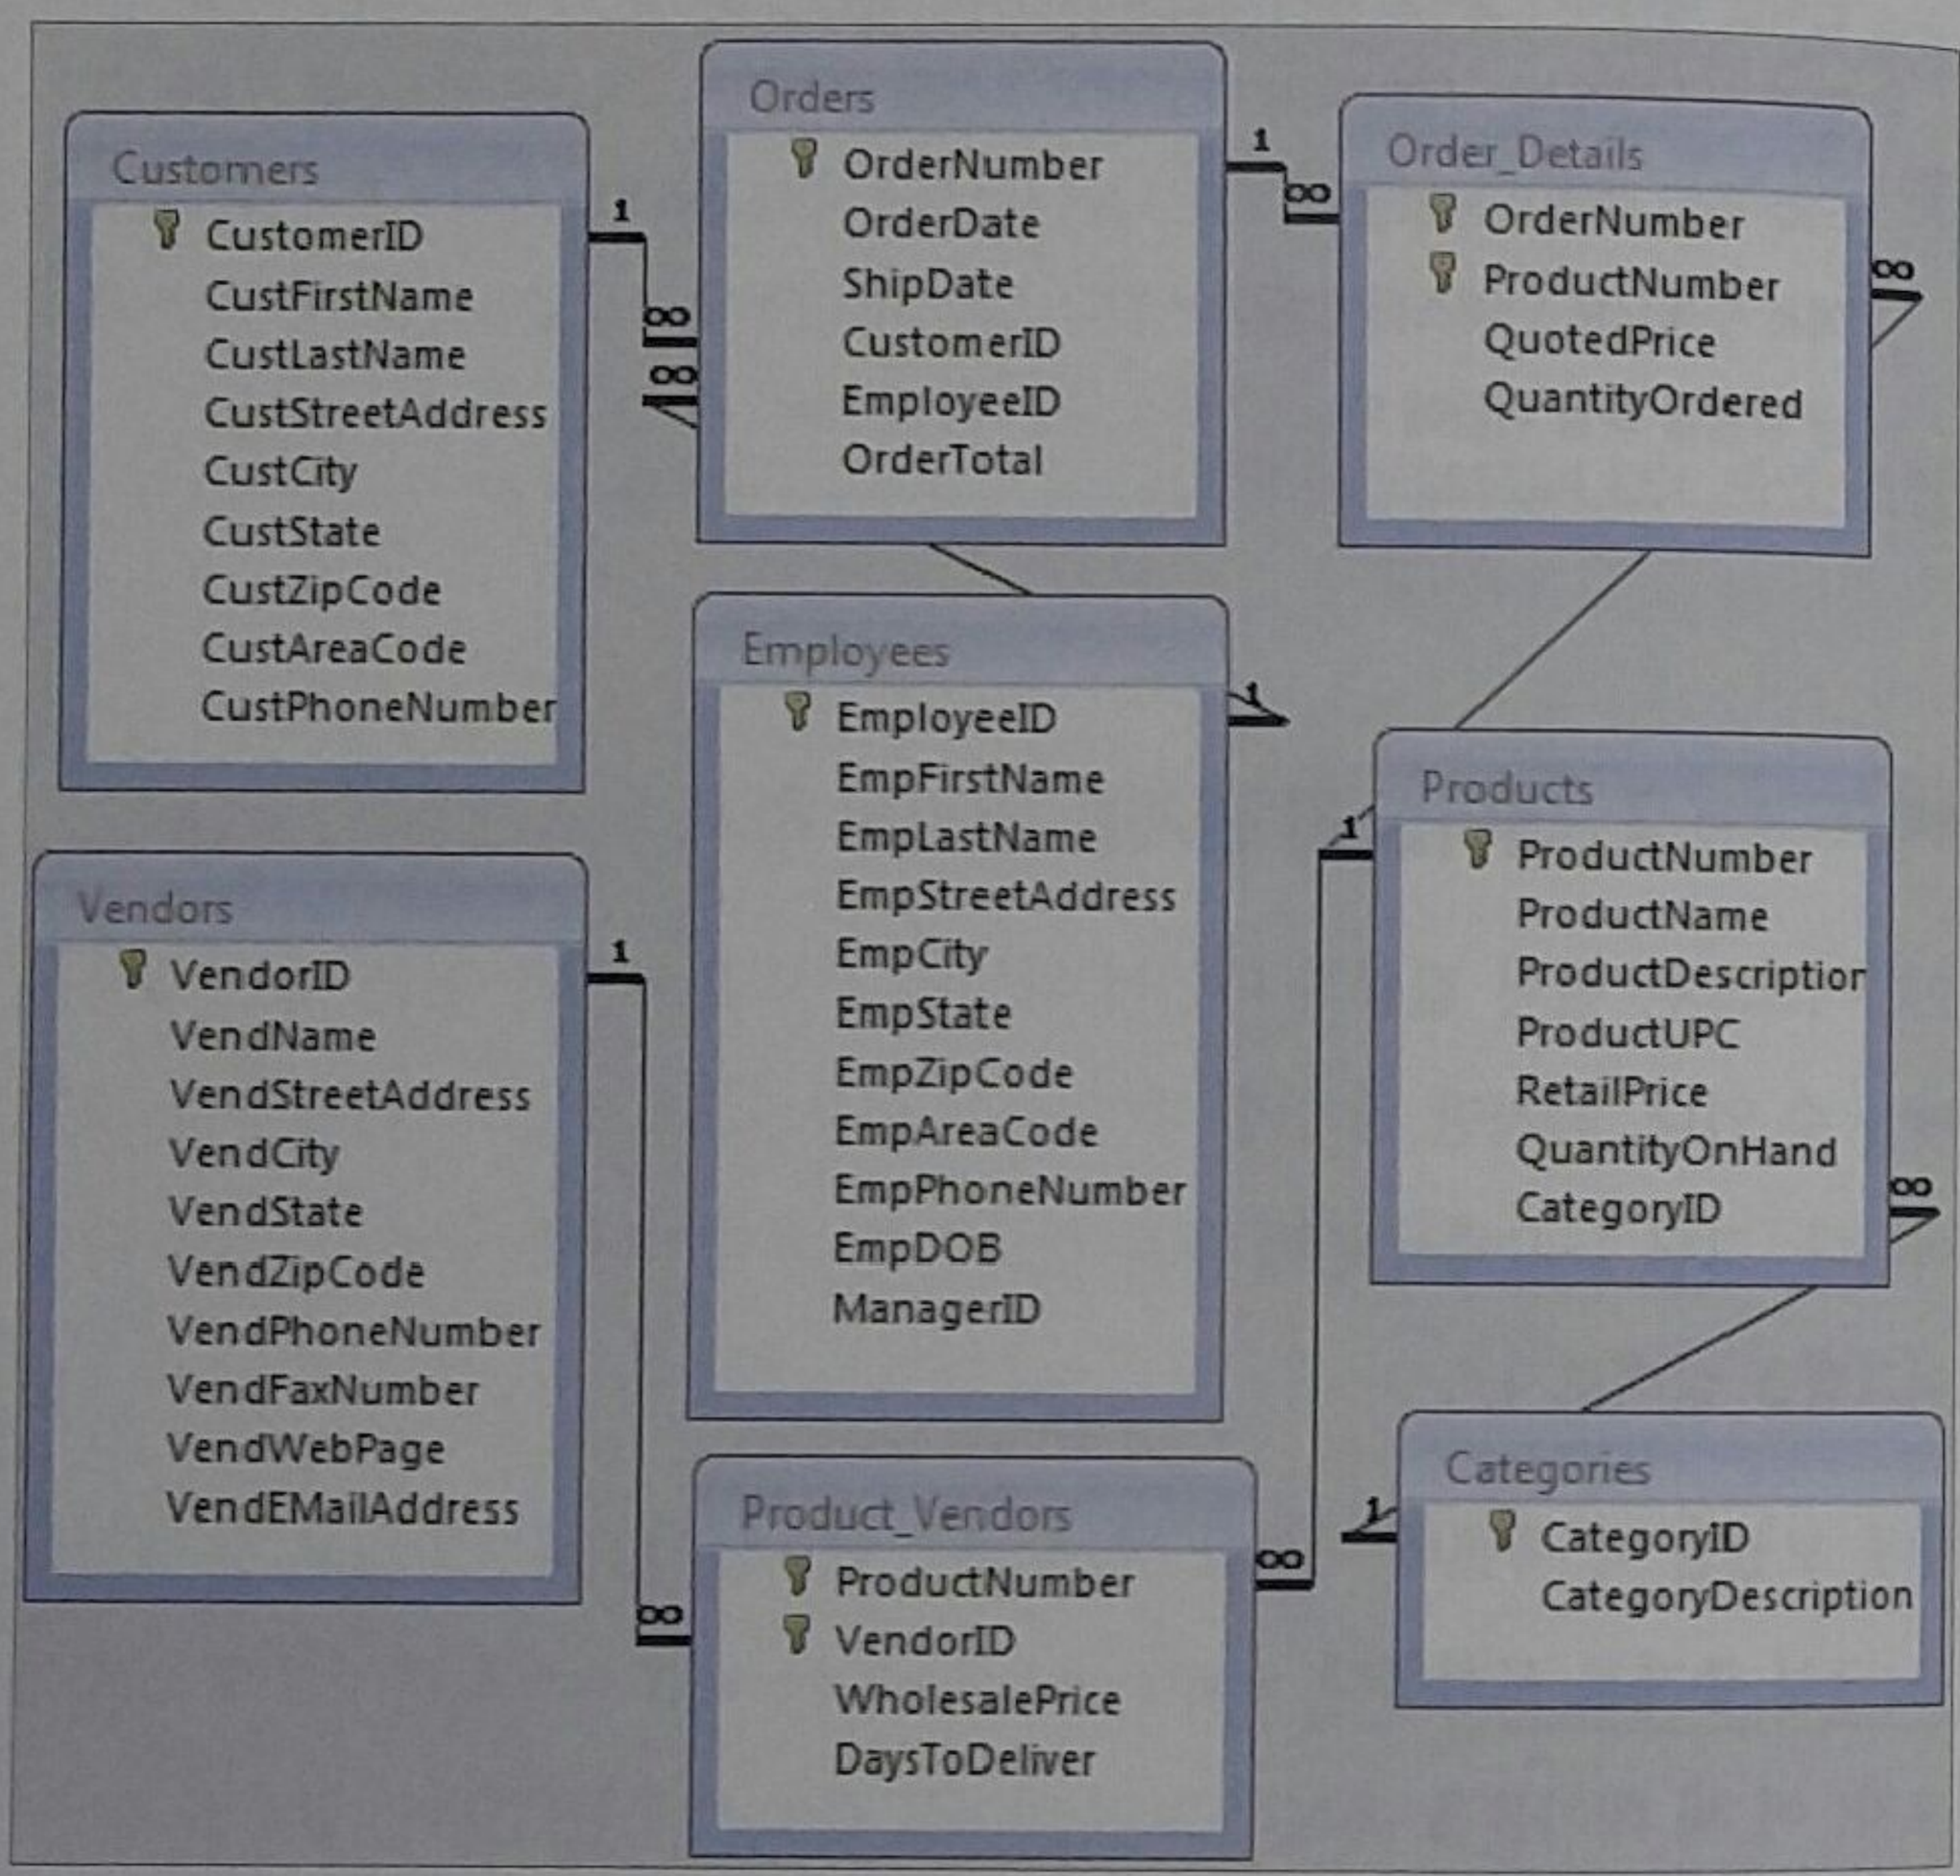

어떤 사람들은 Contacts 테이블과 일대일 관계를 맺은 Customers, Vendors, Employees 테이블을 만들어서 해결할 수 있다고 여긴다. 이렇게 하면 ManagerID나 VendWebPage처럼 엔터티에 특화된 데이터를 다른 고객 로우와 분리해 유지하기가 쉽다는 장점이 있다. 하지만 이렇게 하면 이 데이터베이스 스키마를 사용하는 애플리케이션은 지금보다 훨씬 복잡해진다. 어떤 엔터티이고,

필요한 도메인 특화 데이터는 담았는지 확인해야 하기 때문이다. 결국 애플리케이션이 신규로 입력되는 데이터가 중복 데이터인지 확인하지 않은 채 입력을 허용한다면 추가 테이블은 아무짝에도 쓸모가 없을 것이다. 알다시피 모든 회사가 이런 추가적인 복잡성 문제를 해결하는 데 충분한 시간과 비용을 들이려고 하지 않는다. 공급처나 회사 임직원이 제품을 판매하는 회사의 고객이 될 리는 없으므로, 이렇게 드문 상황에서 가끔 발생하는 중복 데이터를 해결하는 것이 데이터베이스 스키마의 간소화에 비해 비용이 낮기 때문이다.

직원에게 판매 지역을 할당해야 하는 시나리오를 고려해 보면, 결론적으로 판매 지역을 기준으로 고객과 직원을 연결할 수 있다. Customers 테이블의 CustZipCode 컬럼과 Employees 테이블의 EmpZipCode 컬럼 간에 관계를 만드는 것도 이렇게 할 수 있는 한 방법이다. 이 둘은 같은 도메인에 있고 데이터 타입도 동일하다. 두 테이블 간에 관계를 생성하는 대신, Employees와 Customers 테이블의 ZIP 코드 컬럼으로 조인해서 어느 고객이 어느 직원 근처에 사는지 찾아낼 수도 있다.

단순히 Customers 테이블에 EmployeeID 외래키를 생성해 해당 고객을 직원과 연결하는 것도 가능하지만, 이 방법은 실제로 더 많은 문제를 일으킨다. 예를 들어 해당 고객이 다른 판매 지역으로 이사한다면 어떻게 될까? 데이터를 입력하는 직원이 고객의 주소를 올바르게 갱신할 수 있지만, 이 고객과 연결된 직원을 갱신해야 한다는 사실을 알아채거나 기억하지 못해 새로운 오류가 발생될 것이다.

차라리 EmployeeID 외래키를 가진 SalesTerritory라는 테이블을 만들어 직원에게 할당된 ZIP 코드(TerrZip)를 로우로 식별하는 것이 나을 것이다. 동일한 ZIP 코드를 직원 두 명 이상에게 할당하는 것은 원하지 않을 테니 각 ZIP 코드는 SalesTerritory 테이블 내에서는 유일할 것이다. 다음으로 TerrZIP

코드와 Customers 테이블 간에 관계를 생성하면 직원은 자신의 지역에 어떤 고객이 있는지 알아낼 수 있을 것이다.

반대로 판매 지역이 아닌 다른 기준에 따라 고객을 직원에게 할당할 때는 Customers 테이블에 EmployeeID 외래키를 생성하는 방법이 고객과 직원 간 연결에 실질적인 유동성을 반영하는 데 더 좋다. 기본적으로 판매 지역을 기준으로 연결하더라도 이렇게 처리하면 다른 직원과 연결해 달라는 고객의 요청도 반영할 수 있다. 이전 예와 마찬가지로 이런 접근법을 따를 때는 데이터 입력 오류를 최소화할 수 있는 적절한 프로그래밍이 필요하다.

회사에서 판매하는 모든 제품을 나열하면서 각 제품의 세부 데이터와 모든 속성을 추출할 때도 비슷한 문제가 일어난다. 예를 들어 목재회사에는 목재의 길이, 높이, 너비, 나무의 유형을 저장한 제품 테이블이 있을 것이다. 결국 이 회사는 목재를 판매하기 때문이다. 하지만 회사가 다양한 제품을 판매하는 소매점일 때, 아주 가끔 사용하는 컬럼 몇 개를 추가하는 것은 좋은 선택으로 보이지 않는다. 그렇다고 제품 카테고리별로 테이블을 만들어 각 카테고리에 해당하는 데이터를 모두 저장하지도 않을 것이다. 이런 상황에서는 XML이나 JSON 문서를 저장할 수 있는 Attribute 컬럼을 생성하는 것이 더 나을 수도 있다. 이것은 관계형 테이블에 있는 제품의 속성을 노출하도록 규정하는 비즈니스 규칙이 없을 때는 문제가 되지 않는다. 하지만 임의의 속성을 질의할 수 있어야 할 때는 ProductAttributes 테이블을 생성해서 컬럼을 로우로 변환한 후 Products 테이블에 있는 제품과 연결해야 목표를 달성할 수 있을 것이다.* 코드 1-12는 이 테이블에서 가능한 설계를 보여 준다.

* 이것을 EAV(Entity-Attribute-Value) 모델이라고 한다.

코드 1-12 Products와 ProductAttributes 테이블 간 관계 생성

```
CREATE TABLE Products (
  ProductNumber int NOT NULL PRIMARY KEY,
  ProdDescription varchar(255) NOT NULL
);

CREATE TABLE ProductAttributes (
  ProductNumber int NOT NULL,
  AttributeName varchar(255) NOT NULL,
  AttributeValue varchar(255) NOT NULL,
  CONSTRAINT PK_ProductAttributes
    PRIMARY KEY (ProductNumber, AttributeName)
);

ALTER TABLE ProductAttributes
  ADD CONSTRAINT FK_ProductAttributes_ProductNumber
    FOREIGN KEY (ProductNumber)
      REFERENCES Products (ProductNumber);
```

속성 값을 컬럼이 아닌 로우로 저장해 문제를 해결한 것처럼 보이지만, 특정 속성의 특정 제품을 추출하는 쿼리는 훨씬 복잡해졌다. 특히 다뤄야 할 속성이 여러 개라면 더욱 그렇다.

덧붙여 말하면 속성 문제는 설계자에게 정형 데이터와 반정형(Semistructured) 데이터를 구별할 수 있는 능력을 요구한다. 관계형 모델에서는 실제 데이터를 입력하기 전에 가능한 모든 컬럼과 데이터 타입을 나열해 데이터를 제대로 정의해야 한다. 이것은 XML이나 JSON 문서처럼 레코드 수준에서 동일한 스키마를 가질 필요가 없는 반정형 데이터와는 정반대 특성이다. 따라서 관계를 정의하는 데 어려움을 겪고 있다면 혹시 반정형 데이터를 다루고 있지는 않은지, 관계형 모델에서 직접 반정형 데이터를 사용할 필요는 없는지 자문해 보는 것이 좋다. 현재 SQL 표준은 XML과 JSON을 SQL에서 직접 사용하도록 해서 선택의 폭이 넓은데, 이것은 책의 범위를 넘어선다.

앞에서 논의한 내용의 핵심은 데이터 모델의 정확성 유무를 규정하는 것은 비즈니스 규칙이며, 여러분은 애플리케이션을 설계할 때 이 점을 감안해야 한다는 것이다. 원래는 데이터 모델 설계에 맞춰 애플리케이션을 구현해야 하지만, 애플리케이션에 맞춰 데이터 모델을 설계할 가능성이 더 크므로 종종 어려운 일이 된다. 실제로 여러 데이터 모델 중 하나를 선택하면 데이터베이스를 사용할 애플리케이션을 설계하는 방법에 상당한 수준의 변경이 뒤따른다. 이런 변경은 애플리케이션의 개발 비용과 출시 시간에 영향을 미칠 수 있다.

핵심 정리

- 컬럼이 비슷한 테이블을 서로 병합해 관계를 간소화하는 것이 정말 타당한지 면밀히 검토한다.
- 데이터 타입이 일치한다면(또는 묵시적 타입 변환이 가능하다면) 두 테이블에 있는 컬럼 간 조인을 생성할 수 있는데, 이 관계는 해당 컬럼이 같은 도메인에 있을 때만 성립한다. 하지만 조인에 사용되는 두 컬럼의 데이터 타입은 동일한 것이 가장 좋다.
- 데이터 모델에서 실제로 정형 데이터를 다루고 있는지 확인한다. 다루는 데이터가 반정형이라면 필요한 대응책을 마련한다.
- 일반적으로 데이터 모델의 목표를 명확히 식별하면, 주어진 설계의 간소화와 데이터 모델을 사용하는 애플리케이션의 설계에 기인한 복잡성이나 이상 동작을 정당화하는지 판단하는 데 도움이 된다.

BETTER WAY 8 제3정규화로도 부족하다면 더 정규화하자

흔히 떠도는 이야기 중 하나는 대부분의 애플리케이션은 제3정규화(Third Normal Form, 3NF)로 충분하다는 것이다. 많은 실무자가 '일반적으로 제3정규화면 충분하다', '일단 최대한 정규화한 후 애플리케이션이 제대로 돌아갈

때까지 역정규화하라'는 경구만 듣고 재인용한다. 이런 경구는 더 높은 정규화에는 더 많은 수정이 필요하다는 것을 암시한다. 사실 대부분의 데이터 모델에서 이미 제3정규화를 거친 엔터티는 더 높은 수준의 정규화를 만족할 가능성이 크다. 실제로 오늘날 많은 데이터베이스에서 무수한 참조 테이블이 이미 제5정규화, 심지어 제6정규화까지 도달해 있는데도 사람들은 이를 제3정규화로 칭한다. 따라서 제3정규화를 거친 테이블이지만 더 높은 정규화를 위반하는 경우를 찾아야 한다. 드물기는 하지만 분명히 존재하는 상황이므로 해당 테이블이 제3정규화를 만족하는 것처럼 보이더라도 데이터 이상 현상을 일으키는 설계 실수를 쉽게 저지를 수 있다.

제3정규화로 설계했지만, 한 테이블이 다른 테이블 두 개 이상과 관계를 맺는다면 더 높은 정규화 형식을 위반할 수 있으므로 주의해야 한다. 특히 다대다 관계가 둘 이상일 때는 더욱 주의해야 한다. 테이블에 더 높은 정규화 형식을 위반할 수 있는 복합키가 있을 때도 마찬가지다. 대리키를 사용하고 대리키 대신 자연키를 분석할 때는 각별히 주의가 필요하다. 이어지는 예제를 보면 이것을 명확하게 이해할 수 있을 것이다.

결론부터 말하면 처음 세 가지 정규화 형식(그뿐만 아니라 Boyce-Codd 정규화 역시)은 관계의 속성 중 기능적 의존성이 있는 속성과 관련되었다고 할 수 있다. 기능적 의존성은 해당 속성이 관계를 이루는 키에 의존함을 의미한다. 예를 들어 '466.315.0072'라는 전화번호가 더글러스 스틸의 것이라면 이 번호가 저장된 컬럼은 '더글러스 스틸'이 저장된 컬럼에 기능적으로 의존하며, 다른 속성은 둘 간의 관계에 영향을 주지 않는다고 말할 수 있다. 이 전화번호가 키 아닌 다른 속성에 의존한다면 데이터 이상이 발생할 것이다.

제4정규화 형식은 다치 종속(Multivalued Dependency)과 관련이 있다. 제4정규화는 두 속성이 서로 독립적이지만 관계에서 동일한 키에 의존하는 경우를

다룬다. 이때 두 속성 간에 가능한 조합을 만든다. 제4정규화 형식을 위반할 수 있는 특수한 경우가 있다. 표 1-3에서 판매원이 판매한 제품 정보를 살펴보자.

❮ 표 1-3 판매원이 판매한 제품 정보가 있는 테이블

판매원	제조사	제품
Jay Ajurap	Acme	Slicer
Jay Ajurap	Acme	Dicer
Jay Ajurap	Ace	Dicer
Jay Ajurap	Ace	Whomper
Sheila Nyu	A-Z Inc.	Slicer
Sheila Nyu	A-Z Inc.	Whomper

표에 명시되어 있지는 않지만 각 제조사(Manufacturer)는 두 가지 제품만 생산하고, 판매원은 해당 제조사의 모든 제품을 판매해야 한다는 것을 알 수 있다. 따라서 Sheila가 Ace의 제품을 팔기로 했다면 로우를 두 개(하나는 Ace의 Dicer, 다른 하나는 Ace의 Whomper) 새로 입력해야 한다. 이때 이 테이블의 데이터를 제대로 갱신하지 못하면 데이터 이상이 발생할 수 있다. 이런 오류를 피하려면 그림 1-10과 같이 테이블을 여러 개로 분할해야 한다.

❮ 그림 1-10 판매원 재고 데이터베이스의 스키마 다이어그램

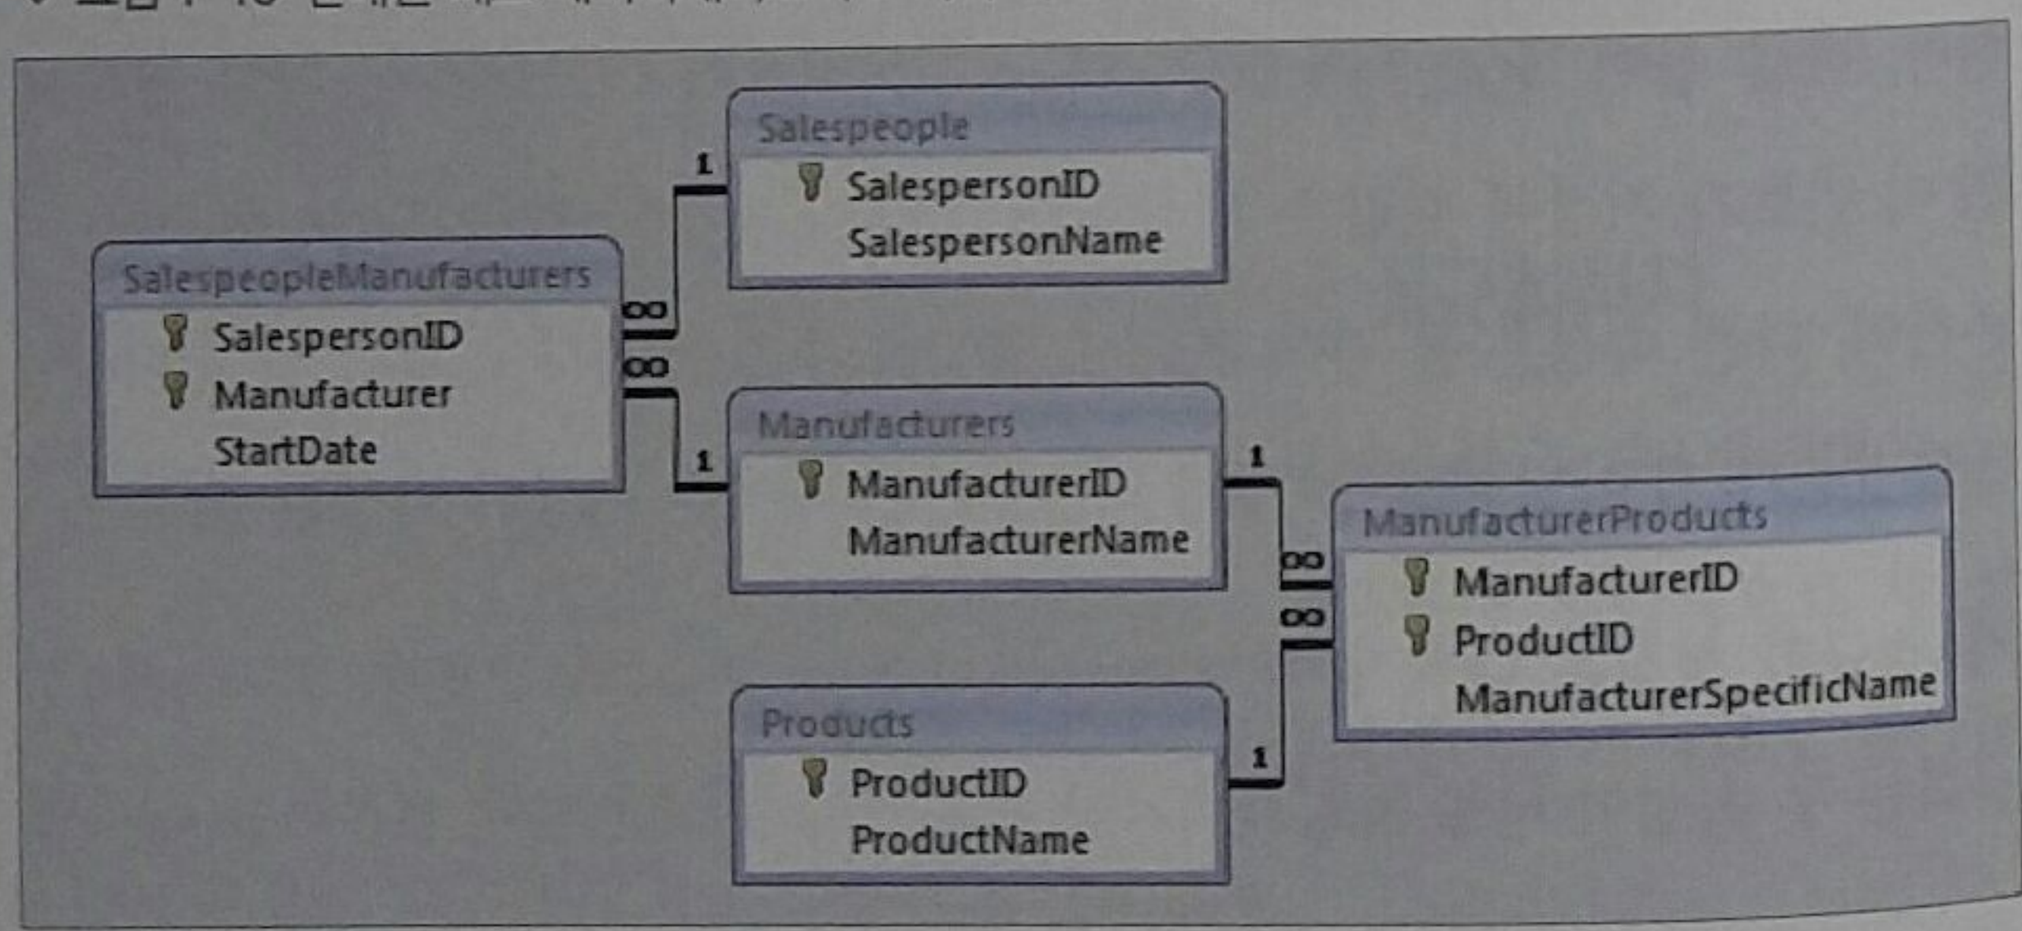

이 모델을 사용하면 임의의 판매원이 판매할 모든 제품을 나열하기만 하면 된다. 그러고 나서 제품의 실제 제조사와 연결하고, SalespeopleManufacturers와 ManufacturerProducts 테이블을 조인해 표 1-3과 같은 결과를 추출하면 임의의 판매원이 실제로 판매하는 제품을 알아낼 수 있다. 여기서 판매원은 해당 제조사가 제조한 모든 제품을 판매해야 한다는 비즈니스 규칙을 따른다는 점에 주목해야 한다. 하지만 현실적으로 판매원은 어느 한 제조사가 제작한 제품의 일부만 판매할 가능성이 크다. 그러면 표 1-3의 데이터는 더 이상 제4정규화를 위반하지 않는다. 이것은 더 높은 정규화 형식을 사용할 때가 왜 드문지 그 이유를 분명히 드러낸다. 즉, 우리가 사용하는 대부분의 비즈니스 규칙 때문에 데이터 모델은 더 높은 정규화 형식을 이미 만족하고 있는 셈이다.

제5정규화 형식에서는 후보키가 모든 조인 의존성을 함축해야 한다. 표 1-4에서 검사실, 의사, 검사 장비의 비정규화된 데이터를 보자.

표 1-4 여러 컬럼에 다중 속성이 포함된 테이블

검사실	의사	검사 장비
Southside	Salazar	X-Ray Machine
Southside	Salazar	CAT Scanner
Southside	Salazar	MRI Imaging
Eastside	Salazar	CAT Scanner
Eastside	Salazar	MRI Imaging
Northside	Salazar	X-Ray Machine
Southside	Chen	X-Ray Machine
Southside	Chen	CAT Scanner
Eastside	Chen	CAT Scanner
Northside	Chen	X-Ray Machine
Southside	Smith	MRI Imaging
Eastside	Smith	MRI Imaging

이 데이터 모델에서 의사는 특정 장비로 검사할 수 있는 검사실을 예약해야 한다. 의사는 해당 장비를 다루는 교육을 이미 받았다고 가정하므로 장비 사용 자격이 없는 검사실로 의사를 보내는 것은 의미가 없다. 하지만 모든 의사가 동일한 교육을 받지는 않는다. 일부는 상대적으로 새롭거나 약간 다르게 전문화되어 있을 수도 있으므로 모든 의사가 동일한 기술을 공유할 필요는 없다.

이제 검사실 위치와 검사 장비를 알았다. 겹치는 항목이 있기는 하지만, 모두 독립적이다. 특정 장비가 있는 검사실은 의사가 해당 장비를 사용하는 방법을 교육받았는지 여부와는 관련이 없다. 그림 1-11과 같이 테이블 여섯 개로 구성된 데이터 모델을 설계하는 일은 할 수 있을 것 같다.

❮ 그림 1-11 의사 · 장비 · 검사실 예약 데이터베이스의 스키마 다이어그램

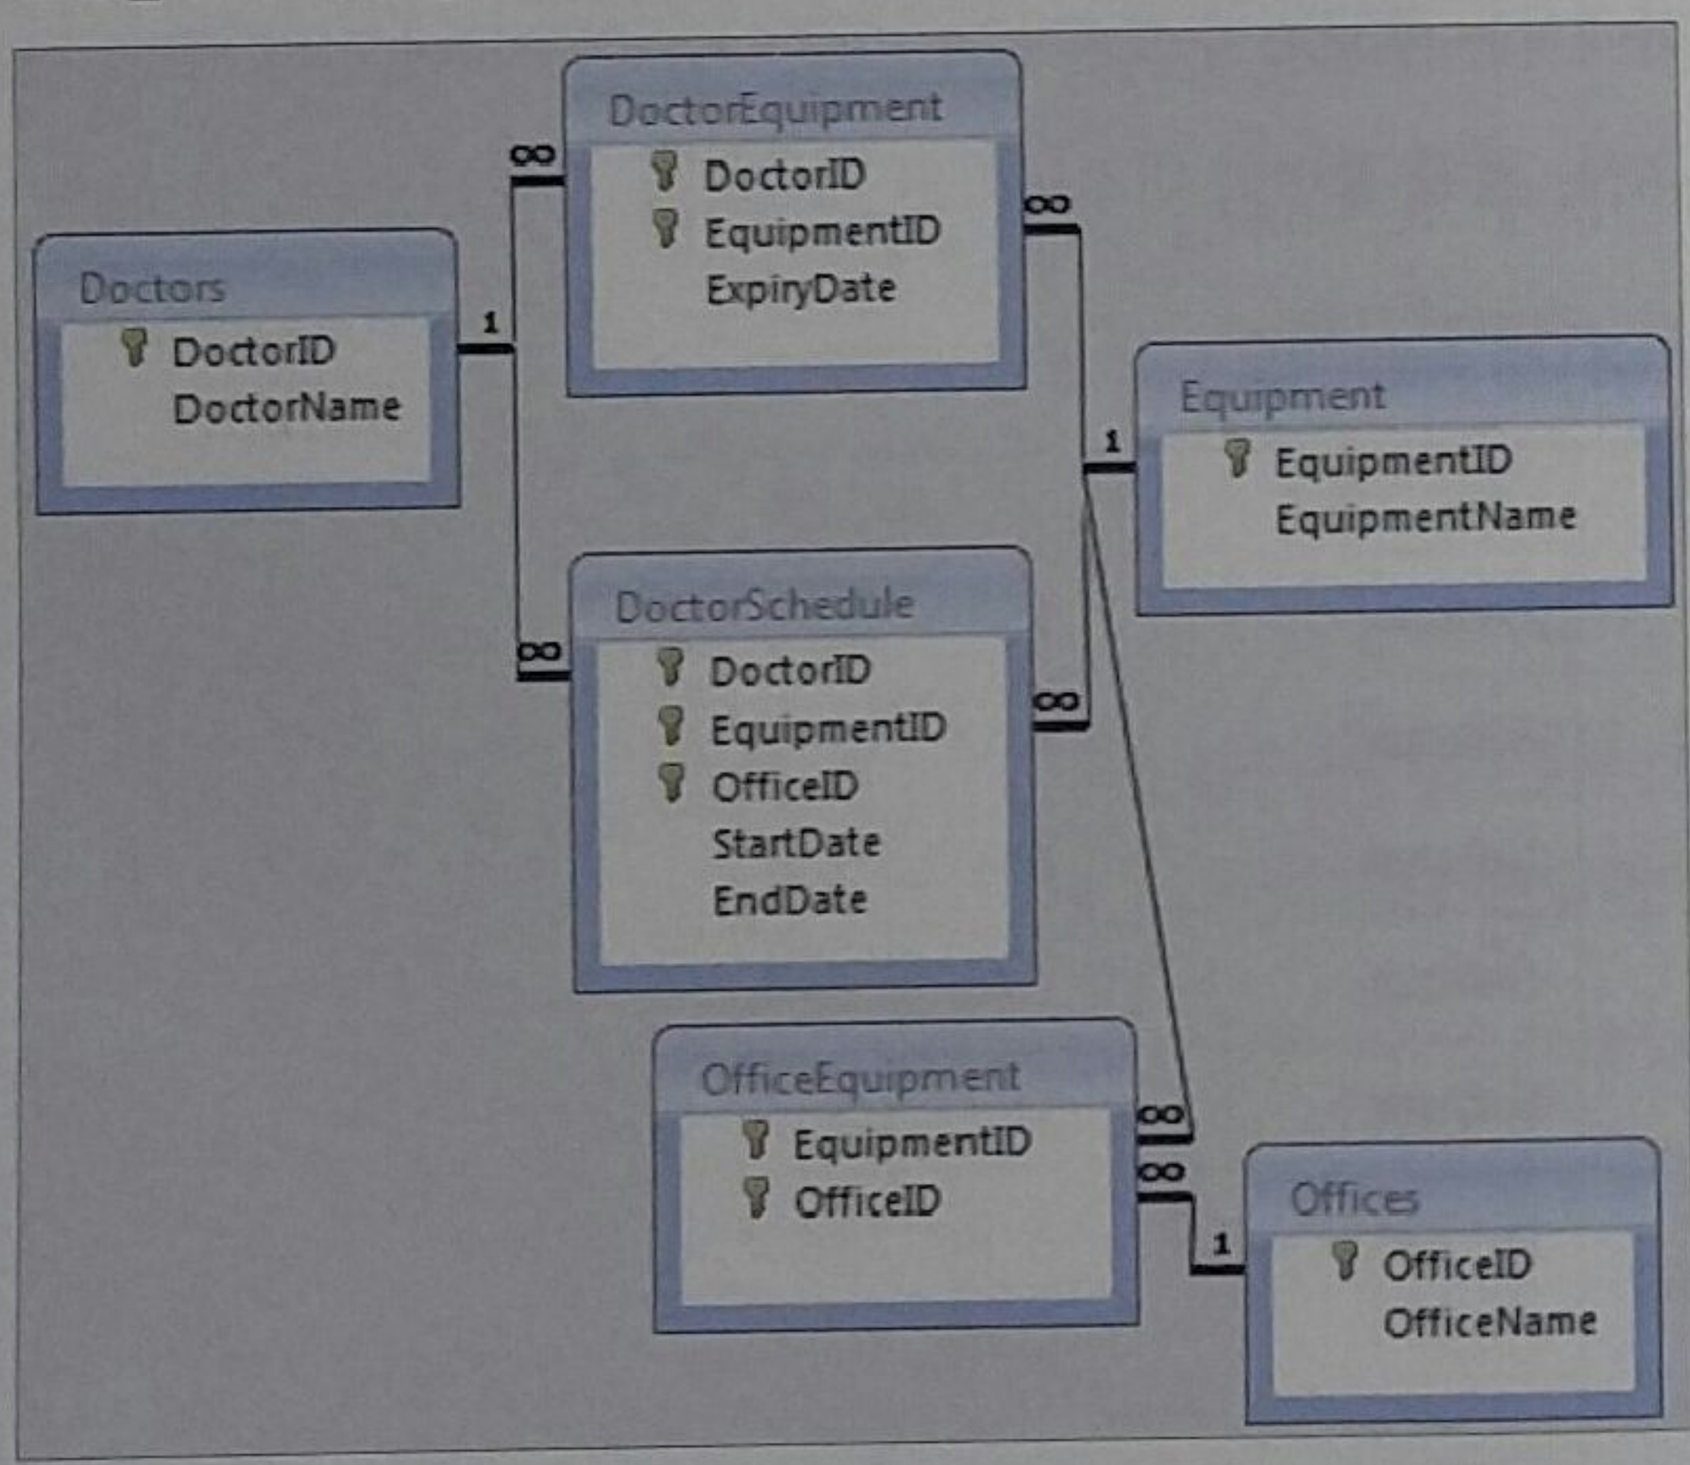

주요 테이블 세 개(Doctors, Equipment, Offices)와 이들을 쌍으로 연결한 연결 테이블(Doctors와 Equipment를 연결한 DoctorEquipment, Offices와 Equipment를 연결한 OfficeEquipment, 암시적으로 Equipment와 함께 Doctors

와 Offices를 연결한 DoctorSchedule)을 만들었다. 따라서 새 검사실이 생기거나 기존 검사실에 새 장비가 들어오거나 의사가 받는 교육 내용이 바뀌더라도 이 요소는 모두 독립적이며, 각 쌍 간에 이상은 발생하지 않는다. 하지만 DoctorSchedule 테이블은 이상이 발생할 위험이 있다. 의사가 해당 장비 사용에 필요한 교육을 받지 못했거나 검사실에 장비가 부족하다면 의사와 검사실을 한 쌍으로 하는 테이블을 만들 수는 있지만, 이것은 문제가 있고 제5 정규화를 위반한다. 이 문제는 그림 1-12와 같은 데이터 모델을 만들어 바로 잡을 수 있다.

그림 1-12 의사 · 장비 · 검사실 예약 데이터베이스의 개선된 스키마 다이어그램

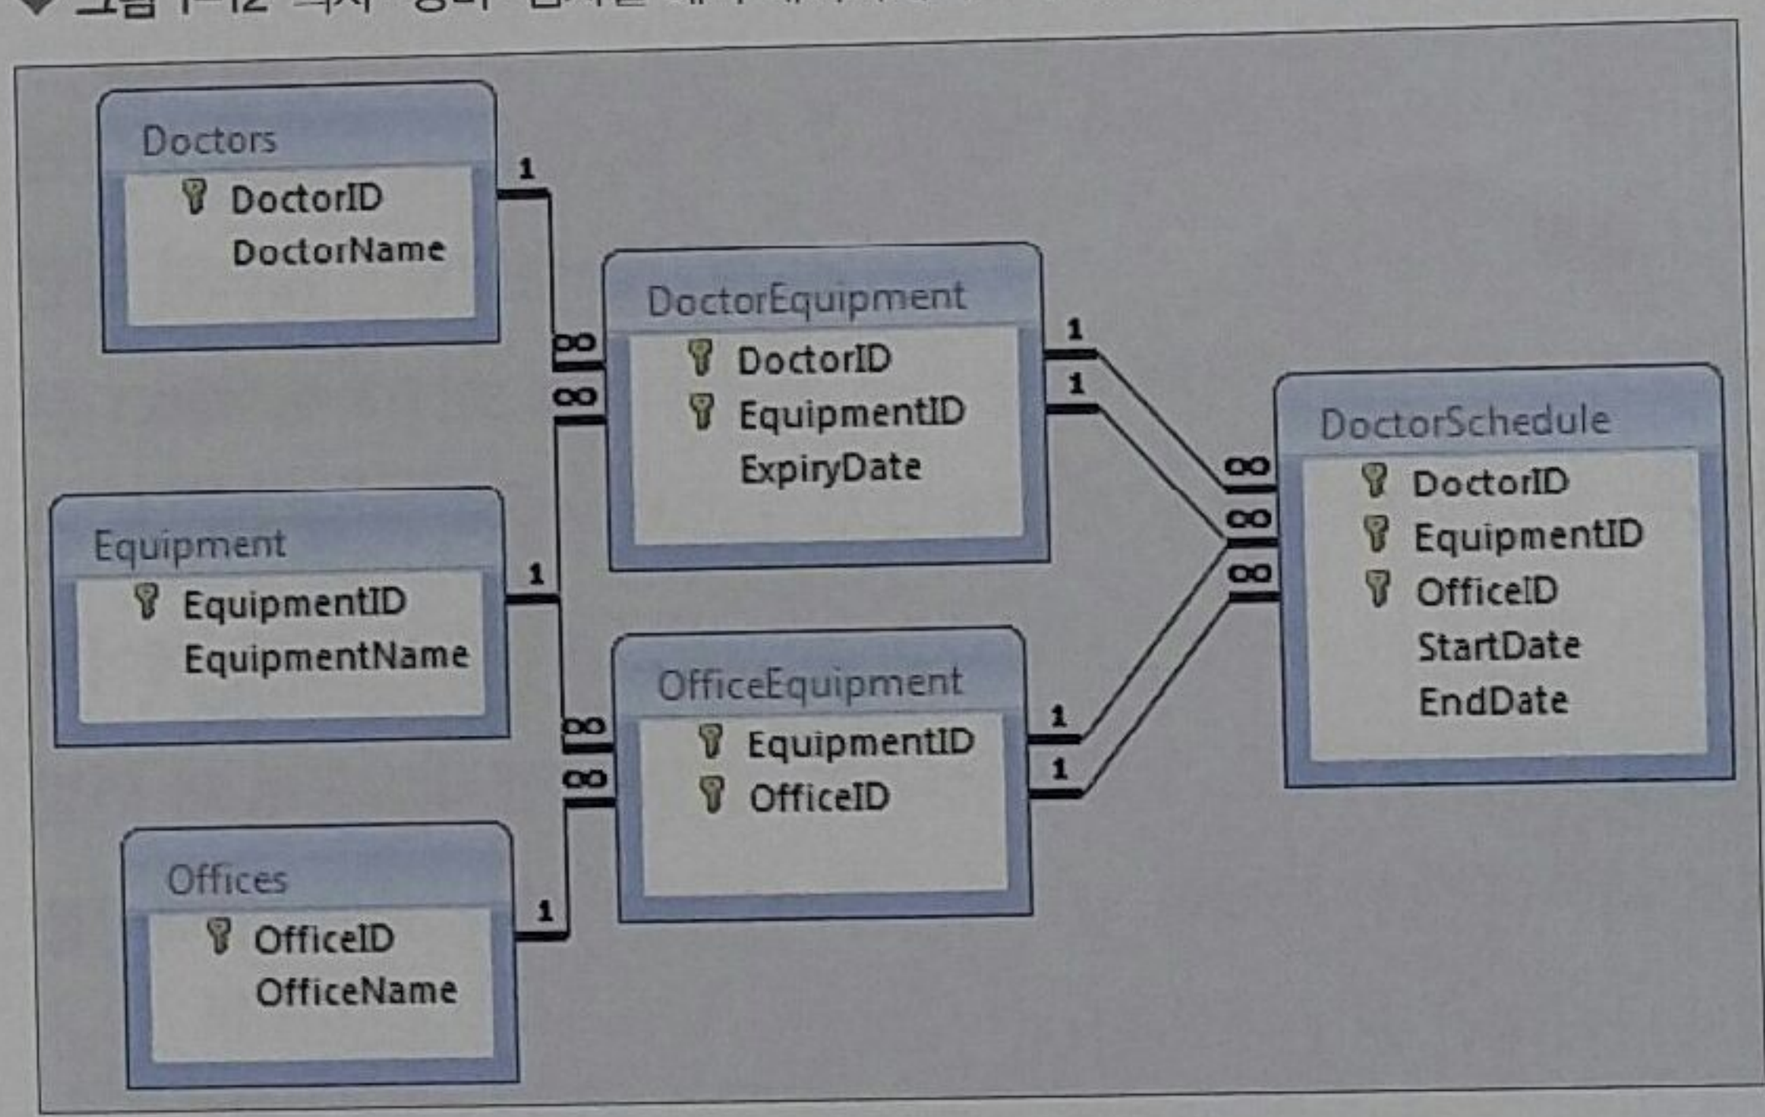

DoctorSchedule 테이블의 EquipmentID 컬럼과 부분적으로 겹치는 외래키가 두 개 있다는 점에 주목하자. 이 두 외래키 제약 조건은 어느 특정 장비에서는 유효한 의사와 검사실 조합만 선택할 수 있도록 보장해 프로그래밍 로직을 작성하지 않아도 되므로 데이터 이상을 방지한다. 여기서 테이블 설계를 변경하지 않은 점에 주목하자. 단지 관계만 변경했을 뿐이다.

다시 강조하지만 DoctorSchedule 테이블에 EquipmentID 컬럼이 필요하지 않

았다면 그림 1-11의 스키마는 이미 제5정규화가 되었을 것이다. 따라서 예약 과정의 일부로 의사가 장비에 배정되었는지 확인하지 않고 의사를 검사실에 예약하기만 해도 되면, 그림 1-11의 첫 번째 스키마로도 충분할 것이다.

예제에서는 복합키를 사용한다는 점에 주목하자. 연결 테이블 OfficeEquipment와 DoctorEquipment에서 대리키를 생성했다면 EquipmentID 컬럼이 모호해졌을 것이므로 그림 1-12 모델에는 반영할 수 없었다. 따라서 기본 값으로 대리키를 사용한다면 해당 키가 스키마에 있는 핵심 정보를 잠재적으로 숨기는지 반드시 조사해야 한다. 다대다 관계에 참여하는 모든 외래키에 주목하고 분석해서 이들이 해당 관계에 어떤 영향을 주는지 확인해야 한다.

더 높은 정규화 형식을 위반하는지 분석할 때 사용할 수 있는 방법 중 하나는 바로 무손실 분할(Lossless Decomposition)이다. 테이블에 컬럼이 많으면 일련의 부분 집합으로 분할해야 한다. 이들 부분 집합에 대해 SELECT DISTINCT 문을 수행한 후 LEFT OUTER JOIN을 사용해 다시 조인한 결과가 원래 테이블 결과와 동일한지 확인한다. 분할한 테이블을 조인으로 재결합한 결과, 데이터 손실이 없다면 원본 테이블은 일부 정규화 형식을 위반한 것이므로 더 면밀히 조사해서 데이터 이상 문제를 일으키는지 파악해야 한다. 표 1-3 테이블을 분할해서 나타내면 표 1-5와 같다.

❤ 표 1-5 표 1-3을 분할한 테이블

판매원	제조사
Jay Ajurap	Acme
Jay Ajurap	Ace
Sheila Nyu	A-Z Inc.

제조사	제품
Acme	Slicer
Acme	Dicer
Ace	Dicer
Ace	Whomper
A-Z Inc.	Slicer
A-Z Inc.	Whomper

제4정규화와 제5정규화 위반 예로 돌아가 보자. 표 1-3에서 로우 하나를 꺼내면 SalespeopleManufacturers와 ManufacturerProducts 테이블을 조인했을 때 데이터 손실이 발생한다. 표 1-5의 테이블들을 조인한 결과와 수정된 표 1-3의 테이블 데이터가 일치하지 않기 때문이다. 이때 수정된 표 1-3의 테이블은 더 이상 제4정규화를 위반하지 않는다. 마찬가지로 EquipmentID가 DoctorSchedule 테이블의 컬럼이 아니라면 다시 데이터 손실이 발생하므로 제5정규화를 위반하지 않는다.* 이 분석에서는 데이터 손실이 발생하는지 제대로 파악하려고 분할할 테이블에 충분한 데이터가 있다고 가정했다.

핵심 정리

- 대부분의 데이터 모델에는 이미 더 높은 정규화가 적용되어 있을 가능성이 높다. 따라서 더 높은 정규화 형식을 명확히 위반하는지 면밀히 관찰해야 한다. 특히 복합키를 사용하거나 여러 다대다 관계에 참여하는 테이블일 때는 더욱 그렇다.
- 한 엔터티에서 관계가 없는 두 속성으로 가능한 모든 조합을 해당 엔터티에 열거해야 하는 특수한 경우에는 제4정규화를 위반할 수 있다.
- 제5정규화는 후보키가 모든 조인 의존성을 함축하는지 확인하는 것이다. 즉, 개별 요소에 근거해 후보키에 유효한 값이 무엇인지 제약할 수 있어야 한다는 말이다. 이것은 키가 복합키일 때만 발생한다.
- 제6정규화는 일반적으로 관계를 키가 아닌 속성 하나로만 줄이는 것이다. 따라서 테이블 개수가 급격히 늘어나지만 널 허용 컬럼을 정의할 필요가 없다.
- 무손실 분할 테스트는 해당 테이블이 더 높은 정규화 형식을 위반하는지 감지하는 효과적인 도구가 될 수 있다.

---

* 실제로 그림 1-12 스키마의 모든 필드가 널을 허용하지 않는다면 이미 제6정규화가 된 것이다.

BETTER WAY 9 데이터 웨어하우스에는 역정규화를 사용하자

개발자에게 정규화된 데이터베이스의 중요성은 아무리 강조해도 지나치지 않는다. 일반적으로 정규화된 테이블은 비정규화된 테이블에 비해 컬럼의 개수가 적고 저장 공간도 많이 차지하지 않는다. 데이터가 여러 테이블에 분산되어 테이블이 버퍼에 들어갈 만큼 작으므로 대개 성능은 좋아진다. 또 데이터가 단일 공간에 있으므로 갱신과 삽입도 빠르게 수행된다. 중복된 데이터가 없으니 GROUP BY 절이나 DISTINCT 쿼리 사용이 줄어든다.

하지만 이것은 논쟁 거리가 될 수 있다. 일반적으로 애플리케이션은 쓰기 작업이 많아서 읽기보다는 쓰기에 부하가 더 걸리기 때문이다. 그럼에도 데이터 웨어하우스 시스템은 이런 예에 포함되지 않는다. 데이터 로드가 일어나는 동안 쓰기 부하는 없을 것이고, 있다 해도 읽기 부하에 비하면 훨씬 덜하다. 완전하게 정규화된 테이블에서 정규화된 데이터는 테이블 간 조인을 의미한다는 문제가 있다. 조인이 많을수록 옵티마이저가 최적의 실행 계획을 찾기가 어려워 읽기 성능은 떨어질 수 있다.

역정규화된 데이터베이스는 읽기 작업이 많을 때도 잘 작동한다. 데이터가 소수의 테이블에 있으므로 필요한 조인 횟수가 적거나 아예 없어서 SELECT 속도가 빠르기 때문이다. 필요한 데이터를 담은 단일 테이블을 사용하면 인덱스를 훨씬 효율적으로 사용할 수 있다. 적절한 컬럼에 인덱스를 만들었다면, 테이블 전체를 직접 읽지 않고 인덱스만으로 원하는 데이터를 빠르게 걸러 내고 정렬할 수 있다. 또 데이터 쓰기 작업이 빈번하지 않으므로 너무 많은 인덱스가 쓰기 성능에 심각한 영향을 줄까 걱정하지 않아도 된다. 필요하다면 테이블에 있는 모든 컬럼에 인덱스를 만들어서 조회와 정렬 성능을 크게 높일 수도 있다.

효과적으로 역정규화하려면 데이터를 잘 파악하고, 데이터를 어떤 식으로 조회하는지 알아야 한다.

가장 쉬운 역정규화 방법은 테이블에 있는 IDENTITY 필드를 복제해 조인을 없애는 것이다. 예를 들어 정규화된 데이터베이스에서 고객을 회계 관리자와 연결하려고 Customers 테이블에 EmployeeID 컬럼을 외래키로 만들었다고 하자. 회계 관리자 데이터를 포함해 청구서 정보를 조회한다면 테이블을 세 개(Invoices, Customers, Employees) 조인해야 한다. 하지만 Invoices 테이블에 EmployeeID 컬럼을 두면 Invoices와 Employees 테이블만 조인한다. 물론 Customers 테이블에 있는 다른 데이터도 조회해야 한다면 다시 세 테이블을 조인한다.

이런 종류의 역정규화를 한 단계 더 진행할 수도 있다. 예를 들어 데이터 웨어하우스 시스템에서는 고객 이름으로 청구서 정보를 많이 검색한다는 사실을 알았다면, Invoices 테이블에 CustomerID뿐만 아니라 고객 이름도 저장하고 인덱스까지 만들어 놓으면 좋을 것이다. 물론 이렇게 하면 한 테이블에 여러 주제(청구서와 고객)와 관련된 정보를 저장하고, 고객 이름을 많은 로우에 반복해서 저장하므로 정규화 규칙을 위반하게 된다. 하지만 데이터 웨어하우스 시스템의 주 목적은 정보를 신속하고 쉽게 찾는 것이므로, 고객 이름 정보를 가져올 때 조인을 피할 수 있다면 엄청난 자원을 절약하는 효과를 볼 수 있다.

또 다른 일반적 접근 방법은 다른 테이블을 가리키는 필드를 추가하는 것이다. 이렇게 하면 성능이 향상될 뿐만 아니라 이력 정보를 관리하는 데도 도움이 된다. 완전히 정규화된 스키마는 보통 현재 상태만 보여 준다. 고객의 현 주소는 Customers 테이블에 저장되어 있다. 고객이 이사하면 이전 주소가 새 주소로 바뀐다. 고객의 주소 이력 정보를 관리하지 않는다면 나중에 이전 청

구서의 정확한 사본을 출력하기는 불가능하다. 하지만 Invoices 테이블에 청구한 시점의 고객 주소 정보를 복사해 보관한다면 정확한 청구서 정보를 가져올 수 있다.

흔히 사용되는 또 다른 역정규화 방법은 계산된 값이나 파생 값을 저장하는 것이다. InvoiceDetails 테이블의 각 로우에 있는 청구서 금액을 더하는 대신 Invoices 테이블에 총 청구서 금액 정보를 저장한다면, 조회 대상 테이블의 개수도 줄어들고 반복적인 계산도 없앨 수 있다. 계산된 값을 저장하면 임의의 계산을 수행하는 방법이 여러 개일 때 이점이 있다. 값을 테이블에 저장해 놓으면 해당 데이터베이스에 대한 쿼리는 계산 결과가 모두 동일하다.

가능한 다른 방법은 반복 그룹을 사용하는 것이다. 월간 성능을 비교하는 일이 많다면 단일 로우에 12개월 정보를 저장해 조회 대상 로우의 개수를 줄일 수 있다.

데이터 웨어하우스 시스템에서는 데이터 분할 및 분석 방법에 대한 요구 사항이 다양하다는 점을 기억하자. 데이터 웨어하우스 전문가인 랄프 킴벌은 데이터 웨어하우스에서 중요한 주제 세 가지로 드릴 다운(Drill-Down), 드릴 어크로스(Drill-Across), 핸들링 타임(Handling Time)을 꼽았다.* 그는 팩트(Fact) 테이블을 '기업의 기본적인 측정치 데이터'이자 '대부분의 데이터 웨어하우스 쿼리의 궁극적 대상'으로 설명하면서 "긴급한 비즈니스 우선순위를 반영하고, 데이터의 품질을 주의 깊게 검수하며, 데이터를 그루핑하고 제한하는 수많은 진입점을 제공하는 디멘젼(Dimension) 테이블을 두지 않는 한 실효성은 미미하다."라고 지적했다.**

---

* http://www.kimballgroup.com/2003/03/the-soul-of-the-data-warehouse-part-one-drilling-down/)

** http://www.kimballgroup.com/2008/11/fact-tables/

그는 팩트 테이블의 유형을 다음 세 가지로 분류한다.

1. **트랜잭션 팩트 테이블** : 단일 시점에 측정된 데이터를 담은 테이블
2. **주기적 스냅샷 팩트 테이블** : 재무 보고 기간처럼 미리 정의된 시간 동안 또는 그 마지막 시점의 데이터를 요약한 테이블
3. **누적 스냅샷 팩트 테이블** : 주문 처리, 클레임 처리, 서비스 콜 처리, 대학 입학 등 시작과 끝 시점이 잘 정의된 예측 가능한 프로세스 데이터를 담은 테이블

킴벌이 소개한 또 다른 핵심 개념은 느리게 변경되는 디멘젼 테이블이다. 그가 한 설명에 따르면 팩트 테이블에 저장되는 대부분의 기본적인 측정 데이터는 타임스탬프와 날짜 디멘젼 테이블에 연결되는 외래키를 포함하는데, 단순한 활동 기준(Activity-based) 타임스탬프보다 시간이 더 많은 영향을 미친다. 고객, 제품, 서비스, 기간, 위치, 임직원 등 기본 엔터티를 비롯해 팩트 테이블과 연결되는 다른 디멘젼 테이블도 모두 시간 경과의 영향을 받는다. 때때로 개정된 설명은 데이터에 있는 오류를 바로잡는 역할만 하지만, 고객이나 제품 같은 특정 디멘젼 항목과 관련된 설명을 개정한 시점에 일어나는 실제 변경을 나타내기도 한다. 이런 변경은 팩트 테이블의 측정 데이터보다는 훨씬 드물게 발생하기 때문에 느리게 변경되는 디멘젼(Slowly Changing Dimension, SCD)이라고 한다.* 효율적이고 효과적인 데이터 웨어하우스를 설계하려면 이 개념을 반드시 이해해야 한다.

데이터를 역정규화하기로 결정했다면 역정규화한 내용을 문서로 잘 정리해 두어야 한다. 역정규화에 숨어 있는 로직과 처리한 단계를 자세히 기술하자. 그렇게 해야 향후 조직에서 데이터를 정규화할 때 수행 담당자들이 정확한 정보를 이용할 수 있다.

---

* http://www.kimballgroup.com/2008/08/slowly-changing-dimensions/

핵심 정리

- 중복으로 저장할 데이터와 그 이유를 정한다.
- 데이터를 일치된 상태로 유지할 계획을 세운다.
- 역정규화된 필드를 사용하도록 쿼리를 리팩토링한다.

CHAPTER

2

인덱스 설계와 프로그램적 처리

논리적으로 데이터 모델을 잘 설계했다는 이유만으로 효율적인 SQL을 작성할 수 있다고 여기면 안 된다. 물리적으로도 적절한 방식으로 설계를 구현해야 하며, 그렇지 않으면 SQL로 데이터에서 의미 있는 정보를 효율적으로 추출하기가 어렵다.

테이블에 적절한 인덱스를 만들었는지 여부는 SQL 쿼리가 잘 수행되는지 확인하는 핵심 요소 중 하나다. 이 장은 올바르게 설계된 데이터 모델을 구현할 때 종종 간과하기 쉬운 내용을 이해하는 데 초점을 맞추었다. 테이블과 인덱스 생성은 데이터베이스 관리자(DBA)의 몫이지만, 인덱스 생성은 개발자가 수행하는 것이 최선이다. 데이터베이스 관리자는 스토리지 시스템 구성과 하드웨어 설정에 풍부한 지식이 있다. 그렇지만 인덱스를 적절히 만드는 문제는 수행되는 쿼리와 대상 데이터에 지식이 필요하다. 보통 데이터베이스 관리자나 외부 컨설턴트는 이런 지식을 습득하기가 힘들지만, 애플리케이션 개발자는 쉽게 알 수 있다. 이 장에서는 인덱스의 중요성을 이해하고, 인덱스를 적절히 구현하는 방법을 이해할 것이다.

'1장. 데이터 모델 설계'에서 다루었듯이 데이터베이스 구현에 직접 관여할 수 있다면, 이 장에서 소개하는 내용을 토대로 여러분이 설계한 모델을 검토한 후 문제점을 찾아 수정할 수 있을 것이다. 데이터 모델 설계에 관여할 수 없다면, 이 장을 학습한 후 데이터베이스를 효율적으로 구축하는 데 필요한 정보를 데이터베이스 관리자에게 제공할 수 있을 것이다.

BETTER WAY 10 인덱스를 만들 때는 널을 고려하자

관계형 데이터베이스에서 널은 '미지의 값', 달리 말하면 컬럼에 데이터가 들어 있지 않음을 나타내는 특별한 값이다. 널은 다른 값, 심지어 또 다른 널과도 동등이나 비동등 연산자로 비교가 불가능하다. 널 값이 있는지 알아내려면 IS NULL 연산자를 사용해야 한다.

대개 WHERE 절의 조건에 자주 사용되는 컬럼 또는 컬럼의 조합에 인덱스를 만들어서 쿼리 성능을 향상시킨다. 컬럼에 인덱스를 만들 때 해당 컬럼 값이 널인지, 데이터베이스 시스템이 인덱스로 생성된 컬럼의 널 값을 어떻게 처리하는지 고려해야 한다.

인덱스로 생성된 컬럼 값이 대부분 널이라면 항상 NULL이 아닌 값을 조회하지 않는 한 해당 인덱스는 많이 사용하지 않을 것이다. 데이터베이스 시스템이 인덱스에서 널을 제외하는 방법을 제공하지 않는다면 인덱스는 저장 공간만 심각하게 낭비할 뿐이다. 일부 데이터베이스 시스템은 빈 문자열을 널로 처리하므로(이런 시스템은 컬럼 값으로 들어온 빈 문자열을 NULL로 변경해 버린다), 컬럼에 인덱스를 만들지 여부를 결정하기가 더 어렵다.

데이터베이스 시스템마다 인덱스에 있는 널 값을 처리하는 방식이 다르다. 모든 주요 데이터베이스 시스템의 공통적인 특성은 기본키에 속한 컬럼에 널

값을 허용하지 않는다는 것이다. 이것은 ISO SQL 표준이라면 당연하다. 지금부터는 각 데이터베이스 시스템과 관련된 내용, 각 인덱스에 있는 널 값과 길이가 0인(Zero-length) 문자열(빈 문자열)을 처리하는 방식을 살펴본다.

DB2

DB2는 기본키를 제외한 모든 인덱스에서 널 값을 인덱스 처리한다. 코드 2-1과 같이 인덱스를 만들 때 EXCLUDE NULL KEYS 옵션을 명시하면 유일(UNIQUE) 인덱스에서 명시적으로 널 값을 제거할 수 있다.

코드 2-1 DB2에서 UNIQUE 인덱스에 널 값 제외 처리

```
CREATE UNIQUE INDEX ProductUPC_IDX
  ON Products (ProductUPC ASC)
  EXCLUDE NULL KEYS;
```

인덱스의 본래 목적에 맞게 DB2는 모든 널 값이 동일하다고 여긴다. 따라서 유일 인덱스에 WHERE NOT NULL을 명시하지 않은 채 인덱스 컬럼에 널 값을 가진 로우를 두 개 이상 입력하면 중복 값 오류가 발생한다. 널 값을 가진 두 번째 로우는 중복된 값으로 인식되며, 유일 인덱스는 중복 값을 허용하지 않는다.

DB2에서는 비유일(Nonunique) 인덱스에 EXCLUDE NULL KEYS 옵션을 추가하면 널 값이 인덱스에 저장되지 않는다. 이것은 인덱스 컬럼 대다수의 값이 NULL일 때 특히 유용하며, 인덱스에 NULL이 없으므로 조건절에서 IS NULL 조건을 검사할 때 인덱스 대신 테이블 전체를 스캔한다. 인덱스에서 널 값을 제거하면 인덱스 저장 공간을 절약할 수 있다.

코드 2-2 DB2에서 표준 인덱스에 있는 널 값 제외 처리

```
CREATE INDEX CustPhone_IDX
  ON Customers (CustPhoneNumber)
  EXCLUDE NULL KEYS;
```

DB2는 VARCHAR와 CHAR 타입 컬럼에 있는 빈 문자열을 널 값으로 처리하지 않는다. 하지만 LUW(리눅스, 유닉스, 윈도우)용 DB2에서 오라클 호환 옵션을 설정하면 VARCHAR 타입 컬럼에 들어오는 빈 문자열을 널 값으로 저장한다. 더 자세한 내용은 '오라클' 부분에서 소개한다.

액세스

액세스는 인덱스로 널 값을 가질 수 있다. 기본키는 널 값을 포함할 수 없으므로 기본키 컬럼에는 NULL을 저장할 수 없다. 인덱스의 Null 무시 속성을 설정하면 인덱스에 널 값을 저장하지 않는다. 그림 2-1은 사용자 인터페이스(UI)에서 인덱스를 정의할 때 이 속성을 지정하는 모습을 보여 준다. 그림에서 고유(Unique) 속성과 기본(Primary) 속성을 지정하는 콤보박스도 볼 수 있다.

그림 2-1 액세스 UI에서 인덱스 기본, 고유, Null 무시 속성

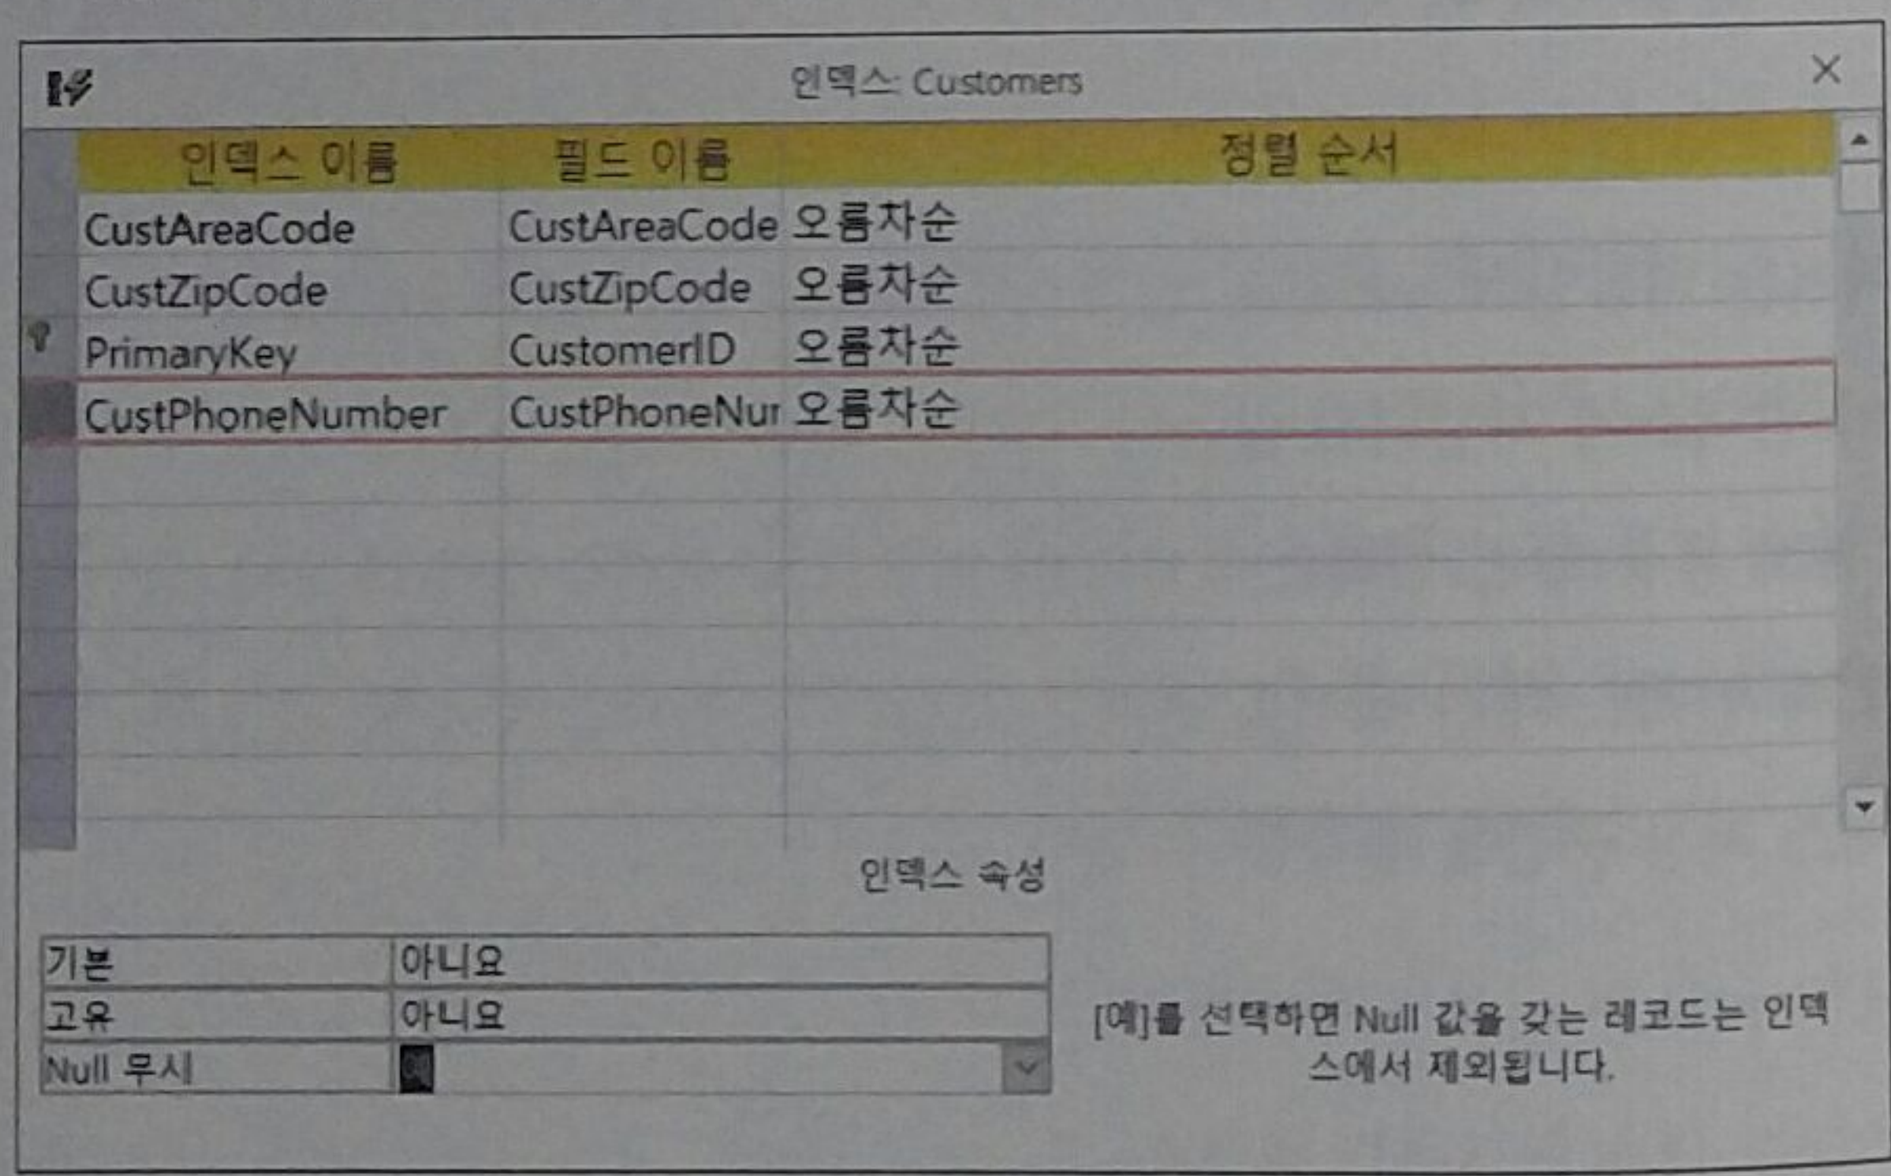

CREATE INDEX 구문에서는 WITH IGNORE NULL을 붙이면 널 무시 속성을 설정할 수 있는데, 방법은 코드 2-3과 같다.

코드 2-3 액세스에서 SQL로 인덱스를 만들 때 IGNORE NULL 설정

```
CREATE INDEX CustPhoneIndex
  ON Customers (CustPhoneNumber)
  WITH IGNORE NULL;
```

또 WITH DISALLOW NULL(이 옵션은 해당 컬럼의 필수(Required) 속성을 '예(Yes)'로 지정하지 않으면 UI로 설정할 수 없다)을 명시하면 인덱스에 널 값이 들어가는 것을 방지할 수 있다.

액세스는 모든 널 값을 동일하지 않다고 처리하므로 유일 인덱스 컬럼에도 NULL을 가진 로우를 여러 개 저장할 수 있다. 액세스에서 유별난 점은 Text 타입(VARCHAR와 동일)의 컬럼에 있는 값 끝에 붙은 공백을 자동으로 제거한다는 것이다. 따라서 UI에서 빈 문자열을 저장하면 액세스는 NULL을 저장한다. 기본키 컬럼에 빈 문자열을 저장하면 오류가 발생할 것이다.

마찬가지로 필수 속성이 '예'로 설정된 컬럼에 빈 문자열을 입력해도 오류가 발생하는데, 빈 문자열 허용(Allow Zero Length) 속성을 '예'로 설정하면 이 오류를 방지할 수 있다. 이렇게 설정하면 액세스는 빈 문자열을 NULL로 변환하지 않지만, UI나 SQL에서 여러분이 직접 빈 문자열을 큰따옴표로 감싸 입력해야 한다. 빈 문자열 허용 속성을 '예'로 설정한 컬럼에 빈 문자열을 입력하면 컬럼 값의 길이는 0이 된다.

SQL Server

DB2와 비슷하게 SQL Server는 인덱스에 널 값 입력이 가능하고 모든 널 값을 동일하다고 여긴다. 기본키 컬럼에는 NULL을 저장하지 못하며, 유일키

컬럼에는 널 값을 하나만 저장할 수 있다.

인덱스에서 널 값을 제외하려면 필터링된 인덱스(Filtered Index)를 만들어야 하는데, 방법은 코드 2-4와 같다.

코드 2-4 SQL Server에서 필터링된 인덱스에 널 값 제외 처리

```
CREATE INDEX CustPhone_IDX
  ON Customers (CustPhoneNumber)
  WHERE CustPhoneNumber IS NOT NULL;
```

쿼리에서 CustPhoneNumber 컬럼에 IS NULL 조건을 제시하면 SQL Server는 해당 조건 검색을 수행할 때 이 필터링된 인덱스를 사용하지 않을 것이다. SQL Server는 빈 VARCHAR 타입 문자열을 NULL로 변환하지 않는다. 코드 2-4의 필터링된 인덱스 예제에서는 CustPhoneNumber 컬럼에 빈 문자열이 포함되어 있어도 인덱스를 만들 수 있는데, 빈 문자열은 NULL이 아니기 때문이다.

MySQL

MySQL은 기본키 컬럼에 널 값을 허용하지 않지만, 인덱스를 만들 때는 모든 널 값이 동일하지 않다고 처리한다. 따라서 널 값이 있는 컬럼에 유일 인덱스를 만들 수 있고, 이 컬럼을 포함한 로우도 여러 개 저장할 수 있다.

MySQL은 인덱스에 널 값을 허용하므로 널 값을 제거하는 옵션이 없다. MySQL에서는 IS NULL과 IS NOT NULL 조건을 검사할 때 인덱스가 있으면 사용한다.

그리고 빈 문자열을 NULL로 변환하지 않는다. NULL 길이를 반환한 결과는 NULL이고, 빈 문자열 길이는 0이다.

오라클

오라클은 인덱스에 널 값을 허용하지 않고, 기본키 컬럼에도 널 값을 넣을 수 없다. 여러 컬럼으로 된 복합키에 NULL이 아닌 컬럼이 하나라도 있으면 인덱스를 만드는 것이 가능하다.

복합키를 구성하는 컬럼의 하나로 상수 값을 포함하거나 NULL을 처리할 수 있는 함수 기반 인덱스로 널 값을 인덱스에 사용하도록 강제할 수 있다. 코드 2-5는 널 값을 가질 수 있는 컬럼을 포함하는 복합 인덱스에 상수 값을 추가하는 방법을 보여 준다.

코드 2-5 가상의 복합키로 오라클이 인덱스에 널 값을 허용하도록 처리

```
CREATE INDEX CustPhone_IDX
  ON Customers (CustPhoneNumber ASC, 1);
```

NVL() 함수를 사용하면 널 값을 다른 값으로 대체할 수 있는데, 방법은 코드 2-6과 같다.

코드 2-6 널 값을 변환해 인덱스 생성

```
CREATE INDEX CustPhone_IDX
  ON Customers (NVL(CustPhoneNumber, 'unknown'));
```

NVL() 함수로 인덱스를 만들면 널 값을 검사할 때 반드시 NVL() 함수를 사용해야 한다는 단점이 생긴다(예를 들어 WHERE NVL(CustPhoneNumber, 'unknown') = 'unknown').

액세스와 마찬가지로 오라클은 길이가 0인 VARCHAR 문자열을 NULL과 동일하게 인식한다. CHAR 타입 컬럼에 빈 문자열을 넣으면 이 컬럼에는 널 값이 아닌 공백이 들어갈 것이다.* 액세스와 다르게 오라클에서는 VARCHAR 타입 컬

* 역주 오라클에서 CHAR 타입 컬럼에도 빈 문자열을 넣으면 널로 인식된다.

럼에 빈 문자열 입력을 허용하는 옵션이 없다. 오라클도 액세스처럼 모든 널 값이 동일하지 않다고 처리하며, 길이가 0인 VARCHAR 문자열을 NULL과 동일하게 인식한다.

PostgreSQL

PostgreSQL은 기본키에 널 값을 넣을 수 없다. MySQL, 액세스와 마찬가지로 모든 널 값이 동일하지 않다고 처리한다. 따라서 유일 인덱스를 만든 후 유일 인덱스 컬럼에 널 값을 여러 개 넣을 수 있다.

PostgreSQL은 인덱스에 널 값을 포함할 수 있지만, 코드 2-7과 같이 WHERE 절에 조건을 정의하는 방식으로 널 값을 제외할 수도 있다.

코드 2-7 PostgreSQL에서 인덱스를 만들 때 널 제외 처리

```
CREATE INDEX CustPhone_IDX
  ON Customers (CustPhoneNumber)
  WHERE CustPhoneNumber IS NOT NULL;
```

SQL Server와 유사하게 PostgreSQL도 길이가 0인 문자열을 NULL이나 그 반대로 자동 변환하지 않으며, 이 둘을 다른 값으로 인식한다.

핵심 정리

- 인덱스로 만들 컬럼에 널 값을 허용할지 고려해야 한다.
- 널 값을 검색하고 싶은데 컬럼 값의 대다수가 NULL이라면, 이 컬럼은 인덱스로 만들지 않는 것이 낫다. 이때는 테이블을 재설계하는 편이 좋다.
- 컬럼에 있는 값을 좀 더 빠르게 검색하고 싶은데 값의 대다수가 NULL이라면, 데이터베이스가 지원하는 한 널 값을 제외하고 인덱스를 만드는 것이 좋다.
- 모든 데이터베이스 시스템은 각기 다른 방식으로 인덱스에 널 값을 넣을 수 있도록 지원한다. 널 값이 포함될 수 있는 컬럼을 인덱스로 만들기 전에 사용 중인 데이터베이스 시스템이 이 기능을 지원하는지 반드시 확인한다.

BETTER WAY 11 인덱스와 데이터 스캔을 최소화하도록 인덱스는 신중히 만들자

하드웨어를 추가해 성능을 향상시킬 수도 있지만, 보통은 쿼리를 튜닝하면 훨씬 적은 비용으로도 탁월한 효과를 낼 수 있다. 흔히 성능 문제는 인덱스가 부족하거나 올바르지 않은 인덱스를 만들어서 발생하기에 데이터베이스 엔진은 쿼리 조건을 만족하는 레코드를 찾는 데 필요 이상으로 많은 데이터를 처리할 가능성이 크다. 이렇게 데이터를 찾는 프로세스는 인덱스 스캔(Index Scan)과 테이블 스캔(Table Scan)으로 나눌 수 있다.

쿼리를 만족하는 레코드를 정확히 짚어 내려고 인덱스를 사용하는 것을 인덱스 탐색(Seek)이라고 하며, 데이터베이스 엔진이 적합한 레코드를 찾으려고 인덱스와 데이터 페이지를 스캔하는 것을 각각 인덱스 스캔, 테이블 스캔이라고 한다. 데이터가 많을수록 인덱스 스캔을 완료하는 데 걸리는 시간은 길다.

코드 2-8의 테이블을 살펴보자.

코드 2-8 SQL을 사용한 테이블 생성

```
CREATE TABLE Customers (
  CustomerID int PRIMARY KEY NOT NULL,
  CustFirstName varchar(25) NULL,
  CustLastName varchar(25) NULL,
  CustStreetAddress varchar(50) NULL,
  CustCity varchar(30) NULL,
  CustState varchar(2) NULL,
  CustZipCode varchar(10) NULL,
  CustAreaCode smallint NULL,
  CustPhoneNumber varchar(8) NULL
);

CREATE INDEX CustState ON Customers (CustState);
```

이 테이블에서 인덱스를 두 개 만든 점에 주목하자. CustomerID를 기본키로 선언했으므로 이 컬럼에 인덱스를 자동으로 만들었고, CREATE INDEX 문으로 CustState 컬럼에도 인덱스를 만들었다.

SELECT * FROM Customers WHERE CustomerID = 1을 실행하면 기본키에서 유일 인덱스 탐색을 한 후 이 인덱스로 Customers 테이블에서 CustomerID = 1인 모든 데이터를 반환한다.

반면에 SELECT CustomerID FROM Customers WHERE CustomerID = 25를 실행하면 필요한 값이 모두 인덱스에 있으므로, 두 번째 단계는 불필요하게 테이블 데이터를 뒤져 보지 않고 유일 인덱스만 탐색할 것이다.

다음으로 SELECT * FROM Customers WHERE CustState = 'TX' 쿼리를 살펴보자. 코드 2-8에서는 CustState 컬럼에 인덱스를 만들었는데, 이 인덱스는 유일 인덱스가 아니다. 따라서 WHERE 조건을 만족하는 모든 값을 찾으려면 인덱스 전체를 뒤져 봐야 한다(인덱스 스캔). 인덱스에 있지 않은 컬럼도 SELECT 리스트에 있기 때문에 이런 값까지 가져오려면 테이블로 돌아가서 데이터를 가져와야 한다.

마지막으로 SELECT CustomerID FROM Customers WHERE CustAreaCode = '905' 쿼리를 보자. CustAreaCode 컬럼에는 인덱스가 없으므로 값을 찾으려면 테이블 스캔을 해야 한다. 즉, 데이터베이스 엔진은 CustAreaCode = '905' 조건에 맞는 데이터를 찾으려면 테이블에서 전체 로우를 뒤져야 한다.

임의의 객체에서 모든 항목을 검색해야 특정 값을 찾을 수 있기 때문에 이때는 테이블 스캔과 인덱스 스캔에 큰 차이가 없어 보인다. 하지만 인덱스는 테이블에 비해 훨씬 작고 특별히 스캔용으로 설계된 객체이므로, 보통 테이블에 있는 소수의 로우만 검색할 때는 인덱스 스캔이 월등히 빠르다. 테이블에서

인덱스가 33% 정도 차지하고 있다면 인덱스를 사용한다고 해서 큰 혜택을 볼 수 없다는 말이다. 하지만 이 값은 정확한 것이 아니며, 빠르게 스캔이 가능한 기준점은 데이터베이스 엔진에 따라 33%보다 높거나 낮을 수 있다.

실제로 테이블 스캔이 더 나은 성능을 보일 때가 있는데, 어느 정도는 반환되는 로우 비율에 의존한다. 대부분은 테이블에 적절한 인덱스를 만드는 것이 낫다. 자세히 알고 싶다면 'BETTER WAY 46. 실행 계획의 작동 원리를 이해하자'를 참고한다.

인덱스가 데이터의 추출 문제를 해결해 주는 만능 해결사라고 여기는 것은 위험한 생각이다. 많은 인덱스가 데이터를 빠르게 가져오지도 않고 데이터 갱신 속도만 느리게 한다. 문제는 인덱스 컬럼 하나를 갱신할 때마다 '인덱스 테이블'을 하나 이상 갱신하게 되며, 이는 더 많은 디스크 읽기와 쓰기가 발생함을 의미한다. 인덱스는 구조화가 매우 잘 되어 있기 때문에 인덱스를 갱신하는 작업은 종종 테이블을 갱신하는 작업보다 비용이 많이 든다.

보통 운영 목적의 테이블은 데이터 갱신 작업이 많으므로 이런 테이블에서는 모든 인덱스를 면밀히 검토해야 한다. 보고서용 테이블이 많은 데이터베이스(데이터 웨어하우스)는 갱신 작업이 많지 않으므로 인덱스 적용에 머뭇거릴 필요가 없다('BETTER WAY 9. 데이터 웨어하우스에는 역정규화를 사용하자'에서 언급했듯이 이런 데이터베이스는 역정규화하기 좋은 후보다). 하지만 인덱스가 만병통치약은 아니다.

여러 DBMS에서 사용하는 가장 흔한 인덱스 유형은 B-tree 인덱스다. 여러 DBMS가 해시, 공간(Spatial) 인덱스 같은 추가 타입이나 다른 특별한 구조의 인덱스를 사용하기는 하지만, B-tree 인덱스가 가장 다재다능해서 많이 사용한다. B-tree 인덱스를 자세히 다루는 것은 이 책의 범위를 넘어서지만

간단히 살펴보자. B-tree는 루트 노드에서 시작해 많은 중간 노드를 거쳐 실제 데이터를 가리키는 수많은 리프 노드를 탐색하는 구조로 되어 있다.

쿼리 성능에 대한 B-tree 인덱스의 기여도는 인덱스 유형에 따라 크게 다르다. 인덱스 유형에는 두 가지, 즉 클러스터 인덱스와 비클러스터 인덱스가 있다. 클러스터 인덱스는 인덱스를 만들 때 명시된 컬럼의 순서대로 테이블의 데이터를 물리적으로 정렬한다. 테이블에 있는 로우를 두 가지 이상의 방식으로 정렬하는 것은 불가능하므로 클러스터 인덱스는 테이블당 하나만 만들 수 있다. 적어도 SQL Server에서는 통상 클러스터 인덱스가 데이터를 직접 포함하는 리프 노드를 가진다. 비클러스터 인덱스는 클러스터 인덱스와 구조가 같지만 다음 두 가지 면에서 다르다.

- 비클러스터 인덱스는 테이블 데이터가 쌓인 물리적인 순서와 다르게 정렬될 수 있다.
- 비클러스터 인덱스의 리프 노드는 데이터를 포함하지 않고 인덱스 키와 데이터를 가리키는 북마크로 구성된다.

> **Note** ≡ 오라클에서 테이블 데이터는 인덱스에 명시된 컬럼에 기초해 정렬되지 않는다. 오라클 옵티마이저는 인덱스가 테이블 데이터의 정렬(클러스터링 팩터)을 얼마나 잘 반영하는지와 관련된 메타데이터를 관리하는데, 실행 계획의 선택에 영향을 준다.

테이블 스캔보다 비클러스터 인덱스 스캔이 더 나은 성능을 발휘하는지 여부는 테이블 크기, 로우의 저장 패턴, 로우의 길이, 쿼리가 반환하는 로우의 비율에 따라 다르다. 흔히 전체 로우 중 최소 10%의 로우가 반환될 때 테이블 스캔이 비클러스터 인덱스보다 나은 성능을 보이기 시작한다. 클러스터 인덱스는 보통 반환되는 로우의 비율이 높을수록 테이블 스캔보다 나은 성능을 발휘한다.

또 다른 중요한 고려 사항은 데이터에 접근하는 방식이다. 보통 WHERE 절에서 사용되지 않는 컬럼을 인덱스로 만들면 큰 혜택을 볼 수 없다. 앞에서 설명했듯이 컬럼의 카디널리티가 낮으면(인덱스 값의 다수가 같은 값일 때) 인덱스의 효과가 미미하다. 인덱스를 사용했지만 테이블에서 최소 비율 이하의 데이터만 읽게 된다면 데이터베이스 엔진은 인덱스를 사용하지 않을 것이다.

게다가 인덱스는 테이블이 클 때만 사용하는 것이 좋다. 데이터베이스 엔진은 대부분 테이블이 작으면 그 데이터를 메모리에 올려놓는다. 데이터가 일단 메모리에 올라오면 여러분이 무슨 작업을 하든 빠르게 데이터를 탐색한다. 여기서 '작다'는 기준은 로우의 개수, 개별 로우의 크기, 페이지에 로드되는 방식과 데이터베이스 서버의 가용 메모리 용량에 의존함을 의미한다.

인덱스를 만들 때는 컬럼의 조합도 중요하다. 대부분의 쿼리에서 특정 컬럼들이 함께 사용된다면 인덱스에 컬럼들을 모두 포함해야 한다. 이들 컬럼에 대해 개별적으로 인덱스를 만든다고 해서 효율적으로 실행 계획을 세울 수 있다고 장담할 수 없다. 여러 컬럼으로 인덱스를 만들 때는 컬럼을 지정하는 순서가 중요하다. 일부 쿼리는 CustLastName 컬럼의 특정 값을 찾고 다른 쿼리는 CustFirstName과 CustLastName의 특정 값을 찾는다면, 인덱스는 CustLastName, CustFirstName 순으로 만들어야 하고(코드 2-9) 그 반대로(코드 2-10) 만들면 안 된다.

코드 2-9 SQL을 이용한 적절한 인덱스 생성

```
CREATE INDEX CustName
  ON Customers (CustLastName, CustFirstName);
```

코드 2-10 SQL을 이용한 적절하지 않은 인덱스 생성

```
CREATE INDEX CustName
  ON Customers (CustFirstName, CustLastName);
```

핵심 정리

- 적절한 인덱스를 만들도록 데이터를 분석해 성능을 향상한다.
- 생성한 인덱스가 실제로 잘 사용되는지 확인한다.

BETTER WAY 12 인덱스를 단순 필터링 이상의 목적으로 사용하자

인덱스는 데이터베이스 내에 있는 독특한 데이터 구조체다. 생성된 각 인덱스에는 별도의 저장 공간이 필요하며, 인덱스화된 테이블 데이터의 복사본이 있어 과잉 데이터를 저장한다. 하지만 이런 과잉 데이터는 수용할 만하다. 인덱스는 테이블의 모든 로우를 매번 검색하지 않고도 데이터 위치를 빠르게 찾아서 테이블에 있는 데이터를 가져오는 속도를 향상하기 때문이다. 이런 인덱스는 여러 면에서 매우 유용하다.

SQL 문에서 검색 조건은 WHERE 절에 기술하는데, 여기서 데이터를 빠르게 찾는다는 인덱스의 핵심 목적이 진가를 발휘한다. 느린 쿼리의 첫 번째 범인은 제대로 작성되지 않은 WHERE 절이다.

컬럼을 인덱스로 만들었는지 여부는 테이블 간 조인이 얼마나 효율적으로 수행되는지에 영향을 미친다. 요컨대 조인을 이용하면 정규화된 모델의 데이터를 특정 처리에 적합한 역정규화된 형태로 변환할 수 있다. 조인은 여러 테이블에 분산된 데이터를 결합하므로 여러 페이지에 있는 데이터를 더 많이 읽느라 디스크 탐색 대기 시간에 민감하다. 따라서 적절하게 인덱스를 만드는 것은 조인이 응답하는 시간에 큰 영향을 줄 수 있다.

쿼리를 수행할 때는 일반적으로 세 가지 조인 알고리즘(중첩 루프, 해시 조인, 소트머지 조인)을 사용하는데, 이들은 한 번에 두 테이블만 접근한다는 점에서 비슷하다. SQL이 더 많은 테이블을 조인하는 경우 더욱더 많은 단계

가 필요하다. 먼저 두 테이블을 조인해 중간 결과 집합을 만든 후 이 결과 집합과 다음 테이블을 조인하는 식으로 처리한다.

중첩 루프(Nested Loop) 조인은 가장 기본적인 조인 알고리즘이다. 쿼리 두 개가 중첩되어 있다고 생각하면 쉽다. 선행(Outer)(드라이빙) 쿼리가 한 테이블에서 결과 집합을 가져오고, 두 번째 쿼리는 선행 쿼리 결과 집합의 각 로우에 대응하는 데이터를 다른 테이블에서 가져온다. 따라서 중첩 루프 조인은 조인 조건에 참여하는 컬럼을 인덱스로 만들었을 때 가장 효과가 좋다. 드라이빙 쿼리가 작은 결과 집합을 반환할 때 중첩 루프 조인은 좋은 성능을 보인다. 그렇지 않으면 옵티마이저는 다른 조인 알고리즘을 선택한다.

해시(Hash) 조인은 조인에 참여하는 한쪽 테이블 데이터를 해시 테이블로 만든 후 다른 쪽 테이블의 각 로우를 매우 빠르게 탐색할 수 있다. 해시 조인을 튜닝할 때는 중첩 루프 조인과는 완전히 다른 인덱스 접근 방법이 필요하다. 해시 조인은 해시 테이블을 사용하므로 조인되는 컬럼을 인덱스로 만들 필요가 없다. 해시 조인의 성능을 향상할 수 있는 유일 인덱스는 WHERE 조건절 또는 조인할 때 ON 절에 사용되는 컬럼에 대한 인덱스다. 실제로 해시 조인은 이 두 가지 경우에만 인덱스를 사용한다. 현실적으로 해시 조인의 성능은 수평적(좀 더 적은 로우) 또는 수직적(좀 더 적은 컬럼)으로 해시 테이블의 크기를 줄여서 향상할 수 있다.

소트머지(Sort-merge) 조인은 조인 조건에 따라 두 테이블을 각각 정렬한 후 지퍼처럼 정렬된 두 항목을 결합하는 식으로 수행된다. 소트머지 조인은 많은 점에서 해시 조인과 유사하다. 조인 조건 컬럼만 인덱스로 만드는 것은 소용없고, 한 번에 모든 후보 레코드를 읽을 수 있는 독립적인 조건을 구성하는 컬럼에 대한 인덱스가 필요하다. 조인 순서가 별 의미가 없고 성능에도 영향을 미치지 않는다는 것은 소트머지 조인에만 있는 특징이다. 다른 조인 알고

리즘은 외부 조인의 방향(Left나 Right 조인)이 조인 순서를 결정하는데, 소트머지 조인은 그렇지 않다. 소트머지 조인은 동시에 Left와 Right 외부 조인(Full 외부 조인)이 가능하다. 일단 데이터가 정렬되면 소트머지 조인은 좋은 성능을 발휘하지만, 양쪽 데이터를 정렬하는 비용이 크기 때문에 잘 사용하지 않는다. 하지만 정렬 순서대로 만든 인덱스가 있다면 전체 데이터의 정렬을 피할 수 있어 소트머지 조인이 진가를 발휘한다. 반면에 해시 조인은 한쪽만 미리 처리하면 되므로 많을 때는 해시 조인이 훨씬 낫다.

지금까지 조인 알고리즘을 설명한 내용은 다소 이론적이다. 특정한 조인을 수행하도록 강제로 조정이 가능하기는 하다(SQL Server와 오라클에서는 힌트로 처리). 그러나 쿼리 옵티마이저가 알아서 현재 데이터를 기반으로 가장 적합한 조인 방법을 선택하도록 하고 여러분이 생성한 인덱스가 적절한지 확인하는 편이 훨씬 낫다.

Note ≡ MySQL은 해시 조인과 소트머지 조인을 지원하지 않는다.

인덱스를 사용할 수 있는 또 다른 방법은 데이터 클러스터링이다. 데이터 클러스터링은 연속적으로 접근되는 데이터를 실제로도 인접해서 저장하므로 I/O 연산이 줄어드는 것을 의미한다. 코드 2-11 쿼리를 살펴보자.

코드 2-11 WHERE 절에서 LIKE를 사용한 SQL

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpState = 'WA'
  AND EmpCity LIKE '%ELLE%';
```

EmpCity에 %를 붙인 LIKE 표현식을 쓰면 인덱스를 사용하지 못하므로 테이블 스캔이 필요하다. 하지만 EmpState 컬럼에 대한 조건은 이 컬럼을 인덱스

로 만들기에 적합하다. 읽어야 하는 로우가 단일 테이블 블록에 저장되어 있다면 테이블 접근은 큰 문제가 되지 않는다. 데이터베이스가 읽기 연산 한 번으로 모든 로우를 가져올 수 있기 때문이다. 하지만 동일한 로우가 다른 블록에 분산해서 저장되어 있을 때, 해당하는 로우를 모두 가져오려면 많은 블록을 읽어야 하므로 심각한 문제가 될 수 있다. 다시 말해 해당 로우의 물리적인 분포에 따라 성능은 달라진다.

테이블의 로우를 인덱스 순서에 맞게 재정렬해서 쿼리 성능을 향상할 수 있지만, 이렇게 처리할 수 있는 경우는 드물다. 물리적인 테이블 로우는 단 하나의 순서로만 저장할 수 있어 오직 한 인덱스에서만 테이블을 최적화할 수 있기 때문이다.

코드 2-12의 인덱스는 코드 2-11의 WHERE 절에서 사용한 순서대로 만든 것으로 매우 효과적이다.

코드 2-12 EmpStateName 인덱스 생성

```
CREATE INDEX EmpStateName
  ON Employees (EmpState, EmpCity);
```

데이터를 가져오려고 테이블에 접근하지 않아도 된다면 쿼리를 훨씬 효율적으로 만들 수 있다. 코드 2-13 테이블을 살펴보자.

코드 2-13 Orders 테이블 생성

```
CREATE TABLE Orders (
  OrderNumber int IDENTITY (1, 1) NOT NULL,
  OrderDate date NULL,
  ShipDate date NULL,
  CustomerID int NULL,
  EmployeeID int NULL,
  OrderTotal decimal NULL
);
```

코드 2-14와 같이 고객별로 전체 주문 금액을 가져올 때는 코드 2-15와 같이 필요한 모든 컬럼을 인덱스로 만들어 놓으면 테이블에 접근하지 않아도 된다.

코드 2-14 고객별 전체 주문 금액을 구하는 쿼리

```
SELECT CustomerID, Sum(OrderTotal) AS SumOrderTotal
FROM Orders
GROUP BY CustomerID;
```

코드 2-15 CustOrder 인덱스 생성

```
CREATE INDEX CustOrder
  ON Orders (CustomerID, OrderTotal);
```

Note ≡ 일부 DBMS에서는 데이터가 소량이라면 코드 2-15에서 생성한 인덱스보다 테이블 스캔을 선호한다.

한 가지 알아 둘 점이 있다. 코드 2-14보다 코드 2-16의 쿼리가 더 적은 로우를 가져오므로 빠르게 수행할 것이라고 기대하겠지만 OrderDate가 인덱스 컬럼이 아니므로 테이블 스캔이 선택될 가능성이 더 크다는 것이다.

코드 2-16 WHERE 절을 변경한 쿼리

```
SELECT CustomerID, Sum(OrderTotal) AS SumOrderTotal
FROM Orders
WHERE OrderDate > '2015-12-01'
GROUP BY CustomerID;
```

인덱스는 ORDER BY 절의 효율에도 영향을 미친다. 정렬 작업은 많은 자원이 필요하다. 보통은 CPU 자원을 많이 사용하지만, 진짜 문제는 데이터베이스가 임시로 결과를 버퍼에 담아 둔다는 점이다. 즉, 첫 번째 결과가 반환되기

전에 모든 데이터를 읽어야 한다. 인덱스에는 인덱스 컬럼 데이터가 정렬되어 있다. 실제로 인덱스는 미리 정렬하는 방식으로 데이터를 저장한다. 따라서 인덱스를 사용하면 ORDER BY 절에 명시된 순서대로 데이터를 정렬할 필요가 없다.

메모리 사용량을 줄이려고 파이프라인(중간 결과 집합을 만드는 즉시 각 로우를 다음 조인 연산으로 넘겨 중간 결과 집합을 저장할 필요가 없다)을 사용할 수 있는 조인과 달리, 정렬 작업은 첫 번째 결과 집합을 만들기 전에 완료해야 한다.

인덱스, 특히 B-tree 인덱스는 인덱스로 만든 컬럼의 데이터를 정렬해 둔다. 이것은 인덱스를 사용하면 ORDER BY 절에 명시된 대로 정렬하는 연산을 피할 수 있다는 의미다. 실제로 정렬된 인덱스는 정렬 작업을 줄일 뿐만 아니라 모든 데이터를 처리하지 않고도 첫 번째 결과 집합을 반환할 수 있는 파이프라인 효과를 볼 수 있다. 이런 효과를 내려면 WHERE 절에서 사용할 인덱스 컬럼을 ORDER BY 절에서도 동일한 순서로 사용해야 한다.

데이터베이스는 양방향으로 인덱스를 읽을 수 있다는 점에 유의하자. 이 말은 ORDER BY 절에 명시된 것과는 정반대 방향으로 인덱스 범위를 스캔하더라도 파이프라인 효과를 볼 수 있다는 의미다. 이렇게 하더라도 WHERE 절에 사용된 인덱스의 유용성은 해치지 않는다. 하지만 인덱스를 컬럼 두 개 이상으로 만들 때는 정렬 방향이 중요할 수 있다.

Note ≡ MySQL은 인덱스를 선언할 때 ASC와 DESC를 무시한다.

핵심 정리

- WHERE 절에 사용된 컬럼의 인덱스 유무는 쿼리 성능에 영향을 미친다.

- SELECT 절에 사용된 컬럼의 인덱스 유무 역시 쿼리 성능에 영향을 미칠 수 있다.
- 조인 조건에 사용된 컬럼의 인덱스 유무는 테이블 간 조인 성능에 영향을 미칠 수 있다.
- 인덱스는 ORDER BY 절의 효율에도 영향을 미칠 수 있다.
- 인덱스의 개수는 쓰기 작업에 영향을 미칠 수 있다.

BETTER WAY 13 트리거를 남발하지 말자

대부분의 DBMS는 테이블에 DELETE, INSERT, UPDATE를 수행할 때 자동으로 트리거를 실행하는 기능을 제공한다. 많은 개발자가 길 잃은 데이터를 방지하려고 트리거를 사용하지만, 'BETTER WAY 6. 참조 무결성을 보호하려면 외래키를 정의하자'에 나온 DRI(선언적 참조 무결성)를 사용하는 것이 더 쉽고 빠르며 효율적이다. 트리거는 또한 계산 값을 갱신하는 데도 사용할 수 있는데 'BETTER WAY 5. 왜 계산 데이터를 저장하면 좋지 않은지 이해하자'에서 지적했듯이 더 나은 방법이 있다.

각종 제약 조건을 사용해 DRI를 유지할 수 있다. 제약 조건을 사용하면 데이터베이스 엔진이 자동으로 데이터베이스의 무결성을 강화하도록 할 수 있다. 제약 조건은 컬럼에 허용된 값 규칙을 정의하며 무결성을 강화하는 표준 메커니즘이다. DML(Data Manipulation Language)(데이터 조작 언어) 트리거, 규칙, 기본 값보다 제약 조건을 사용하는 것이 더 낫다. 또 쿼리 옵티마이저는 제약 조건으로 더 나은 성능의 쿼리 실행 계획을 만든다.

INSERT 문에 대한 DRI를 선언할 때 자식 테이블에 새 로우를 입력하면 RDBMS는 입력된 키 값이 부모 테이블에 존재하는지 검사해 해당 키가 없으면 새 로우를 입력할 수 없게 한다. CASCADE(부모 테이블의 데이터를 변경하거나 삭제할 때 자식 테이블에 전파한다), NO ACTION(해당 로우가 참조되고

있으면 키 값 변경을 불가능하게 한다), SET NULL/SET DEFAULT(부모 테이블의 키 값을 변경하거나 삭제하면 자식 테이블의 값을 NULL이나 기본 값으로 설정한다)처럼 UPDATE와 DELETE에도 DRI를 적용할 수 있다.

부모 테이블의 키 값을 삭제해서 자식 테이블의 값이 길을 잃게 하는 것을 방지하려고 DRI를 적용하는 방법이 코드 2-17에 나와 있다(Orders 테이블의 OrderNumber 값이 삭제되면 자식 테이블인 Order_Details의 OrderNumber 값도 삭제된다).

코드 2-17 자식 테이블에서 길 잃은 레코드를 방지하는 DRI 사용

```
ALTER TABLE Order_Details
  ADD CONSTRAINT fkOrder FOREIGN KEY (OrderNumber)
    REFERENCES Orders (OrderNumber) ON DELETE CASCADE;
```

코드 2-18은 이것과 동일한 동작을 하는 트리거를 생성하는 방법이다.

코드 2-18 자식 테이블의 길 잃은 레코드를 방지하는 트리거 생성

```
CREATE TRIGGER DelCascadeTrig
  ON Orders
  FOR DELETE
AS
  DELETE Order_Details
  FROM Order_Details, deleted
  WHERE Order_Details.OrderNumber = deleted.OrderNumber;
```

앞에서 언급했듯이 DRI 접근법은 트리거보다 빠르게 수행되며 더 효율적이다.

BETTER WAY 5에서 설명했듯이 트리거는 자동으로 값을 계산하는 데도 사용할 수 있다. 예를 들어 코드 2-19는 SQL Server에서 Order_Details 테이블 값이 변할 때마다 트리거를 이용해 Orders 테이블의 OrderTotals 컬럼 값을 변경하는 예제이다.

Note ≡ 코드 2-19는 SQL Server용 구문이다. 다른 DBMS용 코드는 https://github.com/gilbutITbook/006882를 참고하자.

코드 2-19 계산 값을 처리하는 트리거 생성

```
CREATE TRIGGER updateOrdersOrderTotals
  ON Orders
  AFTER INSERT, DELETE, UPDATE
AS
BEGIN UPDATE Orders
  SET OrderTotal = (
      SELECT SUM(QuantityOrdered * QuotedPrice)
      FROM Order_Details OD
      WHERE OD.OrderNumber = Orders.OrderNumber
  )
  WHERE Orders.OrderNumber IN(
    SELECT OrderNumber FROM deleted
    UNION
    SELECT OrderNumber FROM inserted
  );
END;
```

Orders 테이블에 계산 컬럼을 정의해 사용하는 간편함('BETTER WAY 5. 왜 계산 데이터를 저장하면 좋지 않은지 이해하자' 참고)과 트리거 작성 코드의 복잡성을 비교해 보고, BETTER WAY 5에서 제시한 해결책이 더 효율적으로 수행된다는 사실을 다시 한 번 되새겨 보자.

많은 데이터베이스 설계 요소와 마찬가지로 동일한 결과를 얻는 방법은 여러 가지다. 트리거는 데이터를 관리하는 한 가지 접근 방법일 뿐 최상의 방법은 아니다. 물론 다음과 같이 트리거를 사용하는 것이 적절할 때도 있다.

- **중복 또는 파생 데이터의 관리** : 역정규화된 데이터베이스는 일반적으로 데이터를 중복으로 저장한다. 트리거로 이런 데이터를 동기화할 수 있다.

- **복잡한 컬럼 제약 조건** : 컬럼의 제약 조건이 동일한 테이블의 다른 로우 또는 다른 테이블의 로우에 의존한다면, 트리거가 이 컬럼의 제약 조건을 유지하는 최상의 방법이다.
- **복잡한 기본 값** : 다른 컬럼, 로우, 테이블에 있는 데이터를 기준으로 기본 값을 생성하는 데 트리거를 사용할 수 있다.
- **데이터베이스 간 참조 무결성** : 관련 테이블을 두 데이터베이스에 나누었다면 트리거로 데이터베이스 간 참조 무결성을 확보할 수 있다.

Note ≡ 이 경우 테이블보다는 뷰에 트리거를 생성하면 좋다. 이렇게 하면 대량의 가져오기(Import)(임포트)/내보내기(Export)(익스포트) 작업을 할 때는 트리거를 작동하지 않고, 애플리케이션에서 데이터를 처리할 때만 트리거를 작동할 수 있기 때문이다.

Note ≡ DBMS별로 제약 조건이나 기본 값을 처리하는 데 제약이 있다. 예를 들어 일부 DBMS는 서브쿼리에서 CHECK 제약 조건을 생성할 수 없는데, 그 대안으로 트리거를 사용해 처리할 수 있다. 트리거 없이 필요한 처리를 할 수 있는지는 관련 DBMS 문서를 참고하자.

액세스 업사이징(데이터 마이그레이션)

흔한 질문 중 하나는 액세스에서 데이터를 업사이징할 때 테이블 관계를 강화하는 데 DRI를 사용해야 할지, 트리거를 사용해야 할지 결정하는 문제다. SQL Server로 변환할 때, 업사이징 마법사의 테이블 속성 내보내기 화면에서 참조 무결성을 강화하는 두 가지 옵션을 선택할 수 있다. 어느 옵션을 사용할지는 액세스에서 만든 테이블 관계에 의존한다.

DRI를 사용하면 액세스의 관계와 참조 정보가 들어 있는 테이블을 SQL Server에서 별도로 생성한다. 불행히도 SQL Server의 DRI는 '관련 필드 모두 업데이트'와 '관련 필드 모두 삭제 기능'을 지원하지 않으므로 DRI를 선택했다면 이 기능을 잃을 것이다.

액세스에서 관계 창을 연 후 두 테이블을 연결한 선을 클릭하고, 마우스 오른쪽 버튼을 눌러 [관계 편집] 메뉴를 선택해 [관계 편집] 대화상자를 나타낸다. 그림 2-2에서 위쪽에 있는 그리드 박스는 두 테이블 간 관계와 각 테이블의 관련 필드를 보여 준다. 이 대화상자에는 다음 세 가지 체크박스가 있다.

- 항상 참조 무결성 유지
- 관련 필드 모두 업데이트
- 관련 레코드 모두 삭제

계속

'항상 참조 무결성 유지'에 체크하면 마법사에서 DRI 옵션을 사용할 수 있다. 어떤 관계에 대해 '관련 필드 모두 업데이트'나 '관련 레코드 모두 삭제', 또는 이 둘에 모두 체크했다면 마법사의 트리거 옵션을 선택해야 한다.

❮ 그림 2-2 액세스의 [관계 편집] 대화상자

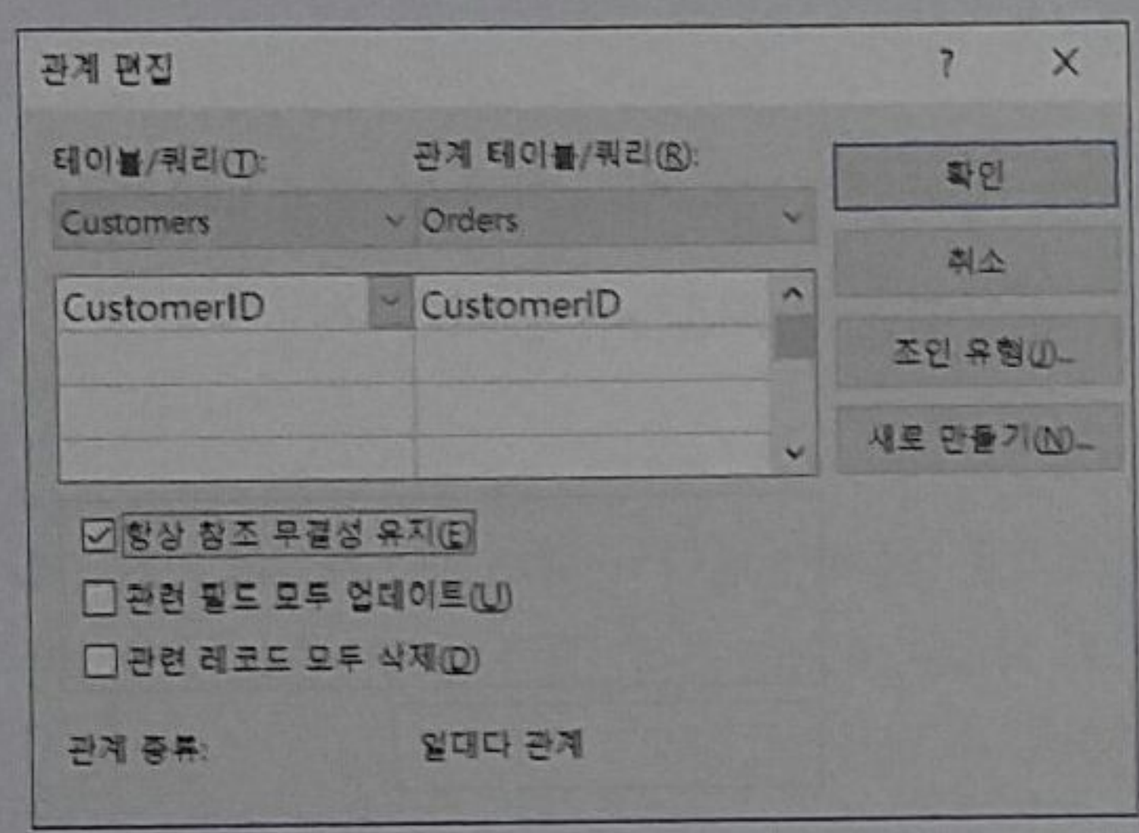

한 가지 문제는 액세스는 자기 참조(한 테이블이 다시 자기 자신을 참조)를 할 때도 관련 필드를 모두 업데이트하거나 삭제할 수 있지만, SQL Server는 그렇지 않다는 점이다. 즉, 코드 2-20을 액세스에서는 허용하지만 SQL Server에서 실행하면 오류가 발생한다.

코드 2-20 자기 참조 관계에 DRI를 적용하는 테이블 생성

```
CREATE TABLE OrgChart (
  employeeID INTEGER NOT NULL PRIMARY KEY,
  manager_employeeID INTEGER
CONSTRAINT SelfReference FOREIGN KEY (manager_employeeID)
REFERENCES OrgChart (employeeID)
ON DELETE SET NULL
ON UPDATE CASCADE
);
```

액세스 2010 버전 이후부터 데이터 매크로를 사용할 수 있는데, SQL Server의 트리거와 유사하다. 액세스 데이터베이스의 데이터 매크로 기능을 유지해야 한다면, SQL Server에서는 트리거로 변환하는 것이 상책이다.

핵심 정리

- 테이블을 생성할 때는 내장 기능으로 계산 컬럼과 제약 조건을 사용한 DRI 구현이 더 나은 성능을 보이므로, 제약 조건이나 계산 컬럼용 내장 기능을 사용하는 방법을 추천한다.
- 일반적으로 트리거는 이식성이 좋지 않다. 한 DBMS에서 생성한 트리거를 다른 DBMS에서 수정하지 않으면 제대로 동작하지 않는다.
- 트리거는 필요할 때만 사용한다. 가능하면 트리거가 멱등성(Idempotence)(한 번 적용한 결과나 두 번 반복해 적용한 결과나 모두 같음)이 있는지 확인한다.

BETTER WAY 14 데이터의 부분 집합을 포함하거나 제외하려면 필터링된 인덱스를 사용하자

쿼리에 사용되는 테이블의 모든 로우를 반환하기 싫다면 WHERE 절을 추가한다. 이때는 일부 로우만 반환되지만 결과를 얻는 I/O 작업량이 반드시 줄어들지는 않는다.

필터링된 인덱스(SQL Server)나 부분(Partial) 인덱스(PostgreSQL)는 비클러스터드 인덱스이며, 테이블에 있는 일부 로우의 집합만 포함한다. 일반적으로 이들은 테이블의 로우 개수와 인덱스의 로우 개수 비율이 1:1인 전통적인 비클러스터드 인덱스에 비해 훨씬 적은 용량을 차지하므로, 필터링된 인덱스는 성능과 저장 용량이라는 두 마리 토끼를 잡을 수 있다. 인덱스에 있는 로우의 개수가 적어서 필요한 I/O 작업도 적기 때문이다. 이 기능을 지원하는 DBMS는 테이블 파티셔닝도 필터링된 인덱스와 비슷한 방식으로 사용한다.

Note ≡ 액세스(적어도 2016 버전까지)와 MySQL(적어도 5.6 버전까지)은 필터링된 인덱스를 지원하지 않는다.

Note ≡ 오라클과 DB2도 필터링된 인덱스를 지원하지 않지만 비슷한 기능을 구현할 수는 있다.*

필터링된 인덱스는 인덱스를 만들 때 WHERE 절을 추가해서 생성한다. 테이블 데이터의 전체 값 중 차지하는 비율이 적고 WHERE 절에서 빈번히 사용되는 값이 있을 때, 필터링된 인덱스를 사용하면 전통적인 인덱스에 비해 그 성능이 월등히 좋아진다.

WHERE 절을 추가해 필터링된 인덱스를 만들 수 있는데, 해당 값들이 모두 NULL이 아니거나 모두 NULL일 때만(인덱스에서 NULL을 사용하는 것은 'BETTER WAY 10. 인덱스를 만들 때는 널을 고려하자' 참고) 제한해서 만들 수 있다. 필터링된 인덱스를 만들 때 사용하는 WHERE 절에서는 결정적 함수만 사용할 수 있고 OR 연산자는 사용할 수 없다('1장. 데이터 모델 설계'의 '결정적 함수와 비결정적 함수' 참고). SQL Server에서는 몇 가지 추가 제약이 있다. 필터 조건에서는 계산 컬럼, UDT(User Defined Type)(사용자 정의 타입) 컬럼, 공간 데이터 타입 컬럼, hierarchyID 데이터 타입 컬럼, BETWEEN, NOT IN 연산자, CASE 문을 사용할 수 없다.

필터링이 적용된 컬럼은 인덱스에 포함할 필요가 없다는 점에 주목하자. 예를 들어 Products 테이블에 QuantityOnHand 컬럼이 있다고 하자. 재고가 적은 제품만 조회하는 쿼리를 만든다면 코드 2-21과 같이 필터링된 인덱스를 만들 수 있다.

코드 2-21 QuantityOnHand 컬럼에서 필터링된 인덱스 생성

```
CREATE NONCLUSTERED INDEX LowProducts
  ON Products (ProductNumber)
  WHERE QuantityOnHand < 10;
```

* http://use-the-index-luke.com/sql/where-clause/null/partial-index

또 다른 가능한 시나리오로 문서 관리 시스템을 생각해 볼 수 있다. 일반적으로 DocumentStatus 테이블의 Status 컬럼에는 Draft(초고), Reviewed(퇴고), Pending publication(발행 보류), Published(발행), Pending expiration(만료 보류), Expired(만료) 같은 값이 있을 것이다. 예를 들어 'Pending publication'이나 'Pending expiration' 상태의 문서를 검색해야 한다고 하자. 코드 2-22는 이 요구 사항에 따라 인덱스를 생성하는 예제이다.

코드 2-22 필터링된 인덱스 생성

```
CREATE NONCLUSTERED INDEX PendingDocuments
  ON DocumentStatus (DocumentNumber, Status)
  WHERE Status IN ('Pending publication', 'Pending expiration');
```

코드 2-23과 같이 동일한 컬럼에 필터링된 인덱스를 여러 개 생성할 수 있다.

코드 2-23 동일 컬럼에 필터링된 인덱스를 여러 개 생성

```
CREATE NONCLUSTERED INDEX PendPubDocuments
  ON DocumentStatus (DocumentNumber, Status)
  WHERE Status = 'Pending publication';
CREATE NONCLUSTERED INDEX PendExpDocuments
  ON DocumentStatus (DocumentNumber, Status)
  WHERE Status = 'Pending expiration';
```

'BETTER WAY 12. 인덱스를 단순 필터링 이상의 목적으로 사용하자'에서 ORDER BY 절을 만족시켜야 하는 정렬 연산을 회피하는 데 인덱스를 사용할 수 있다고 했다. 필터링된 인덱스를 사용하면 이 개념을 더 확장할 수 있다. 코드 2-24의 쿼리에 코드 2-25의 인덱스를 사용하면 정렬 연산을 피할 수 있다.

코드 2-24 정렬 연산이 필요한 쿼리

```
SELECT ProductNumber, ProductName
FROM Products
WHERE CategoryID IN (1, 5, 9)
ORDER BY ProductName;
```

코드 2-25 정렬 연산을 피하려고 필터링된 인덱스 생성

```
CREATE INDEX SelectProducts
  ON Products(ProductName, ProductNumber)
  WHERE CategoryID IN (1, 5, 9);
```

물론 필터링된 인덱스나 부분 인덱스로 할 수 있는 일에는 한계가 있다. 예를 들어 GETDATE() 같은 날짜 함수를 사용할 수 없고, 지난 1년이나 다음 90일까지 등 날짜 컬럼에 특정한 범위 조건을 줄 수 없다. 즉, WHERE 절에서 사용하는 값과 정확히 일치하는 조건만 줄 수 있다.

핵심 정리

- 필터링된 인덱스는 적은 비율의 로우에 인덱스를 사용할 때 저장 용량을 절약할 수 있어 유용하다.
- 필터링된 인덱스는 로우의 하위 집합에서 유일한 제약 조건을 구현하는 데 사용할 수 있다(예를 들어 WHERE active = 'Y'를 만족하는 로우).
- 필터링된 인덱스는 정렬 연산을 피하는 데 사용할 수 있다.
- 테이블 파티셔닝이 다른 인덱스 관리의 오버헤드 없이 필터링된 인덱스와 비슷한 혜택을 줄 수 있는지 고려한다.

BETTER WAY 15 프로그래밍으로 검사하는 대신 선언적 제약 조건을 사용하자

데이터베이스에서 데이터 무결성 강화는 아무리 강조해도 지나치지 않는다. 데이터베이스가 제대로 작동하게 하려면 반드시 각 필드에 유효한 값이 있는지 확인하고 이런 필드에 있는 데이터의 무결성을 강화하는 방법을 수립해야 한다. 다행히도 SQL은 이 분야에 도움이 되는 여러 제약 조건을 제공한다.

SQL은 테이블 데이터 규칙을 명시하는 방식으로 제약 조건을 제공한다. INSERT, DELETE, UPDATE 작업이 일어날 때 모든 제약 조건이 검사된다. 이런 제약 조건을 위반하면 해당 작업은 진행되지 않는다.

다음은 여섯 가지 제약 조건이다.

1. NOT NULL : 기본적으로 테이블 컬럼은 NULL을 가질 수 있다. NOT NULL 제약 조건을 달면 이 컬럼에는 NULL이 아닌 값만 입력된다.
2. UNIQUE : UNIQUE 제약 조건은 특정 필드에 중복 값이 입력되는 것을 방지한다. UNIQUE 제약 조건을 사용하면 기본키가 아닌 특정 컬럼에 중복 값이 들어오는 것을 막는다. PRIMARY KEY 제약 조건과는 달리 UNIQUE 제약 조건은 NULL을 허용한다.
3. PRIMARY KEY : UNIQUE 제약 조건과 유사한 PRIMARY KEY 제약 조건은 테이블에 있는 각 레코드를 유일하게 식별한다. 유일한 값만 입력되게 할 뿐 아니라 NULL이 입력되는 것을 방지한다. 한 테이블에 UNIQUE 제약 조건을 여러 개 만들 수 있는 반면, PRIMARY KEY 제약 조건은 한 개만 만들 수 있다('BETTER WAY 1. 모든 테이블에 기본키가 있는지 확인하자'를 참고한다).
4. FOREIGN KEY : 한 테이블에 있는 외래키는 다른 테이블에 있는 기본키가 된다('BETTER WAY 6. 참조 무결성을 보호하려면 외래키를 정의하자'를 참고한다).

5. CHECK : CHECK 제약 조건은 한 테이블이나 필드에 정의할 수 있다. 단일 필드에 CHECK 제약 조건을 정의하면 이 필드에는 특정 값만 입력될 수 있다. 테이블에 정의하면 특정 필드 값이 동일한 로우의 다른 필드 값을 기준으로 제한된다.
6. DEFAULT : DEFAULT 절은 한 필드의 기본 값을 정의하는 데 사용된다. 새로운 로우를 입력할 때 해당 필드에 값을 입력하지 않으면 데이터베이스는 기본 값을 입력한다.

Note ≡ 기술적으로 SQL 표준에 정의된 내용에 따르면 DEFAULT 절은 제약 조건이 아니다. 하지만 DEFAULT 절은 NOT NULL 제약 조건과 결합해 비즈니스 규칙을 강화하는 수단으로 사용할 수 있다.

Note ≡ SQL Server에서는 유일 인덱스 제약 조건이 있는 컬럼에서 컬럼당 오직 NULL을 한 개만 입력 가능하다. DB2는 WHERE NOT NULL 절을 포함하지 않으면 유일 인덱스 제약 조건이 걸린 컬럼당 NULL을 한 개만 입력할 수 있다.

제약 조건은 테이블을 생성할 때(CREATE TABLE 문)나 테이블을 생성한 후(ALTER TABLE 문)에 명시가 가능하다.

물론 제약 조건을 사용해 DRI가 제공하는 참조 무결성을 강화하는 다른 방법도 있다. 코드로 규칙을 검사하는 절차적 참조 무결성이 그중 하나다. 절차적 참조 무결성을 구현하는 몇 가지 메커니즘이 있는데, 내용은 다음과 같다.

- 클라이언트 애플리케이션에서 작성한 코드
- 저장 프로시저
- 트리거

데이터를 처리하는 컴퓨터 시스템을 개발할 때 데이터베이스의 무결성을 강화하는 것과 관련된 모든 규칙을 처리하도록 프로그램 코드로 작성하는 것도

가능하다. 하지만 이것은 좋은 생각이 아니다. 비즈니스 규칙과 데이터 간 관계를 관리하고 강화하는 것은 데이터 모델의 일부분이어야 하며, 그 역할은 애플리케이션 프로그램이 아닌 데이터베이스에서 수행해야 한다. 모든 사람이 같은 데이터로 작업하고, 이 데이터를 한 가지 방식으로 갱신되게 하려면 데이터 규칙이 애플리케이션에 독립적이어야 한다. 이렇게 해야 계속해서 수천 줄이나 되는 코드를 작성하고 관리하는 부담을 덜 수 있다. 물론 그렇더라도 데이터 무결성을 훼손할 가능성은 있지만, 데이터베이스 자체의 일부분으로 제약 조건을 정의하면 데이터 무결성 훼손 가능성은 줄어든다.

저장 프로시저로 데이터 무결성을 강화하는 방법은 최소한 데이터베이스 내에서 규칙을 보존한다고 볼 수 있지만, 훨씬 어려운 접근 방법이다. 특히 UPDATE 작업일 때는 더욱 그렇다. 또 저장 프로시저로 규칙을 강화할 수는 있지만, 이 방법을 이용하면 사용자가 반드시 저장 프로시저로만 데이터를 수정해야 한다. 이렇게 하려면 사용자에게 해당 저장 프로시저의 실행 권한을 부여해야 하고, 주요 테이블에서는 데이터를 직접 갱신하지 못하게 하는 또 다른 차원의 작업이 필요하다.

참조 무결성을 강화하고 연속적으로 관련 작업을 수행하는 데 트리거를 사용할 수 있다. 트리거는 일상적으로 사용하는 기준 테이블 데이터를 조작하는 것과 동일한 INSERT, UPDATE, DELETE 문을 사용할 수 있는 독립된 해결책이다. 하지만 'BETTER WAY 13. 트리거를 남발하지 말자'에서 이미 트리거를 사용할 때는 주의가 필요하다고 언급했다.

핵심 정리

- 제약 조건 사용을 검토해 데이터 무결성을 강화한다.
- 쿼리 옵티마이저는 고성능 쿼리 실행 계획을 만드는 데 제약 조건을 사용할 수 있다.

BETTER WAY 16 자신이 사용하고 작성하는 SQL의 종류를 파악하자

일반적으로 SQL은 데이터베이스에 접근할 수 있는 표준 언어로 알려져 있다. SQL은 1986년에야 비로소 ANSI 표준이 되었고, 1987년에는 ISO 표준이 되었다. 그러나 특정 SQL 구현체에서 표준을 완벽히 따라야 하는 것은 아니라서 데이터베이스 종류에 따라 호환되지 않기도 한다. 날짜와 시간에 대한 구문, 문자열 결합, NULL 처리, 대·소문자 구분은 DBMS별로 다르다. 효율적으로 SQL 문을 작성하려면 사용 중인 DBMS가 어떤 종류의 SQL을 사용하는지 이해해야 한다.

여기서는 이런 차이점 일부를 소개한다. Danish의 데이터베이스 관리자인 트롤 아빈(Troels Arvin)이 관리하는 http://troels.arvin.dk/db/rdbms/에서 서로 다르게 구현된 SQL을 비교해 놓은 내용을 참고하면 더 많은 정보를 얻을 수 있다.

결과 집합 정렬

SQL 표준에서는 다음 내용을 제외하고 널과 널이 아닌 값의 정렬 방법은 명시하지 않는다.

- 임의의 널 값 두 개는 정렬 순서가 같다.
- 널은 널이 아닌 값의 상위나 하위로 정렬해야 한다.

크게 놀랄 만한 내용은 없다. DBMS별 차이점을 알아보자.

- DB2 : 널은 널이 아닌 값보다 정렬 순서가 높다.
- 액세스 : 널은 널이 아닌 값보다 정렬 순서가 낮다.
- SQL Server : 널은 널이 아닌 값보다 정렬 순서가 낮다.
- MySQL : 널은 널이 아닌 값보다 정렬 순서가 낮다. 트롤 아빈의 말에 따르

면 MySQL 관련 문서에 나온 내용은 아니지만, 컬럼 이름 앞에 -(마이너스) 문자를 추가하면 ASC는 DESC로 바뀌고 DESC는 ASC로 바뀐다고 한다.

- **오라클** : 기본적으로 널은 널이 아닌 값보다 정렬 순서가 높지만, ORDER BY 절에서 NULLS FIRST나 NULLS LAST를 추가하면 정렬 동작이 달라진다.
- PostgreSQL : 기본적으로 널은 널이 아닌 값보다 정렬 순서가 높지만, 8.3 버전부터는 ORDER BY 절에서 NULLS FIRST나 NULLS LAST를 추가하면 정렬 동작이 달라진다.

반환 결과 집합의 개수 제한

SQL 표준은 반환되는 로우의 개수를 제한하는 세 가지 방법을 제공한다.

- FETCH FIRST 사용
- ROW_NUMBER() OVER 같은 윈도우 함수 사용
- 커서 사용

> Note ≡ 여기서 말하는 '제한'은 결과 집합에서 로우를 n개만 뽑아내는 것으로 TOP-n 쿼리를 가리키는 것은 아니다.

DBMS별 구현 방법은 다음과 같다.

- DB2 : 표준 기반의 접근 방법을 모두 지원한다.
- **액세스** : 아무것도 지원하지 않는다.
- SQL Server : ROW_NUMBER()와 표준 기반의 커서만 지원한다.
- MySQL : 표준 기반의 커서와 LIMIT 연산자로 지원한다.
- **오라클** : ROW_NUMBER()와 표준 기반의 커서뿐만 아니라 ROWNUM 의사 컬럼을 이용한 방법도 지원한다.
- PostgreSQL : 표준 기반의 접근 방법을 모두 지원한다.

BOOLEAN 데이터 타입

SQL 표준은 BOOLEAN 타입을 선택 옵션으로 명시하고, BOOLEAN 타입은 다음 값을 가질 수 있다고 명시했다.

- TRUE
- FALSE
- UNKNOWN 또는 NULL(NOT NULL 제약 조건으로 걸리지 않는다면)

DBMS는 NULL을 UNKNOWN으로 해석한다(표준에는 BOOLEAN 타입 값으로 UNKNOWN과 NULL, 또는 둘 모두를 지원해야 하는지가 명시되어 있지 않다). 그리고 TRUE가 FALSE보다 큰 값으로 정의되어 있다.

DBMS별 구현 내용은 다음과 같다.

- DB2 : BOOLEAN 타입을 지원하지 않는다.
- 액세스 : 널이 아닌 Yes/No 타입을 제공한다.
- SQL Server : BOOLEAN 타입을 지원하지 않지만, 대안으로 BIT 타입(0, 1, NULL의 값을 가질 수 있음)이 있다.
- MySQL : BOOLEAN 타입을 지원하지만 표준을 따르지도 않는다(TINYINT(1) 타입의 별칭이다).
- 오라클 : BOOLEAN 타입을 지원하지 않는다.
- PostgreSQL : 표준을 따른다. NULL을 BOOLEAN 값으로 쓸 수 있지만 UNKNOWN은 사용할 수 없다.

SQL 함수

가장 큰 차이점은 SQL 함수 부분일 것이다. 여기서는 지면 제약으로 SQL 표준에 명시된 함수와 실제 구현 내용은 다루지 않을 것이다(많은 DBMS가 표준에 속하지 않는 여러 함수를 구현해 제공한다). 트롤 아빈의 웹 사이트

에서 표준 함수와 그 구현 내용을 일부 소개하고 있지만, 여러분이 사용하는 DBMS 관련 문서를 살펴보는 것이 더 낫다. 날짜와 시간 관련 함수는 '부록. 날짜와 시간 타입, 연산, 함수'에서 간략히 소개한다.

UNIQUE 제약 조건

SQL 표준에서는 DBMS가 선택적 기능인 '널 허용'을 구현하지 않았다면 UNIQUE 제약 조건에 종속되는 컬럼이나 컬럼 집합은 NOT NULL 제약 조건에 종속해야 한다고 명시한다. UNIQUE 제약 조건에 추가된 일부 선택적 기능은 다음과 같다.

- UNIQUE 제약 조건이 있는 컬럼에는 NOT NULL 제약 조건이 있어야 하지만, 꼭 그럴 필요는 없다.
- UNIQUE 제약 조건이 있는 컬럼에 NOT NULL 제약 조건이 없다면 이 컬럼은 널 값을 여러 개 가질 수 있다(NULL <> NULL이라는 사실의 논리적인 결과다).

DBMS별 구현 내용은 다음과 같다.

- **DB2** : UNIQUE 제약 조건의 비선택적 부분을 따른다. '널 허용' 기능은 구현되지 않았다.
- **액세스** : 표준을 따른다.
- **SQL Server** : '널 허용' 기능을 제공하지만 널 값을 하나만 가질 수 있다(즉, 표준의 두 번째 특징을 침해한다).
- **MySQL** : '널 허용' 기능을 포함해 표준을 따른다.
- **오라클** : '널 허용' 기능을 제공한다. 단일 컬럼에 UNIQUE 제약 조건이 있을 때 (표준의 두 번째 특징에서 알 수 있듯이) 이 컬럼은 다수의 널 값을 가질 수 있다. 하지만 여러 컬럼에 UNIQUE 제약 조건이 명시되어 있을 때 로우 두 개가 적어도 한 컬럼에는 NULL을, 나머지 컬럼에는 NULL이 아닌 동일 값을 담고 있으면 오라클은 이 제약 조건이 침해된 것으로 본다.

- PostgreSQL : '널 허용' 기능을 포함해 표준을 따른다.

핵심 정리

- SQL 문이 SQL 표준을 따르더라도 DBMS에 따라 그 동작이 다를 수 있다.
- DBMS별로 SQL 구현 내용이 다르므로 동일한 SQL 문이라도 성능은 다르다.
- 사용하는 DBMS 문서를 참고하는 습관을 들인다.
- SQL 차이점이 궁금하다면 http://troels.arvin.dk/db/rdbms/를 참고한다.

BETTER WAY 17 인덱스에서 계산 결과를 사용할 시기를 파악하자

'BETTER WAY 11. 인덱스와 데이터 스캔을 최소화하도록 인덱스는 신중히 만들자'에서는 계산 컬럼을 저장하기보다는 함수를 사용하는 내용을 다루었다. 함수 기반의 계산 컬럼을 인덱스로 만드는 것이 가능하므로, 여러분이 생각하는 것만큼 불리하지는 않다.

DB2는 함수 기반 인덱스를 zOS에서는 9 버전부터 지원하지만, LUW에서는 10.5 버전부터 지원한다. 하지만 사용자 정의 함수는 인덱스에서 사용할 수 없다. 한 가지 해결책은 함수나 표현식의 결과를 저장하는 실제 컬럼을 만들고(애플리케이션이나 트리거로 관리해야 한다), 이 컬럼을 인덱스로 만드는 것이다. 이 새 컬럼은 인덱스로 만들 수 있고 WHERE 절에서도 표현식 없이 사용할 수 있다.

MySQL은 5.7 버전부터 다른 컬럼의 계산 결과 값을 저장하는 GENERATED 컬럼을 인덱스로 만들 수 있다. 그 이전 버전에서는 DB2에서 처리한 것과 같은 방식으로 사용해야 한다.

오라클은 8i 버전부터 함수 기반 인덱스를 지원하고, 11g 버전부터는 가상 컬럼을 지원한다.

PostgreSQL은 7.4 버전부터 표현식에서 인덱스를 사용할 수 있고, 7.2 버전부터는 부분적으로 지원한다.

SQL Server는 2000 버전부터 계산 컬럼을 인덱스로 만들 수 있는데, 다음 조건을 만족해야 한다.

- **소유권 요구 사항** : 계산 컬럼에 사용된 모든 함수의 소유자는 테이블 소유자와 같아야 한다.
- **결정성 요구 사항** : 계산 컬럼은 결정적이어야 한다('1장. 데이터 모델 설계'의 '결정적 함수와 비결정적 함수'를 참고한다).
- **정밀도 요구 사항** : 함수에서는 `float`나 `real` 데이터 타입의 표현식을 사용할 수 없고, 함수를 정의할 때도 `float`나 `real` 데이터 타입을 사용할 수 없다.
- **데이터 타입 요구 사항** : `text`, `ntext`, `image` 타입을 사용할 수 없다.
- **SET 옵션 요구 사항** : 계산 컬럼의 계산이 수행되는 내용을 정의하는 `CREATE TABLE` 문이나 `ALTER TABLE` 문이 실행될 때 `ANSI_NULLS` 연결 수준 옵션이 `ON`으로 설정되어야 한다.

함수 기반 인덱스를 사용하는 공통적인 이유 한 가지는 쿼리에서 대·소문자를 처리하기 위해서다. 액세스 SQL Server, MySQL은 기본적으로 대·소문자를 구분하지 않는다(MySQL은 악센트도 구분하지 않는다). 코드 2-26의 쿼리를 살펴보자.

코드 2-26 대·소문자를 구분하지 않는 RDBMS용 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpLastName = 'Viescas';
```

실제로 저장된 값이 viescas, VIESCAS, Viescas, 심지어는 ViEsCaS더라도 액세스 SQL Server와 MySQL은 동일한 사람을 결과로 반환한다. 다른

DBMS는 이름이 정확히 Viescas로 입력된 사람만 찾는데, 이런 DBMS에서 대·소문자에 상관없이 결과를 얻으려면 코드 2-27과 같은 쿼리를 사용해야 한다.

코드 2-27 대·소문자를 구분하는 RDBMS용 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE UPPER(EmpLastName) = 'VIESCAS';
```

이처럼 WHERE 절에서 함수를 사용하는 쿼리는 인덱스로 쿼리 속도를 빠르게 하지 못하고('BETTER WAY 28. 데이터베이스 엔진이 인덱스를 사용하도록 사거블 쿼리를 작성하자' 참고) 테이블 스캔이 수행된다. 이 함수는 테이블에 있는 모든 로우에 적용해야 하기 때문이다.

하지만 코드 2-28과 같이 인덱스를 만든다면 코드 2-27에 있는 쿼리는 인덱스를 사용할 것이다.

코드 2-28 대·소문자를 구분하는 RDBMS에서 인덱스 생성

```
CREATE INDEX EmpLastNameUpper
  ON Employees (UPPER(EmpLastName));
```

DB2, SQL Server, 오라클, PostgreSQL에서는 함수 기반 인덱스로 UPPER() 같은 내장 함수는 물론 '컬럼1 + 컬럼2' 같은 표현식이나 사용자 정의 함수까지도 사용할 수 있다.

Note ≡ SQL Server에서는 단순히 함수를 기반으로 인덱스를 만들 수 없고, 테이블에 계산 컬럼을 추가한 후 이 컬럼에 인덱스를 만들어야 한다.

사용자 정의 함수를 사용할 때 중요한 제약 사항은 해당 함수가 반드시 결정적 함수여야 한다는 점이다('1장. 데이터 모델 설계'의 '결정적 함수와 비결정

적 함수'를 참고한다). 예를 들어 함수에서는 직접적이든 간접적이든 현재 시간을 참조하는 함수를 인덱스로 만드는 것은 불가능하다. 나이에 따라 임직원 정보를 추출한다고 할 때, 코드 2-29와 같은 함수를 생성할 것이다. 여기서는 현재 일자(SYSDATE)와 임직원의 출생연도를 사용해 나이를 계산한다.

코드 2-29 비결정적 함수

```
CREATE FUNCTION CalculateAge(Date_of_Birth DATE)
  RETURNS NUMBER
AS
BEGIN
  RETURN
    TRUNC((SYSDATE - Date_of_Birth) / 365);
END
```

Note ≡ 코드 2-29의 CalculateAge() 함수는 오라클에서만 작동한다. SQL Server에서는 DATEDIFF("d", Date_Of_Birth, Date) / 365를 사용해야 한다. DB2에서는 TRUNC((DAYS(CURRENT_DATE) - DAYS(Date_of_Birth)) / 365, 0)으로 사용해야 하고, MySQL에서는 TRUNCATE(DATEDIFF(SYSDATE(), Date_of_Birth) / 365, 0)으로 사용해야 한다. 액세스는 SQL로 함수를 생성할 수 없고 대신 VBA를 사용해야 한다. 이 함수는 나이를 올바르게 계산하지 못한다는 점에 유의하자. CASE를 사용해 제대로 계산하는 예제는 'BETTER WAY 24. CASE로 문제를 해결해야 할 때를 파악하자'를 참고한다.

코드 2-30은 CalculateAge() 함수를 사용해 50세 이상인 임직원을 찾는 쿼리다.

코드 2-30 CalculateAge() 함수를 사용한 SQL

```
SELECT EmployeeID, EmpFirstName, EmpLastName,
  CalculateAge(EmpDOB) AS EmpAge
FROM Employees
WHERE CalculateAge(EmpDOB) > 50;
```

WHERE 절에서 이 함수를 사용하면 테이블 스캔이 수행되므로, 이 쿼리를 최적화하려면 함수 기반 인덱스를 사용해야 한다는 사실은 분명해 보인다. 불행히도 CalculateAge()를 호출한 결과는 매개변수에 따라 값이 달라지는 비결정적 함수다. 또 이 함수의 호출 결과는 SYSDATE() 함수가 반환하는 값에 따라 달라진다. 오직 결정적 함수만 인덱스로 만들 수 있다.

PostgreSQL과 오라클에서는 결정적 함수를 정의할 때 반드시 DETERMINISTIC(오라클)이나 IMMUTABLE(PostgreSQL) 키워드를 명시해야 한다. 이들 키워드를 명시하면 개발자가 함수를 올바르게 선언했음을 신뢰하므로 CalculateAge() 함수를 결정적 함수로 선언해 인덱스 정의에 사용할 수 있다. 하지만 인덱스가 생성된 시점에 계산된 값이 저장되므로 날짜가 변경되더라도 값은 변하지 않기에 의도한 대로 작동하지는 않을 것이다.

함수 기반 인덱스는 쿼리 최적화 관점에서 많은 이점을 제공하기 때문에 극단적으로 모든 것을 인덱스로 만들어 사용할 여지가 있는데, 이는 좋은 생각이 아니다. 모든 인덱스는 관리 차원에서 문제가 있다. 테이블에 인덱스가 많을수록 UPDATE 작업은 느리다. 특히 함수 기반 인덱스는 중복 인덱스를 만들기가 매우 쉬우므로 문제가 된다.

핵심 정리

- 인덱스를 과다하게 만들지 않는다.
- 예상되는 데이터베이스 사용 실태를 분석해 필터링된 인덱스를 적합하게 사용하는지 확인한다.

CHAPTER

3

데이터 모델 설계를 변경할 수 없는 경우

적절한 논리적 데이터 모델을 갖추려고 상당한 시간을 들이며, 이를 적합한 물리적인 모델로 구현하려고 열심히 작업했다고 하자. 불행히도 데이터의 일부는 여러분이 손댈 수 없는 소스에서 가져와야 한다고 하자.

상황이 이렇다고 해서 여러분이 작성한 SQL 쿼리가 잘 수행되지 않는다는 말은 아니다. 이 장에서는 부적절하게 설계된 다른 소스에서 가져온 데이터로 작업을 할 때 손봐야 하는 부분을 설명할 것이다. 이런 데이터에 여러분이 작성한 쿼리 일부를 변형해서 수행하는 방법과 객체를 생성하는 식으로 데이터 자체를 변형하는 방법을 알아볼 것이다.

외부 데이터의 제어권이 없으므로 데이터베이스 설계 내용을 변경할 수 없다. 하지만 이 장 내용을 참고하면 DBA와 협업해서 효율적인 SQL을 작성할 수 있을 것이다.

BETTER WAY 18 설계를 변경할 수 없을 때는 뷰로 데이터를 간소화하자

뷰는 하나 이상의 테이블이나 다른 뷰에 SQL 쿼리를 미리 정의해 놓고는 테이블처럼 데이터를 볼 수 있는 객체다. 단순한 객체임에도 장점이 매우 많다.

Note ≡ 액세스는 뷰라는 객체는 지원하지 않지만, 저장된 쿼리로 뷰처럼 사용할 수는 있다.

뷰를 사용해 역정규화에서 이슈 몇 가지를 개선할 수 있다. 'BETTER WAY 2. 중복으로 저장된 데이터 항목을 제거하자'에서 이미 CustomerSales 테이블을 역정규화해서 독립적인 테이블(Customers, AutomobileModels, SalesTransactions, Employees) 네 개로 분할했다. 또 'BETTER WAY 3. 반복 그룹을 제거하자'에서는 반복 그룹이 있는 Assignments 테이블을 Drawings와 Predecessors라는 테이블 두 개로 분할했다. 이런 역정규화 문제를 해결하면서 원하는 형태로 데이터를 표현하는 데 뷰를 사용한다.

코드 3-1과 같이 CustomerSales 테이블에 서로 다른 뷰를 만들 수 있다.

코드 3-1 역정규화된 테이블을 정규화하는 뷰

```
CREATE VIEW vCustomers AS
SELECT DISTINCT cs.CustFirstName, cs.CustLastName, cs.Address,
  cs.City, cs.Phone
FROM CustomerSales AS cs;

CREATE VIEW vAutomobileModels AS
SELECT DISTINCT cs.ModelYear, cs.Model
FROM CustomerSales AS cs;

CREATE VIEW vEmployees AS
SELECT DISTINCT cs.SalesPerson
FROM CustomerSales AS cs;
```

그림 3-1과 같이 vCustomers 뷰에는 Tom Frank 로우가 두 개 들어 있는데, 원본 테이블에 이 사람의 주소가 두 개 있기 때문이다. 하지만 더 작은 데이터 집합으로 작업하는 것이 좋다. CustFirstName과 CustLastName으로 정렬하면 중복된 데이터를 쉽게 찾을 수 있고, CustomerSales 테이블에 있는 데이터를 올바르게 수정할 수 있다.

그림 3-1 vCustomers 뷰 데이터

vCustomers

CustFirstName	CustLastName	Address	City	Phone
Amy	Bacock	111 Dover Lane	Chicago	312-222-1111
Barney	Killjoy	4655 Rainier Ave.	Auburn	253-111-2222
Debra	Smith	3223 SE 12th Pl.	Seattle	206-333-4444
Homer	Tyler	1287 Grady Way	Renton	425-777-8888
Tom	Frank	7435 NE 20th St.	Bellevue	425-888-9999
Tom	Frank	7453 NE 20th St.	Bellevue	425-888-9999

'BETTER WAY 3. 반복 그룹을 제거하자'에서는 UNION 쿼리를 사용해 반복 그룹을 포함하는 테이블을 '정규화'하는 방법을 알려 주었다. 코드 3-2와 같이 이 뷰를 사용해도 동일한 결과를 얻을 수 있다.

코드 3-2 반복 그룹이 있는 테이블을 정규화하는 뷰

```
CREATE VIEW vDrawings AS
SELECT a.ID AS DrawingID, a.DrawingNumber
FROM Assignments AS a;

CREATE VIEW vPredecessors AS
SELECT 1 AS PredecessorID, a.ID AS DrawingID,
  a.Predecessor_1 AS Predecessor
FROM Assignments AS a
WHERE a.Predecessor_1 IS NOT NULL
UNION
SELECT 2, a.ID, a.Predecessor_2
FROM Assignments AS a
WHERE a.Predecessor_2 IS NOT NULL
```

```
UNION
SELECT 3, a.ID, a.Predecessor_3
FROM Assignments AS a
WHERE a.Predecessor_3 IS NOT NULL
UNION
SELECT 4, a.ID, a.Predecessor_4
FROM Assignments AS a
WHERE a.Predecessor_4 IS NOT NULL
UNION
SELECT 5, a.ID, a.Predecessor_5
FROM Assignments AS a
WHERE a.Predecessor_5 IS NOT NULL;
```

여기서 한 가지 짚고 넘어가자. 지금까지 보여 준 모든 뷰는 적절하게 설계된 테이블을 형상화하지만 오직 조회 용도로만 사용할 수 있었다. 코드 3-1의 뷰에서는 SELECT DISTINCT를 사용했고, 코드 3-2의 뷰에서는 UNION을 사용했기 때문에 이들 뷰는 갱신할 수 없다. 일부 DBMS에서는 뷰에 트리거(INSTEAD OF 트리거라고도 한다)를 사용해 뷰로 원본 테이블의 데이터를 수정하는 로직을 작성할 수 있게 허용함으로써 이런 한계점을 해결한다.

> Note ≡ DB2, SQL Server, 오라클, PostgreSQL은 뷰에 트리거를 사용할 수 있지만, MySQL에서는 뷰에 트리거를 사용할 수 없다.

뷰를 사용하는 이유를 정리하면 다음과 같다.

- **특정 데이터에 집중** : 뷰로 특정 작업에 사용하는 특정 데이터에 집중할 수 있다. 이런 뷰는 하나 이상의 테이블에 있는 모든 로우나 WHERE 절로 걸러 낸 로우를 반환한다. 또 하나 이상의 테이블에 있는 컬럼의 일부 집합만 반환할 수도 있다.
- **컬럼 이름을 간소화 또는 명료화** : 뷰를 사용하면 원래 컬럼 이름 대신 별칭을 사용해 좀 더 의미 있는 이름을 부여할 수 있다.

- **여러 테이블에 있는 데이터를 한눈에 보기** : 뷰로 여러 테이블 데이터를 결합해 논리적인 단일 레코드로 통합해서 볼 수 있다.
- **데이터 조작 간소화** : 뷰는 사용자가 데이터로 작업하는 방식을 간소하게 만들 수 있다. 예를 들어 보고서용으로 복잡한 쿼리를 작성한다고 하자. 사용자별로 서브쿼리, 외부 조인, 일련의 테이블 그룹에서 데이터를 추출해서 집계하는 대신 뷰를 만들어 사용할 수 있다. 이렇게 하면 데이터 접근을 간단하게 할 수 있을 뿐만 아니라(보고서 데이터를 생성할 때마다 주요 쿼리를 작성할 필요가 없으므로), 각 사용자가 해당 쿼리를 생성하도록 강제하지 않고도 데이터의 일관성을 유지할 수 있다. 또 매개변수가 있는 뷰나 WHERE 절의 조건에 매개변수를 가진 뷰 또는 복잡한 쿼리의 일부분으로 논리적으로 동작하는 인라인 사용자 정의 함수도 만들 수 있다. 여기서 말하는 인라인 함수는 스칼라 함수와는 다르다는 점에 유의하자!
- **중요 데이터 보호** : 테이블에 민감하고 중요한 데이터가 저장되어 있을 때 이 데이터를 뷰로 만들어 뺄 수 있다. 예를 들어 고객의 신용 카드 정보를 노출하는 대신 신용 카드 숫자를 변형해서 실제 숫자는 숨긴 채 기능을 수행하는 함수를 사용하는 뷰를 만들 수 있다. DBMS에 따라 다르지만, 이런 뷰를 특정 사용자만 볼 수 있게 할 수 있어 주요 테이블을 직접 노출하지 않을 수 있다. 또 뷰는 컬럼이나 로우 수준의 보안 기능을 제공한다. WITH CHECK OPTION 절로 사용자가 뷰에 걸린 제약 조건을 위반하는 데이터 삭제나 갱신 작업을 수행하는 것을 차단할 수 있다.
- **하위 호환성 제공** : 하나 이상의 테이블 스키마를 변경해야 할 때 기존 테이블의 스키마와 동일한 뷰를 만들어 처리할 수 있다. 이렇게 하면 기존 애플리케이션은 원래 테이블 데이터를 조회하는 쿼리를 수정 없이 사용할 수 있다. 심지어 해당 애플리케이션에서 데이터를 조작할 때라도 INSTEAD OF 트리거를 사용하면 주요 테이블의 뷰로 INSERT, UPDATE, DELETE 작업을 할 수 있다.
- **데이터 커스터마이징** : 뷰를 만들면 어느 사용자가 다른 방식으로 동일한 데이터를, 심지어 똑같은 시간에 다른 방식으로 보게 할 수 있다. 예를 들어 사

용자의 로그인 ID 값에 따라 특정 사용자와 관련된 고객 정보를 조회하는 뷰를 만들어 사용할 수 있다.

- **요약 데이터 제공** : 집계 함수(SUM(), AVERAGE() 등)를 사용한 뷰로 데이터 일부분의 계산 결과 값만 볼 수 있다.
- **데이터 가져오기와 내보내기** : 뷰를 이용하면 다른 애플리케이션에 데이터를 내보낼 수 있다. 원하는 데이터를 제공하는 뷰를 생성한 후 적당한 유틸리티를 이용하면 해당 데이터를 내보낼 수 있다. 또 가져오기용 뷰를 만들면 주요 테이블에 있는 모든 컬럼이 아닌 필요한 컬럼 데이터만 가져와 사용할 수도 있다.

뷰를 참조하는 뷰는 생성하지 말자

다른 뷰를 참조하는 뷰를 생성하는 것은 가능하다. 이것은 명령형 프로그래밍 언어에 있는 프로시저를 처리하는 방식으로 뷰를 사용하는 것인데, 이렇게 하면 큰 실수를 할 수 있고 성능과 관리적 문제점을 일으킨다. 이런 뷰는 사용 이점을 모두 갉아먹는 결과만 낳을 뿐이다. 코드 3-3은 다른 뷰를 참조하는 뷰를 생성하는 예제이다.

코드 3-3 세 가지 뷰 생성

```
CREATE VIEW vActiveCustomers AS
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  c.CustFirstName + ' ' + c.CustLastName AS CustFullName
FROM Customers AS c
WHERE EXISTS
  (SELECT NULL
   FROM Orders AS o
   WHERE o.CustomerID = c.CustomerID
     AND o.OrderDate > DATEADD(MONTH, -6, GETDATE()));

CREATE VIEW vCustomerStatistics AS
SELECT o.CustomerID, COUNT(o.OrderNumber) AS OrderCount,
  SUM(o.OrderTotal) AS GrandOrderTotal,
  MAX(o.OrderDate) AS LastOrderDate
FROM Orders AS o
GROUP BY o.CustomerID;
```

계속

```
CREATE VIEW vActiveCustomerStatistics AS
SELECT a.CustomerID, a.CustFirstName, a.CustLastName,
  s.LastOrderDate, s.GrandOrderTotal
FROM vActiveCustomers AS a
  INNER JOIN vCustomerStatistics AS s
    ON a.CustomerID = s.CustomerID;
```

이런 뷰에는 몇 가지 잠재적인 문제점이 있는데, DBMS에 따라 그 양상이 다르다. 하지만 일반적으로 옵티마이저는 뷰를 보는 순간 일단 그 뷰를 분해한다. 분해한 뷰에 또 다른 뷰가 있다면 이런 뷰도 분해한다. 이상적인 관점에서 보면 옵티마이저는 이 뷰 세 개를 코드 3-4와 같이 효율적인 인라인 형태의 문장으로 결합한다.

코드 3-4 뷰를 결합한 문장

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  s.LastOrderDate, s.GrandOrderTotal
FROM Customers AS c
  INNER JOIN
    (SELECT o.CustomerID,
       SUM(o.OrderTotal) AS GrandOrderTotal,
       MAX(o.OrderDate) AS LastOrderDate
     FROM Orders AS o
     GROUP BY o.CustomerID) AS s
    ON c.CustomerID = s.CustomerID
WHERE EXISTS
  (SELECT NULL
   FROM Orders AS o
   WHERE o.CustomerID = c.CustomerID
     AND o.OrderDate > DATEADD(MONTH, -6, GETDATE()));
```

코드 3-4에서는 실제로 사용되지 않는 특정 컬럼이나 표현식을 제거했다. 특히 주 쿼리와 서브쿼리 어디에도 없는 OrderCount와 CustFullName은 없애 버렸다. 하지만 실제로는 중간 결과를 산출하는 또 다른 중간 결과의 집합을 조인하는 모든 표현식 계산을 포함해서 이 뷰에 있는 내용들을 옵티마이저가 미리 처리할 것이다. 힘들여 모든 계산을 수행했음에도 최종 뷰에서 사용하지 않아 일부 표현식을 버린 것이다.

이와 동일한 로직이 필터링된 로우에도 적용된다. 예를 들어 비활성화된 고객은 vCustomerStatistics에는 포함되지만 vActiveCustomers에서는 제외되므로 결국 최

계속

종 뷰인 vActiveCustomerStatistics에서도 이들 내역은 볼 수 없다. 따라서 예상보다 많은 I/O 작업이 수반될 수 있다. 관련된 내용은 'BETTER WAY 46. 실행 계획의 작동 원리를 이해하자'에서 자세히 설명한다. 여기서 사용한 예는 지나치게 단순화한 측면이 없지 않지만, 다른 뷰를 참조할 때 옵티마이저가 단순히 인라인화할 수 없는 뷰를 만드는 것은 꽤 쉽다. 게다가 인라인화할 수 없는 이런 뷰를 생성하는 방법도 여러 가지다. 결국 일반적으로 실제 필요한 데이터만 정확히 요구하는 좀 더 간단한 쿼리 표현식으로 뷰를 만들 때 옵티마이저는 더 나은 작업을 수행한다.

이런 이유로 뷰를 참조하는 뷰는 만들지 않는 것이 상책이다. 이미 만든 뷰를 다른 형태로 봐야 한다면 적절한 필터나 그룹으로 묶어 기준 테이블을 직접 참조하는 새 뷰를 만들면 좋다. 또 뷰에서도 서브쿼리를 사용할 수 있는데, 뷰에서만 볼 수 있는 계산 값을 집계할 때 매우 유용하다. 이것은 사용하기 편리하지 않은 뷰 생성을 남발하지 않고 쉽게 데이터베이스를 관리하는 데 도움이 되는 접근 방법이다. 'BETTER WAY 42. 가능하면 서브쿼리 대신 공통 테이블 표현식을 사용하자'에서 더 많은 기법을 볼 수 있다.

핵심 정리

- 사용자에게 직관적인 데이터를 제공하려면 뷰를 사용한다.
- 사용자가 정확히 필요한 데이터를 보거나(종종 수정하거나) 더는 필요 없는 데이터를 보지 않게 제한하려면 뷰를 사용한다. 필요하면 WITH CHECK OPTION을 사용한다.
- 복잡한 쿼리를 숨기고 재사용하려면 뷰를 사용한다.
- 여러 테이블에 있는 데이터를 취합해 보고용 데이터를 만들 때는 뷰를 사용한다.
- 뷰를 사용하면 코딩 규칙이나 명명법을 강화할 수 있다. 특히 기존 데이터베이스 설계를 변경해서 작업할 때 특히 유용하다.

BETTER WAY 19 비관계형 데이터를 정보성 데이터로 변환할 때는 ETL을 사용하자

추출(Extract), 변환(Transform), 로드(Load)를 의미하는 ETL은 외부 소스에 있는 데이터를 추출한 후 관계형 설계 규칙이나 다른 요구 사항에 맞게 변환하

고, 분석이나 다른 목적으로 사용하려고 데이터베이스에 로드하는 일련의 절차나 도구를 의미한다. 거의 모든 데이터베이스 시스템은 이런 처리를 지원하는 다양한 유틸리티를 제공한다. 이런 유틸리티는 꽤 빠르게 원시 데이터를 정보성 데이터로 변환해 준다.

윈도우 시대의 첫 번째 데이터베이스 시스템인 액세스에 있는 일부 도구는 데이터를 변형하고 로드해서 유용한 데이터로 만드는 방식을 제공하는데, 이 도구로 유틸리티가 무엇을 할 수 있는지 알아보자. 여러분은 아침 식사용 시리얼을 생산하는 회사의 마케팅 관리자다. 경쟁사의 판매 명세는 물론이고 브랜드별로 세부적으로 분석해야 한다고 가정하자.

공개된 자료를 토대로 전체 판매량은 대략 가늠할 수 있지만, 필요한 자료는 브랜드별 판매 데이터다. 그래서 주요 식료품 체인점에서 판매 정보를 받기로 하고, 여러분은 그 보상으로 자사 제품을 할인해 주는 협정을 체결했다고 하자. 이들 체인점은 작년도 브랜드별 판매 정보를 스프레드시트 형태로 보내 왔는데, 그 내용은 표 3-1과 같다.

표 3-1 경쟁사 판매 데이터

Product		Jan		Feb		Mar
Alpha-Bits		57775.87		40649.37		...
Golden Crisp		33985.68		17469.97		...
Good Morenings		40375.07		36010.81		...
Grape-Nuts		55859.51		38189.64		...
Great Grains		37198.23		41444.41		...
Honey Bunches of Oats		63283.28		35261.46		...
나머지 로우는 생략						

읽기 편하게 하려고 필요 없는 데이터는 빈칸으로 처리했다. 이 데이터를 월별로 제품당 한 로우로 변환하고, 제품별로 기본키를 가진 별도의 테이블로 분할해야 한다. 이것은 각 제품 이름에 키 값을 할당하고 이를 외래키로도 사용하면 가능하다.

먼저 좀 더 사용이 편한 형태로 스프레드시트 데이터를 추출해 보자. 액세스는 여러 형태로 데이터 가져오기를 수행할 수 있다. 먼저 스프레드시트 데이터는 외부 데이터 가져오기 도구를 실행해서 얻는다. 해당 파일을 찾아 어떤 형태(현재 데이터베이스의 새 테이블로 원본 데이터 가져오기, 다음 테이블에 레코드 복사본 추가, 연결 테이블을 만들어 데이터 원본에 연결, 연결 테이블을 만들어 데이터 원본에 연결)로 데이터를 받을지 결정해야 한다.

그다음 단계로 이동하면 그림 3-2와 같이 스프레드시트 데이터 일부를 그리드 형태로 보여 준다. 첫 번째 행은 컬럼 이름으로 사용하고, 빈 컬럼은 새로 생성된 이름으로 할당한다.

❮ 그림 3-2 초기 분석을 하려고 스프레드시트 가져오기 마법사로 데이터 가져오기

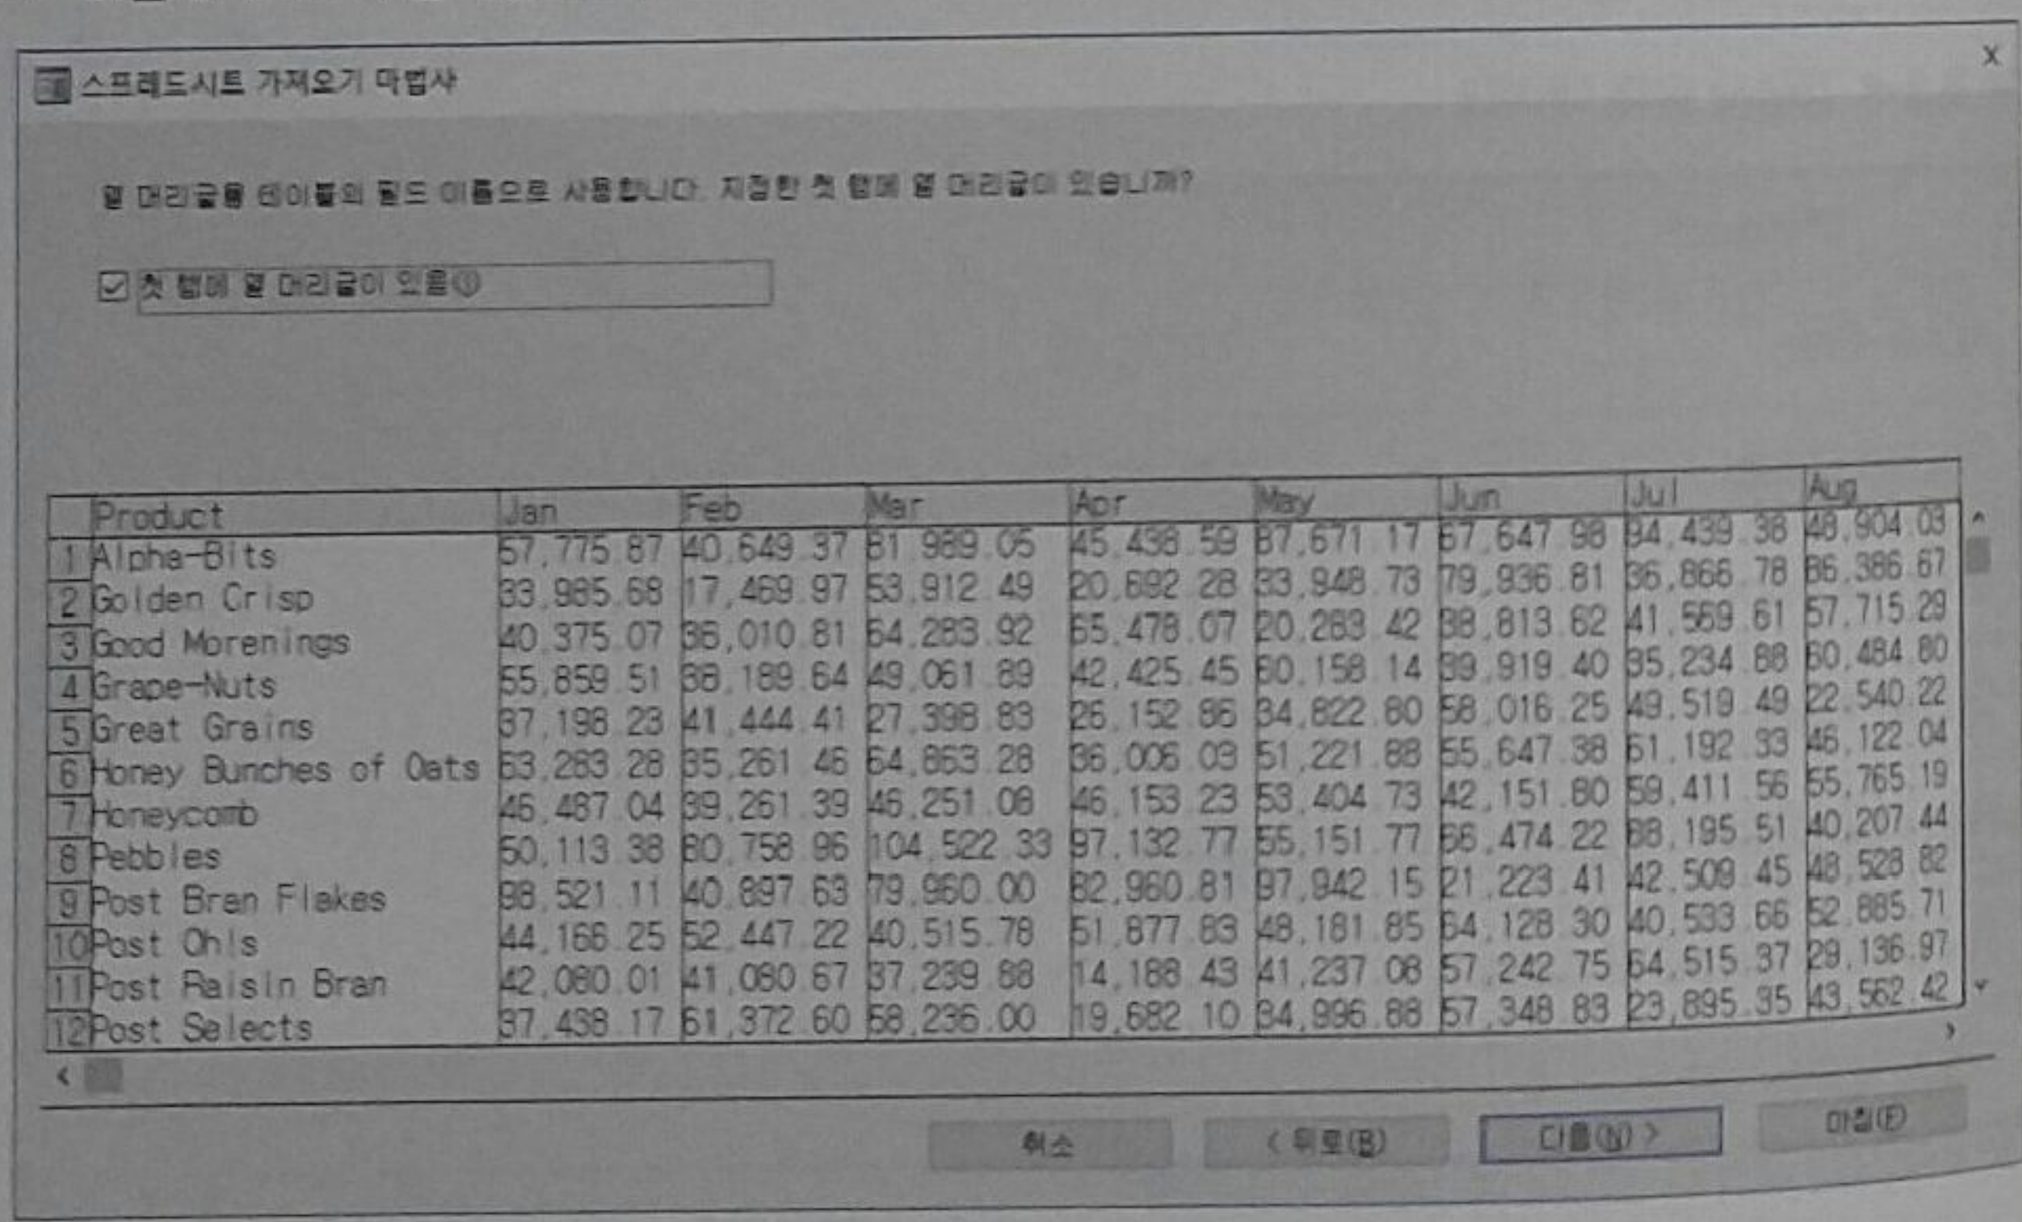

	Product	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug
1	Alpha-Bits	57,775.87	40,649.37	81,989.05	45,438.59	87,671.17	67,647.98	84,439.38	48,904.03
2	Golden Crisp	33,985.68	17,469.97	53,912.49	20,692.28	33,948.73	79,936.81	36,866.78	86,386.67
3	Good Morenings	40,375.07	36,010.81	64,283.92	65,478.07	20,283.42	88,813.62	41,569.61	57,715.29
4	Grape-Nuts	55,859.51	38,189.64	49,061.89	42,425.45	80,158.14	89,919.40	35,234.88	60,484.80
5	Great Grains	37,198.23	41,444.41	27,398.83	26,152.86	34,822.80	58,016.25	49,519.49	22,540.22
6	Honey Bunches of Oats	63,283.28	35,261.46	64,863.28	36,006.03	51,221.88	55,647.38	51,192.33	46,122.04
7	Honeycomb	46,487.04	39,261.39	46,251.08	46,153.23	53,404.73	42,151.80	59,411.56	55,765.19
8	Pebbles	50,113.38	80,758.96	104,522.33	97,132.77	55,151.77	56,474.22	88,195.51	40,207.44
9	Post Bran Flakes	98,521.11	40,897.63	79,960.00	82,960.81	97,942.15	21,223.41	42,509.45	48,528.82
10	Post Ohls	44,166.25	52,447.22	40,515.78	51,877.83	48,181.85	64,128.30	40,533.66	52,885.71
11	Post Raisin Bran	42,080.01	41,080.67	37,239.88	14,188.43	41,237.08	57,242.75	64,515.37	29,136.97
12	Post Selects	37,438.17	61,372.60	58,236.00	19,682.10	84,996.88	57,348.83	23,895.35	43,562.42

이제 한 번에 하나씩 컬럼을 선택해야 하는데, 불필요한 컬럼은 넘어가고 데이터 타입(데이터 형식)을 올바르게 맞춘다. 그림 3-3은 이 데이터 중 컬럼 타입을 하나 선택하는 방법이다. 여기서는 숫자 타입이 보이는데 이 데이터 값에 소수점이 포함되어 있어 실수(Double)형 데이터가 자동으로 선택되었다. 여기 있는 값들은 달러 금액이므로 쉽게 볼 수 있도록 데이터 타입을 통화(Currency)로 선택했다. 가져오지 않을 컬럼은 '필드 포함 안 함(Do not import)'에 체크한다.

❤ 그림 3-3 가져올 컬럼과 데이터 타입 선택

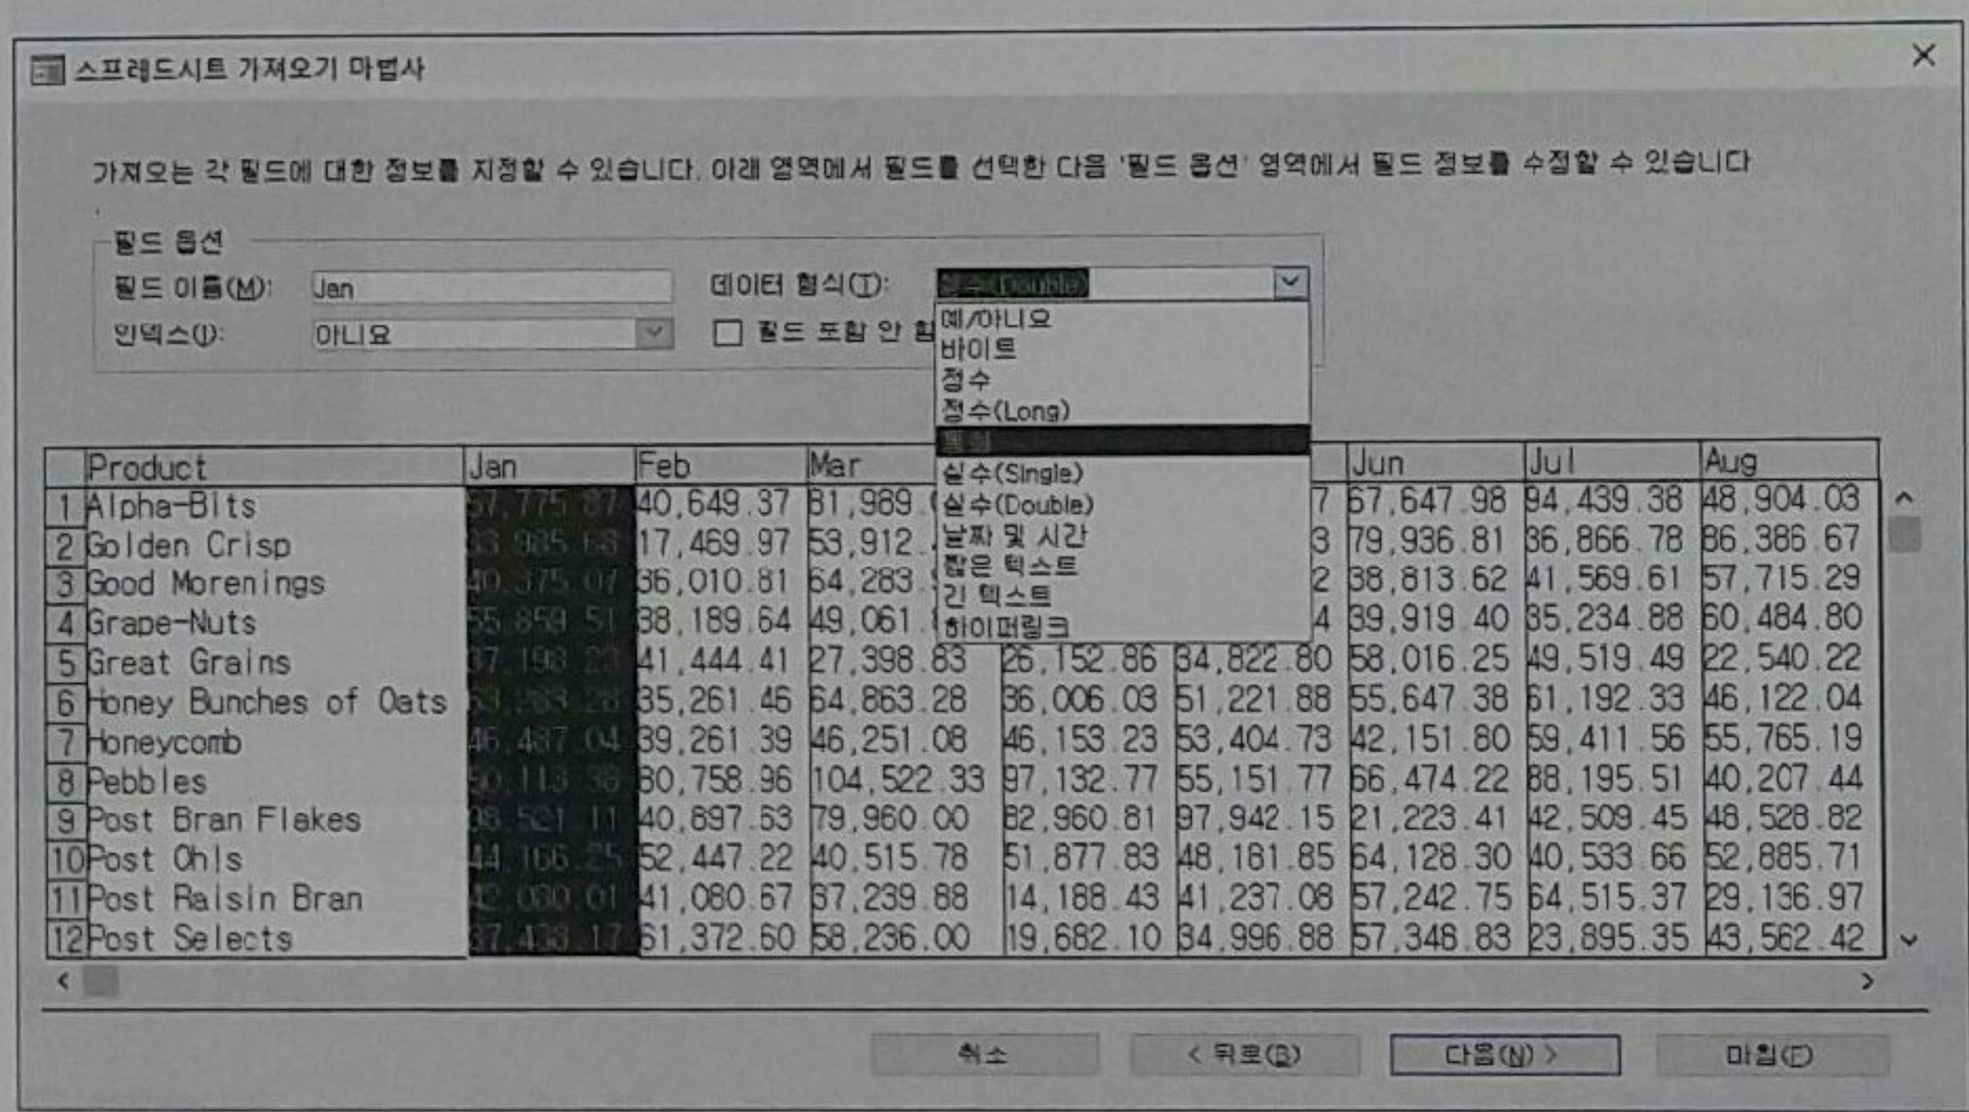

이번에는 기본키가 될 컬럼을 골라야 하는데, 자동 증가하는 정수형 ID 컬럼을 생성할 수도 있고 테이블에 기본키를 할당하지 않을 수도 있다. 마지막 단계로 테이블 이름을 입력한다(명시하지 않으면 워크시트 이름이 테이블 이름이 된다). 가져오기가 끝나면 또 다른 유틸리티를 실행해 추가 분석을 수행하고, 좀 더 정규화된 테이블을 설계한 후 데이터를 다시 읽어 로드할 수 있다. '데이터를 가져온 뒤 마법사에서 테이블을 분석'에 체크했다면 그림 3-4와 같은 테이블 분석 마법사 창이 뜰 것이다. 여기서는 Product라는 컬럼을

드래그해서 별도의 테이블로 만들고 두 테이블에 이름을 붙였다. 그림에서 볼 수 있듯이 유틸리티는 자동으로 제품 테이블(tblPostProducts)에 기본키를 생성했고, 판매 데이터 테이블(tblPostSales2)에는 관련된 외래키를 생성했다.

그림 3-4 테이블 분석 마법사로 각 제품을 별도의 테이블로 분할

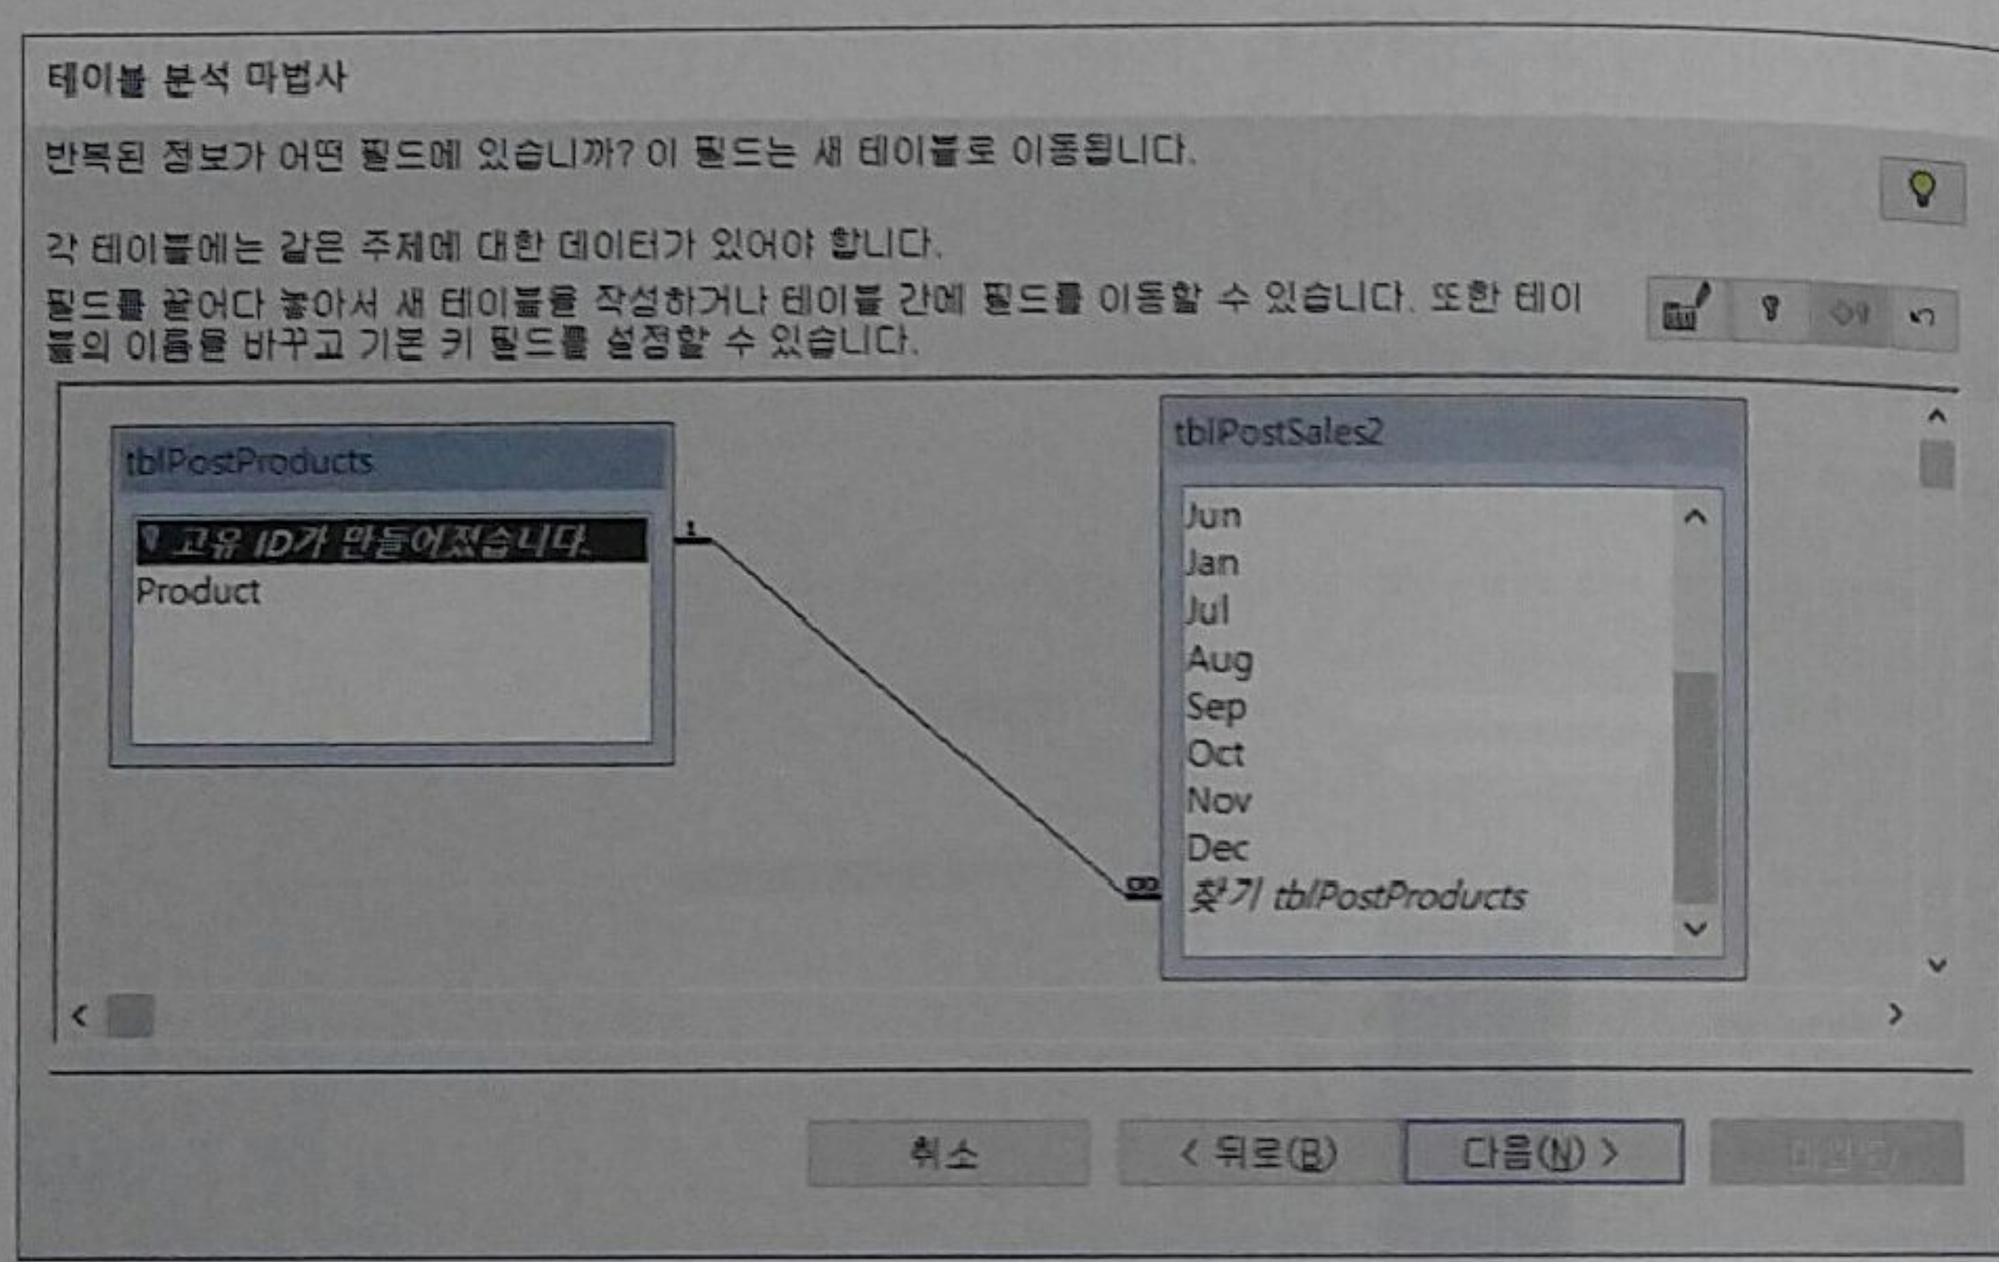

테이블 분석 기능을 사용한 후에도 판매 데이터를 월별로 한 로우씩 분할해 정규화하려면 해야 할 작업이 더 있다. 코드 3-5와 같이 UNION 쿼리를 사용해 판매 데이터를 '언피벗(Unpivot)'해서 컬럼을 로우 형태로 바꿔야 한다('BETTER WAY 21. 비정규화된 데이터를 '언피벗'하려면 UNION 문을 사용하자'를 참고한다).

코드 3-5 반복 그룹을 언피벗하는 데 UNION 쿼리 사용

```
SELECT '2015-01-01' AS SalesMonth, Product, Jan AS SalesAmt
FROM tblPostSales
UNION ALL
SELECT '2015-02-01' AS SalesMonth, Product, Feb AS SalesAmt
```

```
FROM tblPostSales
UNION ALL
  ... 12개월을 모두 처리
```

액세스에서 제공하는 도구는 꽤 간단한 편이지만(예를 들어 로우 합계를 처리할 수 없다), ETL을 수행해서 외부 데이터를 데이터베이스에 로드할 때 어떤 작업이 필요한지는 가늠할 수 있다. 이전에도 말했지만 대부분의 데이터베이스 시스템은 이와 비슷한 상황에서는 더 강력한 도구를 제공한다. SQL Server Integration Services(SSIS), Oracle Data Integrator(ODI), IBM의 InfoSphere DataStage가 그 예다. 상용 제품으로 Informatica, SAP, SAS 등이 있고 웹에서도 많은 오픈 소스 도구를 찾아볼 수 있을 것이다.

여기서는 도구들을 사용해 비즈니스가 요구하는 데이터 모델에 맞게 데이터를 변환하는 것이지 그 반대가 아니라는 점이 중요하다. 흔히 저지르기 쉬운 실수는 읽어 오는 데이터에 맞춰 테이블을 만들고, 이 데이터를 애플리케이션에서 그대로 사용하는 것이다. 여러 형태의 데이터 소스에서 원시 데이터를 수집하는 번거로움이 있지만, 데이터를 변형하는 이런 노력은 결국 데이터베이스에서 관리하고 이해하기 쉬운 데이터를 만드는 형태로 결실을 맺을 것이다.

핵심 정리

- ETL 도구를 사용하면 비관계형 데이터를 적은 노력으로도 데이터베이스로 가져올 수 있다.
- ETL 도구로 데이터 형태를 변경하고 재배열해서 정보성 데이터로 탈바꿈할 수 있다.
- 대부분의 데이터베이스 시스템은 상용 도구를 포함해 여러 수준의 ETL 도구를 제공한다.

BETTER WAY 20 요약 테이블을 만들어 관리하자

이전에 언급했듯이('BETTER WAY 18. 설계를 변경할 수 없을 때는 뷰로 데이터를 간소화하자' 참고) 뷰를 이용하면 복잡한 쿼리를 단순화하고 데이터를 적절히 요약해 사용할 수 있다. 그런데 처리하는 데이터가 많다면 요약 테이블을 생성하는 것이 더 바람직할 수도 있다.

요약 테이블을 생성하면 필요한 모든 데이터를 한 테이블로 모아 주므로 데이터 구조 파악이 쉽고 원하는 정보를 빠르게 파악할 수 있다.

이것은 세부 데이터를 요약하는 테이블을 생성하고, 트리거를 사용해 원본 테이블의 데이터가 변경될 때마다 요약 테이블의 데이터를 갱신하는 방법을 활용하면 가능하다. 하지만 원본 테이블이 빈번하게 변경된다면 많은 부하를 줄 수 있는 방법이기도 하다.

또 다른 방법은 저장 프로시저를 사용해 주기적으로 요약 테이블을 갱신하는 것이다. 즉, 요약 테이블 데이터를 모두 삭제한 후 다시 요약 데이터를 생성하는 것이다.

DB2는 요약 테이블 개념을 제공한다. DB2의 요약 테이블은 하나 이상의 원본 테이블 데이터를 집계해 관리할 수 있다. 원본 테이블이 변경될 때마다 자동 또는 수동으로 데이터를 갱신할 수 있다. DB2의 요약 테이블은 사용자에게 빠른 결과를 제공할 뿐만 아니라, 요약 테이블을 생성할 때 ENABLE QUERY OPTIMIZATION을 명시하면 사용자 쿼리가 정보를 요청할 경우 옵티마이저는 요약 테이블에서 미리 요약된 정보를 사용할 수 있다. 이 모든 작업을 처리할 때 어느 정도의 비용이 들지만, 최소한 요약 데이터를 관리하는 데 트리거나 저장 프로시저를 사용할 필요가 없다는 장점이 있다.

코드 3-6은 DB2에서 테이블 여섯 개에 든 데이터를 요약해 SalesSummary라는 요약 테이블을 생성하는 스크립트다. 이 SQL을 보면 알겠지만 뷰를 생성하는 것과 별반 다르지 않다. 실제로 요약 테이블은 구체화된 쿼리 테이블(Materialized Query Table, MQT)의 한 타입으로 MQT의 CREATE SQL 문에서 GROUP BY 절을 사용한 것이 요약 테이블이라고 보면 된다. MQT에서는 FROM 절에 명시적인 INNER JOIN 사용을 제한해 두므로 여기서는 WHERE 절에 조인 조건을 기술했고, REPRESH IMMEDIATE 절을 활성화하는 데 사용한 SELECT 절에는 COUNT(*)를 추가했다는 점에 주의하자. 이런 내용은 옵티마이저가 MQT를 사용할 때 필요한 사항이다.

코드 3-6 테이블 여섯 개를 참조해 만든 요약 테이블(DB2)

```
CREATE SUMMARY TABLE SalesSummary AS (
SELECT
  t5.RegionName AS RegionName,
  t5.CountryCode AS CountryCode,
  t6.ProductTypeCode AS ProductTypeCode,
  t4.CurrentYear AS CurrentYear,
  t4.CurrentQuarter AS CurrentQuarter,
  t4.CurrentMonth AS CurrentMonth,
  COUNT(*) AS RowCount,
  SUM(t1.Sales) AS Sales,
  SUM(t1.Cost * t1.Quantity) AS Cost,
  SUM(t1.Quantity) AS Quantity,
  SUM(t1.GrossProfit) AS GrossProfit
FROM Sales AS t1, Retailer AS t2, Product AS t3,
  datTime AS t4, Region AS t5, ProductType AS t6
WHERE t1.RetailerId = t2.RetailerId
  AND t1.ProductId = t3.ProductId
  AND t1.OrderDay = t4.DayKey
  AND t2.RetailerCountryCode = t5.CountryCode
  AND t3.ProductTypeId = t6.ProductTypeId
GROUP BY t5.RegionName, t5.CountryCode, t6.ProductTypeCode,
  t4.CurrentYear, t4.CurrentQuarter, t4.CurrentMonth
```

```
)
DATA INITIALLY DEFERRED
REFRESH IMMEDIATE
ENABLE QUERY OPTIMIZATION
MAINTAINED BY SYSTEM
NOT LOGGED INITIALLY;
```

코드 3-7에는 비슷한 유형의 오라클에서 제공하는 구체화된 뷰(Materialized View)가 있다.

코드 3-7 오라클에서 테이블 여섯 개를 참조하는 구체화된 뷰 생성

```
CREATE MATERIALIZED VIEW SalesSummary
  TABLESPACE TABLESPACE1
  BUILD IMMEDIATE
  REFRESH FAST ON DEMAND
AS
SELECT SUM(t1.Sales) AS Sales,
  SUM(t1.Cost * t1.Quantity) AS Cost,
  SUM(t1.Quantity) AS Quantity,
  SUM(t1.GrossProfit) AS GrossProfit,
  t5.RegionName AS RegionName,
  t5.CountryCode AS CountryCode,
  t6.ProductTypeCode AS ProductTypeCode,
  t4.CurrentYear AS CurrentYear,
  t4.CurrentQuarter AS CurrentQuarter,
  t4.CurrentMonth AS CurrentMonth
FROM Sales AS t1
  INNER JOIN Retailer AS t2
    ON t1.RetailerId = t2.RetailerId
  INNER JOIN Product AS t3
    ON t1.ProductId = t3.ProductId
  INNER JOIN datTime AS t4
    ON t1.OrderDay = t4.DayKey
  INNER JOIN Region AS t5
    ON t2.RetailerCountryCode = t5.CountryCode
  INNER JOIN ProductType AS t6
    ON t3.ProductTypeId = t6.ProductTypeId
```

```
GROUP BY t5.RegionName, t5.CountryCode, t6.ProductTypeCode,
  t4.CurrentYear, t4.CurrentQuarter, t4.CurrentMonth;
```

SQL Server는 구체화된 뷰를 지원하지는 않지만 뷰에 인덱스를 만들어 비슷한 효과를 낼 수 있다. 따라서 비슷한 방식으로 인덱싱된 뷰를 사용할 수 있다.

> Note ≡ DBMS에 따라 추가적인 제한이 있다. 요약 테이블, 구체화된 뷰, 인덱싱된 뷰를 생성하기 전에 실제로 어떤 기능을 지원하는지 관련 문서를 먼저 확인하자.

요약 테이블에도 몇 가지 단점이 있는데, 그 내용은 다음과 같다.

- 요약 테이블은 별도의 데이터를 저장하므로 저장 공간을 차지한다.
- 원본 테이블과 요약 테이블 간 데이터를 일관되게 유지하려면 관리 작업(트리거, 제약 조건, 저장 프로시저 등)이 필요하다.
- 사용자에게 필요한 집계 값을 미리 계산하고 요약 테이블에 담아 놓으려면 그 데이터가 무엇인지 미리 파악해 두어야 한다.
- 그루핑 조건이나 필터 조건이 다를 때는 요약 테이블이 여러 개 필요하다.
- 스케줄을 만들어 요약 테이블 데이터를 갱신하도록 한다.
- SQL을 사용해 요약 테이블 데이터를 주기적으로 관리해야 한다. 예를 들어 요약 테이블에서 지난 12개월간 데이터를 보여 주려면 이 테이블에서 1년 이상 지난 데이터는 제거하는 로직이 필요하다.

추가적인 트리거, 제약 조건, 저장 프로시저를 사용하면서 늘어나는 관리 비용을 없애는 한 가지 방법을 캔 핸더슨은 〈강력한 SQL 프로그래밍을 위한 Transact SQL〉(인사이트, 2002)에서 인라인 요약이란 형태로 제안했다. 인라인 요약은 기존 테이블에 집계 컬럼을 추가하는 방법이다. 보통은 INSERT INTO 문을 사용해 데이터를 집계하고 저장할 것이다. 집계 데이터에

포함되지 않는 컬럼 데이터는 NULL이나 일부 고정된 날짜 데이터처럼 알려진 값으로 설정될 것이다. 인라인 요약의 장점은 요약 데이터와 요약 전 데이터를 합치거나 분리해서 손쉽게 질의할 수 있다는 것이다. 요약된 데이터는 특정 컬럼에서 알려진 값을 보면 쉽게 식별할 수 있지만, 이 점을 제외하면 요약 전 데이터와 분간할 수 없다는 단점이 있다. 이 방법을 사용하려면 요약 전과 후의 데이터를 포함하는 테이블에서 모든 쿼리를 제대로 작성해야 한다.

핵심 정리

- 요약 데이터를 저장하면 집계에 필요한 처리를 최소화할 수 있다.
- 요약 데이터를 저장해 놓은 테이블을 사용하면 집계 작업을 할 때 좀 더 효율적으로 집계된 데이터가 포함된 필드에 인덱스를 만들 수 있다.
- 요약 작업은 다소 정적인 테이블에 적합하다. 원천 테이블이 빈번히 변경된다면 요약 작업의 부하는 무시할 수 없을 정도로 커진다.
- 요약 작업을 수행하는 데 트리거를 사용할 수 있지만, 요약 테이블 데이터를 지우고 다시 생성하는 식으로 수행한다면 저장 프로시저를 사용하는 편이 더 낫다.

BETTER WAY 21 비정규화된 데이터를 '언피벗'하려면 UNION 문을 사용하자

'BETTER WAY 3. 반복 그룹을 제거하자'에서 UNION 쿼리로 반복 그룹을 제거하는 방법을 살펴보았는데, 이번에는 좀 더 깊게 들어가 보자. 또 'BETTER WAY 22. 관계 대수와 이를 SQL로 구현하는 방법을 이해하자'에서는 에드거 커드 박사가 정의한 관계형 모델 내에서 수행되는 여덟 가지 관계 대수 작업 중 UNION 쿼리 동작을 살펴볼 것이다. UNION 쿼리는 두 개 이상의 SELECT 문으로 데이터 집합을 결합할 때 사용된다.

데이터를 분석해야 하는데 그림 3-5와 같은 엑셀 스프레드시트 형식의 데이터가 주어졌다고 가정하자. 문제는 이 데이터는 정규화되지 않았다는 점이다.

❤ 그림 3-5 비정규화된 엑셀 데이터

	Category	Oct Quantity	Oct Sales	Nov Quantity	Nov Sales	Dec Quantity	Dec Sales	Jan Quantity	Jan Sales	Feb Quantity	Feb Sales
3	Accessories	930	$61,165.40	923	$60,883.03	987	$62,758.14	1223	$80,954.76	979	$60,242.47
4	Bikes	413	$536,590.50	412	$546,657.00	332	$439,831.50	542	$705,733.50	450	$585,130.50
5	Car racks	138	$24,077.15	96	$16,772.05	115	$20,137.05	142	$24,794.75	124	$21,763.30
6	Clothing	145	$5,903.20	141	$5,149.96	139	$4,937.74	153	$5,042.62	136	$5,913.98
7	Components	286	$34,228.55	322	$35,451.79	265	$27,480.22	325	$35,151.97	307	$32,828.02
8	Skateboards	164	$60,530.06	203	$89,040.58	129	$59,377.20	204	$79,461.30	147	$61,125.19
9	Tires	151	$4,356.91	110	$3,081.24	150	$4,388.55	186	$5,377.60	137	$3,937.70

여러분의 DBMS에서 이 데이터를 가져올 때 쓸 수 있는 방법은 기껏해야 반복 그룹 다섯 쌍(OctQuantity, OctSales, NovQuantity, NovSales, …, FebQuantity, FebSales)으로 구성된 테이블(SalesSummary)을 생성하는 것이다. 코드 3-8은 10월 데이터를 조회하는 쿼리다.

코드 3-8 10월 데이터를 추출하는 SQL

```
SELECT Category, OctQuantity, OctSales
FROM SalesSummary;
```

물론 다른 달의 데이터는 쿼리를 변경해야 볼 수 있다. 정규화되지 않은 데이터는 분석 용도로 사용하기에 많이 어렵다는 것을 잊지 말자. 이런 측면에서 UNION 쿼리가 도움이 된다.

UNION 쿼리를 사용할 때 적용되는 세 가지 기본 규칙은 다음과 같다.

1. UNION 쿼리를 구성하는 각 쿼리는 컬럼의 개수가 동일해야 한다.
2. 각 쿼리의 컬럼 순서도 일치해야 한다.
3. 각 쿼리에서 사용된 컬럼의 데이터 타입도 일치하거나 서로 호환해야 한다.

하지만 UNION 쿼리를 구성하는 각 쿼리에서 사용된 컬럼 이름은 달라도 상관없다. 코드 3-9는 정규화된 뷰에 이 데이터를 합치는 방법을 보여 준다.

코드 3-9 UNION으로 데이터를 정규화하는 방법

```
SELECT Category, OctQuantity, OctSales
FROM SalesSummary
UNION
SELECT Category, NovQuantity, NovSales
FROM SalesSummary
UNION
SELECT Category, DecQuantity, DecSales
FROM SalesSummary
UNION
SELECT Category, JanQuantity, JanSales
FROM SalesSummary
UNION
SELECT Category, FebQuantity, FebSales
FROM SalesSummary;
```

표 3-2는 코드 3-9 쿼리의 결과로 반환되는 데이터 일부다.

표 3-2 코드 3-9의 UNION 쿼리가 반환한 데이터 일부

Category	OctQuantity	OctSales
Accessories	923	60883.03
Accessories	930	61165.4
...	...	...
Bikes	450	585130.5
Bikes	542	705733.5
Car racks	96	16772.05
Car racks	115	20137.05
Car racks	124	21763.3
...	...	...

계속

Category	OctQuantity	OctSales
Skateboards	203	89040.58
Skateboards	204	79461.3
Tires	110	3081.24
Tires	137	3937.7
Tires	150	4388.55
Tires	151	4356.91
Tires	186	5377.6

두 가지 점이 눈에 띈다. 먼저 어느 달의 데이터인지 구분할 방법이 없다. 예를 들어 처음 로우 데이터 두 개는 10월과 11월의 액세서리(Accessories) 매출 수량과 금액인데, 어떤 것이 10월 데이터인지 알 수 있는 방법이 없다. 5개월치 판매 데이터를 추출한 것이지만, 컬럼 이름은 `OctQuantity`와 `OctSales`이다. 이것은 `UNION` 쿼리에서 컬럼 이름을 첫 번째 `SELECT` 문에서 가져왔기 때문이다.

코드 3-10은 이 문제를 해결한 쿼리다.

코드 3-10 좀 더 다듬은 UNION 쿼리를 사용한 데이터 정규화

```
SELECT Category, 'Oct' AS SalesMonth, OctQuantity AS Quantity,
  OctSales AS SalesAmt
FROM SalesSummary
UNION
SELECT Category, 'Nov', NovQuantity, NovSales
FROM SalesSummary
UNION
SELECT Category, 'Dec', DecQuantity, DecSales
FROM SalesSummary
UNION
SELECT Category, 'Jan', JanQuantity, JanSales
FROM SalesSummary
```

```
UNION
SELECT Category, 'Feb', FebQuantity, FebSales
FROM SalesSummary;
```

표 3-3은 코드 3-10 쿼리의 결과로 반환되는 데이터 일부다.

표 3-3 코드 3-10의 UNION 쿼리가 반환한 데이터 일부

Category	SalesMonth	Quantity	SalesAmount
Accessories	Dec	987	62758.14
Accessories	Feb	979	60242.47
...	...	...	...
Bikes	Nov	412	546657
Bikes	Oct	413	536590.5
Car racks	Dec	115	20137.05
Car racks	Feb	124	21763.3
Car racks	Jan	142	24794.75
...	...	...	...
Skateboards	Nov	203	89040.58
Skateboards	Oct	164	60530.06
Tires	Dec	150	4388.55
Tires	Feb	137	3937.7
Tires	Jan	186	5377.6
Tires	Nov	110	3081.24
Tires	Oct	151	4356.91

정렬 순서를 변경해 데이터를 추출하려면 코드 3-11과 같이 UNION 쿼리의 마지막 SELECT 문에 ORDER BY 절을 추가한다.

코드 3-11 UNION 쿼리에 정렬 순서 명시

```
SELECT Category, 'Oct' AS SalesMonth, OctQuantity AS Quantity,
  OctSales AS SalesAmt
FROM SalesSummary
UNION
SELECT Category, 'Nov', NovQuantity, NovSales
FROM SalesSummary
UNION
SELECT Category, 'Dec', DecQuantity, DecSales
FROM SalesSummary
UNION
SELECT Category, 'Jan', JanQuantity, JanSales
FROM SalesSummary
UNION
SELECT Category, 'Feb', FebQuantity, FebSales
FROM SalesSummary
ORDER BY SalesMonth, Category;
```

표 3-4는 코드 3-11 쿼리의 결과로 반환되는 데이터 일부다.

▼ 표 3-4 코드 3-11의 UNION 쿼리가 반환한 데이터 일부

Category	SalesMonth	Quantity	SalesAmount
Accessories	Dec	987	62758.14
Bikes	Dec	332	439831.5
Car racks	Dec	115	20137.05
Clothing	Dec	139	4937.74
Components	Dec	265	27480.22
Skateboards	Dec	129	59377.2
Tires	Dec	150	4388.55
Accessories	Feb	979	60242.47
Bikes	Feb	450	585130.5
Car racks	Feb	124	21763.3
...	...	...	...

Note ≡ 액세스 같은 일부 DBMS는 마지막이 아닌 곳에도 ORDER BY 절을 추가할 수 있지만, 그렇게 해도 실제 정렬 순서는 변경되지 않는다.

ORDER BY 절에 컬럼을 나열할 때는 일반적으로 컬럼 이름(컬럼 이름은 첫 번째 SELECT 문의 컬럼 이름을 기술해야 한다)이나 컬럼 순서를 명시한다. 즉, 코드 3-11과 같이 ORDER BY SalesMonth, Category로 명시해도 되고 ORDER BY 2, 1로 명시해도 된다. 오라클에서는 컬럼 순번을 사용하도록 권고한다.

UNION 쿼리를 사용할 때 고려할 또 다른 점은 중복 로우를 제거하는 것이다. 중복되는 로우까지 추출하려면 UNION 대신 UNION ALL을 사용한다. 원천 데이터에 중복되는 데이터가 없다는 사실을 알고 있을 때 UNION ALL을 사용하면 중복되는 로우를 제거하는 단계가 사라지므로 성능 향상을 기대할 수 있다. 따라서 이런 종류의 쿼리에는 UNION ALL을 사용하면 좋다.

핵심 정리

- UNION 쿼리에서 각 SELECT 문은 컬럼의 개수가 동일해야 한다.
- 각 SELECT 문에서 사용하는 컬럼 이름이 달라도 문제는 없지만, 각 컬럼의 데이터 타입은 서로 호환되어야 한다.
- 데이터의 정렬 순서를 조정하려면 마지막 SELECT 문에 ORDER BY 절을 추가한다.
- 중복 로우를 제거할 필요가 없거나 중복 로우를 제거해서 일어난 성능 문제를 없애려면 UNION 대신 UNION ALL을 사용한다.

CHAPTER

4

데이터 필터링과 검색

하나 이상의 테이블에서 데이터를 검색해 유용한 정보로 변환할 때 SQL로 할 수 있는 가장 중요한 작업은 아마도 원하는 데이터를 찾거나 원하지 않는 데이터를 걸러 내는 필터링일 것이다. 필터링은 다른 데이터 집합 전체와 임의의 데이터 집합 전체를 비교해 일치하는 것을 찾기도 하고, 하나 이상의 컬럼에 있는 특정 값을 검사할 목적으로 수행하기도 한다. 이 장에서는 데이터베이스에서 원하는 정보를 정확히 찾아낼 수 있는 기법들을 살펴본다.

BETTER WAY 22 관계 대수와 이를 SQL로 구현하는 방법을 이해하자

에드거 커드 박사는 데이터베이스를 관리하는 관계형 모델의 '아버지'로 칭송이 자자하다. 그는 관계(테이블이나 뷰), 튜플(로우), 속성(컬럼) 용어를 만들었고, 이 모델로 수행할 수 있는 관계 대수라는 일련의 연산을 설명했다. 이 연산의 종류는 다음과 같다.

1. 선택(제한이라고도 한다.)
2. 추출
3. 조인
4. 교집합
5. 카티전 곱
6. 합집합
7. 나누기
8. 차집합

SQL로 이 작업을 수행할 수 있지만, 여기서 나열한 용어는 SQL과 조금 다를 수 있다. 나누기('BETTER WAY 26. 완전히 일치하는 데이터가 필요할 때는 데이터를 분할하자' 참고)에서 원하는 결과를 얻으려면 여러 형태의 SQL을 조합해야 한다.

선택(제한)

선택(제한)은 로우를 선택한 후 필터링해서 원하는 데이터 집합을 얻는 것이다. FROM 절에서 원하는 데이터 집합의 원천이 무엇인지 정의한 후 WHERE나 HAVING 절을 사용해 반환되는 로우를 걸러 내는 작업이다. 그림 4-1은 데이터 집합을 일련의 컬럼과 로우 집합으로 표현한 것이다. 그림에서 색칠한 부분이 바로 선택(제한) 작업 결과로 반환된 로우다.

그림 4-1 선택 연산 수행

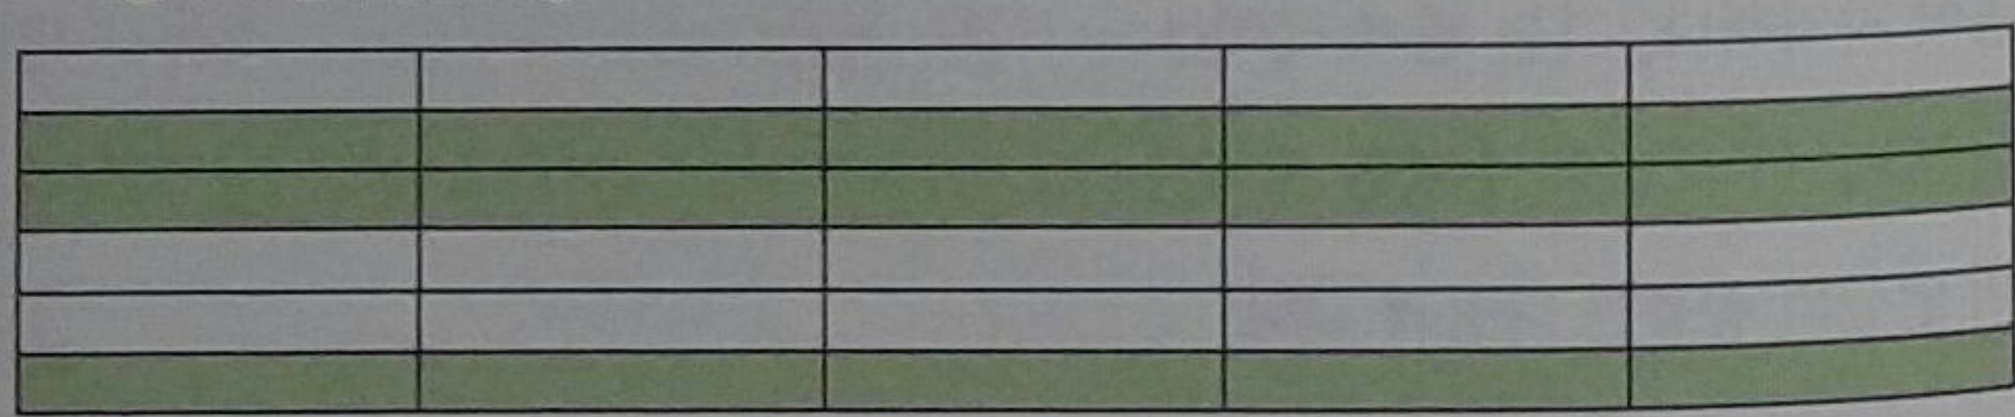

추출

추출(Project)은 데이터베이스 시스템이 반환하는 컬럼과 표현식을 선택하는 연산을 의미한다. SQL에서는 데이터베이스 시스템이 반환하는 컬럼을 정의하려고 집계 함수, GROUP BY 절을 포함한 SELECT 절로 구현한다. 선택된 집합이 일련의 컬럼과 로우라고 할 때 추출 연산은 그림 4-2에서 노란색으로 표시한 컬럼을 반환한다.

❤ 그림 4-2 추출 연산 수행

추출 연산으로 선택되지 않은 컬럼 값을 사용해서 반환될 로우를 걸러 내는 것은 선택(제한) 작업의 몫이라는 점을 기억하자.

조인

조인은 키 값으로 연결된 데이터 집합이나 관련된 테이블을 연결하는 것이다. 모든 관계(테이블)는 반드시 유일한 식별자(기본키)를 가져야 하며, 관계가 형성된 또 다른 테이블은 이런 유일한 식별자의 복사본(외래키)을 가져야 한다는 점이 관계형 모델의 핵심 요소이다. FROM 절에 JOIN 키워드를 사용해야만 조인을 수행한다고 생각할 수도 있지만, SQL은 INNER JOIN, NATURAL JOIN, OUTER JOIN까지 사용할 수 있도록 확장되었다. 그림 4-3은 관계가 있는 두 테이블에서 INNER JOIN과 OUTER JOIN을 수행한 결과를 보여 준다. 여기서는 1번 테이블의 PKey와 2번 테이블의 FKey로 조인했다.

❮ 그림 4-3 관련된 두 테이블에서 INNER JOIN과 OUTER JOIN을 수행한 결과

1번 테이블

PKey	ColA	ColB
1	A	q
2	B	r
3	C	s
4	D	t
5	E	u
6	F	v

2번 테이블

PKey	FKey	ColX	ColY
90	1	55	ABC
91	6	62	GHI
92	3	77	PQR
93	5	50	KLM
94	2	32	STU
95	3	84	DEF
96	6	48	XYZ

1번 테이블과 2번 테이블의 INNER JOIN

PKey	ColA	ColB	PKey	ColX	ColY
1	A	q	90	55	ABC
2	B	r	94	32	STU
3	C	s	92	77	PQR
3	C	s	95	84	DEF
5	E	u	93	50	KLM
6	F	v	91	62	GHI
6	F	v	96	48	XYZ

1번 테이블과 2번 테이블의 LEFT OUTER JOIN

PKey	ColA	ColB	PKey	ColX	ColY
1	A	q	90	55	ABC
2	B	r	94	32	STU
3	C	s	92	77	PQR
3	C	s	95	84	DEF
4	D	t	Null	Null	Null
5	E	u	93	50	KLM
6	F	x	91	62	GHI
6	F	x	96	48	XYZ

INNER JOIN을 한 결과는 두 테이블에서 일치하는 로우만 포함되었고, OUTER JOIN을 한 결과는 1번 테이블의 모든 로우와 이와 일치하는 2번 테이블의 로우가 포함되었다는 점에 주목하자. 2번 테이블의 값과 일치하지 않는 1번 테이블의 로우는 2번 테이블의 컬럼에 널 값이 반환되었다.

Note ≡ NATURAL JOIN은 INNER JOIN과 비슷하지만, 두 테이블에서 이름이 동일한 컬럼의 조인을 수행해 일치하는 로우만 반환하며 ON 절은 명시하지 않는다. MySQL, 오라클, PostgreSQL에서만 NATURAL JOIN을 지원한다.

교집합

교집합은 컬럼이 동일한 두 집합에서 수행된다. 교집합의 결과는 이런 각 컬럼 값과 일치하는 모든 로우를 반환한다. DB2, SQL Server, 오라클, PostgreSQL에서 교집합 기능을 지원한다. 교집합 기능을 지원하는 DBMS는 한 데이터 집합에서 선택(제한)과 추출 작업을 수행한 후 첫 번째 데이터 집합과 두 번째 집합에서 INTERSECT를 명시하면 된다.

사용 중인 데이터베이스에서 교집합 기능을 지원하지 않는다면(액세스와 MySQL은 지원하지 않는다), 두 데이터 집합에 있는 모든 컬럼에서 INNER JOIN을 수행해 동일한 결과를 얻을 수 있다. 코드 4-1은 INTERSECT를 사용해 자전거(Bike)와 스케이트보드(Skateboard)를 모두 구매한 고객을 추출하는 쿼리다.

> Note ≡ 판매 주문(Sales Orders) 샘플 데이터베이스에 있는 실제 제품 이름은 단순히 Bike와 Skateboard로 되어 있지 않다. 따라서 코드 4-1~코드 4-3의 쿼리를 수행하면 반환되는 결과가 없을 것이다. 샘플 데이터베이스에서 결과를 얻으려면 LIKE '%Bike%'와 LIKE '%Skateboard%'를 사용해야 한다. 여기서는 이해를 도우려고 쿼리를 간단하게 작성한 것이지 검색에 최적화된 효율적인 문장은 아니다.

코드 4-1 교집합 연산을 수행하는 쿼리

```
SELECT c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE c.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Bike')
INTERSECT
```

```
SELECT c2.CustFirstName, c2.CustLastName
FROM Customers AS c2
WHERE c2.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Skateboard');
```

코드 4-2는 INNER JOIN을 사용해 동일한 결과를 얻는 쿼리다.

코드 4-2 INNER JOIN으로 교집합 연산과 동일한 기능 구현

```
SELECT c.CustFirstName, c.CustLastName
FROM
  (SELECT DISTINCT c.CustFirstName,
     c.CustLastName
   FROM Customers AS c
     INNER JOIN Orders AS o
       ON c.CustomerID = o.CustomerID
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Bike') AS c
INNER JOIN
  (SELECT DISTINCT c.CustFirstName,
     c.CustLastName
   FROM Customers AS c
     INNER JOIN Orders AS o
       ON c.CustomerID = o.CustomerID
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Skateboard'
```

```
) AS c2
 ON c.CustFirstName = c2.CustFirstName
   AND c.CustLastName = c2.CustLastName;
```

INTERSECT를 사용할 때 데이터베이스 시스템은 중복 로우를 제거한다. DB2와 PostgreSQL은 중복을 포함해 모든 로우를 반환하는 INTERSECT ALL을 지원한다.

카티전 곱

카티전 곱(Cartesian Product)은 한 데이터 집합에 있는 모든 로우와 두 번째 데이터 집합에 있는 모든 로우를 결합한 결과를 반환한다. 반환 결과의 로우 개수가 첫 번째 집합의 전체 로우 개수와 두 번째 집합의 전체 로우 개수를 곱한 것과 같아 '곱'이라고 하는 것이다. 예를 들어 첫 번째 집합에 로우가 여덟 개 있고 두 번째 집합에 로우가 세 개 있다면, 결과는 24로우(8 * 3 = 24)가 된다.

카티전 곱을 수행하려면 JOIN 절 없이 FROM 절에 해당 테이블만 명시한다. 주요 DBMS에서 카티전 곱을 지원하고 있지만, 그중 일부는 CROSS JOIN으로 명시해야 한다. 카티전 곱을 사용한 예제는 '8장. 카티전 곱'과 '9장. 탤리 테이블'을 참고하자.

합집합

합집합 연산은 컬럼의 유형이 동일한 두 데이터 집합을 병합하는 것으로 SQL에서는 UNION 키워드로 구현되어 있다. 교집합과 유사하게 한 데이터 집합에서 선택과 추출을 한 후 UNION 키워드를 추가하고 두 번째 집합에서 선택과 추출을 한다.

SQL에 구현된 합집합에서 특이한 점은 UNION ALL이다. UNION ALL을 사용하면 데이터베이스 시스템이 두 집합에서 발견된 중복 로우를 제거하지 않으므로 중복된 로우를 찾아낼 수 있다.

합집합 연산은 매우 유용하게 사용된다. 예를 들어 관계가 없는 고객과 공급처 두 테이블에서 이름, 주소, 도시 등 정보를 추출해 고객과 공급처 모두에 대한 메일링 목록을 결합해서 만들 수 있다. '3장. 데이터 모델 설계를 변경할 수 없는 경우'에서 이미 다룬 것처럼 UNION을 사용하면 반복 그룹을 가진 잘못 설계된 테이블에서 '정규화' 데이터를 추출할 수 있다.

나누기

관계 대수의 나누기 연산은 몫과 나머지를 얻으려고 한 수를 다른 수로 나누는 것처럼 그리 간단하지 않다. 데이터베이스 시스템에서 한 데이터 집합을 다른 집합으로 나누면 제수 데이터 집합의 모든 멤버를 포함하는 피제수 데이터 집합에 있는 로우가 모두 반환될 것이다. 이것은 매우 유용한 측면이 있다. 예를 들어 특정한 직업에서 모든 요구 사항(자격 요건 집합2)을 만족하는 모든 지원자(자격 요건 집합1)를 찾는다고 하자. 지원자를 자격 요건으로 나눈 결과는 모든 요구 사항을 만족하는 지원자 집합이 될 것이다.

나누기 연산을 SQL로 구현한 상용 DBMS는 없지만 표준 SQL을 사용해 나누기 연산과 동등한 결과를 얻을 수 있다. 'BETTER WAY 26. 완전히 일치하는 데이터가 필요할 때는 데이터를 분할하자'에서 그 예를 소개한다.

차집합

차집합 연산은 기본적으로 한 집합에서 다른 집합을 빼는 것이다. 합집합과 교집합처럼 차집합도 컬럼이 동일하거나 유사한 두 집합을 대상으로 작업해

야 한다. DB2, SQL Server, PostgreSQL 모두 EXCEPT 키워드로 차집합 연산을 지원한다(DB2는 중복 로우를 제거하지 않는 EXCEPT ALL도 지원한다). 오라클은 MINUS 키워드를 사용한다. MySQL과 액세스는 차집합 기능을 직접 지원하지는 않지만 OUTER JOIN으로 유사하게 구현할 수 있다. 이때 차감하는 집합에서는 널 값이 나올 것이다.

스케이트보드만 주문하고 헬멧은 주문하지 않는 모든 고객을 찾아야 한다고 하자. 코드 4-3은 EXCEPT를 사용해 이 문제를 해결한 쿼리다.

코드 4-3 차집합 연산으로 문제를 해결한 쿼리

```
SELECT c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE c.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Skateboard')
EXCEPT
SELECT c2.CustFirstName, c2.CustLastName
FROM Customers AS c2
WHERE c2.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Helmet');
```

OUTER JOIN과 IS NULL 검사로 차집합 문제를 해결하는 방법은 'BETTER WAY 29. LEFT 조인의 오른쪽 데이터를 올바르게 걸러 내자'를 참고한다.

SQL이 모든 관계 대수 연산을 정확히 지원하지는 않지만, 주요 DBMS 엔진은 SQL 쿼리를 최적화하는 데 관계 대수를 사용한다. 따라서 관계 대수를 잘 이해하면 여러분의 데이터베이스 엔진이 SQL 쿼리를 실행 계획으로 변환하는 방법을 이해하는 데 도움이 될 것이다. 이 장의 나머지 항목에서는 SQL로는 직접 수행할 수 없는 관계 대수를 다룬다. 여기서 다루는 내용을 잘 이해하면 데이터베이스 엔진이 관계 대수로 내부 작업을 수행하는 내용을 다루는 'BETTER WAY 46. 실행 계획의 작동 원리를 이해하자'를 읽는 데 도움이 될 것이다.

핵심 정리

- 관계형 모델은 집합에서 수행할 수 있는 여덟 가지 연산을 정의한다.
- 주요 DBMS는 선택, 추출, 조인, 카티전 곱, 합집합 기능을 지원한다.
- 일부 DBMS는 INTERSECT와 EXCEPT 또는 MINUS 키워드를 사용해 교집합과 차집합 기능을 지원한다.
- 나누기 연산은 직접적으로 구현하지 않지만, SQL의 다른 기능을 사용해 동일한 결과를 얻을 수 있다.

BETTER WAY 23 일치하지 않거나 누락된 레코드를 찾아내자

SQL을 사용해 데이터베이스에 있는 세부 데이터를 조회하는 것이 일반적이지만 없는 데이터를 조회할 때도 종종 있다.

여러분이 한 회사의 재고를 관리한다고 가정해 보자. 이 회사는 다양한 제품을 판매하는데, 특정 제품이 얼마나 잘 팔리는지 파악하려고 판매 주문 데이터베이스에서 데이터를 추출하는 방법은 알고 있다. 그런데 잘 팔리지 않는 제품은 무엇이고, 이것은 어떻게 하면 알아낼 수 있을까?

아마도 가장 쉬운 방법은 코드 4-4와 같이 판매된 제품 목록을 뽑은 후 이 목록에 포함되지 않은 제품을 조회하면 될 것이다. 서브쿼리로 Order_Details 테이블에서 판매된 제품 목록을 조회하고, NOT IN 연산자로 이 목록에 없는 제품을 조회한다.

코드 4-4 NOT IN을 사용한 쿼리

```
SELECT p.ProductNumber, p.ProductName
FROM Products AS p
WHERE p.ProductNumber
  NOT IN (SELECT ProductNumber FROM Order_Details);
```

표 4-1은 코드 4-4의 쿼리를 실행한 결과다.

표 4-1 판매되지 않은 제품

ProductNumber	ProductName
4	Victoria Pro All Weather Tires
23	Ultra-Pro Rain Jacket

이 쿼리는 이해하기 쉽지만 실행 관점에서 효율적이지 않다. 서브쿼리에서 Order_Details 테이블 전체를 검색해 판매된 제품 목록을 추출하는데, 여기서 중복된 값을 걸러 낸 후 Products 테이블의 각 ProductNumber 값을 이 서브쿼리 목록과 일일이 비교해야 한다.

이보다 더 효율적인 방법도 있다. 그중 하나는 코드 4-5와 같이 서브쿼리가 로우를 적어도 하나는 반환하는지 확인하는 EXISTS 연산자를 사용하는 방법이다. 이제 Order_Details 테이블에 대한 서브쿼리는 특정 제품만 확인한다. 이론적으로는 EXISTS 연산자를 사용하는 것이 NOT IN보다 빠르다. 특히 서브쿼리가 반환하는 결과 집합이 클 때는 더욱 빠르다. 쿼리 엔진이 조건에 일치

하는 레코드를 발견하면 동일한 레코드에서는 이후 비교 작업을 더는 진행하지 않기 때문이다.

코드 4-5 EXISTS 연산자 사용

```
SELECT p.ProductNumber, p.ProductName
FROM Products AS p
WHERE NOT EXISTS
  (SELECT *
   FROM Order_Details AS od
   WHERE od.ProductNumber = p.ProductNumber);
```

Note ≡ 'BETTER WAY 41. 연관성 있는 서브쿼리와 연관성 없는 서브쿼리의 차이점을 파악하자'에서 어떤 경우에 연관성 있는 서브쿼리를 사용하면 좋은지 설명한다.

또 다른 방법은 코드 4-6과 같이 LEFT JOIN을 사용하고 WHERE 절에서 널 값을 찾는 것인데, 종종 '좌절성(Frustrated) 조인'이라고도 칭한다. LEFT JOIN은 보통 '왼쪽' 테이블에 있는 모든 로우를 반환할 목적으로 사용한다. 그런데 WHERE 절에서 '오른쪽' 테이블과 일치하지 않는 레코드에 해당하는 로우만 반환하는 조건을 제시하므로, WHERE 절 입장에서는 짜증이 나고 답답해 좌절할 만해서 그렇게 이름을 붙인 것이다.

코드 4-6 좌절성 조인

```
SELECT p.ProductNumber, p.ProductName
FROM Products AS p LEFT JOIN Order_Details AS od
  ON p.ProductNumber = od.ProductNumber
WHERE od.ProductNumber IS NULL;
```

불행히도 어떤 방법이 최선인지는 명확하게 답할 수 없다. DBMS 엔진마다 편향성이 다르기 때문이다. 일부(액세스와 MySQL의 구 버전)는 좌절성 조인

을 선호하고, 나머지(SQL Server)는 EXISTS를 선호한다. 'BETTER WAY 44. 사용 중인 시스템의 쿼리 분석기 사용법을 파악하자'에서 여러분이 가진 데이터를 검사하는 최상의 방법을 배울 것이다. 각 DBMS 엔진이 선호하는 바는 다르지만, 데이터가 분포된 방식의 차이로 각 DBMS 엔진이 어떤 방법을 선호하는지는 알아낼 수 있을 것이다.

한 가지 더 고려할 요소는 바로 DBMS 옵티마이저는 종종 코드 4-4의 쿼리를 코드 4-5나 코드 4-6의 쿼리로 자동 변환할 정도로 똑똑하다는 점이다. 하지만 좀 더 복잡한 쿼리에서는 이런 자동 변환 기능이 잘 작동하지 않을 것이므로 사용 중인 DBMS가 어떤 쿼리를 잘 변환하며 성능이 좋은지 자세히 파악하는 것이 좋다.

핵심 정리

- NOT IN 연산자는 이해하기는 쉽지만 일반적으로 가장 효율적인 접근 방법은 아니다.
- NOT IN보다는 NOT EXISTS 연산자를 사용하는 것이 더 빠르다.
- '좌절성 조인'이 효율적일 때도 있지만 DBMS가 널을 처리하는 방법에 따라 달라진다.
- 여러분이 처한 특정한 상황에서 최선의 방법을 찾으려면 DBMS 쿼리 분석기를 사용한다.

BETTER WAY 24 CASE로 문제를 해결해야 할 때를 파악하자

어떤 값이나 표현식이 정확한 결과를 산출하는지 검사해야 할 때 CASE를 사용한다. CASE는 IF…THEN…ELSE 문의 SQL 버전이라고 할 수 있다. 컬럼을 반환하는 SELECT 절, 검색 조건이 있는 WHERE나 HAVING 절 등 값 표현식을 사용하는 곳이라면 어디에나 CASE를 사용할 수 있다.

여러분의 고객은 주문할 때 자신의 등급에 따라 할인을 받는다고 하자. 'A' 등급은 10% 할인, 'B' 등급은 5% 할인, 'C' 등급은 할인이 없다고 한다면 고객

데이터별로 룩업(Lookup) 테이블을 만들어 세 가지 등급을 비교해서 처리해야 할 것이다. 하지만 CASE를 사용하면 등급별로 올바른 할인율을 쉽게 적용할 수 있다. 물론 룩업 테이블을 사용하면 할인율을 쉽게 수정할 수 있어 확장성 면에서 더 좋지만, 데이터를 추출할 때 항상 추가적인 조인이 필요하다.

아마도 여러분의 테이블 일부는 코드 값(성별 M이나 F 같은)을 사용하겠지만, 보고서용 데이터를 추출할 때는 단어 전체를 보여 주고 싶을 것이다. 또 고객의 국적이 다양하다면 그들의 통화에 따라 금액을 청구할 것이므로 고객에 맞게 적합한 통화 코드도 표시하고 싶을 것이다. 데이터베이스에 세계 전체 날씨 데이터가 있을 때는 섭씨와 화씨를 각각 C와 F로 사용할 것인데, 보고서에는 적절하게 변환 공식을 적용하고 싶을 것이다.

용어 정의

- **값 표현식(Value Expression)** : 리터럴(Literal), 컬럼 참조, 함수 호출, CASE 표현식, 스칼라 값을 반환하는 서브쿼리를 의미한다. 값 표현식은 데이터 타입에 따라 +, -, *, /, || 같은 연산자와 결합될 수 있다.
- **조회 조건(Search Condition)** : 서술 논리 연산 앞에 NOT과 AND나 OR를 붙인다.
- **서술 논리 연산(Predicate)** : TRUE나 FALSE를 반환하는 조건을 의미한다. 서술 논리 연산은 비교, 범위, 집합 멤버, 패턴 매칭, 널, 정량화, 존재 판별 등에 사용된다. 비교는 =, <>, <, >, <=, >=를 사용해 값 표현식 둘을 비교하는 것을 의미한다. 범위는 하나의 값 표현식과 또 다른 값 표현식 사이 또는 그 사이가 아님을 확인하는 값 표현식이다. 집합 멤버는 서브쿼리나 값 표현식 목록이 반환하는 목록 또는 그 목록이 아닌 값 표현식이다. 패턴 매칭은 패턴 문자열과 같거나 패턴 문자열과 같지 않은 값 표현식이다. 널은 NULL 키워드를 사용한(선택적으로 NOT) 값 표현식이다. 정량화는 뒤에 비교 연산자, ALL, SOME, ANY 키워드, 서브쿼리가 오는 값 표현식이다. 존재 판별은 다른 쿼리에서 반환한 값을 걸러 내는 서브쿼리에 EXISTS 키워드를 사용한 것이다.

CASE 문은 단순형과 검색형 두 가지 형태로 사용된다. 단순형 CASE 문은 값 표현식이 다른 값 표현식과 같은지 비교해 일치하면 값 표현식 하나를 반환하고, 일치하지 않으면 다른 값 표현식 하나를 반환한다. 코드 4-7은 단순형 CASE 표현식의 예제이다.

Note ≡ ISO 표준에서는 CASE 문에 WHEN IS NULL을 명시할 수 있다고 하지만, 대부분의 주요 DBMS는 이 구문을 지원하지 않는다. NULL 검사를 해야 한다면 검색형 CASE 문에서 WHEN 절에 NULLIF나 <표현식> IS NULL을 사용한다.

코드 4-7 단순형 CASE 표현식 예제

```
-- (코드를 단어로 치환하는 예제 두 개)
CASE Students.Gender
  WHEN 'M'
    THEN 'Male'
    ELSE 'Female' END

CASE Students.Gender
  WHEN 'M' THEN 'Male'
  WHEN 'F' THEN 'Female'
  ELSE 'Unknown' END

-- (섭씨 읽기를 화씨로 변환)
CASE Readings.Measure
  WHEN 'C'
    THEN (Temperature * 9 / 5) + 32
    ELSE Temperature
END

-- (고객 등급을 기준으로 할인율 반환)
CASE (SELECT Customers.Rating FROM Customers
  WHERE Customers.CustomerID = Orders.CustomerID)
WHEN 'A' THEN 0.10
WHEN 'B' THEN 0.05
ELSE 0.00 END
```

동등 검사 이외의 작업을 하고 싶거나 값 표현식 두 개 이상을 검사하고 싶다면 검색형 CASE를 사용한다. CASE 키워드 다음에 곧바로 값 표현식을 기술하는 대신 하나 이상의 검색 조건이 있는 WHERE 절을 사용하면 된다. 검색 조건은 두 값 표현식 사이에 비교 연산자를 두어 사용할 수도 있지만, 범위, 집합 멤버, 패턴 매칭, 널, 정량화 검사나 존재 여부 판별 등은 코드가 좀 더 복잡하다. 코드 4-8에서는 검색형 CASE 예제를 몇 가지 보여 준다. 데이터베이스 시스템은 TRUE 결과를 만나자마자 나머지 표현식 평가를 종료한다.

코드 4-8 검색형 CASE 표현식 예제

```
-- (성별 및 결혼 상태에 따라 인사말 생성)
CASE WHEN Students.Gender = 'M' THEN 'Mr.'
  WHEN Students.MaritalStatus = 'S' THEN 'Ms.'
  ELSE 'Mrs.' END

-- (제품 판매량에 따른 판매 등급 평가)
SELECT Products.ProductNumber, Products.ProductName,
CASE WHEN
    (SELECT SUM(QuantityOrdered)
     FROM Order_Details
     WHERE Order_Details.ProductNumber =
       Products.ProductNumber) <= 200
  THEN 'Poor'
  WHEN
    (SELECT SUM(QuantityOrdered)
     FROM Order_Details
     WHERE Order_Details.ProductNumber =
       Products.ProductNumber) <= 500
  THEN 'Average'
WHEN
    (SELECT SUM(QuantityOrdered)
     FROM Order_Details
     WHERE Order_Details.ProductNumber =
       Products.ProductNumber) <= 1000
  THEN 'Good'
  ELSE 'Excellent' END
```

```
FROM Products;

-- (직위에 따라 급여 인상 계산)
CASE Staff.Title
  WHEN 'Instructor'
  THEN ROUND(Salary * 1.05, 0)
  WHEN 'Associate Professor'
  THEN ROUND(Salary * 1.04, 0)
  WHEN 'Professor' THEN ROUND(Salary * 1.035, 0)
  ELSE Salary END
```

CASE(특히 검색형 CASE)는 어떻게 사용하느냐에 따라 그 형태가 매우 다양하다. CASE에 대한 완벽한 이해를 돕고자 완성된 SQL 문으로 예를 들어 보겠다. 코드 4-9는 생년월일을 기준으로 나이를 계산하는 문장이다(존 비아시에스와 마이클 헤르난데즈가 쓴 〈SQL Queries for Mere Mortals, Third Edition〉(Addison-Wesley, 2014)에서 발췌했다).

코드 4-9 CASE를 사용한 나이 계산

```
SELECT S.StudentID, S.LastName, S.FirstName,
   YEAR(SYSDATE) - YEAR(S.BirthDate) -
    CASE WHEN MONTH(S.BirthDate) < MONTH(SYSDATE)
      THEN 0
    WHEN MONTH(S.BirthDate) > MONTH(SYSDATE)
      THEN 1
    WHEN DAY(S.BirthDate) > DAY(SYSDATE)
      THEN 1
      ELSE 0 END AS Age
FROM Students AS S;
```

Note ≡ DB2에서는 SYSDATE가 아닌 CURRENT DATE 특수 레지스터를 사용해야 한다. 오라클에서는 YEAR 대신 EXTRACT를 사용하고, SQL Server에서는 SYSDATETIME()이나 GETDATE()를 사용한다. 액세스는 CASE 문을 지원하지 않지만 대신 IIf()와 Date() 함수를 사용해 비슷한 결과를 얻을 수 있다.

WHERE나 HAVING 절의 조건식 일부로 CASE를 사용할 수 있지만 다른 방법에 비해 그리 효율적이지는 않다. '이것이면 이렇게, 저것이면 저렇게' 형태의 조건을 여러 개 사용할 때는 문제가 될 수 있다. 예를 들어 스케이트보드는 구매했지만 헬멧은 구매하지 않은 고객 목록을 추출해야 하는 경우다. 코드 4-10은 WHERE 절에서 CASE를 사용해 해결하는 방법을 보여 준다.

> **Note** ≡ 판매 주문 샘플 데이터베이스에는 제품 이름이 Skateboard와 Helmet이 아니므로 코드 4-10에 나타낸 쿼리가 반환하는 로우는 없다. 결과를 보려면 LIKE '%Skateboard%'와 LIKE '%Helmet%'를 사용해야 한다. 여기서는 이해를 도우려고 쿼리를 수정했다.

코드 4-10 스케이트보드는 구매했지만 헬멧은 구매하지 않은 고객 찾기

```
SELECT CustomerID, CustFirstName, CustLastName
FROM Customers
WHERE (1 =
  (CASE WHEN CustomerID NOT IN
    (SELECT Orders.CustomerID
     FROM Orders
       INNER JOIN Order_Details
         ON Orders.OrderNumber = Order_Details.OrderNumber
       INNER JOIN Products
         ON Order_Details.ProductNumber
             = Products.ProductNumber
     WHERE Products.ProductName = 'Skateboard')
    THEN 0
  WHEN CustomerID IN
    (SELECT Orders.CustomerID
     FROM Orders
       INNER JOIN Order_Details
         ON Orders.OrderNumber = Order_Details.OrderNumber
       INNER JOIN Products
         ON Order_Details.ProductNumber
             = Products.ProductNumber
     WHERE Products.ProductName = 'Helmet')
    THEN 0
    ELSE 1 END));
```

먼저 스케이트보드를 구매하지 않은 고객을 없앤 후 헬멧을 구매한 고객을 없애는 식으로 쿼리가 구현되어 있다. 이어서 나오는 BETTER WAY 25에서 IN과 NOT IN을 사용해 문제를 해결하는 방법을 소개할 것이다.

핵심 정리

- IF…THEN…ELSE 문제를 해결해야 할 때 CASE만큼 강력한 도구는 없다.
- 값이 동일한지 검사할 때는 단순형을 사용하고, 복잡한 조건에는 검색형 CASE를 사용한다.
- SELECT 절의 컬럼, WHERE나 HAVING 절의 조건 일부를 포함해 값 표현식을 쓸 수 있는 곳에서는 CASE를 사용할 수 있다.

BETTER WAY 25 다중 조건 문제를 해결하는 기법을 파악하자

한 테이블에서 조건이나 복합 조건을 사용해 문제를 해결하는 것은 상대적으로 직관적인 편이다. 관계를 맺은 테이블에 적용된 조건을 기준으로 다른 테이블에 있는 로우를 반환해야 할 때는 좀 더 복잡해진다. 특히 복합 조건을 적용해야 할 때 더욱 그렇다. 한 예로 '헬멧이나 무릎 보호대를 포함해 스케이트보드를 주문한 건을 모두 찾아라' 같은 경우에는 실제 반환되는 것은 Orders 테이블의 로우이지만 조건은 Order_Details 테이블에 적용해야 한다.

'스케이트보드를 주문한 고객과 헬멧, 무릎 보호대, 장갑까지 주문한 고객을 찾아라'처럼 한 단계 수준을 높이면 더 복잡해진다. 이 문제를 해결하려면 Orders와 Order_Details 테이블에 조건을 적용함과 동시에 Customers 테이블에서 고객 정보를 뽑아야 한다.

이런 종류의 문제를 해결하는 데 사용할 수 있는 방법 몇 가지는 다음과 같다.

- IS NULL 조건과 함께 INNER JOIN이나 OUTER JOIN 사용
- 서브쿼리와 IN이나 NOT IN 사용
- 서브쿼리와 함께 EXISTS나 NOT EXISTS 사용

실제로 우량 고객을 모두 찾아보자. 스케이트보드뿐만 아니라 헬멧과 무릎 보호대, 장갑까지 구매한 고객 명단을 추출해야 한다. 판매 주문 데이터베이스의 스키마가 그림 4-4와 같이 구성되어 있다고 하자.

> **Note** ≡ 간략히 논의하려고 여기서는 제품 이름과 일치하는 데이터를 추출할 것이다. 하지만 현장에서 사용하는 데이터베이스에는 스케이트보드, 장갑, 헬멧, 무릎 보호대의 브랜드나 모델이 하나 이상일 것이므로 제품 카테고리 테이블과 조인해 제품 카테고리 이름과 일치하는 데이터를 찾아야 한다. 판매 주문 데이터베이스에 있는 실제 제품 이름도 단순한 스케이트보드, 헬멧, 무릎 보호대, 장갑이 아니므로 예제 쿼리 결과로 반환되는 로우는 없을 것이다. 결과를 얻으려면 LIKE '%Skateboard%', LIKE '%Helmet%'처럼 사용해야 한다.

그림 4-4 전형적인 판매 주문 데이터베이스 설계

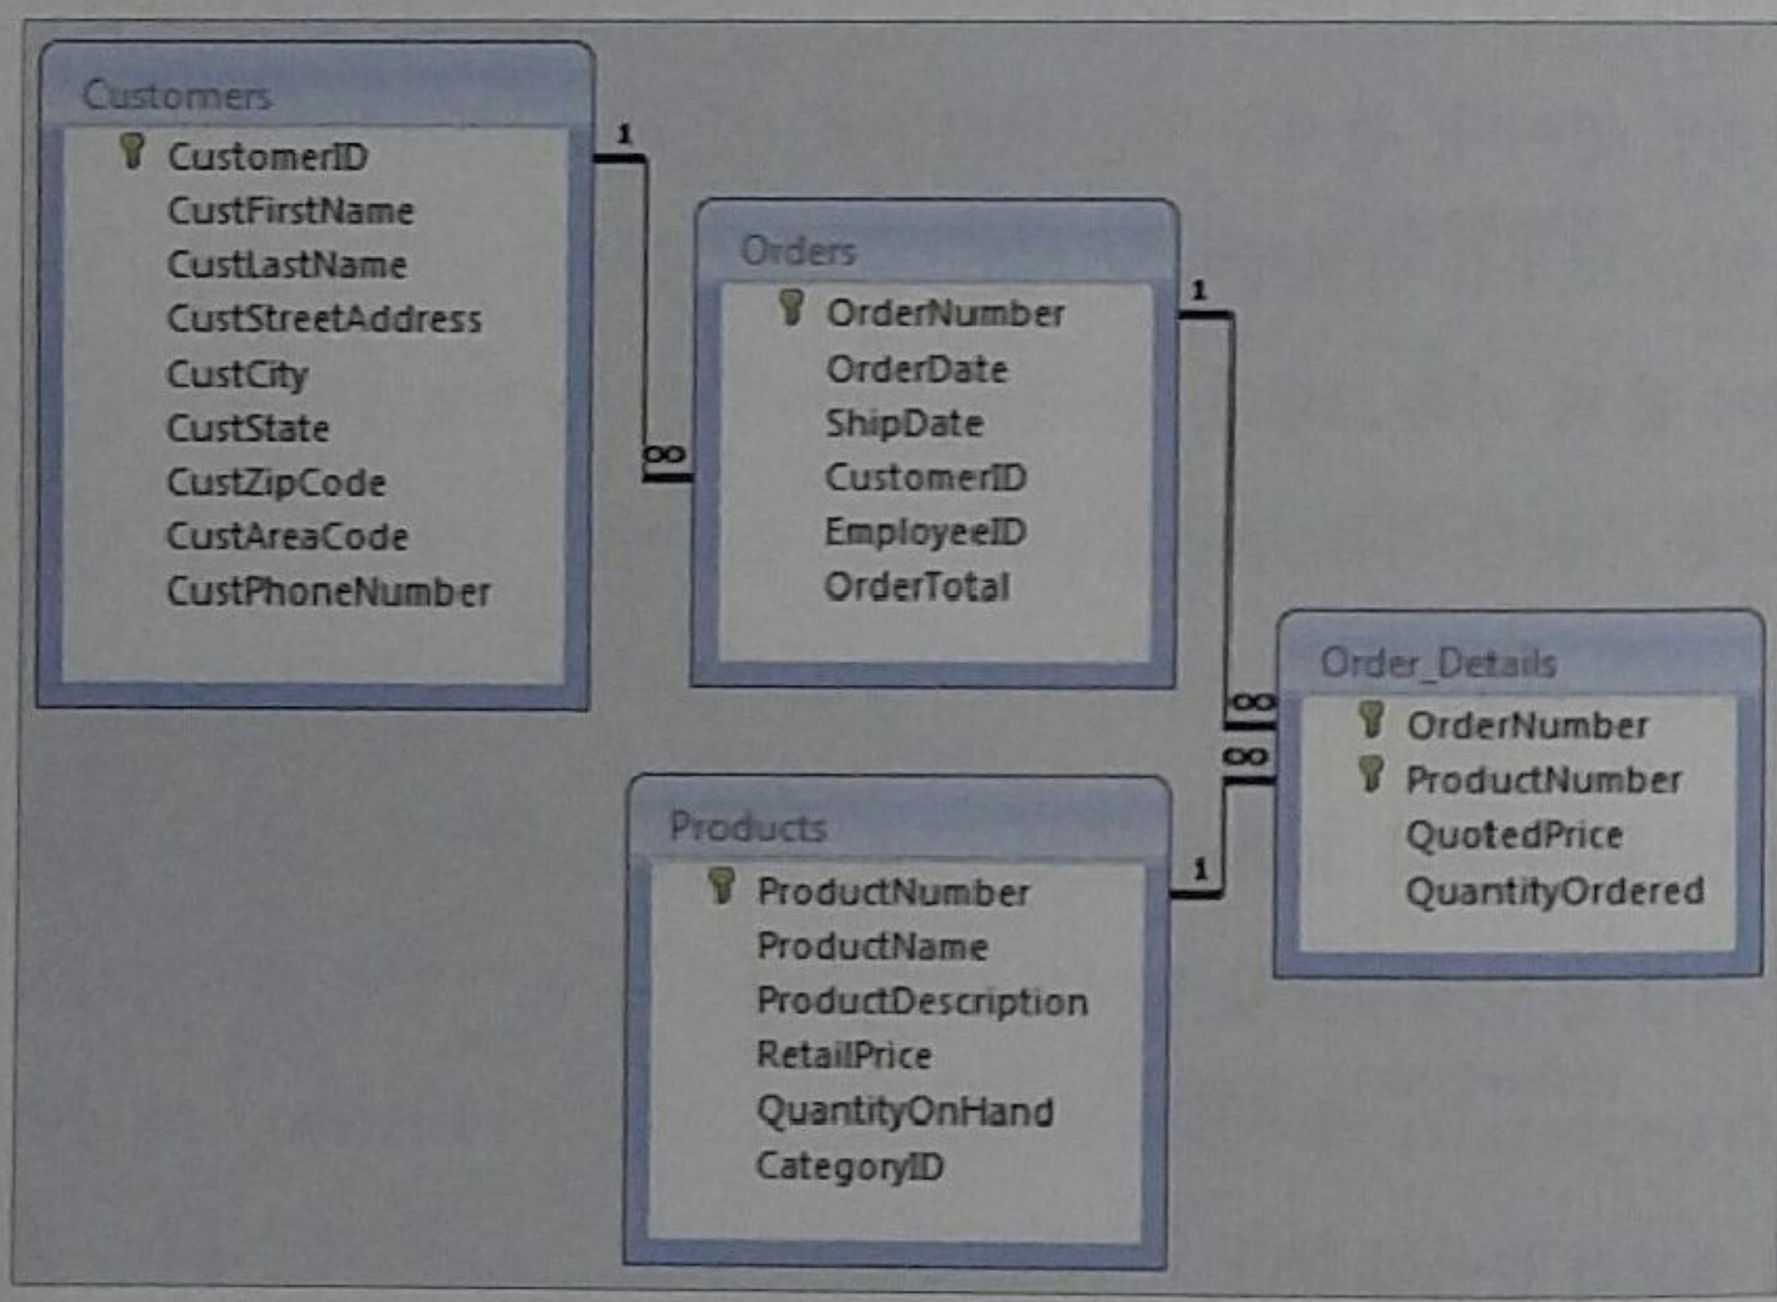

여러분은 이런 종류의 문제를 해결하려고 아마도 코드 4-11과 같은 쿼리를 작성하고 싶은 유혹에 빠질 것이다.

코드 4-11 잘못된 방식으로 작성된 쿼리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE c.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName
     IN ('Skateboard', 'Helmet', 'Knee Pads', 'Gloves'));
```

이 쿼리는 스케이트보드 또는 헬멧 또는 무릎 보호대 또는 장갑을 주문한 고객 목록을 추출하기 때문에 원하는 결과가 나오지 않을 것이다. 제대로 작성하면 SQL이 좀 더 복잡해진다. 먼저 코드 4-12와 같이 INNER JOIN을 사용해 보자.

코드 4-12 복합 조건을 처리하는 올바른 쿼리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName
FROM Customers AS c
  INNER JOIN
    (SELECT DISTINCT o.CustomerID
     FROM Orders AS o
       INNER JOIN Order_Details AS od
         ON o.OrderNumber = od.OrderNumber
       INNER JOIN Products AS p
         ON p.ProductNumber = od.ProductNumber
     WHERE p.ProductName = 'Skateboard') AS OSk
    ON c.CustomerID = OSk.CustomerID
  INNER JOIN
    (SELECT DISTINCT o.CustomerID
     FROM Orders AS o
       INNER JOIN Order_Details AS od
         ON o.OrderNumber = od.OrderNumber
       INNER JOIN Products AS p
```

```
        ON p.ProductNumber = od.ProductNumber
    WHERE p.ProductName = 'Helmet') AS OHel
  ON c.CustomerID = OHel.CustomerID
INNER JOIN
  (SELECT DISTINCT o.CustomerID
    FROM Orders AS o
      INNER JOIN Order_Details AS od
        ON o.OrderNumber = od.OrderNumber
      INNER JOIN Products AS p
        ON p.ProductNumber = od.ProductNumber
    WHERE p.ProductName = 'Knee Pads') AS OKn
  ON c.CustomerID = OKn.CustomerID
INNER JOIN
  (SELECT DISTINCT o.CustomerID
    FROM Orders AS o
      INNER JOIN Order_Details AS od
        ON o.OrderNumber = od.OrderNumber
      INNER JOIN Products AS p
        ON p.ProductNumber = od.ProductNumber
    WHERE p.ProductName = 'Gloves') AS OGl
  ON c.CustomerID = OGl.CustomerID;
```

쿼리가 훨씬 복잡하지만, 두 번째 쿼리는 올바른 결과를 반환한다. FROM 절에 서브쿼리를 네 개 추가해 네 가지 제품을 모두 구매한 고객만 찾기 때문이다. 서브쿼리에서 DISTINCT를 사용한 이유는 고객 한 명당 로우를 하나만 추출하기 위해서다. 또 코드 4-13과 같이 서브쿼리 네 개와 Customers 테이블에 대해 WHERE 절을 추가해 IN 조건을 달 수도 있다. 서브쿼리를 처리하는 부분을 함수로 만든 덕분에 마지막 SQL 문은 꽤 간단하다.

코드 4-13 함수를 사용한 처리

```
CREATE FUNCTION CustProd(@ProdName varchar(50)) RETURNS Table
AS
RETURN
  (SELECT Orders.CustomerID AS CustID
    FROM Orders
      INNER JOIN Order_Details
```

```
    ON Orders.OrderNumber
        = Order_Details.OrderNumber
INNER JOIN Products
  ON Products.ProductNumber
      = Order_Details.ProductNumber
WHERE ProductName = @ProdName);

SELECT C.CustomerID, C.CustFirstName, C.CustLastName
FROM Customers AS C
WHERE C.CustomerID IN
  (SELECT CustID FROM CustProd('Skateboard'))
AND C.CustomerID IN
  (SELECT CustID FROM CustProd('Helmet'))
AND C.CustomerID IN
  (SELECT CustID FROM CustProd('Knee Pads'))
AND C.CustomerID IN
  (SELECT CustID FROM CustProd('Gloves'));
```

마지막으로 IN과 EXISTS, 연관성 있는 서브쿼리를 사용해 이 문제를 해결할 수 있다('BETTER WAY 41. 연관성 있는 서브쿼리와 연관성 없는 서브쿼리의 차이점을 파악하자'를 참고한다). EXISTS를 사용해 WHERE 절을 구성하는 방법은 코드 4-14의 쿼리를 참조한다.

코드 4-14 EXISTS를 사용한 복합 조인 문제 처리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE EXISTS
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
   INNER JOIN Products AS p
     ON p.ProductNumber = od.ProductNumber
 WHERE p.ProductName = 'Skateboard'
   AND o.CustomerID = C.CustomerID)
AND EXISTS ...
```

관련 테이블에서 참과 거짓 조건을 여러 개 사용해 원하는 로우를 찾아야 할 때도 동일한 문제에 직면할 것이다. 스케이트보드와 함께 보호 장비를 구매한 고객을 찾는 관점에서는 이런 조건에 관심이 있겠지만, 마케팅 관점에서 판매자들은 스케이트보드만 구매한 고객에게 관심을 더 기울인다. 이들에게 보호 장비도 구매해야 한다는 마케팅 이메일이나 우편물을 발송할 수 있기 때문이다.

그럼 스케이트보드는 구매했지만 헬멧, 장갑, 무릎 보호대는 모두 구매하지 않은 고객을 찾아보자. 여러분은 아마도 코드 4-15와 같이 쿼리를 작성하고 싶은 유혹에 빠질 것이다.

코드 4-15 보호 장비를 구매하지 않은 고객 찾기

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE c.CustomerID IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName = 'Skateboard')
  AND c.CustomerID NOT IN
  (SELECT o.CustomerID
   FROM Orders AS o
     INNER JOIN Order_Details AS od
       ON o.OrderNumber = od.OrderNumber
     INNER JOIN Products AS p
       ON p.ProductNumber = od.ProductNumber
   WHERE p.ProductName
     IN ('Helmet', 'Gloves', 'Knee Pads'));
```

이 쿼리는 왜 제대로 작동하지 않을까? 이 쿼리로는 헬멧, 장갑, 무릎 보호대 중 하나라도 구매한 고객은 결과에 나오지 않을 것이다. 이전에 만든 함수를 이용해 쿼리를 다시 작성해 보자. 코드 4-16은 올바르게 작성한 쿼리다.

코드 4-16 모든 보호 장비를 구매하지 않은 고객 찾기

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName
FROM Customers AS c
WHERE c.CustomerID IN
    (SELECT CustID FROM CustProd('Skateboard'))
  AND (c.CustomerID NOT IN
    (SELECT CustID FROM CustProd('Helmet'))
  OR c.CustomerID NOT IN
    (SELECT CustID FROM CustProd('Gloves'))
  OR c.CustomerID NOT IN
    (SELECT CustID FROM CustProd('Knee Pads')));
```

WHERE 절의 첫 번째 조건은 스케이트보드를 구매한 고객을 찾는 것이고, 나머지 조건은 헬멧 또는 장갑 또는 무릎 보호대를 구매하지 않은 고객을 찾는 것이다. 자세히 보면 알 수 있듯이 뭔가가 필요할 때는 AND를 사용했고, 가능성을 포함해야 할 때는 OR를 사용했다.

핵심 정리

- 관련된 테이블을 사용해 여러 조건을 검사해야 하는 문제를 올바르게 해결하는 방법은 간단하거나 직관적이지 않다.
- 하나 이상의 관련된 자식 테이블에 한 개 이상의 조건을 적용해 부모 테이블에 있는 로우를 추출하려면 서브쿼리에 대한 널 검사(좌절성 조인), IN과 AND 또는 NOT IN과 OR를 포함한 INNER JOIN이나 OUTER JOIN을 사용해야 올바른 결과를 얻을 수 있다.

BETTER WAY 26 완전히 일치하는 데이터가 필요할 때는 데이터를 분할하자

나누기는 에드거 커드 박사가 쓴 〈The Relational Model for Database Management〉(Addison-Wesley, 2000)에 정의된 여덟 가지 집합 연산 중 하나다(다른 연산은 'BETTER WAY 22. 관계 대수와 이를 SQL로 구현하는 방법을 이해하자'를 참고한다). 이 연산은 큰 집합(피제수)을 작은 집합(제수)으로 나눠 몫을 구하는 것이다(피제수 집합의 모든 항목은 제수 집합과 완전히 일치한다).

다음을 포함해 나누기 문제를 처리할 때 나타나는 문제점이 몇 가지 있다.

- 주어진 작업에 대한 모든 요구 사항을 만족하는 작업을 모조리 찾아야 한다.
- 구성품을 만드는 데 필요한 모든 부품을 제공하는 공급자 목록을 모두 뽑아야 한다.
- 특정 집합의 제품을 주문하는 모든 고객 명단을 뽑아야 한다.

그림 4-5는 나누기 연산을 시각화한 것이다.

❮ 그림 4-5 모든 고객의 구매 제품을 관심 제품으로 나누기

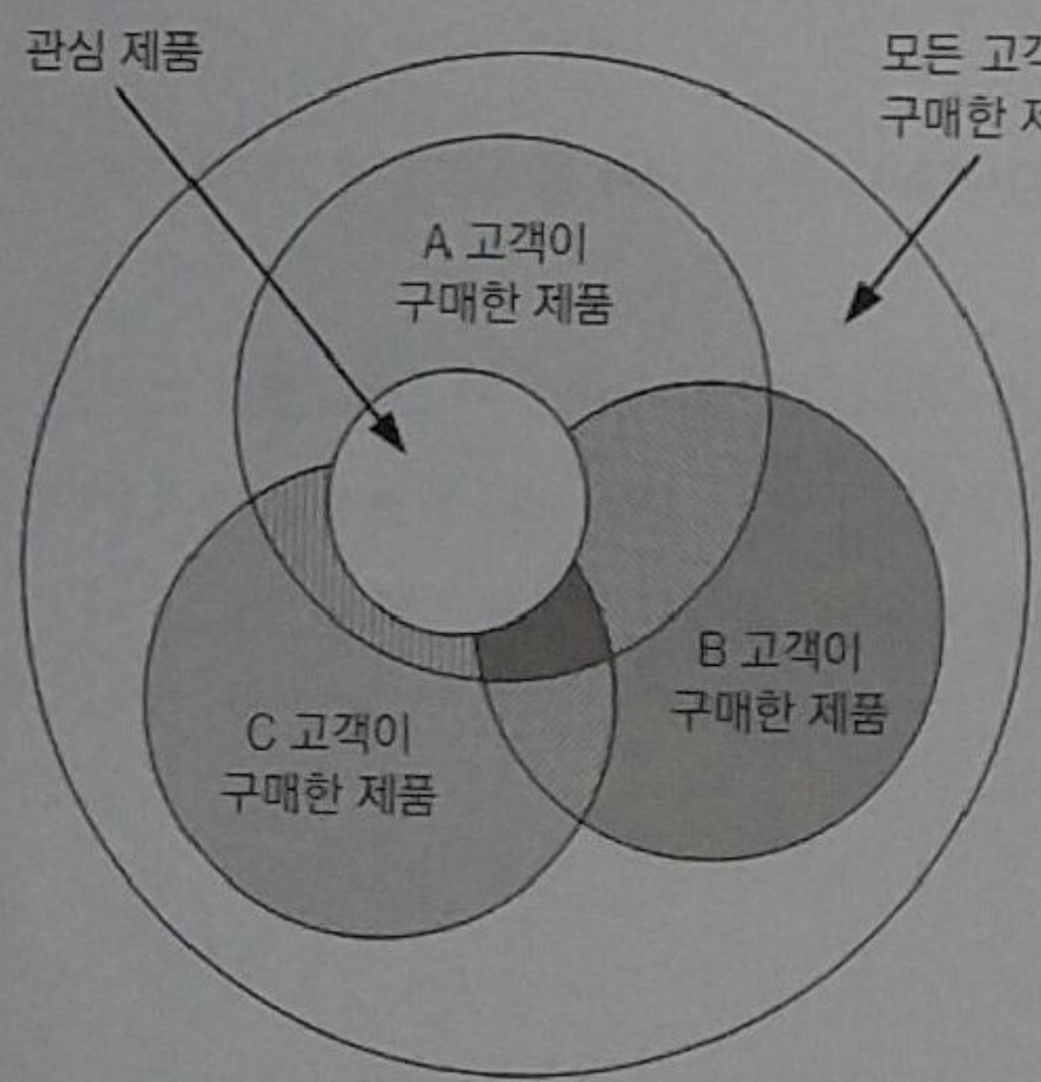

그림에서 바깥쪽 원은 고객이 구매한 모든 제품을 나타낸다. 작은 원 세 개는 특정 고객이 구매한 제품을 나타내는데, 일부 제품은 고객 세 명이 모두 구매했음을 알 수 있다. 가운데에 있는 작은 흰색 원은 해당 제품을 구매한 고객을 찾으려고 우리가 관심을 기울여야 하는 세품을 나타낸다.

이 예에서 고객 세 명은 관심 제품 집합에 있는 일부 항목을 구매했지만, A 고객은 관심 제품을 모두 구매했다. 고객이 구매한 모든 제품을 관심 제품으로 나눈 결과는 관심 제품을 모두 구매한 A 고객이다.

불행히도 이런 나누기 연산 수행은 단일 SQL 문으로 처리할 수 없고 원하는 결과를 얻으려면 몇 가지 기능을 조합해 사용해야 한다. 'BETTER WAY 25. 다중 조건 문제를 해결하는 기법을 파악하자'에서 제수 집합의 각 항목에 대한 서브쿼리와 IN을 사용해 나누기 문제를 해결하는 방법을 한 가지 선보였다. 제수 집합이 작다면 수용 가능한 방법이지만, 반대로 매우 크다면 이 방식으로는 실행이 거의 불가능할 것이다. 피제수와 제수 집합에 대해 뷰를 만들어 보자. 코드 4-17은 모든 고객과 그들이 구매한 제품이 있는 피제수 집합에 대한 뷰를 만드는 쿼리다.

코드 4-17 모든 고객과 그들의 제품에 대한 뷰 생성

```
CREATE VIEW CustomerProducts AS
SELECT DISTINCT c.CustomerID, c.CustFirstName,
  c.CustLastName, p.ProductName
FROM Customers AS c
  INNER JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
  INNER JOIN Order_Details AS od
    ON o.OrderNumber = od.OrderNumber
  INNER JOIN Products AS p
ON p.ProductNumber = od.ProductNumber;
```

한 고객이 동일 제품을 여러 번 구매한 경우 이 제품과 고객당 로우 하나만 추출하려고 DISTINCT를 사용했다.

이번에는 제수 집합(관심 제품)에 대한 뷰를 만들어 보자. 'BETTER WAY 25. 다중 조건 문제를 해결하는 기법을 파악하자'와 같이 스케이트보드, 헬멧, 장갑, 무릎 보호대를 구매한 고객을 찾아보자. 코드 4-18은 해당 뷰 생성 쿼리를 보여 준다.

코드 4-18 관심 제품을 추출하는 뷰 생성

```
CREATE VIEW ProdsOfInterest AS
SELECT Products.ProductName
FROM Products
WHERE ProductName IN
('Skateboard', 'Helmet', 'Knee Pads', 'Gloves');
```

Note ≡ 판매 주문 샘플 데이터베이스에는 제품 이름이 스케이트보드, 헬멧, 무릎 보호대, 장갑으로 되어 있지 않다. 따라서 코드 4-17~코드 4-20의 쿼리 결과로 반환되는 로우는 없을 것이다. 여기서는 이해를 도우려고 쿼리를 단순화한 것이다. 하지만 소스 파일에서 LIKE를 사용해 제품 이름을 분류 이름으로 변환하는 약간 복잡한 버전의 쿼리도 제공하니 이를 참고하자.

이번에는 원하는 결과를 얻을 수 있는 나누기 연산을 수행하는 새로운 방법을 알아보자. 이 방법은 커드 박사의 동료인 크리스 데이트(Chris Date)가 쓴 〈The Database Relational Model: A Retrospective Review and Analysis〉(Pearson, 2000)에 설명되어 있으며, 코드 4-19에서 해당 쿼리를 보여 준다.

코드 4-19 서브쿼리를 사용해 고객 제품을 관심 제품으로 나누는 쿼리

```
SELECT DISTINCT CP1.CustomerID, CP1.CustFirstName,
  CP1.CustLastName
FROM CustomerProducts AS CP1
WHERE NOT EXISTS
```

```
(SELECT ProductName
 FROM ProdsOfInterest AS PofI
 WHERE NOT EXISTS
   (SELECT CustomerID
    FROM CustomerProducts AS CP2
    WHERE CP2.CustomerID = CP1.CustomerID
      AND CP2.ProductName = PofI.ProductName));
```

간단히 말해 이 쿼리는 고객 제품에서 제품 이름과 고객 ID가 일치하는 로우가 아닌 것 중 관심 제품이 아닌 로우를 모두 추출한다. 아니라는 말을 두 번 사용해서 좀 혼동되지만, 로직은 간단한 편이다. 이 방법의 흥미로운 부수 효과는 제수 집합(이 경우 관심 제품)이 비어 있을 때 쿼리는 모든 고객 제품 로우를 반환한다는 점이다.

이번에는 GROUP BY와 HAVING 절을 이용한 다른 방법(이 방법은 조 셀코(Joe Celko)가 쓴 〈SQL for Smarties: Advanced SQL Programming, Fifth Edition〉(Morgan Kaufmann, 2014)에서 소개한 후 유명해졌다)을 살펴보자. 이 방법에서는 첫 번째 뷰에서 유일한 고객 제품을 가져오려고 DISTINCT를 사용했다는 점이 중요하다. 이 방법은 제품 개수를 사용해 문제를 해결하는데, 제품 개수가 야기한 혼란으로 구매 내역을 중복해 가져오면 안 되기 때문이다. 예를 들어 스케이트보드와 헬멧과 장갑 두 쌍을 (서로 다른 주문으로) 구매한 고객이 생성하는 로우의 개수는 네 개인데, 이 숫자는 관심 제품 뷰에 있는 로우 건수와 일치해 혼란을 줄 수 있다. DISTINCT가 없으면 무릎 보호대를 구매하지 않은 고객도 결과로 선택되는 오류가 발생한다. 두 번째 뷰에서는 제품 이름으로 Products 테이블에서 로우를 선택하므로 DISTINCT가 필요 없다. 코드 4-20에 답이 있다.

코드 4-20 GROUP BY와 HAVING 절을 사용해 두 집합 분할

```
SELECT CP.CustomerID, CP.CustFirstName, CP.CustLastName
FROM CustomerProducts AS CP
  CROSS JOIN ProdsOfInterest AS PofI
WHERE CP.ProductName = PofI.ProductName
GROUP BY CP.CustomerID, CP.CustFIrstName, CP.CustLastName
HAVING COUNT(CP.ProductName) =
  (SELECT COUNT(ProductName) FROM ProdsOfInterest);
```

기본적으로 관심 제품에 있는 로우와 일치하는 모든 고객의 제품 로우를 찾았지만, 개수를 비교해 관심 제품에 있는 제품의 로우 개수와 일치하는 로우만 추출했다. 제수 집합이 비어 있을 때 이 쿼리가 반환하는 로우의 개수는 0이며, 첫 번째 방법과는 다른 결과가 나왔음에 유의하자.

핵심 정리

- 나누기는 여덟 가지 관계형 집합 연산 중 하나이지만, SQL 표준이나 주요 데이터베이스 시스템 모두에서 DIVIDE 키워드는 지원하지 않는다.
- 나누기 방법을 이용하면 두 번째 집합에 있는 모든 로우와 일치하는 첫 번째 집합의 로우를 찾을 수 있다.
- 제수 집합에 있는 각 로우를 검사하고('BETTER WAY 25. 다중 조건 문제를 해결하는 기법을 파악하자'에서 다룬 IN을 사용한 서브쿼리), NOT EXISTS와 GROUP BY/HAVING 절을 사용해 나누기 연산을 수행할 수 있다.

BETTER WAY 27 날짜와 시간을 모두 포함하는 컬럼에서 날짜 범위를 올바르게 검색하는 방법을 알아 두자

쿼리가 반환하는 결과를 제한하는 데 WHERE 절을 사용한다. 하지만 많은 개발자가 효율적으로 날짜 범위를 검색하지 못하는 경우를 많이 보았다.

날짜와 시간 데이터를 저장하는 데 사용할 수 있는 데이터 타입은 꽤 많은데, '부록. 날짜와 시간 타입, 연산, 함수'에서 다룰 것이다. 표 4-2에는 날짜 관련 데이터 타입을 정리했다.

표 4-2 날짜와 시간 데이터 타입

DBMS	데이터 타입
DB2	TIMESTAMP
액세스	Date/Time
SQL Server	smalldatetime, datetime, datetime2, datetimeoffset
MySQL	datetime, timestamp
오라클	TIMESTAMP
PostgreSQL	TIMESTAMP

코드 4-21의 테이블을 살펴보자.

코드 4-21 데이터 정의어(DDL)로 생성한 로그 테이블

```
CREATE TABLE ProgramLogs (
  LogID int PRIMARY KEY,
  LogUserID varchar(20) NOT NULL,
  LogDate datetime NOT NULL,
  Logger varchar(50) NOT NULL,
  LogLevel varchar(10) NOT NULL,
  LogMessage varchar(1000) NOT NULL
);
```

특정 일자의 로그 메시지를 봐야 한다면, 코드 4-22와 같은 문장을 사용하고 싶은 유혹에 빠질 것이다.

코드 4-22 특정 일자의 로그 메시지를 보는 첫 번째 쿼리

```
SELECT L.LogUserID, L.Logger, L.LogLevel, L.LogMessage
FROM ProgramLogs AS L
WHERE L.LogDate = CAST('7/4/2016' AS datetime);
```

이 쿼리에는 미묘한 문제가 있다. 7월 4일(7/4) 데이터를 가져오려고 쿼리를 작성했지만, 해당 시스템이 영국으로 설정되어 있거나 언어가 프랑스어로 설정되어 있다면 어떻게 될까? 7/4는 4월 7일로도 볼 수 있다! 따라서 yyyy-mm-dd, yyyymmdd나 yyyy-mm-dd hh:mm:ss[.nnn]처럼 날짜 형식을 명확하게 기술해야 한다.

> **Note** ≡ ISO 8601 날짜 형식인 yyyy-mm-ddThh:mm:ss[.nnn]은 유효한 형식이지만, SQL 표준 일부는 아니다. 날짜와 시간에 대한 ANSI SQL 표준 형식은 yyyy-mm-dd hh:mm:ss인데, 이것은 'T' 구분자가 있는 ISO 8601과는 맞지 않는다. 모든 DBMS가 ISO 8601 형식을 지원하는 것은 아니다.

이것이 전부는 아니다. 예를 들어 마이크로소프트는 날짜에서 nnnn-nn-nn이라는 표준이 아닌 형식을 채택했다. 일반적인 날짜 형식이 dmy(일월연)라면 SQL Server는 날짜를 연도가 맨 먼저 나오는 ymd 형식으로 해석한다. 기본 날짜 형식은 시스템 설정에 따라 다르므로 언어 설정 값에 따라 2016-07-04가 2016년 4월 7일로도 해석될 수 있다. 이런 문제를 회피하려면 묵시적 날짜 변환 기능에 의존하지 말고, 명시적으로 날짜 변환 함수를 사용하는 것이 좋다. 예를 들어 코드 4-23은 코드 4-22의 쿼리를 재작성한 것이다.

코드 4-23 특정 일자의 로그 메시지를 보는 두 번째 쿼리

```
SELECT L.LogUserID, L.Logger, L.LogLevel, L.LogMessage
FROM ProgramLogs AS L
WHERE L.LogDate = CONVERT(datetime, '2016-07-04', 120);
```

> **Note** ≡ BETTER WAY 27에서 다룬 쿼리는 모두 SQL Server용이므로 여러분이 쓰는 DBMS에서 사용하려면 관련 문서를 참고해야 한다. 예를 들어 CONVERT() 함수가 없는 DBMS도 있다. SQL Server는 SQL 표준인 CAST() 함수를 지원하지만, 이 함수는 명시적인 날짜 형식을 기술하지 않는다. 120은 yyyy-mm-dd hh:mm:ss 형식을 의미한다.

이 쿼리를 실행하면 반환되는 결과가 없을 것인데, LogDate 컬럼을 datetime 타입으로 정의했으므로 날짜와 시간을 갖고 있기 때문이다. 이 쿼리에서는 시간 값을 주지 않았으므로 데이터베이스 시스템은 2016-07-04를 2016-07-04 00:00:00으로 자동 변환해 처리한다. 따라서 이 시간과 정확히 일치하는 정보가 없다면 반환되는 로우도 없을 것이다.

CAST(L.LogDate AS date)처럼 해당 컬럼에서 시간 정보를 제거할 수도 있지만, 이렇게 하면 해당 컬럼에 인덱스가 있을 때 인덱스를 사용할 수 없다(더 자세한 내용은 'BETTER WAY 28. 데이터베이스 엔진이 인덱스를 사용하도록 사거블 쿼리를 작성하자'를 참고한다).

코드 4-24에서는 인덱스를 사용하는 쿼리를 보여 준다.

코드 4-24 특정 일자의 로그 메시지를 보는 세 번째 쿼리

```
SELECT L.LogUserID, L.Logger, L.LogLevel, L.LogMessage
FROM ProgramLogs AS L
WHERE L.LogDate BETWEEN CONVERT(datetime, '2016-07-04', 120)
  AND CONVERT(datetime, '2016-07-05', 120);
```

이 쿼리의 잠재적인 문제점은 BETWEEN이 포괄적 연산자라는 것이다. 2016-07-05 00:00:00이란 데이터가 있다면 이것도 쿼리 결과에 포함될 것이다. 이것을 피하려면 코드 4-25와 같이 좀 더 정확하게 날짜와 시간 형식을 명시해야 한다.

코드 4-25 특정 일자의 로그 메시지를 보는 네 번째 쿼리

```
SELECT L.LogUserID, L.Logger, L.LogLevel, L.LogMessage
FROM ProgramLogs AS L
WHERE L.LogDate BETWEEN CONVERT(datetime, '2016-07-04', 120)
  AND CONVERT(datetime, '2016-07-04 23:59:59.999', 120);
```

하지만 이 쿼리도 문제가 있다. SQL Server에서 datetime 타입의 정확도는 3.33ms(밀리초, 1/1000초)이다. 이는 SQL Server가 2016-07-04 23:59:59.999를 2016-07-05 00:00:00.000으로 반올림한다는 의미이므로 잘못된 결과를 반환할 것이다. 좀 더 정확히 2016-07-04 23:59:59.997이라고 명시해 반올림 문제를 피할 수도 있다. 그러나 모든 datetime 필드의 정밀도가 동일한 것은 아니며, smalldatetime 타입의 컬럼은 여전히 반올림될 것이다. 또 새로운 버전이나 DBMS를 변경하면 정밀도가 달라질 가능성도 있다. 좀 더 안정적인 해결책은 코드 4-26과 같이 포괄성을 가진 BETWEEN을 사용하지 않는 것이다.

코드 4-26 특정 일자의 로그 메시지를 볼 때 추천하는 쿼리

```
SELECT L.LogUserID, L.Logger, L.LogLevel, L.LogMessage
FROM ProgramLogs AS L
WHERE L.LogDate >= CONVERT(datetime, '2016-07-04', 120)
  AND L.LogDate < CONVERT(datetime, '2016-07-05', 120);
```

이 쿼리는 고민거리를 하나 더 남겼다. 이 쿼리를 직접 실행할 때(날짜형 매개변수를 가진 저장 프로시저를 호출하는 식으로) 사용자는 종종 시작 일자와 끝 일자를 각각 2016-07-04와 2016-07-05라고 입력할 것이다. 하지만 실제로 원하는 것은 >= '2016-07-04'와 < '2016-07-06'이다. 따라서 코드 4-27과 같이 DATEADD 함수를 사용해 쿼리를 작성하는 습관을 들이면 좋다.

코드 4-27 사용자 입력으로 제공되는 끝 일자 개선

```
WHERE L.LogDate >=
    CONVERT(datetime, @startDate, 120)
  AND L.LogDate <
    CONVERT(datetime, DATEADD(DAY, 1, @endDate) 120);
```

핵심은 DBMS의 날짜 구현 방식에 의존하기보다는 DATEADD나 DBMS가 제공하는 대용 함수를 사용해 명확히 정의된 방식으로 날짜를 연산하고, 사용자나 소프트웨어 프로그램이 끝 일자를 해석하는 방식의 차이를 보정하는 것이다.

핵심 정리

- 묵시적 날짜 변환에 의존하지 말고 명시적으로 날짜 변환 함수를 사용한다.
- 인덱스를 사용하지 못하므로 datetime 타입의 컬럼에 직접 함수를 사용하지 않는다.
- datetime 값은 반올림 오류가 있음을 기억하자. BETWEEN 대신 >=, <= 연산자를 사용한다.

BETTER WAY 28 데이터베이스 엔진이 인덱스를 사용하도록 사거블 쿼리를 작성하자

'BETTER WAY 11. 인덱스와 데이터 스캔을 최소화하도록 인덱스는 신중히 만들자'에서 쿼리 성능을 향상하려면 적절한 인덱스를 만드는 것이 왜 중요한지 강조했다. 하지만 인덱스만으로는 부족하다. DBMS 엔진이 인덱스를 잘 활용하려면 쿼리의 서술 논리절(WHERE, ORDER BY, GROUP BY, HAVING 절)이 인덱스를 사용해야 하는데, 이것을 사거블(Search ARGument ABLE, Sargable)이라는 용어로 표현한다. 따라서 쿼리가 사거블이 되지 않는 이유를 이해하는 것이 중요하다.

Note ≡ DB2는 버전1과 버전2에서 사거블과 넌사거블(Non-sargable)을 사용했지만, 이 용어는 더 이상 사용되지 않는다. 대신 Stage1과 Stage2라는 용어를 사용하는데 Stage1이 Stage2를 능가한다. 따라서 DB2 버전에 따라 Stage2에서 Stage1로 변경할 때가 종종 있다.

비교하려는 값에 따라 일반적으로 사거블 쿼리를 만드는 연산자는 다음과 같다.

- =
- >
- <
- >=
- <=
- BETWEEN
- LIKE(검색 문자열 앞에 %를 붙이지 않을 때)
- IS [NOT] NULL

다음 연산자는 사거블이지만 성능 향상 목적으로는 좀처럼 사용하지 않는다.

- <>
- IN
- OR
- NOT IN
- NOT EXISTS
- NOT LIKE

인덱스를 사용하지 못할 때는 다음과 같다.*

- WHERE 절 조건에서 한 개 이상의 필드에 대해 연산하는 함수를 사용하는 쿼리(각 로우에서 함수가 연산을 수행하므로 인덱스 자체에 동일한 함수가 포함되어 있지 않다면 쿼리 옵티마이저는 인덱스를 사용하지 않을 것이다.)
- WHERE 절에서 필드에 대해 수치 연산을 하는 경우
- LIKE '%something%'처럼 %를 사용하는 경우

* SELECT 절에서 넌사거블 표현식을 사용할 수 있는데, 그렇다 하더라도 성능에 악영향을 주지 않는다.

코드 4-28의 Employees 테이블을 살펴보자. 이 테이블의 각 필드에서 인덱스를 만든다.

코드 4-28 DDL을 이용한 테이블과 인덱스 생성

```
CREATE TABLE Employees (
  EmployeeID int IDENTITY (1, 1) PRIMARY KEY,
  EmpFirstName varchar(25) NULL,
  EmpLastName varchar(25) NULL,
  EmpDOB date NULL,
  EmpSalary decimal(15,2) NULL
);

CREATE INDEX [EmpFirstName]
  ON [Employees]([EmpFirstName] ASC);

CREATE INDEX [EmpLastName]
  ON [Employees]([EmpLastName] ASC);

CREATE INDEX [EmpDOB]
  ON [Employees]([EmpDOB] ASC);

CREATE INDEX [EmpSalary]
  ON [Employees]([EmpSalary] ASC);
```

코드 4-29는 특정 연도에 태어난 직원만 조회하는 넌사거블 방식의 쿼리다. 어떤 로우가 조건에 맞는지 확인하려고 각 로우에서 YEAR 함수를 호출해 비교하기에 인덱스를 사용하지 못하는 것이다. 이때는 EmpDOB 컬럼에 만든 인덱스는 사용하지 않는다.

코드 4-29 특정 연도 데이터를 조회하는 넌사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE YEAR(EmpDOB) = 1950;
```

Note ≡ 오라클은 YEAR() 함수를 제공하지 않으므로 EXTRACT(year FROM EmpDOB)처럼 작성해야 한다.

코드 4-30은 사거블 방식으로 동일한 데이터를 조회하는 쿼리다.

코드 4-30 특정 연도 데이터를 조회하는 사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpDOB >= CAST('1950-01-01' AS Date)
  AND EmpDOB < CAST('1951-01-01' AS Date);
```

코드 4-31은 성(姓)이 특정 문자로 시작하는 직원을 조회하는 넌사거블 쿼리다.

코드 4-31 특정 글자로 시작하는 데이터를 조회하는 넌사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE LEFT(EmpLastName, 1) = 'S';
```

Note ≡ 오라클은 LEFT() 함수를 제공하지 않으므로 SUBSTR(EmpLastName, 1, 1)처럼 사용해야 한다.

코드 4-32는 사거블 방식으로 동일하게 처리하는 쿼리다. 코드에서는 와일드카드 문자 %가 검색 문자열 뒤에만 붙어 있는데, LIKE 연산자를 사용했어도 넌사거블 쿼리가 되지 않는다는 점에 주목하자. 그렇다고 항상 인덱스를 사용한다고 보장하지는 못한다.

코드 4-32 특정 문자로 시작되는 데이터를 조회하는 사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpLastName LIKE 'S%';
```

코드 4-33은 IsNull() 함수를 사용한 넌사거블 쿼리다.

코드 4-33 NULL 허용 컬럼에서 특정 이름을 찾는 넌사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE IsNull(EmpLastName, 'Viescas') = 'Viescas';
```

Note ≡ IsNull()은 SQL Server 함수다. 오라클에서는 NVL() 함수를 사용하고, DB2와 MySQL에서는 IFNULL() 함수를 사용한다. 또 다른 방법은 COALESCE() 함수를 사용하는 것이다.

코드 4-34는 동일한 쿼리를 사거블 방식으로 처리한 것이다.

코드 4-34 NULL 허용 컬럼에서 특정 이름을 찾는 사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpLastName = 'Viescas'
  OR EmpLastName IS NULL;
```

사실 OR를 사용하면 EmpLastName 컬럼에 있는 인덱스를 사용하지 못할 수도 있다. 따라서 코드 4-35의 쿼리가 더 안전하다고 할 수 있다. 특히 검색 값과 널에 대해 별도로 필터링된 인덱스가 있을 때는 더욱 그렇다.

코드 4-35 널 허용 컬럼에서 특정 이름을 찾는 개선된 사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpLastName = 'Viescas'
UNION ALL
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpLastName IS NULL;
```

코드 4-36에서 다루는 쿼리는 해당 필드에서 계산을 수행하므로 넌사거블 쿼리다. EmpSalary 컬럼의 인덱스는 사용되지 않으며, 이 계산은 테이블에 있는 모든 로우에서 수행한다.

코드 4-36 값을 계산해 결과를 찾는 넌사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpSalary * 1.10 > 100000;
```

하지만 이런 계산에 필드가 포함되어 있지 않으면 코드 4-37과 같이 사거블 쿼리가 된다.

코드 4-37 계산 값을 찾는 사거블 쿼리

```
SELECT EmployeeID, EmpFirstName, EmpLastName
FROM Employees
WHERE EmpSalary > 100000/1.10;
```

아쉽게도 LIKE '%something%'를 사거블 쿼리로 만드는 방법은 없다.

핵심 정리

- 넌사거블 연산자를 사용하지 않는다.
- WHERE 절에서 하나 이상의 필드에 대해 연산하는 함수를 사용하지 않는다.

- WHERE 절에서 필드에 대한 수치 연산을 수행하지 않는다.
- LIKE 연산자를 사용할 때 % 문자는 검색 문자열 끝에 붙인다('%something'이나 'some%thing'처럼 사용하지 않는다).

BETTER WAY 29 LEFT 조인의 오른쪽 데이터를 올바르게 걸러 내자

주문을 한 건도 하지 않은 고객을 조회하려면 SQL에서 차집합 연산(다시 말해 집합2가 아닌 집합1의 데이터를 반환)을 수행해야 하는데, OUTER JOIN과 IS NULL을 조합해 사용하면 된다. 예를 들어 주문을 한 건도 하지 않은 고객을 모두 찾으려면 Customers LEFT OUTER JOIN Orders와 Orders 테이블의 기본 키에 널 값 검사 조건을 달아야 한다. 즉, 주문 고객 집합에 속하지 않는 고객을 찾으려면 전체 고객 집합에서 주문 고객 집합을 빼면 된다.

> Note ≡ 'BETTER WAY 22. 관계 대수와 이를 SQL로 구현하는 방법을 이해하자'에서 다른 관계형 연산자를 자세히 설명했다.

더 큰 데이터 집합(기본적으로 'LEFT' 조인의 '오른쪽'에 있는 집합이나 테이블, 또는 그 반대)에서 차감하는 결과 집합에 조건을 달 때는 실수를 저지르기 쉽다. Customers LEFT JOIN Order 조인의 왼쪽은 Customers 테이블이고, 오른쪽은 Orders 테이블이다. 다음 문제를 생각해 보자.

모든 고객과 2015년 4/4분기 동안 주문한 고객의 정보를 조회하라.

아마도 코드 4-38과 같이 쿼리를 작성하고 싶은 유혹에 빠질 것이다.

코드 4-38 모든 고객과 일부 주문을 보여 주는 첫 번째 쿼리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  o.OrderNumber, o.OrderDate, o.OrderTotal
FROM Customers AS c
```

```
  LEFT JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
WHERE o.OrderDate BETWEEN CAST('2015-10-01' AS DATE)
AND CAST('2015-12-31' AS DATE);
```

Note ≡ BETTER WAY 29에서 사용하는 SQL은 ISO 표준이다. 다른 형태의 SQL은 여러분이 사용하는 데이터베이스 관련 문서를 참고한다. 예를 들어 여러분의 데이터베이스에서 CAST() 함수를 지원하지 않을 수도 있다.

이 쿼리를 실행하면 모든 로우에 있는 주문 데이터가 조회되는데, 고객 일부가 빠져 있을 것이다. 이렇게 '빠진' 정보를 검색하려면 널 검사 조건을 달아야 하는데, 방법은 코드 4-39와 같다.

코드 4-39 모든 고객과 일부 주문을 보여 주는 두 번째 쿼리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  o.OrderNumber, o.OrderDate, o.OrderTotal
FROM Customers AS c
  LEFT JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
WHERE (o.OrderDate BETWEEN CAST('2015-10-01' AS DATE)
    AND CAST('2015-12-31' AS DATE))
  OR o.OrderNumber IS NULL;
```

두 번째 쿼리의 결과가 좀 더 나아 보이지만, 여전히 모든 고객 로우를 보여주는 것은 아니다.

데이터베이스 엔진은 먼저 FROM 절을 처리한 후 WHERE 절을 적용하고, 마지막으로 SELECT 절에 명시한 컬럼을 반환한다. Customers LEFT JOIN Orders는 모든 고객 로우와 Orders 테이블에서 일치하는 로우를 반환한다. WHERE 절이 적용되면 주문하지 않은 고객은 제거된다. 이런 고객은 Orders 테이블에서 가져온 컬럼 값이 널이기 때문이다. NULL은 어떤 값과도 비교할 수 없으므로 날

짜 범위로 데이터를 걸러 내어 이런 로우를 제거한다. 따라서 코드 4-38의 쿼리는 특정 날짜 범위 내에 주문한 고객을 반환하는데, INNER JOIN을 사용한 결과와 동일하다.

코드 4-39의 쿼리에서는 해당 날짜 범위에 속한 주문뿐만 아니라 모든 고객 정보를 가져오려고 OrderNumber 컬럼 값이 널인 로우까지도 추출한다. 사실 FROM 절에 따라 반환되는 집합에 모든 고객이 담겨 있다. 고객이 주문하면 Orders 테이블의 해당 컬럼은 널 값이 아닐 것이다. 고객이 전혀 주문하지 않으면 이 쿼리는 해당 고객에게 대응해 Orders 테이블에서 가져온 컬럼 값이 널인 로우 하나를 정확히 반환한다.

따라서 코드 4-39의 쿼리는 주문하지 않은 모든 고객과 2015년 마지막 분기에 주문한 고객 정보를 반환한다. 마지막 분기 이전에 주문한 고객은 나타나지 않는다. 날짜 조건에서 이런 로우를 제거하기 때문이다.

올바른 해결책은 차감하려는 집합과 조인하기 전에 차감 집합에 대해 조건 검색을 하는 것이다. 코드 4-40과 같이 FROM 절에서 SELECT 문을 사용해 (SQL 표준에서는 이를 파생(Derived) 테이블이라고 한다) 조건 검색한 집합을 미리 계산해 놓으면 된다.

코드 4-40 모든 고객과 주문 정보 일부를 올바르게 검색하는 쿼리

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  OFil.OrderNumber, OFil.OrderDate, OFil.OrderTotal
FROM Customers AS c
  LEFT JOIN
   (SELECT o.OrderNumber, o.CustomerID,
     o.OrderDate, o.OrderTotal
    FROM Orders AS o
    WHERE o.OrderDate BETWEEN CAST('2015-10-01' AS DATE)
     AND CAST('2015-12-31' AS DATE)) AS OFil
   ON c.CustomerID = OFil.CustomerID;
```

논리적으로 보면, 코드 4-40의 쿼리는 먼저 두 날짜 사이의 주문 집합을 가져온 후 Customers 테이블과 조인한다. 이 쿼리는 모든 고객을 반환하지 않는다. 특정 기간에 주문하지 않은 고객은 OFil 서브쿼리의 결과 컬럼 값이 널이다. 2015년 마지막 분기에 주문하지 않은 고객만 추출하려면 ON 절 다음 WHERE 절에서 NULL을 검사하는 조건을 추가한다.

핵심 정리

- SQL에서 차감 연산을 할 때는 OUTER JOIN을 사용한다.
- LEFT 조인의 오른쪽에 대해 (또는 그 반대로) 밖에 있는 WHERE 절에서 필터 조건을 적용하면 원하는 결과를 얻지 못한다.
- 걸러 낸 부분 집합을 제대로 차감하려면, 데이터베이스 시스템이 외부 조인을 수행하기 전에 데이터를 걸러 내야 한다.

CHAPTER

5

집계

초창기부터 SQL 표준은 데이터 집계 기능을 지원했다. 집계 기능은 보고서 데이터를 생성하는 데 유용하다. 하지만 뭔가를 집계할 때 '이것부터 저것까지 데이터가 필요한데, 그중 x, y 또는 z 데이터만 필요하다'고 말하는 것만으로는 충분하지 않다. '이것과 저것'에 전체 합계를 요구하는 것으로는 부족하고 '고객별 전체', '일별 주문 수', '부문별 월평균 매출액'처럼 요구하는 것이 일반적이다. 여기서 '~별'이란 단어에 주의한다. 이 장에서는 이런 종류의 질문을 처리하는 GROUP BY와 HAVING 절을 살펴볼 것이다. 또 집계 쿼리를 작성하면서 저지르기 쉬운 실수를 줄이고 성능을 가장 좋게 하는 기법도 다룰 것이다. 마지막으로 좀 더 복잡한 집계 작업을 처리할 수 있는 기능에 대한 증가된 요구의 해결책으로 SQL 표준협회에서 내놓은 윈도우 함수도 살펴볼 것이다. 이것은 '데이터베이스에서 데이터를 추출해 스프레드시트로 옮겨 놓고 데이터를 이리저리 조작하자'는 요구를 반영한 것이다. 데이터 크기가 폭발적으로 증가하는 요즘 상황에서 이런 기능은 바람직하거나 실용적이지 않을 수도 있다. 이 때문에 SQL로 집계 작업을 처리할 때 나타나는 장단점을 파악하는 것이 중요하다.

BETTER WAY 30 GROUP BY 절의 작동 원리를 이해하자

특정 유형으로 집계하려면 데이터를 분할해 그룹(그루핑 컬럼을 동일한 값별로 묶은 로우의 집합)으로 묶어야 할 때가 종종 있는데, GROUP BY 절(필요에 따라 HAVING 절이 오기도 한다)로 구현할 수 있다. 하지만 집계하는 쿼리를 올바르게 작성하는 방법은 다소 혼동될 수 있다. 코드 5-1은 SQL SELECT 문에서 사용하는 일반적인 구문이다.

코드 5-1 SELECT 문의 집계 쿼리 구문

```
SELECT select_list
FROM table_source
[WHERE search_condition ]
[GROUP BY group_by_expression ]
[HAVING search_condition ]
[ORDER BY order_expression [ ASC | DESC ] ]
```

Note ≡ ISO SQL 표준에는 FROM 절이 없는 SELECT 문은 표준에 부합하지 않는다고 명시하지만, 많은 DBMS에서 FROM 절을 옵션 항목으로 허용한다.

집계 쿼리가 작동하는 순서는 다음과 같다.

1. FROM 절에서 데이터 집합을 만든다.
2. WHERE 절은 FROM 절에서 만든 데이터 집합을 조건에 맞게 걸러 낸다.
3. GROUP BY 절은 WHERE 절에서 필터링한(조건에 맞는 데이터를 걸러 낸) 데이터 집합을 집계한다.
4. HAVING 절은 GROUP BY 절에서 집계한 데이터 집합을 다시 조건에 맞게 필터링한다.
5. SELECT 절은 집계하고 필터링한 데이터 집합을 변환(보통 집계 함수로 처리)한다.
6. ORDER BY 절은 변환된 데이터 집합을 정렬한다.

GROUP BY 절에 기술된 컬럼을 그루핑 컬럼이라고 하는데, 이 컬럼들이 SELECT 절에 꼭 포함되어야 하는 것은 아니다(그루핑된 값들이 보이지 않으면 결과가 이상하게 보이기는 한다!). 그리고 GROUP BY 절에서는 컬럼 별칭을 사용할 수 없다.

SELECT 절에는 있지만 GROUP BY 절에는 기술되지 않은 컬럼들은 반드시 집계 함수를 사용(계산 결과가 집계나 상수 형태로 나올 수도 있지만)해야 한다. 집계 함수는 일련의 값 집합에서 계산을 수행하고 단일 값을 반환하는 결정적 함수다('1장. 데이터 모델 설계'의 '결정적 함수와 비결정적 함수'를 참고한다). 이때 계산이 수행된 값 집합은 GROUP BY 절의 결과가 된다. 각 그룹에서는 한 개 이상의 집계 함수를 사용할 수 있는데, 해당 그룹에 있는 모든 로우에 대해 계산을 수행한다(집계 함수를 하나도 사용하지 않을 때 GROUP BY 절은 SELECT DISTINCT와 동일하게 수행된다).

ISO SQL 표준은 다수의 집계 함수를 정의하는데, 대표적인 함수는 다음과 같다.

- COUNT() : 집합이나 그룹에 있는 로우의 개수를 반환한다.
- SUM() : 집합이나 그룹에 있는 값의 합계를 반환한다.
- AVG() : 집합이나 그룹에 있는 수치 값들의 평균을 반환한다.
- MIN() : 집합이나 그룹에 있는 가장 작은 값을 반환한다.
- MAX() : 집합이나 그룹에 있는 가장 큰 값을 반환한다.
- VAR_POP()와 VAR_SAMP() : 집합이나 그룹에 있는 특정 컬럼에 대한 모 분산과 표본 분산 값을 반환한다.
- STDDEV_POP()와 STDDEV_SAMP() : 집합이나 그룹에 있는 특정 컬럼에 대한 모 표준 편차와 표본 표준 편차 값을 반환한다.

SELECT 절에 기술한 컬럼의 형태는 GROUP BY 절에 있는 컬럼의 형태에 영향을 준다. 집계 함수에서 사용되지 않은 SELECT 절의 컬럼은 반드시 GROUP BY 절에서 사용해야 하기 때문이다. 코드 5-2는 그루핑을 할 때 SELECT 절에서 사용할 수 있는 컬럼 형태의 예제이다.

코드 5-2 올바른 GROUP BY 절 사용

```
SELECT ColumnA, ColumnB
FROM Table1 GROUP BY ColumnA, ColumnB;

SELECT ColumnA + ColumnB
FROM Table1 GROUP BY ColumnA, ColumnB;

SELECT ColumnA + ColumnB
FROM Table1 GROUP BY ColumnA + ColumnB;

SELECT ColumnA + ColumnB + 상수
FROM Table1 GROUP BY ColumnA, ColumnB;

SELECT ColumnA + ColumnB + 상수
FROM Table1 GROUP BY ColumnA + ColumnB;

SELECT ColumnA + 상수 + ColumnB
FROM Table1 GROUP BY ColumnA, ColumnB;
```

하지만 코드 5-3과 같이 SELECT 절의 컬럼 표시 형태와 그루핑이 일치하지 않으면 그루핑은 허용되지 않는다.

코드 5-3 잘못 사용된 GROUP BY 절

```
SELECT ColumnA, ColumnB
FROM Table1 GROUP BY ColumnA + ColumnB;

SELECT ColumnA + 상수 + ColumnB
FROM Table1 GROUP BY ColumnA + ColumnB;
```

ISO SQL 표준에 따르면 GROUP BY 절은 결과 집합을 정렬하지 않고, 정렬하려면 ORDER BY 절을 사용해야 한다. 사실 대부분의 DBMS는 별도로 순서를 지정하지 않으면 GROUP BY 절에 사용된 컬럼에서 임시로 인덱스를 생성한 후 GROUP BY 절에 있는 컬럼 순서대로 정렬해 결과를 반환한다. 하지만 결과 집합의 순서가 중요할 때는 반드시 원하는 순서대로 정렬하도록 ORDER BY 절을 기술해야 한다.

가능하면 데이터는 WHERE 절을 사용해 필터링한다. 집계 대상의 데이터양을 줄여 주기 때문이다. 집계된 결과에서 다시 필터링할 때는 HAVING Count(*) > 5나 HAVING Sum(Price) < 100처럼 HAVING 절을 사용해야 한다.

ROLLUP, CUBE, GROUPING SETS 기능을 사용하면 좀 더 복잡한 형태의 그루핑 연산을 수행할 수 있다. 이들은 각 특정 그루핑 집합별로 집계 계산을 수행하고 이 특정 그룹별로 데이터를 분리해 FROM과 WHERE 절에 따라 선택된 데이터를 집계한다. 그루핑 집합을 명시하지 않으면 집계 쿼리에서 GROUP BY 절을 포함하지 않은 것처럼 모든 로우가 단일 그룹으로 집계된다.

> Note ≡ 액세스와 MySQL을 포함해 몇몇 제품은 ROLLUP과 CUBE 기능을 사용한 그루핑을 지원하지 않는다.

샘플 쿼리로 사용할 표 5-1의 데이터를 살펴보자.

표 5-1 재고 데이터

Color	Dimension	Quantity
Red	L	10
Blue	M	20
Red	M	15
Blue	L	5

ROLLUP을 사용하면 한 그룹에 있는 컬럼 집합별로 집계 값을 추가로 얻을 수 있다. 표 5-2는 코드 5-4의 쿼리를 실행한 결과다.

코드 5-4 ROLLUP을 사용한 쿼리

```
SELECT Color, Dimension, SUM(Quantity)
FROM Inventory
GROUP BY ROLLUP (Color, Dimension);
```

표 5-2 ROLLUP을 사용한 집계 결과

Color	Dimension	Quantity
Blue	L	5
Blue	M	20
Blue	NULL	25
Red	L	10
Red	M	15
Red	NULL	25
NULL	NULL	50

색상별 총 수량과 전체 수량을 얻었다. 하지만 치수(Dimension)별 총 수량은 얻지 못했는데 이는 ROLLUP이 오른쪽에서 왼쪽으로 연산하기 때문이다. 추가로 집계하려면 CUBE를 사용한다. 표 5-3은 코드 5-5의 쿼리를 실행한 결과다.

코드 5-5 CUBE를 사용한 쿼리

```
SELECT Color, Dimension, SUM(Quantity)
FROM Inventory
GROUP BY CUBE (Color, Dimension);
```

▼표 5-3 CUBE를 사용한 집계 결과

Color	Dimension	Quantity
Red	M	15
Red	L	10
Red	NULL	25
Blue	M	20
Blue	L	5
Blue	NULL	25
NULL	M	35
NULL	L	15
NULL	NULL	50

마지막으로 집계 연산을 좀 더 확장해 추가적인 그루핑을 수행하고 싶다면 GROUPING SETS를 사용한다. 코드 5-6의 SQL 문을 사용해 표 5-4의 결과를 얻을 수 있다. 이 SQL 문에는 Color, Dimension, 빈 집합(전체 합계가 결과로 나온다) 이렇게 독립적인 그루핑 집합이 세 개 있다.

코드 5-6 GROUPING SETS를 사용한 쿼리

```
SELECT Color, Dimension, SUM(Quantity)
FROM Inventory
GROUP BY GROUPING SETS ((Color), (Dimension), ());
```

▼표 5-4 GROUPING SETS를 사용한 결과 데이터

Color	Dimension	Quantity
Red	NULL	25
Blue	NULL	25
NULL	L	15
NULL	M	35
NULL	NULL	50

ROLLUP, CUBE와 달리 모든 조합에서 원하는 값을 산출하려고 그루핑할 항목을 정확히 명시했다는 점에 주목하자. 본질적으로 ROLLUP과 CUBE뿐만 아니라 GROUPING SETS는 쿼리 하나로 여러 쿼리를 UNION으로 연결한 것과 동일한 결과를 산출한다. 코드 5-7은 코드 5-5에 있는 쿼리와 동일한 결과를 얻으려고 단순한 GROUP BY 문을 UNION으로 연결한 쿼리다.

코드 5-7 GROUPING SETS 대신 단순한 GROUP BY 사용

```
SELECT Color, NULL AS Dimension, SUM(Quantity)
FROM Inventory
GROUP BY Color
UNION
SELECT NULL, Dimension, SUM(Quantity)
FROM Inventory
GROUP BY Dimension
UNION
SELECT NULL, NULL, SUM(Quantity)
FROM Inventory;
```

액세스에서는 ROLLUP, CUBE, GROUPING SETS를 사용할 수 없다. 액세스는 그리드에 조건을 추가할 때마다 기본으로 HAVING 절이 사용된다. 그림 5-1의 쿼리를 SQL 문으로 변환하면 코드 5-8과 같다.

그림 5-1 액세스에서 집계 쿼리 생성

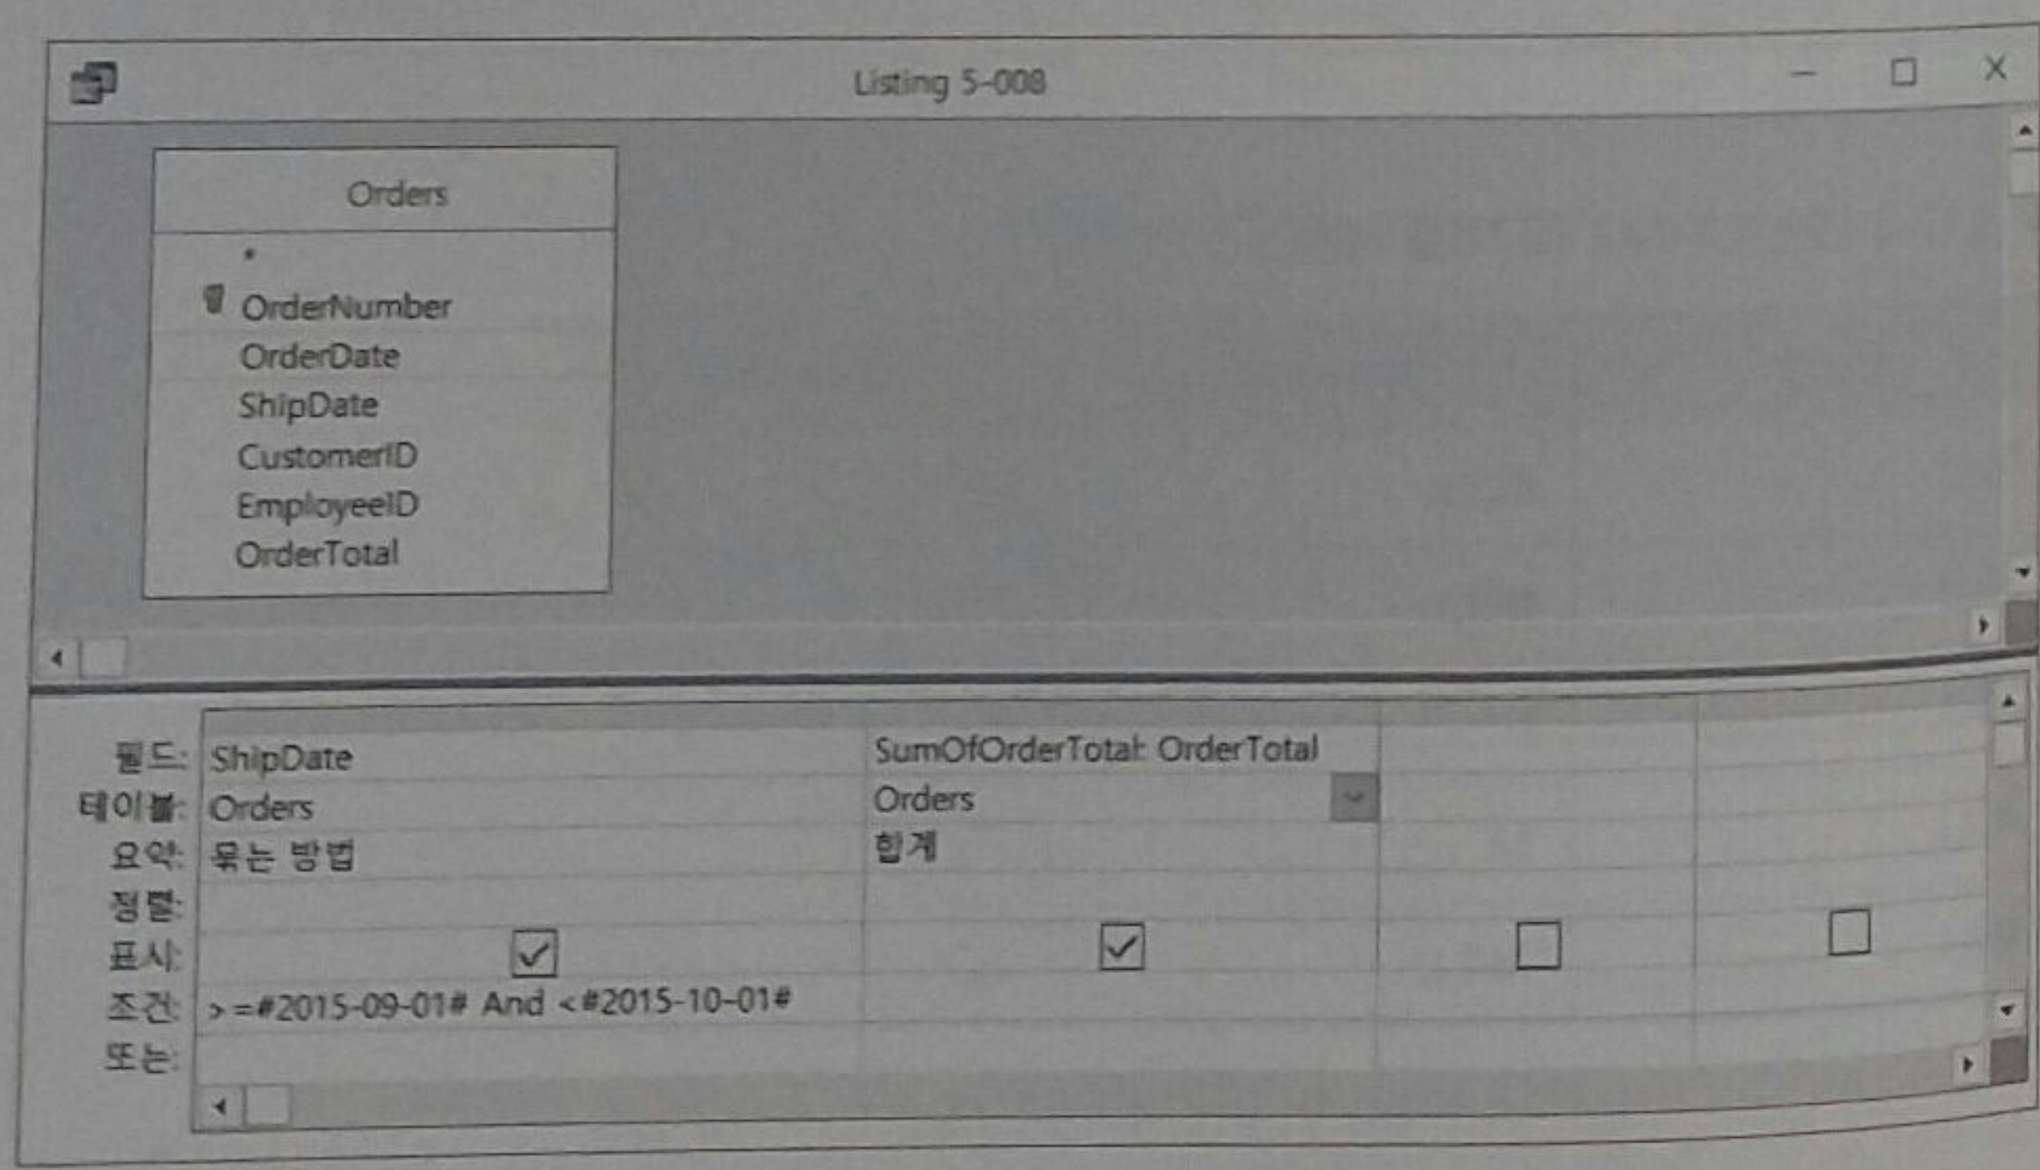

코드 5-8 그림 5-1의 쿼리를 SQL로 변환

```
SELECT O.ShipDate, Sum(O.OrderTotal) AS SumOfOrderTotal
FROM Orders AS O
GROUP BY O.ShipDate
HAVING (((O.ShipDate) >= #9/1/2015#
  AND (O.ShipDate) < #10/1/2015#));
```

코드 5-9와 같이 좀 더 적합한 SQL 문으로 만들려면 그림 5-2와 같이 조건을 명시적으로 분할해야 한다.

코드 5-9 그림 5-2의 쿼리를 SQL로 변환

```
SELECT o.ShipDate, Sum(o.OrderTotal) AS SumOfOrderTotal
FROM Orders AS o
WHERE o.ShipDate >= #9/1/2015#
  AND o.ShipDate < #10/1/2015#
GROUP BY o.ShipDate;
```

▼ 그림 5-2 액세스에서 좀 더 선호하는 집계 쿼리 조건을 추가하는 방법

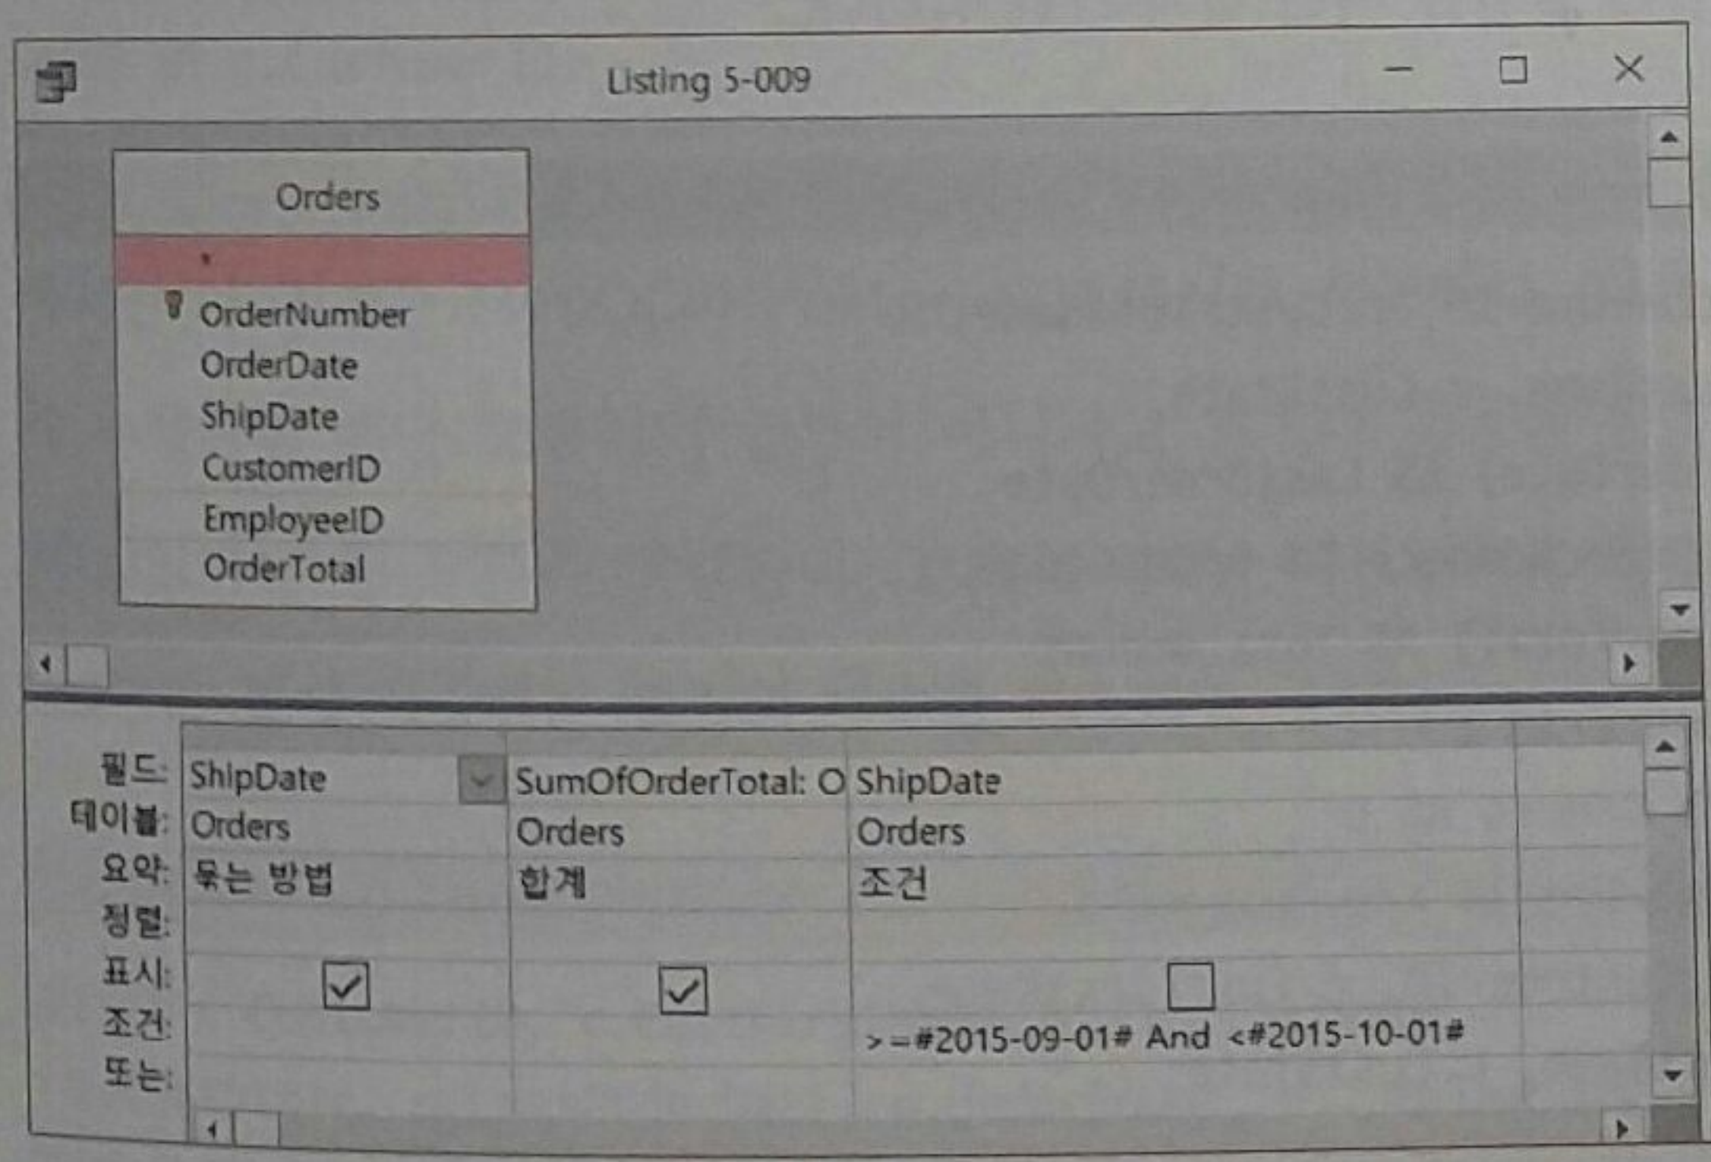

핵심 정리

- 집계 수행 전 WHERE 절이 적용된다.
- GROUP BY 절은 필터링된 데이터 집합을 집계한다.
- HAVING 절은 집계된 데이터 집합을 다시 필터링한다.
- ORDER BY 절은 변형된 데이터 집합을 정렬한다.
- SELECT 절에서 집계 함수나 집계 계산에 포함되지 않은 컬럼은 GROUP BY 절에 명시해야 한다.
- ROLLUP, CUBE, GROUPING SETS를 사용하면, 여러 집계 쿼리를 UNION으로 연결하는 대신 쿼리 하나로 좀 더 가능한 조합 결과를 산출할 수 있다.

BETTER WAY 31 GROUP BY 절은 간단하게 만들자

SQL-92 표준까지는 집계 연산을 수행하지 않는 모든 컬럼은 반드시 GROUP BY 절에 기술해야 했는데, 많은 DBMS가 이 조건을 따랐다. 코드 5-10은 GROUP BY 절에 컬럼을 여러 개 추가한 쿼리다.

코드 5-10 SQL-92 표준을 따르는 GROUP BY 절에 컬럼을 여러 개 둔 집계 쿼리

```
SELECT c.CustomerID, c.CustFirstName,
  c.CustLastName, c.CustState,
  MAX(o.OrderDate) AS LastOrderDate,
  COUNT(o.OrderNumber) AS OrderCount,
  SUM(o.OrderTotal) AS TotalAmount
FROM Customers AS c
  LEFT JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
GROUP BY c.CustomerID, c.CustFirstName,
  c.CustLastName, c.CustState;
```

이 쿼리는 모든 DBMS에서 사용 가능한데, GROUP BY 절에 컬럼이 네 개 있다는 점에 주목하자. Customers 테이블의 기본키인 CustomerID별로 집계한다고

하자. 기본키는 유일해야 하므로 다른 세 컬럼의 값이 무엇인지는 중요하지 않다. 기본키 값은 유일하며, 집계 연산 수행 결과를 봐도 이 값은 변하지 않는다.

이것을 기능적 의존성(Functional Dependency)이라고 한다. CustFirstName, CustLastName, CustState 컬럼은 기능적으로 CustomerID에 의존하며, SQL-99 표준부터 인지된 사실이다. 따라서 코드 5-11의 쿼리는 현재 SQL 표준을 충족한다.

코드 5-11 현재 SQL 표준을 따르도록 코드 5-10 쿼리를 수정한 버전

```
SELECT c.CustomerID, c.CustFirstName,
  c.CustLastName, c.CustState,
  MAX(o.OrderDate) AS LastOrderDate,
  COUNT(o.OrderNumber) AS OrderCount,
  SUM(o.OrderTotal) AS TotalAmount
FROM Customers AS c
  LEFT JOIN Orders AS o
    ON c.CustomerID = o.CustomerID
GROUP BY c.CustomerID;
```

하지만 이 쿼리는 MySQL과 PostgreSQL에서만 작동한다. 다른 DBMS에서 수행하면 해당 표현식의 일부가 아니라고 하거나 참조한 컬럼이 집계되지 않았다는 등 오류가 발생한다. 코드 5-12는 서브쿼리로 동일한 쿼리를 GROUP BY 절에 기술하는 컬럼의 개수를 최소화한 것이다.

코드 5-12 코드 5-10 쿼리를 수정한 버전

```
SELECT c.CustomerID, c.CustFirstName, c.CustLastName,
  c.CustState, o.LastOrderDate, o.OrderCount, o.TotalAmount
FROM Customers AS c
  LEFT JOIN (
    SELECT t.CustomerID, MAX(t.OrderDate) AS LastOrderDate,
      COUNT(t.OrderNumber) AS OrderCount,
```

```
  SUM(t.OrderTotal) AS TotalAmount
FROM Orders AS t
GROUP BY t.CustomerID
) AS o
ON c.CustomerID = o.CustomerID;
```

Note ≡ 코드 5-12의 쿼리를 좀 더 읽기 쉽게 만든 버전을 'BETTER WAY 42. 가능하면 서브쿼리 대신 공통 테이블 표현식을 사용하자'에서 설명한다.

코드 5-12의 쿼리는 실제로 집계되는 컬럼이 무엇인지 쉽게 파악할 수 있다는 큰 장점이 있다. 이 예제에서는 기본키인 CustomerID를 사용했지만, 항상 기본키를 그루핑해서 집계할 필요는 없다. 코드 5-13에서 다룬 GROUP BY 절을 살펴보자.

코드 5-13 복잡한 형태인 GROUP BY 절

```
...
GROUP BY CustCity, CustState, CustZip, YEAR(OrderDate),
  MONTH(OrderDate), EmployeeID
...
```

GROUP BY 절에서 빼도 되는 기능적 의존성 컬럼이 보이는가? 지금 고객의 위치 정보를 근거로 집계하는가? 주문을 한 직원과 연도/월로 집계하고 있는가? 아니면 다른 정보로 집계하는가? 아마도 알 수 없을 것이다. 그루핑하는 데 필수적인 정보를 결정하려면 전체 쿼리를 분석하고 결과 집합을 연구해야 한다. 이 쿼리의 최종 결과는 세부 정보를 담은 컬럼이 많아 원래 목적이 흐려졌기에 분석하고 이해하기 어렵다. 따라서 주요 테이블에 적용하는 기준을 결정하거나 최적화하려면 쿼리를 다시 작성해야 한다.

이런 이유로 집계 쿼리는 데이터를 집계할 때 실제로 필요한 컬럼만 GROUP BY 절에 기술하는 방식으로 작성해야 좋다. 세부적인 정보를 얻는 데 컬럼이 더 필요하다면, 이들을 GROUP BY 절에 추가하기보다는 별도의 서브쿼리로 빼는 것이 좋다.

핵심 정리

- 현재 SQL 표준에서 더는 요구하지 않더라도, 몇몇 DBMS에서는 집계되지 않는 컬럼을 GROUP BY 절에 추가해야 한다.
- GROUP BY 절에 컬럼을 과도하게 기술하면 쿼리의 성능에 악영향을 미칠 뿐만 아니라, 읽고 이해하고 재작성하기가 어렵다.
- 집계와 세부 정보 조회 두 가지 목적을 달성해야 하는 쿼리를 작성할 때는 먼저 서브쿼리에서 모든 집계를 수행한 후 세부 데이터를 담은 테이블과 조인해 해당 정보를 가져온다.

BETTER WAY 32 복잡한 문제를 해결하려면 GROUP BY나 HAVING 절을 사용하자

집계 함수는 전체 데이터 집합이나 해당 집합 내 일부 로우 그룹의 값을 계산하는 강력한 도구를 제공한다. 'BETTER WAY 30. GROUP BY 절의 작동 원리를 이해하자'에서는 집계되는 데이터 집합을 정의하는 GROUP BY 절을 배웠다. 여기서는 결과를 더 정제하는 HAVING 절을 설명할 것이다.

집계 전 로우를 필터링하는 역할을 WHERE 절이 수행하는 반면, HAVING 절은 집계된 후 로우에서 데이터를 필터링하는 역할을 한다. 특정 값보다 크거나 작은 집계 값만 추출해야 한다고 하자. HAVING 절의 진정한 힘은 한 그룹의 집계 결과를 다른 집계 값과 비교하는 능력에 있다. HAVING 절로는 다음 문제를 해결할 수 있다.

- 평균 배송 시간이 모든 판매회사의 평균 배송 시간을 초과하는 판매자를 찾아라.
- 특정 기간의 총 판매액이 동일한 카테고리에 속한 모든 제품의 평균 판매액보다 큰 제품을 찾아라(즉, 카테고리별 최고의 제품을 찾아라).
- 임의의 일자에 주문한 총액이 1,000달러 이상인 고객을 모두 찾아라(일별 우량 고객을 찾아라).
- 지난 분기 단일 제품 항목의 주문 비율을 계산하라.

먼저 HAVING 절로 처음 두 문제를 해결해 보자. 사용할 테이블은 그림 5-3과 같다.

그림 5-3 전형적인 판매 주문 데이터베이스의 테이블

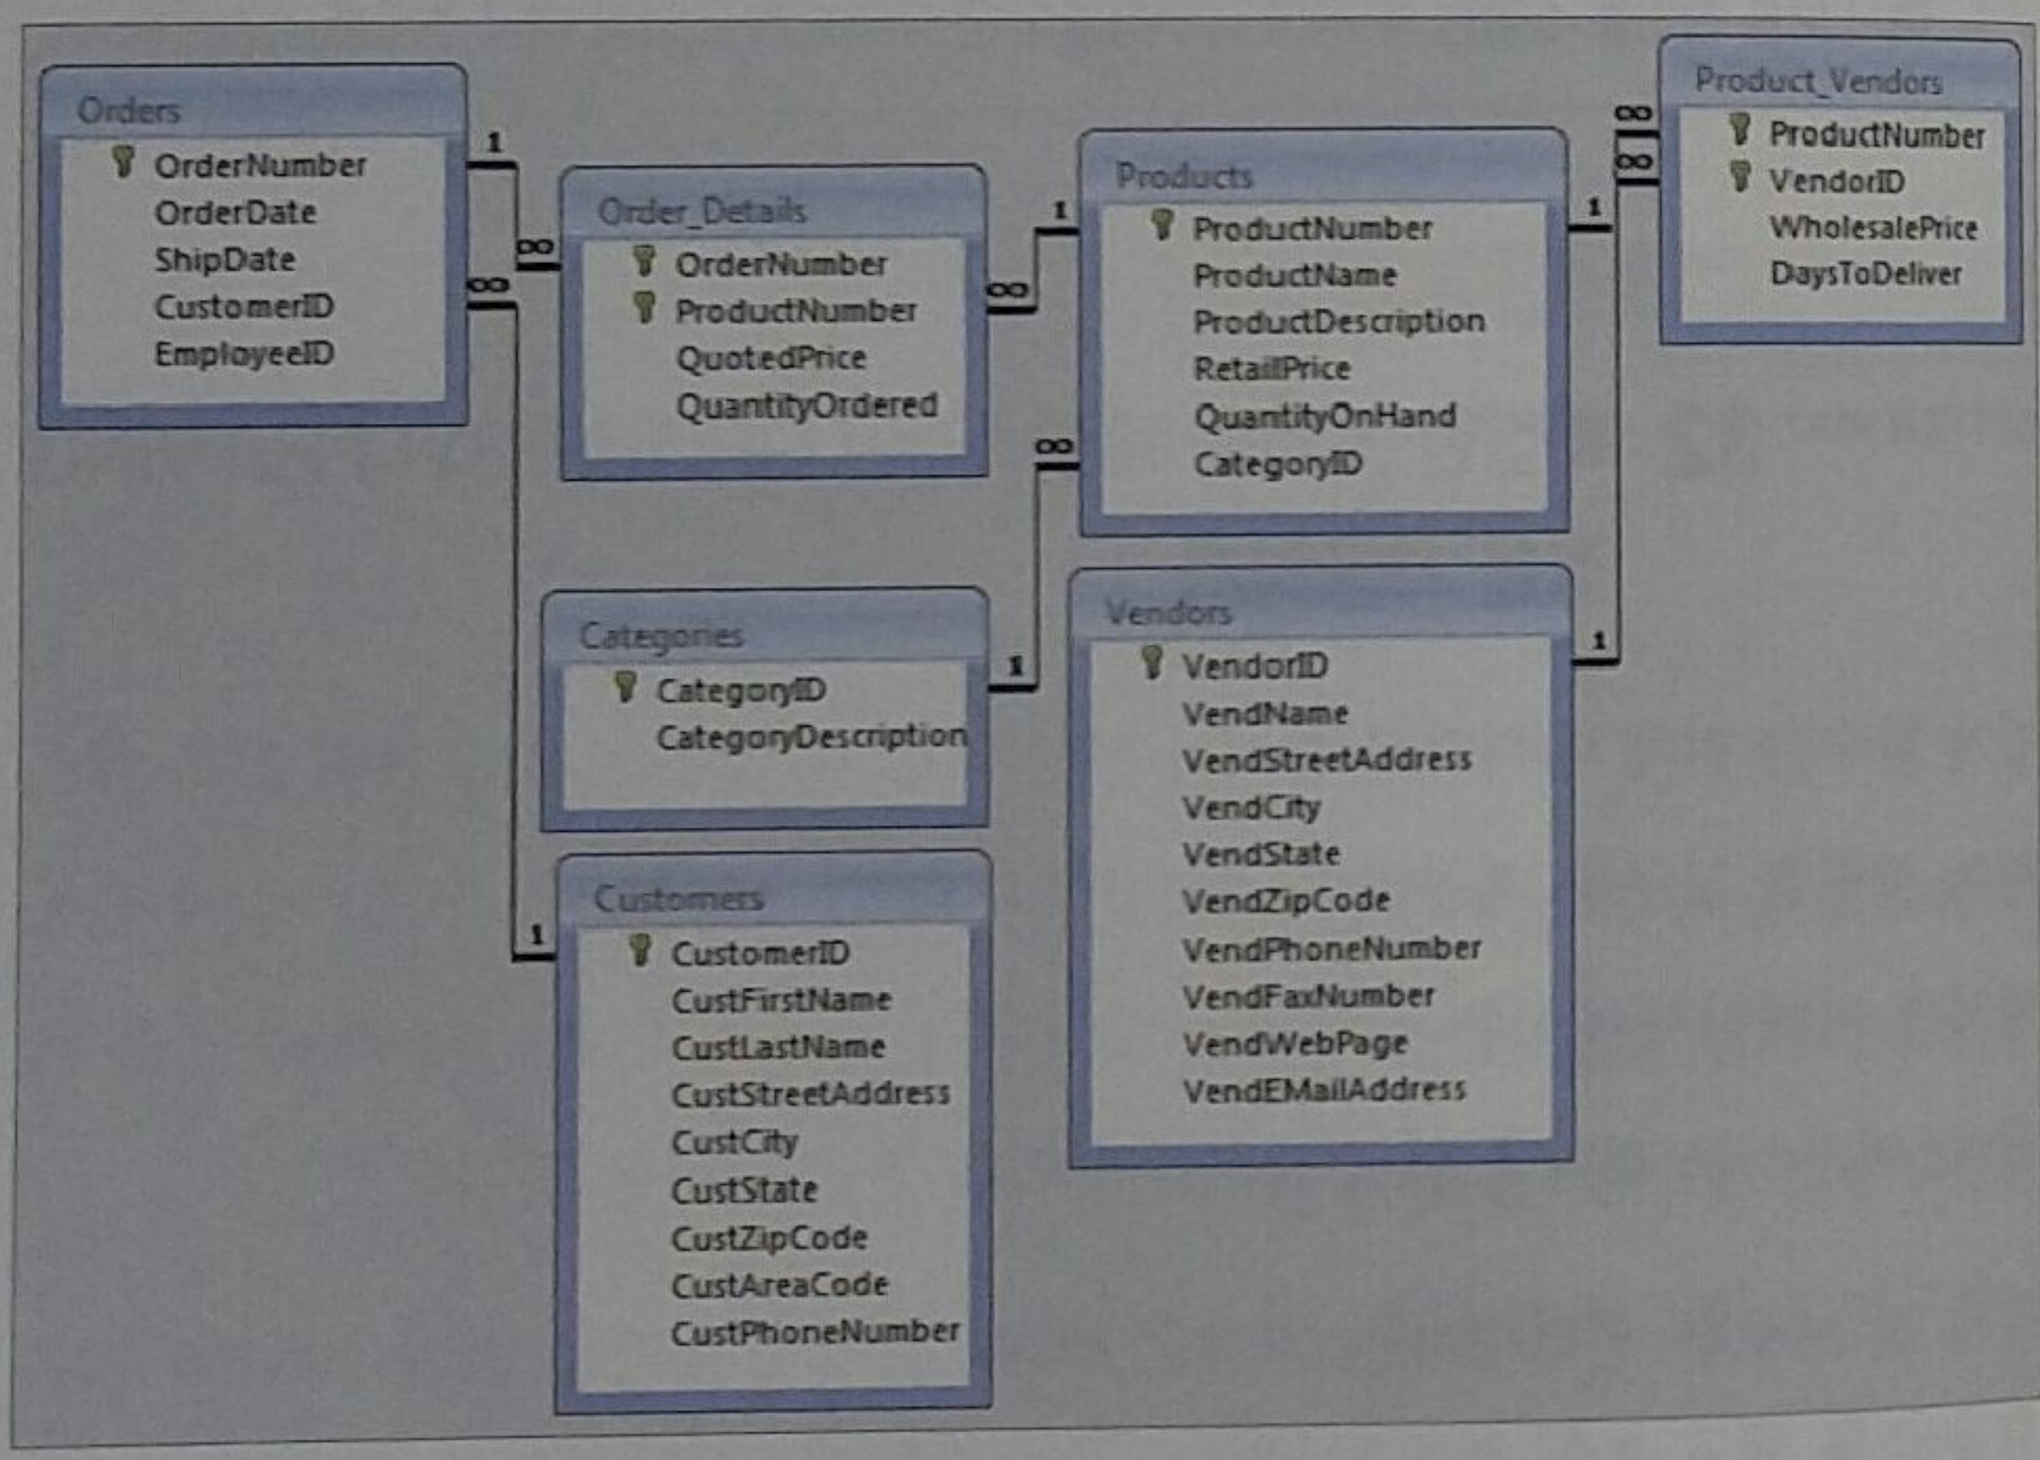

먼저 배송 시간이 느린 판매자를 찾아보자. 여기서는 판매 주문 데이터베이스의 Vendors와 PurchaseOrders 테이블을 사용할 것이다. PurchaseOrders 테이블에는 Vendors 테이블과 연결하는 외래키(VendorID) 한 개, 특정 주문을

배송 처리하는 데 걸리는 시간을 계산하는 OrderDate와 DeliveryDate 컬럼이 있다. 코드 5-14는 2015년 마지막 분기 동안 이 문제에서 답을 구하는 쿼리다.

Note ≡ 여기서는 datetime 연산을 수행하는 SQL Server 함수를 사용했다. '부록. 날짜와 시간 타입, 연산, 함수'나 데이터베이스 관련 문서에서 여러분의 DBMS에서 사용할 수 있는 함수를 찾을 수 있을 것이다.

코드 5-14 2015년 4분기 배송 시간이 평균보다 느린 판매자를 찾는 쿼리

```
SELECT v.VendName, AVG(DATEDIFF(DAY, p.OrderDate,
   p.DeliveryDate)) AS DeliveryDays
FROM Vendors AS v
  INNER JOIN PurchaseOrders AS p
    ON v.VendorID = p.VendorID
WHERE p.DeliveryDate IS NOT NULL
  AND p.OrderDate BETWEEN '2015-10-01' AND '2015-12-31'
GROUP BY v.VendName
HAVING AVG(DATEDIFF(DAY, p.OrderDate, p.DeliveryDate)) > (
  SELECT AVG(DATEDIFF(DAY, p2.OrderDate, p2.DeliveryDate))
  FROM PurchaseOrders AS p2
  WHERE p2.DeliveryDate IS NOT NULL
    AND p2.OrderDate BETWEEN '2015-10-01' AND '2015-12-31'
  );
```

표 5-5는 마지막 분기의 전체 평균 배송 시간(14일)보다 느린 판매자를 추출하는 쿼리를 실행한 결과다. 사실 미국은 추수감사절과 크리스마스 시즌이 있어 마지막 분기에는 전반적으로 배송이 느리다. 이런 이유로 대부분의 소매업자가 이 시즌 전에는 주문 재고를 쌓아 놓는다. 하지만 이런 데이터는 긴급한 주문을 처리할 때 특정 시간에는 주문을 피해야 하는 판매자를 식별하는 데 도움이 된다.

표 5-5 2015년 4분기 배송 시간이 느린 판매자

VendName	DeliveryDays
Armadillo Brand	15
Big Sky Mountain Bikes	17
Nikoma of America	22
ProFormance	15

Note ≡ DeliveryDays 값은 DBMS에 따라 다를 수 있다. 또 ROUND() 함수를 구현하는 방식도 DBMS별로 다르므로 일자가 틀어지는 것을 원하지 않는다면 평균 결과 값을 적절한 형식으로 표현해야 한다.

대다수 DBMS의 구현 내용과 ISO SQL 표준에 따르면 DeliveryDays 이름으로는 SELECT 절에서 계산을 수행하거나 HAVING 절을 사용하거나 동일한 표현식 내에서 사용할 수 없다. 반드시 해당 표현식을 있는 그대로 재사용해야 한다는 점에 주의하자.

다음으로 주어진 기간의 전체 판매액이 동일한 카테고리에 있는 모든 제품의 평균 판매액보다 큰 제품을 찾아보자. 해당 쿼리는 코드 5-15와 같다.

코드 5-15 2015년 4분기 카테고리별 우량 판매자 찾기

```
SELECT c.CategoryDescription, p.ProductName,
  SUM(od.QuotedPrice * od.QuantityOrdered) AS TotalSales
FROM Products AS p
  INNER JOIN Order_Details AS od
    ON p.ProductNumber = od.ProductNumber
  INNER JOIN Categories AS c
    ON c.CategoryID = p.CategoryID
  INNER JOIN Orders AS o
    ON o.OrderNumber = od.OrderNumber
WHERE o.OrderDate BETWEEN '2015-10-01' AND '2015-12-31'
GROUP BY p.CategoryID, c.CategoryDescription, p.ProductName
```

```
HAVING SUM(od.QuotedPrice * od.QuantityOrdered) > (
  SELECT AVG(SumCategory)
  FROM (
    SELECT p2.CategoryID,
      SUM(od2.QuotedPrice * od2.QuantityOrdered)
        AS SumCategory
    FROM Products AS p2
      INNER JOIN Order_Details AS od2
        ON p2.ProductNumber = od2.ProductNumber
      INNER JOIN Orders AS o2
        ON o2.OrderNumber = od2.OrderNumber
    WHERE p2.CategoryID = p.CategoryID
      AND o2.OrderDate BETWEEN '2015-10-01' AND '2015-12-31'
    GROUP BY p2.CategoryID, p2.ProductNumber
    ) AS s
  GROUP BY CategoryID
  )
ORDER BY c.CategoryDescription, p.ProductName;
```

이 쿼리는 HAVING 절이 매우 복잡하다. 먼저 현재 그룹의 카테고리에 속하는 제품별 판매액 합계를 계산한 후 이 합의 평균을 계산해야 한다. 현재 그룹의 카테고리별로 필터링하는 것은 서브쿼리로 처리했다. 또 특정 날짜 범위로 데이터를 제한하려고 Orders 테이블과 조인하면서 쿼리가 더 복잡해졌다. 최종 결과는 표 5-6과 같다.

표 5-6 2015년 4분기 카테고리별 평균보다 많이 팔린 제품 목록

CategoryDescription	ProductName	TotalSales
Accessories	Cycle-Doc Pro Repair Stand	32595.76
Accessories	Dog Ear Aero-Flow Floor Pump	15539.15
Accessories	Glide-O-Matic Cycling Helmet	23640.00
Accessories	King Cobra Helmet	27847.26
Accessories	Viscount CardioSport Sport Watch	16469.79

계속

CategoryDescription	ProductName	TotalSales
Bikes	GT RTS-2 Mountain Bike	527703.00
Bikes	Trek 9000 Mountain Bike	954516.00
Clothing	StaDry Cycling Pants	8641.56
Components	AeroFlo ATB Wheels	37709.28
Components	Cosmic Elite Road Warrior Wheels	32064.45
Components	Eagle SA-120 Clipless Pedals	17003.85
Car racks	Ultimate Export 2G Car Rack	31014.00
Tires	Ultra-2K Competition Tire	5216.28
Skateboards	Viscount Skateboard	196964.30

'BETTER WAY 42. 가능하면 서브쿼리 대신 공통 테이블 표현식을 사용하자'에는 공통 테이블 표현식(CTE)으로 훨씬 간단하게 처리한 쿼리가 있다. 코드 5-16은 CTE를 사용한 쿼리다.

코드 5-16 CTE를 사용해 코드 5-15를 간략하게 만든 쿼리

```
WITH CatProdData AS (
  SELECT c.CategoryID, c.CategoryDescription,
    p.ProductName, od.QuotedPrice, od.QuantityOrdered
  FROM Products AS p
    INNER JOIN Order_Details AS od
      ON p.ProductNumber = od.ProductNumber
    INNER JOIN Categories AS c
      ON c.CategoryID = p.CategoryID
    INNER JOIN Orders AS o
      ON o.OrderNumber = od.OrderNumber
  WHERE o.OrderDate BETWEEN '2015-10-01' AND '2015-12-31'
  )
SELECT d.CategoryDescription, d.ProductName,
  SUM(d.QuotedPrice * d.QuantityOrdered) AS TotalSales
FROM CatProdData AS d
GROUP BY d.CategoryID, d.CategoryDescription, d.ProductName
```

```
HAVING SUM(d.QuotedPrice * d.QuantityOrdered) > (
 SELECT AVG(SumCategory)
 FROM (
  SELECT d2.CategoryID,
   SUM(d2.QuotedPrice * d2.QuantityOrdered)
    AS SumCategory
  FROM CatProdData AS d2
  WHERE d2.CategoryID = d.CategoryID
  GROUP BY d2.CategoryID, d2.ProductName
  ) AS s
 GROUP BY CategoryID
 )
ORDER BY d.CategoryDescription, d.ProductName;
```

CTE를 사용하면 복잡한 조인과 날짜의 조건을 한 번만 처리해 놓고는 서브쿼리와 외부 쿼리에서 재사용할 수 있다.

핵심 정리

- 그루핑하기 전에 로우를 필터링할 때는 WHERE 절을 사용하고, 그루핑 후에는 HAVING 절을 사용한다.
- HAVING 절을 사용해 집계 표현식에 조건을 줄 수 있다.
- SELECT 절에 집계 표현식에 대한 별칭을 부여할 수는 있지만, 이를 HAVING 절에서 사용하려면 별칭이 아닌 표현식을 다시 사용해야 한다. 즉, SELECT 절에 기술한 별칭은 사용할 수 없다.
- 집계 값이 복잡한 서브쿼리가 반환한 값과 다른 집계 값을 비교할 수 있다.

BETTER WAY 33 GROUP BY 절 없이 최댓값, 최솟값을 찾자

GROUP BY 절로 많은 문제를 해결할 수 있지만, 너무 많은 데이터가 집계되기도 하며 종종 원하는 세부 정보를 얻을 수 없을 때도 있다. 윈도우 함수('BETTER WAY 37. 윈도우 함수 사용법을 알아 두자' 참고)를 지원하지 않는 DBMS

에서는 집계하지 않고도 추가적인 컬럼과 데이터를 가져오는 대안을 마련해야 한다. 이런 대안을 사용하면 'BETTER WAY 23. 일치하지 않거나 누락된 레코드를 찾아내자'에서 소개한 아이디어를 확장해 집계를 수행하지 않고도 최댓값이나 최솟값을 찾는 것이 가능하다.

표 5-7에 정리한 데이터를 살펴보자.

❮ 표 5-7 BeerStyles 테이블

Category	Country	Style	MaxABV
American Beers	United States	American Barley Wine	12
American Beers	United States	American Lager	4.2
American Beers	United States	American Malt Liquor	9
American Beers	United States	American Stout	11.5
American Beers	United States	American Style Wheat	5.5
American Beers	United States	American Wild Ale	10
American Beers	United States	Double/Imperial IPA	10
American Beers	United States	Pale Lager	5
British or Irish Ales	England	English Barley Wine	12
British or Irish Ales	England	India Pale Ale	7.5
British or Irish Ales	England	Ordinary Bitter	3.9
British or Irish Ales	Ireland	Irish Red Ale	6
British or Irish Ales	Scotland	Strong Scotch Ale	10
European Ales	Belgium	Belgian Black Ale	6.2
European Ales	Belgium	Belgian Pale Ale	5.6
European Ales	Belgium	Flanders Red	6.5
European Ales	France	Bière de Garde	8.5
European Ales	Germany	Berliner Weisse	3.5
European Ales	Germany	Dunkelweizen	6

❍ 계속

Category	Country	Style	MaxABV
European Ales	Germany	Roggenbier	6
European Lagers	Austria	Vienna Lager	5.9
European Lagers	Germany	Maibock	7.5
European Lagers	Germany	Rauchbier	6
European Lagers	Germany	Schwarzbier	3.9
European Lagers	Germany	Traditional Bock	7.2

카테고리별로 알코올 도수(MaxABV)가 가장 높은 것을 찾아야 한다면 코드 5-17과 같은 SQL 문을 사용한다.

코드 5-17 카테고리별로 도수가 가장 높은 알코올을 추출하는 SQL

```
SELECT Category, MAX(MaxABV) AS MaxAlcohol
FROM BeerStyles
GROUP BY Category;
```

표 5-8은 코드 5-17의 쿼리를 실행한 결과다.

♥ 표 5-8 카테고리별 높은 알코올 도수

Category	MaxAlcohol
American Beers	12
British or Irish Ales	12
European Ales	8.5
European Lagers	7.5

Note ≡ 'BETTER WAY 30. GROUP BY 절의 작동 원리를 이해하자'에서 설명했듯이 DBMS에 따라 정렬 결과가 약간 다를 수 있는데, ORDER BY 절을 명시하지 않았기 때문이다.

가장 높은 도수뿐만 아니라 어느 나라의 어떤 스타일의 맥주인지까지 조회하고 싶을 때 코드 5-18과 같이 쿼리에 Country만 추가해서는 원하는 결과를 얻지 못할 것이다.

코드 5-18 알코올 도수가 가장 높은 맥주의 원산지 국가를 추출하는 잘못된 SQL

```
SELECT Category, Country, MAX(MaxABV) AS MaxAlcohol
FROM BeerStyles
GROUP BY Category, Country;
```

코드 5-18의 쿼리 결과는 표 5-9와 같은데, 원하던 결과가 아니다. 분명히 다른 방법이 필요하다.

표 5-9 알코올 도수가 높은 맥주의 원산지 국가를 잘못 추출한 결과

Category	Country	MaxAlcohol
American Beers	United States	12
British or Irish Ales	England	12
British or Irish Ales	Ireland	6
British or Irish Ales	Scotland	10
European Ales	Belgium	6.5
European Ales	France	8.5
European Ales	Germany	6
European Lagers	Austria	5.9
European Lagers	Germany	7.5

이 문제의 핵심은 카테고리별로 테이블에서 MaxABV 값이 가장 큰 로우를 찾는 것이다. 이 테이블을 셀프 조인해 해당 카테고리에 속하는 다른 로우의 MaxABV 값과 각 로우에 있는 MaxABV 값을 비교하면 원하는 로우를 찾을 수 있다. 코드 5-19는 이렇게 처리한 쿼리다.

코드 5-19 BeerStyles 테이블을 셀프 조인해 각 로우의 MaxABV 값을 비교한 쿼리

```
SELECT l.Category, l.MaxABV AS LeftMaxABV,
  r.MaxABV AS RightMaxABV
FROM BeerStyles AS l
  LEFT JOIN BeerStyles AS r
    ON l.Category = r.Category
      AND l.MaxABV < r.MaxABV;
```

이 쿼리는 테이블에 있는 각 로우를 동일한 카테고리의 다른 로우와 비교한 후 MaxABV 값이 큰 로우만 반환한다. LEFT 조인을 사용했기 때문에 오른쪽 테이블에 MaxABV 값이 큰 로우가 없더라도 왼쪽에 있는 테이블에서 적어도 한 개는 반환된다. 표 5-10은 코드 5-19의 쿼리를 실행한 결과다.

▼ 표 5-10 모든 로우에서 각 로우의 MaxABV를 비교한 결과의 일부

Category	LeftMaxABV	RightMaxABV
...	...	...
European Lagers	3.9	7.2
European Lagers	3.9	7.5
British or Irish Ales	12	NULL
British or Irish Ales	7.5	10
British or Irish Ales	7.5	12
European Ales	6.5	8.5
European Lagers	7.5	NULL
American Beers	5	11.5
American Beers	5	12
American Beers	5	9
...	...	...

표 5-10에서 로우 두 개의 RightMaxABV 컬럼에 널 값이 들어 있음에 주목하자. LeftMaxABV 컬럼의 값은 카테고리별 최대 도수를 나타낸다. 표 5-8을 보면 British or Irish Ales의 최대 도수는 12%이고, European Lagers는 7.5%임을 알 수 있다.

원하는 각 로우를 식별하는 방법을 알아냈다. 코드 5-20은 다른 컬럼을 가져오는 쿼리다.

코드 5-20 카테고리별 MaxABV 최댓값을 가진 로우의 세부 정보를 조회하는 쿼리

```
SELECT l.Category, l.Country, l.Style, l.MaxABV AS MaxAlcohol
FROM BeerStyles AS l
  LEFT JOIN BeerStyles AS r
    ON l.Category = r.Category
      AND l.MaxABV < r.MaxABV
WHERE r.MaxABV IS NULL
ORDER BY l.Category;
```

표 5-11은 코드 5-20의 쿼리를 실행한 결과다.

표 5-11 카테고리별 도수가 가장 높은 항목의 세부 정보

Category	Country	Style	MaxAlcohol
American Beers	United States	American Barley Wine	12
British or Irish Ales	England	English Barley Wine	12
European Ales	France	Bière de Garde	8.5
European Lagers	Germany	Maibock	7.5

코드 5-20의 쿼리에 집계 함수가 없어 GROUP BY 절을 사용하지 않은 점에 주목하자. GROUP BY 절이 없으므로 다른 테이블과 쉽게 조인이 가능하다.

코드 5-20 쿼리에서 ON 절의 첫 번째 표현식인 l.Category = r.Category는 코드 5-18의 GROUP BY Category와 기능이 동일하다. 두 번째 표현식인 l.MaxABV < r.MaxABV는 MAX(MaxABV)와 역할이 같은데, WHERE r.MaxABV IS NULL 절이 최댓값만(l.MaxABV > r.MaxABV라고 하면 최솟값) 가져오기 때문이다.

집계 연산과 GROUP BY 절 모두 자원을 많이 소모하는 연산이라는 점에 유의한다. MaxAlcohol = (SELECT MAX(MaxAlcohol) FROM BeerStyles AS b2 WHERE b2.Category = BeerStyles.Category)처럼 사용할 수 있지만, 이것은 집계 함수뿐만 아니라 연관성 있는 서브쿼리도 사용한다. 'BETTER WAY 41. 연관성 있는 서브쿼리와 연관성 없는 서브쿼리의 차이점을 파악하자'에서 배우겠지만, 연관성 있는 서브쿼리는 데이터베이스 엔진이 모든 로우에 대해 해당 서브쿼리를 실행하므로 치러야 할 비용이 큰 편이다.

Note ≡ 이 쿼리는 테이블을 두 번씩 스캔해야 하므로 큰 테이블을 대상으로 사용하는 것은 바람직하지 않다. 여러분이 처한 상황에서 최적의 방법이 무엇인지 알아보려면 'BETTER WAY 44. 사용 중인 시스템의 쿼리 분석기 사용법을 파악하자'를 참고한다.

핵심 정리

- '주' 테이블을 셀프 조인할 때는 LEFT JOIN을 사용한다.
- GROUP BY 절에 포함된 모든 컬럼은 ON 절에서 동등 연산자(=)를 사용할 수 있다.
- MAX()나 MIN()에 포함된 컬럼은 ON 절에서 <나 >를 사용할 수 있다.
- ON 절에 있는 컬럼을 인덱스로 만들면 성능을 높일 수 있다. 특히 큰 데이터 집합을 다룰 때는 더욱 그렇다.

BETTER WAY 34 OUTER JOIN에서는 잘못된 결과를 내는 COUNT() 함수를 사용하지 말자

SQL 코드를 작성하면서 가끔씩 범하는 간단한 실수는 한 데이터 집합의 로우 개수를 세는 것처럼 잘못된 결과를 뽑는 것이다. 그림 5-4의 데이터베이스 설계 다이어그램을 보고 식당의 요리사나 집에서 사용하는 요리를 추적해 보자.

❮ 그림 5-4 간단한 요리법(Recipes) 데이터베이스 설계

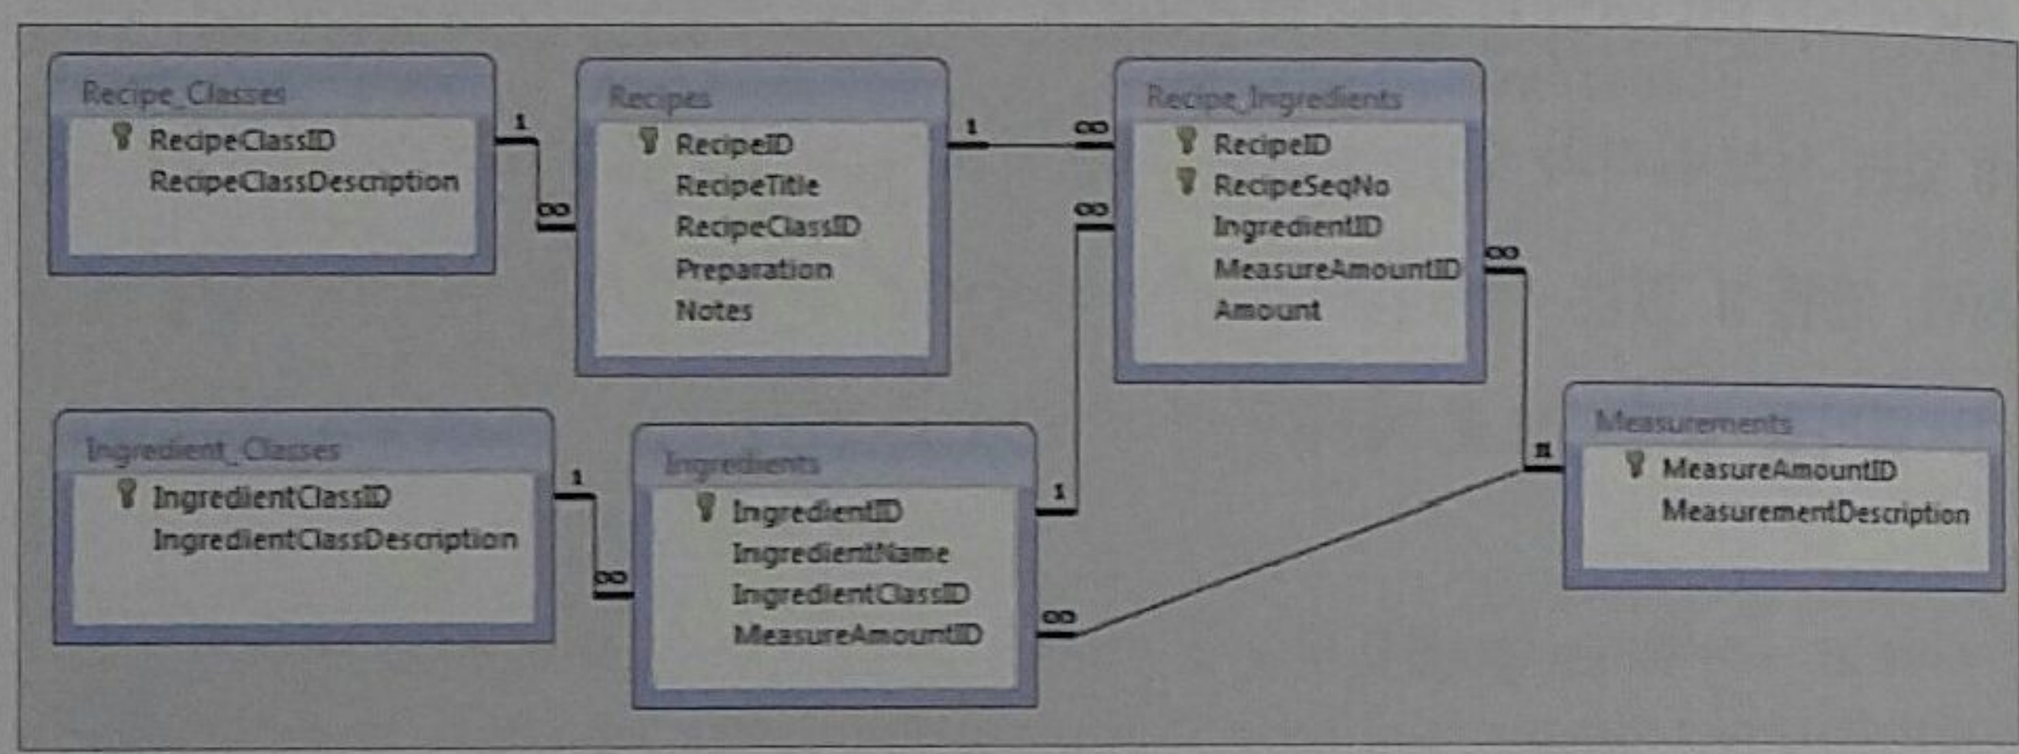

모든 종류의 요리법과 종류별 요리 개수를 조회하는 것은 복잡하지 않은 문제다. 모든 등급의 요리를 조회해야 하므로 외부 조인을 사용하면 될 것이다. 코드 5-21은 이 문제를 해결할 수 있는 첫 번째 쿼리다.

코드 5-21 모든 종류의 요리법 개수를 구하는 쿼리

```
SELECT Recipe_Classes.RecipeClassDescription,
  COUNT(*) AS RecipeCount
FROM Recipe_Classes
  LEFT OUTER JOIN Recipes
    ON Recipe_Classes.RecipeClassID = Recipes.RecipeClassID
GROUP BY Recipe_Classes.RecipeClassDescription;
```

표 5-12는 코드 5-21의 쿼리를 실행한 결과다.

▼표 5-12 요리 종류별 요리 수

RecipeClassDescription	RecipeCount
Dessert	2
Hors d'oeuvres	2
Main course	7
Salad	1
Soup	1
Starch	1
Vegetable	2

종류별로 요리가 최소 하나는 있는 것 같지만, 결과가 잘못되었기 때문에 좀 이상해 보인다. COUNT(*)는 그룹별로 반환되는 로우의 개수를 반환한다. 하지만 Recipes 테이블의 데이터 중 요리 종류에 존재하지 않는 로우의 컬럼은 널 값을 반환함에도 LEFT OUTER JOIN을 사용했기 때문에 요리 종류별로 로우를 적어도 하나는 얻었다('BETTER WAY 36. 겹치지 않는 개수를 얻으려면 DISTINCT를 사용하자'를 참고한다).

한 가지 해결책은 Recipes 테이블에서 반환되는 컬럼 중 하나의 개수를 세는 것이다. * 대신 컬럼 이름을 사용하면 데이터베이스 엔진은 널 값을 가진 로우를 무시해 버린다. 코드 5-22는 올바른 방법을 보여 준다.

코드 5-22 모든 종류의 요리법 개수를 구하는 올바른 쿼리

```
SELECT Recipe_Classes.RecipeClassDescription,
  COUNT(Recipes.RecipeClassID) AS RecipeCount
FROM Recipe_Classes
  LEFT OUTER JOIN Recipes
    ON Recipe_Classes.RecipeClassID = Recipes.RecipeClassID
GROUP BY Recipe_Classes.RecipeClassDescription;
```

표 5-13에서 볼 수 있듯이 이제 올바른 결과를 얻었다(수프 요리 데이터가 사라졌다).

표 5-13 올바르게 구한 종류별 요리의 개수

RecipeClassDescription	RecipeCount
Dessert	2
Hors d'oeuvres	2
Main course	7
Salad	1
Soup	0
Starch	1
Vegetable	2

이 문제를 해결하는 가장 효율적인 방법은 LEFT OUTER JOIN과 GROUP BY 절을 사용하는 것일까? 아마 그렇지 않을 것이다! 종류별 요리의 개수가 수천까지는 아니더라도 수백은 있을 수 있겠지만, 요리 종류는 몇 가지 되지 않으므로 개수 세기에는 서브쿼리를 사용하면 더 효율적이다.

Recipes 테이블에 있는 모든 로우를 가져와서 그루핑해 그룹별로 수를 세는 대신 서브쿼리를 사용하면 훨씬 빠를 것이다. 특히 인덱스 컬럼의 개수를 센다면 데이터베이스 엔진은 실제 로우가 아닌 인덱스 항목의 개수를 셀 것이다. 코드 5-23에 대안이 되는 쿼리가 있다. 이 쿼리의 실행 결과는 표 5-13과 동일하다.

코드 5-23 서브쿼리로 각 종류별 요리의 개수를 구하는 쿼리

```
SELECT Recipe_Classes.RecipeClassDescription, (
    SELECT COUNT(Recipes.RecipeClassID)
    FROM Recipes
    WHERE Recipes.RecipeClassID = Recipe_Classes.RecipeClassID
    ) AS RecipeCount
FROM Recipe_Classes;
```

그림 5-5는 서브쿼리가 더 빠를 것이라는 가정(연관성 있는 서브쿼리라 하더라도)을 뒷받침하려고 SQL Server의 쿼리 창에서 두 쿼리를 실행한 후 예상 실행 계획을 출력한 것이다. (더 자세한 내용은 'BETTER WAY 44. 사용 중인 시스템의 쿼리 분석기 사용법을 파악하자'를 참고한다. 그리고 연관성 있는 쿼리와 연관성 없는 서브쿼리에 관련된 더 자세한 내용은 'BETTER WAY 41. 연관성 있는 서브쿼리와 연관성 없는 서브쿼리의 차이점을 파악하자'를 참고한다.)

▼ 그림 5-5 SQL Server에서 쿼리를 두 개 분석

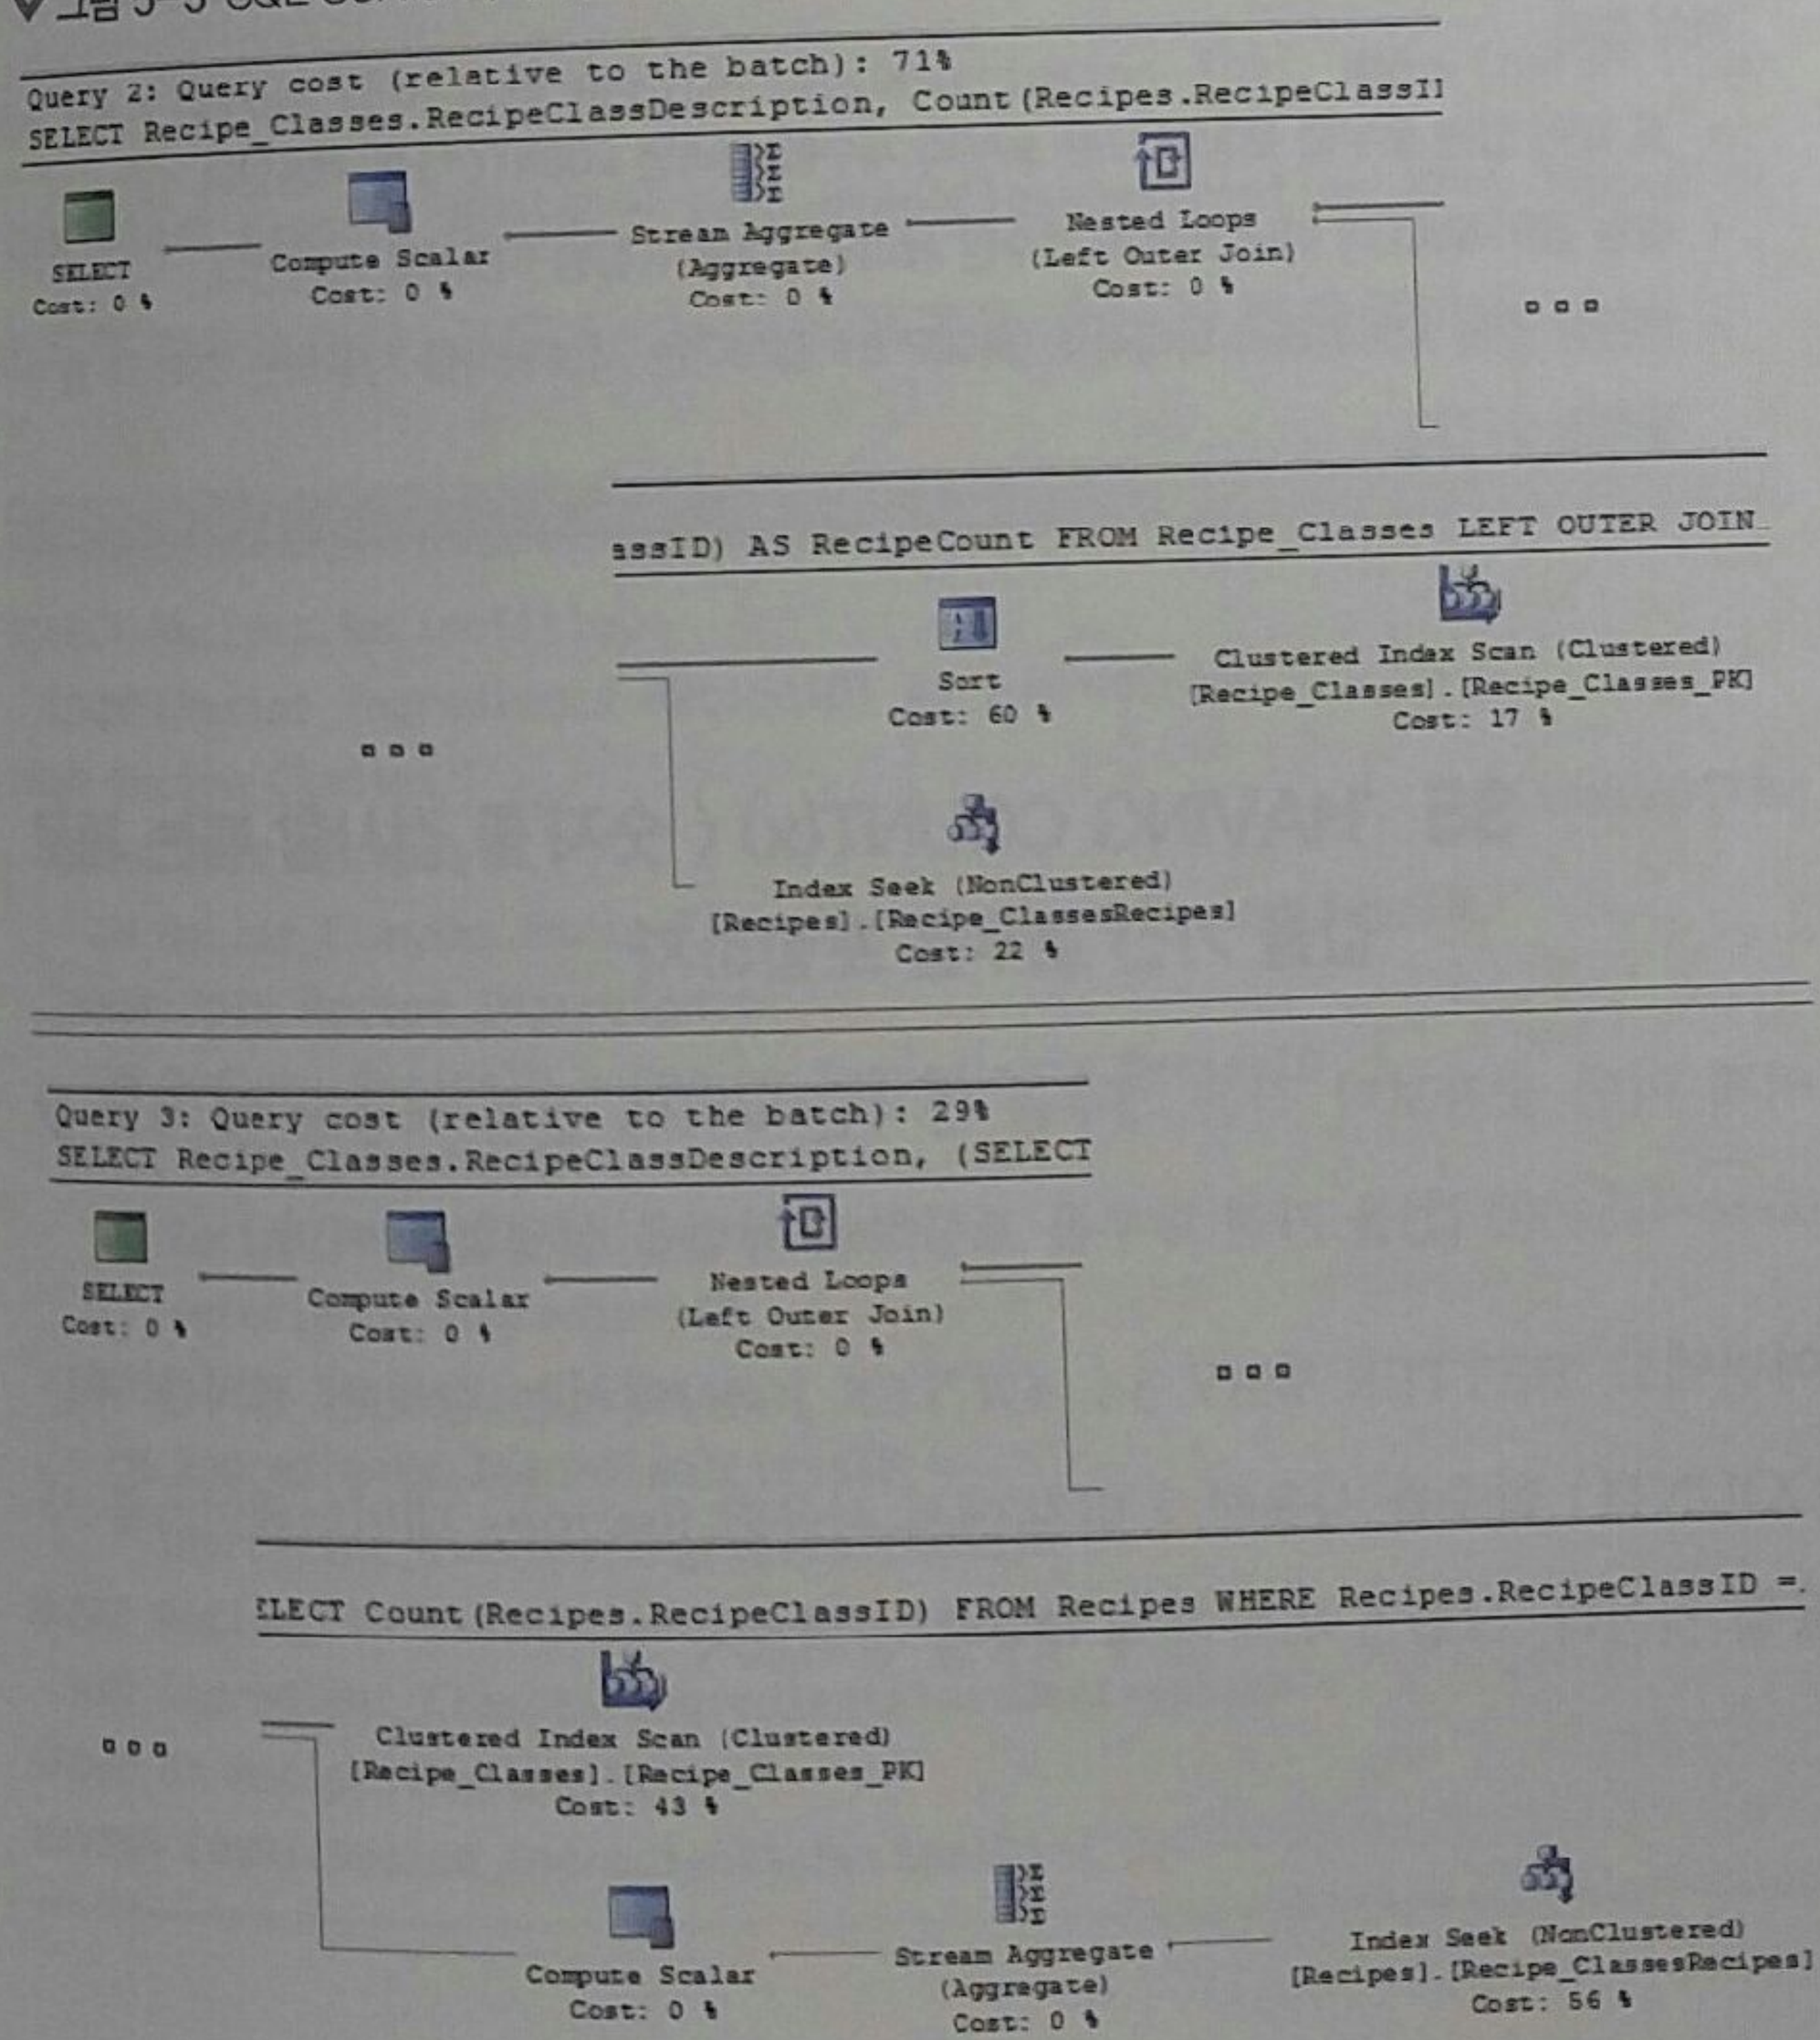

상대적으로 적은 양의 데이터를 대상으로 처리했지만, GROUP BY 절을 사용한 쿼리가 서브쿼리를 사용한 것보다 2배나 비용이 많이 들었다(GROUP BY 절은 71%, 서브쿼리는 29%). 하지만 이 결과는 SQL Server 데이터베이스 엔진에서 처리한 것이며, 다른 엔진에서는 결과가 반대로 나올 수도 있다. SQL로 문제를 해결하는 효율적인 방식을 찾고자 한다면 대안이 될 만한 방법을 찾는 것을 주저하지 말자. SQL의 효율성 검증을 더 자세히 알고 싶다면, '7장. 메타데이터 획득 및 분석'을 참고하자.

핵심 정리

- 널 값이 있는 로우를 포함해 모든 로우의 개수를 세려면 COUNT(*)를 사용한다.
- 컬럼 값이 NULL이 아닌 로우의 개수만 세려면 COUNT(〈컬럼 이름〉)을 사용한다.
- 연관성 있는 서브쿼리라 하더라도 GROUP BY 절보다는 서브쿼리를 사용하는 것이 더 효율적일 수 있다.

BETTER WAY 35 'HAVING COUNT(x) 〈 숫자'를 검사할 때는 제로 값을 가진 로우를 포함하자

이제 어떤 숫자보다 작은 개수를 명시한 HAVING 절을 적용할 때 제로 값(Zero-value)(0 값)을 가진 로우를 포함하는 방법을 설명할 것이다.

이번에도 'BETTER WAY 34. OUTER JOIN에서는 잘못된 결과를 내는 COUNT() 함수를 사용하지 말자'에서 사용한 Recipes 데이터베이스를 사용할 것이다. 그림 5-6의 설계 내용을 살펴보자.

✔ 그림 5-6 Recipes 데이터베이스 설계

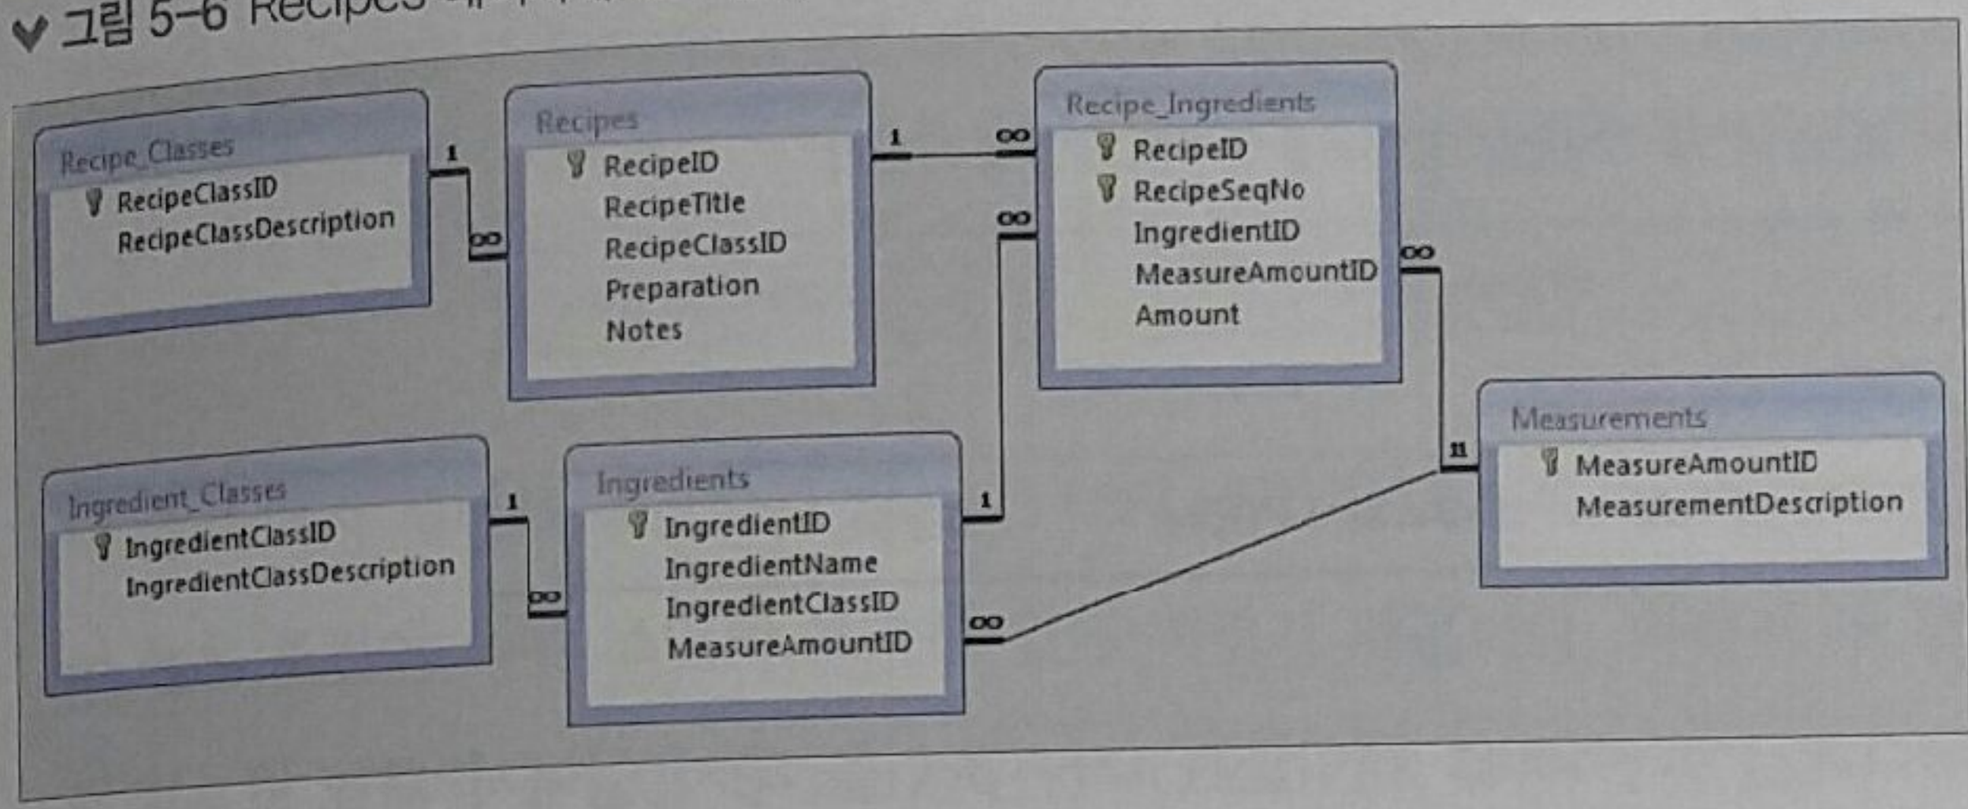

세 개 미만의 향신료(Spice)를 첨가한 메인 코스 요리를 찾아야 한다고 하자. Recipe_Classes 테이블의 RecipeClassDescription 값이 'Main Course'이고 Ingredient_Classes 테이블의 IngredientClassDescription 값이 'Spice'인 로우를 찾아야 한다. 코드 5-24는 이 로우를 찾는 첫 번째 쿼리다.

코드 5-24 세 개 미만의 향신료를 첨가한 메인 코스 요리를 찾는 쿼리

```
SELECT Recipes.RecipeTitle,
  COUNT(Recipe_Ingredients.RecipeID) AS IngredCount
FROM Recipe_Classes
  INNER JOIN Recipes
    ON Recipe_Classes.RecipeClassID = Recipes.RecipeClassID
  INNER JOIN Recipe_Ingredients
    ON Recipes.RecipeID = Recipe_Ingredients.RecipeID
  INNER JOIN Ingredients
    ON Recipe_Ingredients.IngredientID =
      Ingredients.IngredientID
  INNER JOIN Ingredient_Classes
    ON Ingredients.IngredientClassID =
      Ingredient_Classes.IngredientClassID
WHERE Recipe_Classes.RecipeClassDescription = 'Main course'
  AND Ingredient_Classes.IngredientClassDescription = 'Spice'
GROUP BY Recipes.RecipeTitle
HAVING COUNT(Recipe_Ingredients.RecipeID) < 3;
```

표 5-14는 코드 5-24의 쿼리를 실행한 결과다.

표 5-14 세 개 미만의 향신료를 첨가한 메인 코스 요리

RecipeTitle	IngredCount
Fettuccine Alfredo	2
Salmon Filets in Parchment Paper	2

Recipe_Ingredients 테이블과 LEFT 조인을 하지 않아서 제로 카운트(Zero Count)인 로우, 즉 향신료를 하나도 첨가하지 않은 요리를 가져오지 못했기 때문에 이 결과는 잘못되었다. 코드 5-25에 동일한 쿼리가 있는데, 이번에는 LEFT JOIN을 사용했다.

코드 5-25 세 개 미만의 향신료를 첨가한 메인 코스 요리를 찾는 두 번째 쿼리

```
SELECT Recipes.RecipeTitle,
  COUNT(ri.RecipeID) AS IngredCount
FROM Recipe_Classes
  INNER JOIN Recipes
    ON Recipe_Classes.RecipeClassID = Recipes.RecipeClassID
  LEFT OUTER JOIN (
    SELECT Recipe_Ingredients.RecipeID,
      Ingredient_Classes.IngredientClassDescription
    FROM Recipe_Ingredients
      INNER JOIN Ingredients
        ON Recipe_Ingredients.IngredientID =
          Ingredients.IngredientID
      INNER JOIN Ingredient_Classes
        ON Ingredients.IngredientClassID =
          Ingredient_Classes.IngredientClassID
    ) AS ri
    ON Recipes.RecipeID = ri.RecipeID
WHERE Recipe_Classes.RecipeClassDescription = 'Main course'
  AND ri.IngredientClassDescription = 'Spice'
GROUP BY Recipes.RecipeTitle
HAVING COUNT(ri.RecipeID) < 3;
```

Note ≡ 대부분의 데이터베이스 구현 내용과 구문이 호환될 수 있도록 외부 조인의 오른쪽에 서브쿼리를 사용했다. 예를 들어 액세스에서 단순히 INNER를 LEFT OUTER로 치환하면 이 쿼리는 '모호한 외부 조인(Ambiguous Outer Join)' 오류를 일으킬 것이다.

이 쿼리 역시 제대로 동작하지 않는다. LEFT 조인의 '오른쪽' 테이블(ri)에 달아 놓은 조건이 외부 조인의 효과를 없애 버리기 때문이다. 따라서 두 번째 쿼리는 첫 번째와 동일한 결과를 반환한다('BETTER WAY 29. LEFT 조인의 오른쪽 데이터를 올바르게 걸러 내자'를 참고한다). 조인을 수행하기 전에 이 조건을 서브쿼리 내로 옮겨야 하는데, 방법은 코드 5-26과 같다.

코드 5-26 세 개 미만의 향신료를 첨가한 메인 코스 요리를 찾는 올바른 쿼리

```
SELECT Recipes.RecipeTitle,
  COUNT(ri.RecipeID) AS IngredCount
FROM Recipe_Classes
  INNER JOIN Recipes
    ON Recipe_Classes.RecipeClassID = Recipes.RecipeClassID
  LEFT OUTER JOIN (
    SELECT Recipe_Ingredients.RecipeID,
      Ingredient_Classes.IngredientClassDescription
    FROM Recipe_Ingredients
      INNER JOIN Ingredients
        ON Recipe_Ingredients.IngredientID =
          Ingredients.IngredientID
      INNER JOIN Ingredient_Classes
        ON Ingredients.IngredientClassID =
          Ingredient_Classes.IngredientClassID
    WHERE Ingredient_Classes.IngredientClassDescription = 'Spice'
    ) AS ri
    ON Recipes.RecipeID = ri.RecipeID
WHERE Recipe_Classes.RecipeClassDescription = 'Main course'
GROUP BY Recipes.RecipeTitle
HAVING COUNT(ri.RecipeID) < 3;
```

표 5-15는 마지막 쿼리의 결과다.

❮ 표 5-15 세 개 미만의 향신료를 첨가한 메인 코스 요리

RecipeTitle	IngredCount
Fettuccine Alfredo	2
Irish Stew	0
Salmon Filets in Parchment Paper	2

솔직히 말해 아이리시 스튜 요리에 소금과 후추가 없는 것은 상상도 할 수 없는 일이므로 별로 흥미로운 예제는 아니다. 이 경우 특정 재료를 제외한 것을 발견했으니 요리할 때 해당 재료를 첨가하면 된다.

'BETTER WAY 34. OUTER JOIN에서는 잘못된 결과를 내는 COUNT() 함수를 사용하지 말자'에서처럼 이 쿼리의 SELECT 절에서 COUNT(RI.RecipeID) 대신 COUNT(*)를 사용하는 실수를 저질렀다면, 아이리시 스튜에서 1이라는 잘못된 값이 반환될 것이다. BETTER WAY 34와 여기서 배웠듯이, COUNT() 함수나 HAVING 절을 사용해 특정 값보다 작은 건을 찾으면서 제로 값을 처리할 때는 주의를 기울여야 한다.

마지막으로 코드 5-25의 쿼리에서 AND ri.IngredientClassDescription = 'Spice' 부분(WHERE 절에 있는)을 JOIN 절의 ON 조건에 넣어도 된다. 이렇게 하면 조인하기 전에 ON 절로 옮긴 조건절이 처리되어 코드 5-26의 쿼리와 동일한 결과를 얻을 수 있다. 반면 WHERE 절에 이 조건을 두면 조인 후에 처리되는데, 이 때문에 해당 조건이 '너무 늦게' 적용되어 잘못된 결과를 반환한다.

핵심 정리

- INNER JOIN을 사용하면 제로 카운트를 찾는 작업이 제대로 작동하지 않을 것이다.
- LEFT 조인의 오른쪽에 조건을 달면 INNER 조인과 동일한 결과를 얻는다. 이 조건을 서브쿼리로 밀어넣거나 ON 절에서 오른쪽 테이블에 달아 둔다.
- 제로 카운트를 찾는 과정에서 그 값이 1 이상일 때는 데이터에 문제가 있다는 의미다.

BETTER WAY 36 겹치지 않는 개수를 얻으려면 DISTINCT를 사용하자

COUNT() 집계 함수의 목적은 그 이름에서 유추할 수 있을 것이다. 여기서는 이 함수가 가진 미묘한 차이점을 자세히 살펴볼 것이다.

한 그룹의 항목 개수를 반환하는 데 사용되는 COUNT() 집계 함수의 용도는 다음 세 가지로 구분할 수 있다.

- COUNT(*) : 널 값과 중복된 값을 포함해 한 그룹의 항목 개수를 반환한다.
- COUNT(ALL <표현식>)(ALL은 기본 값이므로 주로 COUNT(<표현식>)으로 사용) : 한 그룹의 각 로우에 있는 표현식을 평가해 NULL이 아닌 값의 개수를 반환한다.
- COUNT(DISTINCT <표현식>) : 한 그룹에 있는 각 로우에 대해 지정한 표현식을 평가해서 유일하고 널이 아닌 값의 개수를 반환한다.

보통 〈표현식〉에는 필드 이름이 오지만, 단일 데이터 값을 얻으려고 기호나 연산자의 조합이 올 수도 있다.

표 5-16의 데이터를 살펴보자.

❮ 표 5-16 샘플 데이터

Order Number	OrderDate	ShipDate	Customer ID	Employee ID	Order Total
16	2012-09-02	2012-09-06	1001	707	2007.54
7	2012-09-01	2012-09-04	1001	NULL	467.85
2	2012-09-01	2012-09-03	1001	703	816.00
3	2012-09-01	2012-09-04	1002	707	11912.45
8	2012-09-01	2012-09-01	1003	703	1492.60
15	2012-09-02	2012-09-06	1004	701	2974.25
9	2012-09-01	2012-09-04	1007	NULL	69.00
4	2012-09-01	2012-09-03	1009	703	6601.73
24	2012-09-03	2012-09-05	1010	705	864.85
20	2012-09-02	2012-09-02	1011	706	4699.98
10	2012-09-01	2012-09-04	1012	701	2607.00
14	2012-09-02	2012-09-03	1013	704	6819.90
17	2012-09-02	2012-09-03	1014	702	4834.98
21	2012-09-03	2012-09-03	1014	702	709.97
6	2012-09-01	2012-09-05	1014	702	9820.29
18	2012-09-02	2012-09-03	1016	NULL	807.80
23	2012-09-03	2012-09-04	1017	705	16331.91
25	2012-09-03	2012-09-04	1017	NULL	10142.15
1	2012-09-01	2012-09-04	1018	707	12751.85
11	2012-09-02	2012-09-04	1020	706	11070.65
5	2012-09-01	2012-09-01	1024	NULL	5544.75
13	2012-09-02	2012-09-02	1024	704	7545.00
12	2012-09-02	2012-09-05	1024	706	72.00
22	2012-09-03	2012-09-07	1026	702	6456.16
19	2012-09-02	2012-09-06	1027	707	15278.98

COUNT(*)를 사용해 표 5-16에서 테이블의 로우 개수가 25라는 것을 알 수 있다.

이 테이블의 모든 로우에는 CustomerID 컬럼 값이 있으므로 COUNT(CustomerID)를 사용해도 동일한 결과인 25가 반환된다. 하지만 COUNT(EmployeeID)를 사용하면 20이 반환되는데, EmployeeID에 널 값을 가진 로우가 다섯 개 있기 때문이다.

COUNT(DISTINCT CustomerID)를 사용하면 로우 25개 중에서 겹치지 않는 CustomerID 값이 18개 있음을 알 수 있다.

앞에서도 언급했듯이 COUNT() 함수의 매개변수로 컬럼 이름만 사용할 수 있는 것은 아니다. 1,000.00달러를 초과하는 주문이 몇 개인지 파악한다고 하자. 코드 5-27의 쿼리를 실행하면 18개가 나올 것이다. 또 COUNT(CASE WHEN OrderTotal > 1000 THEN CustomerID END)를 사용해도 18이 반환되는데, CASE 문에서 OrderTotal 값이 1,000.00달러보다 큰 로우의 CustomerID만 반환하고 다른 경우에는 널 값을 반환하기 때문이다.

코드 5-27 1,000.00달러를 초과하는 주문의 개수를 구하는 쿼리

```
SELECT COUNT(*) AS TotalOrders
FROM OrdersTable
WHERE OrderTotal > 1000;
```

CASE 문과 DISTINCT를 결합해 사용하는 것도 가능하다. COUNT(DISTINCT CASE WHEN OrderTotal > 1000 THEN CustomerID END)를 사용하면 1,000.00달러를 초과하는 1주문 그룹 18개에서 겹치지 않는 고객 데이터 15개(1001, 1002, 1003, 1004, 1009, 1011, 1012, 1013, 1014, 1017, 1018, 1020, 1024, 1026, 1027)를 반환한다.

코드 5-28과 같이 단일 쿼리에서 COUNT()를 여러 개 사용해도 반환되는 로우는 한 개뿐이다.

코드 5-28 단일 쿼리에서 COUNT()를 여러 개 사용한 쿼리

```
SELECT COUNT(*) AS TotalRows,
  COUNT(CustomerID) AS TotalOrdersWithCustomers,
  COUNT(EmployeeID) AS TotalOrdersWithEmployees,
  COUNT(DISTINCT CustomerID) AS TotalUniqueCustomers,
  COUNT(CASE WHEN OrderTotal > 1000
    THEN CustomerID END) AS TotalLargeOrders,
  COUNT(DISTINCT CASE WHEN OrderTotal > 1000
    THEN CustomerID END) AS TotalUniqueCust_LargeOrders
FROM OrdersTable;
```

표 5-17은 코드 5-28의 쿼리를 실행한 결과다.

표 5-17 COUNT()가 여러 개 있는 쿼리를 반환한 결과

Total Rows	TotalOrders WithCustomers	TotalOrders WithEmployees	TotalUnique Customers	TotalLarge Orders	TotalUniqueCust_ LargeOrders
25	25	20	18	18	15

Note ≡ COUNT() 함수는 정수 값을 반환하는데 반환 값이 2,147,483,647로 제한된다는 것을 의미한다. DB2와 SQL Server에서는 bigint 값을 반환하는 COUNT_BIG() 함수를 제공하는데, 반환 가능한 최댓값은 9,223,372,036,854,775,807이다.

액세스에서는 COUNT()와 DISTINCT를 결합해서 사용할 수 없다.

핵심 정리

- 적절한 형식으로 COUNT() 함수를 사용하면 계산을 단순화할 수 있다.
- WHERE 절을 사용하지 않고 여러 계산을 결합하려면 COUNT() 함수의 매개변수로 다른 함수를 사용하는 방안을 고려한다.

BETTER WAY 37 윈도우 함수 사용법을 알아 두자

SQL:2003 표준 이전에 정한 SQL 표준이 가진 단점은 인접한 로우에 의존한 데이터를 다루지 못한다는 것이다. 이전 표준에는 '인접한 로우'란 개념 자체가 없었다. 이론적으로 주어진 조건과 일치하는 한 로우의 순서는 그리 중요하지 않았다. ORDER BY 절은 오랫동안 관계형 연산의 일부라기보다는 데이터 출력에 더 많은 의미를 두었다. 여기서 말하려는 요점은 특정 유형의 연산은 SQL 단독으로 수행하기가 매우 어렵다는 것이다. 표 5-18에서 이동 합계를 구한 결과를 살펴보자.

▼표 5-18 이동 합계를 구한 결과

OrderNumber	CustomerID	OrderTotal	TotalByCustomer	TotalOverall
1	1	213.99	213.99	213.99
2	1	482.95	696.94	696.44
3	1	321.50	1018.44	1018.44
4	2	192.20	192.20	1210.64
5	2	451.00	643.20	1661.64
6	3	893.40	893.40	2555.04
7	3	500.01	1393.41	3055.05
8	4	720.99	720.99	3776.04

SQL:2003 표준 이전에는 이런 결과를 뽑는 쿼리를 작성하기가 매우 어려웠고, 쿼리를 만들었다 해도 매우 비효율적이고 느리게 수행되었다. SQL:2003 표준에서는 윈도우 함수(Window Function) 개념을 소개했는데, 여기서 '윈도우'는 대상 로우를 둘러싼 로우(해당 로우 앞이나 뒤에 있는 로우)의 집합을 의미한다. SUM(), COUNT(), AVG() 등 이미 친숙한 집계 함수를 윈도우 함수로 사용할 수 있다. 게다가 SQL:2003 표준에서는 ROW_NUMBER()

와 RANK() 같은 새 함수를 도입했는데, 이들은 윈도우 함수로만 사용할 수 있다. 몇몇 DBMS에서는 이미 현재 버전에서 최소한 이 중 일부는 구현해 놓았는데, 어떤 윈도우 함수를 사용할 수 있는지 알고 싶다면 관련 문서를 참고하자.

코드 5-29는 표 5-18과 같은 이동 합계를 구하는 쿼리를 윈도우 함수로 구현한 것이다.

코드 5-29 이동 합계를 구하는 쿼리

```
SELECT
  o.OrderNumber, o.CustomerID, o.OrderTotal,
  SUM(o.OrderTotal) OVER (
    PARTITION BY o.CustomerID
    ORDER BY o.OrderNumber, o.CustomerID
  ) AS TotalByCustomer,
  SUM(o.OrderTotal) OVER (
    ORDER BY o.OrderNumber
  ) AS TotalOverall
FROM Orders AS o
ORDER BY o.OrderNumber, o.CustomerID;
```

코드 5-29의 쿼리에는 눈여겨볼 점이 몇 가지 있는데, 먼저 OVER 절부터 살펴보자. 이 절은 윈도우에 SUM() 함수를 사용한다는 의미다. OVER 절에서는 PARTITION BY와 ORDER BY를 사용하는데, PARTITION BY는 윈도우를 어떻게 분할하는지 명시한다. 이것을 생략하면 데이터베이스 시스템은 윈도우 함수를 전체 결과 집합에 적용한다. TotalByCustomer는 o.CustomerID를 명시하는데, o.CustomerID 값이 같은 로우들에 SUM()을 적용해야 함을 의미한다. 이것은 개념적으로는 GROUP BY 절과 유사하지만, PARTITION 조건이 SUM() 함수 연산 대상이 되는 윈도우에만 그루핑을 수행해 독립적으로 적용된다는 주된 차이점이 있다. 반면에 GROUP BY 절은 전체 쿼리에 적용되며, 'BETTER WAY 30.

GROUP BY 절의 작동 원리를 이해하자'에서 다루었듯이 그루핑 대상이나 집계 대상이 아닌 컬럼은 참조할 수 없다는 추가적인 제약이 있다.

TotalOverall에는 PARTITION BY 절이 없다는 점에 주목하자. 이것은 쿼리가 반환하는 로우의 전체 집합에 대해 그루핑을 하는 것과 기능적으로 똑같다. 즉, GROUP BY 절을 뺐을 때와 같다.

다음으로 ORDER BY 조건을 살펴보자. 이 BETTER WAY 초반부에서 설명했듯이 결과 집합에서 로우가 반환되는 순서는 중요하다. 이 쿼리에서는 윈도우로 읽어 들여야 하는 로우의 순서를 명시했다.

이 모든 경우에서 주의할 점은 각 OVER 절 내에 정의된 조건은 다를 수 있으며, 각각 독립적으로 집계 함수가 적용된다는 것이다. 따라서 코드 5-30과 같이 작성해도 무방하다.

코드 5-30 각 OVER 절에서 서로 다른 조건을 가진 쿼리

```
SELECT
  t.AccountID, t.Amount,
  SUM(t.Amount) OVER (
    PARTITION BY t.AccountID
    ORDER BY t.TransactionID DESC
  ) - t.Amount AS TotalUnspent,
  SUM(t.Amount) OVER (
    ORDER BY t.TransactionID
  ) AS TotalOverall
FROM Transactions AS t
ORDER BY t.TransactionID;
```

이 쿼리는 전체 지출 비용과 지출 건별 실제 지출액을 모두 보여 주는 지출 보고서용으로 사용하기 적합하다. 남은 비용을 보여 주려고 TotalUnspent에서 t.TransactionID를 내림차순으로 정렬했다. 표 5-19는 코드 5-30의 쿼리를 실행한 결과다.

표 5-19 코드 5-30의 쿼리를 실행한 결과

AccountID	Amount	TotalUnspent	TotalOverall
1	1237.10	606.98	1237.10
1	298.19	308.79	1535.29
1	54.39	254.40	1589.68
1	123.77	130.63	1713.45
1	49.25	81.38	1762.70
1	81.38	0.00	1844.08
2	394.29	1676.49	2238.37
2	683.39	993.10	2921.76
2	993.10	0.00	3914.86

윈도우 함수를 사용하지 않고 표 5-19와 같은 결과를 얻으려면 개별적으로 각 윈도우를 계산하는 중첩된 SELECT 문을 여러 개 사용해야 할 것이다. 윈도우 함수를 사용하면 각 OVER 절에 PARTITION BY와 ORDER BY를 명시할 수 있으므로, 문장 수준의 GROUP BY 절을 고수할 필요 없이 단일 문장만으로도 여러 데이터 범위에 걸쳐 집계할 수 있다.

'BETTER WAY 38. 로우 번호를 만들어 다른 로우 대비 순위를 매기자'에서 새로운 윈도우 집계 함수를 다룰 것이다. 또 'BETTER WAY 39. 이동 집계를 만들자'에서는 윈도우 크기를 서술하는 좀 더 개선된 옵션을 다룰 것이다.

핵심 정리

- 윈도우 함수는 주변을 둘러싼 로우를 인지하므로, 전통적인 집계 함수와 문장 수준의 그루핑보다는 쉽게 이동 집계 연산을 할 수 있다.
- 윈도우 함수는 데이터에 다르게 그리고(또는) 독립적으로 적용해야 하는 집계에 제시할 수 있는 훌륭한 대안이다.

- 윈도우 함수는 SUM(), COUNT(), AVG() 같은 기존 집계 함수와 함께 사용할 수 있으며, OVER 절과도 함께 사용한다.
- PARTITION BY 조건은 집계 표현식을 적용해야 하는 그룹을 명시하는 데 사용한다.
- ORDER BY 조건은 뒤에 이어서 나오는 로우들의 집계 표현식 계산을 수행하는 방법에 영향을 주므로 중요하다.

BETTER WAY 38 로우 번호를 만들어 다른 로우 대비 순위를 매기자

'BETTER WAY 37. 윈도우 함수 사용법을 알아 두자'에서는 SUM() 같은 친숙한 집계 함수와 윈도우 함수를 사용하는 방법을 살펴보았다. 하지만 반드시 OVER 절과 함께 사용해야 하는 ROW_NUMBER()와 RANK() 같은 새로운 집계 함수도 있다. 어떤 데이터가 다른 데이터보다 높은 순위인지 정의하지 않고서는 순위를 매길 수 없으므로 당연하다. 코드 5-31에서는 이 두 함수의 사용 방법을 보여 준다.

코드 5-31 ROW_NUMBER()와 RANK() 함수를 사용한 쿼리

```
SELECT
  ROW_NUMBER() OVER (
    ORDER BY o.OrderDate, o.OrderNumber
    ) AS OrderSequence,
  ROW_NUMBER() OVER (
    PARTITION BY o.CustomerID
    ORDER BY o.OrderDate, o.OrderNumber
    ) AS CustomerOrderSequence,
  o.OrderNumber, o.CustomerID, o.OrderDate, o.OrderTotal,
  RANK() OVER (
    ORDER BY o.OrderTotal DESC
    ) AS OrderRanking,
  RANK() OVER (
    PARTITION BY o.CustomerID
    ORDER BY o.OrderTotal DESC
```

```
    ) AS CustomerOrderRanking
FROM Orders AS o
ORDER BY o.OrderDate;
```

표 5-20은 코드 5-31의 쿼리가 반환한 결과다.

표 5-20 코드 5-31의 쿼리가 반환한 결과

Order Sequence	Customer OrderSequence	Order Number	CustomerID	...
1	1	2	4	...
2	1	9	3	...
3	2	4	3	...
4	1	3	1	...
5	1	1	2	...
6	2	5	2	...
7	3	6	3	...
8	2	7	4	...
9	3	8	4	...
10	4	10	4	...

...	Order Date	Amount	Order Ranking	Customer OrderRanking
...	2/15	291.01	6	3
...	2/16	102.23	8	3
...	2/16	431.62	3	2
...	2/16	512.76	2	1
...	2/17	102.23	8	1
...	2/18	49.12	10	2
...	2/18	921.87	1	1
...	2/19	391.39	5	2
...	2/20	428.48	4	1
...	2/20	291.01	6	3

Note ≡ SQL Server는 DB2, 오라클, PostgreSQL과는 다른 순위를 반환할 수도 있다. 따라서 이 책의 깃허브 리포지터리에 있는 DBMS별 스크립트가 반환하는 데이터는 표 5-20과 결과가 다를 것이다.

BETTER WAY 37에서 언급했듯이 PARTITION BY 조건은 순위 함수가 효율적으로 그루핑하는 데 영향을 미친다. OrderSequence 윈도우는 전체 데이터 집합에 적용되는 반면, CustomerOrderSequence 윈도우는 CustomerID로 그루핑한 집합에 적용된다. 따라서 고객 순위를 매길 때 두 번째 ROW_NUMBER()가 반환하는 순번은 '재시작'되어 해당 고객의 첫 번째, 두 번째 등 주문을 식별한다.

RANK() 함수는 동일한 ORDER BY 조건을 사용하지 않았다. 금액별 순위(즉, 지급액이 큰 순서)를 보기 원하므로 금액의 크고 적음에 따라 어떤 로우가 첫 번째, 두 번째 순위인지 결정된다. ROW_NUMBER()에서 처리했듯이, 그룹별로 순위를 분할해서 특정 고객에 대해 어떤 주문이 가장 큰지 식별할 수 있게 했다. CustomerOrderRanking 윈도우는 고객별로 가장 큰 주문, 두 번째 주문 등이 어떤 주문인지 알 수 있게 분할한다.

순위가 동일한 로우에서 RANK() 함수의 연산이 어떻게 수행되는지 파악하는 것도 중요하다. OrderRanking에서 OrderNumber 2와 10, 9와 1의 순위가 동일하다. 결과적으로 RANK() 함수의 순위 결과에 뭔가 빠져 있다. OrderRanking 값에는 7과 9가 빠져 있는데, 각각 6순위와 8순위의 주문과 순위를 공유(같은 순위)하고 있기 때문이다. 이 결과가 마음에 들지 않는다면 DENSE_RANK() 함수를 사용해도 된다. 또는 이런 동일 순위를 만들지 않도록 OVER 절을 다시 작성할 수도 있다.

이 함수들에서 주목해야 할 또 다른 점은 ORDER BY 조건이 필요하다는 것이다. 이 두 함수는 ORDER BY 조건에 다른 컬럼을 명시하면 다른 결과를 반환하기 때문이다.

핵심 정리

- ROW_NUMBER(), RANK()를 비롯한 순위 함수는 항상 윈도우에서 사용해야 하므로 OVER 절 없이는 사용할 수 없다.
- 순위 함수를 사용할 때는 동일한 순위를 어떻게 처리할지 고려해야 한다. 연속적인 순위를 보려면 DENSE_RANK() 함수를 사용한다.
- 순위 함수에서는 ORDER BY 조건을 반드시 사용해야 한다. 순번이나 순위를 매기는 데 영향을 미치기 때문이다.

BETTER WAY 39 이동 집계를 만들자

'BETTER WAY 37. 윈도우 함수 사용법을 알아 두자'와 'BETTER WAY 38. 로우 번호를 만들어 다른 로우 대비 순위를 매기자'에서 소개한 예제에서는 그룹을 묶을 때 윈도우 함수의 기본 경계 설정 동작을 살펴보았다. 하지만 이동 집계를 생성할 때는 이런 기본 경계 설정 동작이 활성화되지 않을 것이다. 종종 전체 데이터 집합보다 더 작은 범위의 집합 내에서 비교해 성과 지표를 보고 싶을 때가 있다. 예를 들어 전체 기간보다는 3개월 평균 매출을 산출하는 보고서가 더 유용하다. 또 지난달보다는 특정 달의 지난해 매출과 비교할 때가 더 많다. 이 두 경우 모두 적용하는 함수에서 윈도우 프레임(윈도우로 묶인 로우를 둘러싼 틀)의 경계를 어떻게 분할할지 명시해야 한다. 그런데 BETTER WAY 37과 BETTER WAY 38에서는 어떤 경계도 명시하지 않아서 ORDER BY 조건을 명시했는지 여부에 따라 디폴트로 그 경계가 만들어

졌다. 코드 5-32는 코드 5-29의 쿼리와 동일하지만, 윈도우 프레임의 경계를 지정했다.

코드 5-32 이동 집계를 수행하는 윈도우 함수

```
SELECT o.OrderNumber, o.CustomerID, o.OrderTotal,
  SUM(o.OrderTotal) OVER (
    PARTITION BY o.CustomerID
    ORDER BY o.OrderNumber, o.CustomerID
    RANGE BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
  ) AS TotalByCustomer,
  SUM(o.OrderTotal) OVER (
    PARTITION BY o.CustomerID
    --RANGE BETWEEN UNBOUNDED PRECEDING AND UNBOUNDED FOLLOWING
  ) AS TotalOverall
FROM Orders AS o
ORDER BY o.OrderID, o.CustomerID;
```

TotalOverall에서 윈도우 프레임 정의 부분을 주석 처리했음에 주목하자. ORDER BY 조건 없이 윈도우 프레임을 정의하는 것은 유효하지 않기 때문이다. 그렇더라도 이 쿼리로 윈도우 함수 표현식을 생성할 때마다 기본 설정이 적용된다는 점은 알 수 있다. RANGE 구문에는 다음 세 가지 경계 설정 옵션을 사용할 수 있다.

- BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
- BETWEEN CURRENT ROW AND UNBOUNDED FOLLOWING
- BETWEEN UNBOUNDED PRECEDING AND UNBOUNDED FOLLOWING

처음 두 옵션에서는 BETWEEN…AND… 구문을 사용하는 대신 다음과 같이 줄여서 쓸 수 있다.

- UNBOUNDED PRECEDING
- UNBOUNDED FOLLOWING

RANGE를 사용하면 현재 로우를 다른 로우와 비교하고, ORDER BY 조건을 기준으로 그루핑한다. 하지만 항상 바람직한 방법은 아니다. ORDER BY 조건에 대해 두 로우의 결과가 동일한지와 별개로 물리적 오프셋(Physical Offset)(물리적으로 정확한 로우의 범위 지정)을 지정하고 싶을 수도 있기 때문이다. 물리적 오프셋을 사용하려면 RANGE 대신 ROWS를 명시해야 한다.

앞에서 설명한 세 가지 옵션에 다음 세 가지를 더 추가해서 사용할 수 있다.

- BETWEEN N PRECEDING AND CURRENT ROW
- BETWEEN CURRENT ROW AND N FOLLOWING
- BETWEEN N PRECEDING AND N FOLLOWING

여기서 N은 양의 정수를 의미한다. 또 경우에 따라 CURRENT ROW를 UNBOUNDED PRECEDING이나 UNBOUNDED FOLLOWING으로 대체해 사용할 수도 있다. 윈도우 프레임의 크기를 자유롭게 설정하려면 ROWS를 사용한다. 단, 현재 로우를 기준으로 한 물리적 오프셋으로만 윈도우 프레임의 크기를 설정할 수 있다. 표현식으로 윈도우 프레임의 크기를 설정할 수는 없지만, 윈도우 프레임 설정을 적용하기 전에 데이터를 미리 처리하는 방식으로 한계를 극복할 수 있다. 예를 들어 공통 테이블 표현식(CTE)으로 일부 그룹을 만들고 나서 CTE에 윈도우 함수를 적용하면 된다.

구문을 숙지하고 3개월 이동 평균을 만들어 보자. 올바르게 평균을 계산하려고 코드 5-33에서는 LAG와 LEAD 함수를 사용했다. 여기서는 CTE 정의 부분인 PurchaseStatistics가 빠졌다는 점에 유의하자(이 책의 깃허브 리포지터리에 있는 스크립트에 정의되어 있다).

코드 5-33 윈도우 함수를 사용한 이동 평균

```
SELECT
  s.CustomerID, s.PurchaseYear, s.PurchaseMonth,
  LAG(s.PurchaseTotal, 1) OVER (
    PARTITION BY s.CustomerID, s.PurchaseMonth
    ORDER BY s.PurchaseYear
  ) AS PreviousMonthTotal,
  s.PurchaseTotal AS CurrentMonthTotal,
  LEAD(s.PurchaseTotal, 1) OVER (
    PARTITION BY s.CustomerID, s.PurchaseMonth
    ORDER BY s.PurchaseYear
  ) AS NextMonthTotal,
  AVG(s.PurchaseTotal) OVER (
    PARTITION BY s.CustomerID, s.PurchaseMonth
    ORDER BY s.PurchaseYear
    ROWS BETWEEN 1 PRECEDING AND 1 FOLLOWING
  ) AS MonthOfYearAverage
FROM PurchaseStatistics AS s
ORDER BY s.CustomerID, s.PurchaseYear, s.PurchaseMonth;
```

CustomerID와 PurchaseMonth로 분할한 점에 주목하자. 이렇게 하면 같은 그룹에서 현재 월 이전 또는 이후가 아니라 해당 연도의 모든 월을 그루핑해서 한 연도의 월과 다른 연도의 월을 비교할 수 있다. 그래서 윈도우 프레임의 경계를 설정할 때 PRECEDING과 FOLLOWING 앞에 각각 1이라는 물리적 오프셋을 명시했다. 표 5-21은 코드 5-33의 쿼리를 실행한 결과다.

❮ 표 5-21 코드 5-33의 쿼리를 실행한 결과

Customer ID	Purchase Year	Purchase Month	Previous MonthTotal	Current MonthTotal	Next MonthTotal	MonthOf YearAverage
1	2011	5	NULL	1641.16	9631.94	5636.55
1	2011	6	NULL	1402.53	6254.64	3828.59
1	2011	7	NULL	2517.81	10202.26	6360.04
...	...	...	...	...	...	...
1	2012	5	1641.16	9631.94	10744.23	7339.11
1	2012	6	1402.53	6254.64	8400.52	5352.56
1	2012	7	2517.81	10202.26	12517.99	8412.69
...	...	...	...	...	...	...
1	2013	5	9631.94	10744.23	4156.48	8177.55
1	2013	6	6254.64	8400.52	6384.93	7013.36
1	2013	7	10202.26	12517.99	10871.25	11197.17
...	...	...	...	...	...	...
1	2014	5	10744.23	4156.48	11007.72	8636.14
1	2014	6	8400.52	6384.93	6569.74	7118.40
1	2014	7	12517.99	10871.25	12786.33	12058.52

평균 매출을 보면 2012년과 2013년에는 실적이 좋았다. 2012년 6월을 보면 2011년 월 합계 1,402.53달러, 2013년 월 합계 8,400.52달러, 2012년 월 합계 6,254.64달러의 평균을 낸 전체 평균은 5,352.56달러다.

물리적 오프셋에 의존하는 쿼리가 일관적이라는 점을 중요하게 여겨야 한다. 이 쿼리는 연도마다 항상 로우가 12개 있다고 가정한다. 그렇지 않으면 PARTITION BY와 ORDER BY 절이 제대로 작동하지 못한다. 특정 월에 매출이 없을 때도(예를 들어 회사가 잠시 문을 닫아 매출이 없는 경우) 해당 월

에 대응하는 로우가 반환되어야 한다. 'BETTER WAY 56. 특정 범위에 있는 모든 날짜를 나열한 일정 달력을 만들자'에서는 Purchases 테이블과 LEFT 조인해 빠진 월의 합계가 0이 되어 올바르게 분할되는 달력 데이터를 만드는 예제를 다룬다.

RANGE나 ROWS는 언제 사용할까?

RANGE와 ROWS의 차이를 구분하는 것은 쉽지 않다. 앞에서 언급했듯이 RANGE는 논리적인 그루핑과 함께 작동해 ORDER BY 조건이 중복된 값을 반환할 때만 차이가 명확히 드러난다. 코드 5-34는 동일한 경계 프레임에서 RANGE와 ROWS를 사용한 쿼리다. 지면 제약 때문에 CTE로 정의한 PurchaseStatistics가 빠져 있지만 이 책의 깃허브 리포지터리에 있는 스크립트에는 포함되어 있다.

코드 5-34 RANGE와 ROWS를 사용한 쿼리

```
SELECT
  s.CustomerID, s.PurchaseYear, s.PurchaseMonth,
  SUM(s.PurchaseCount) OVER (
    PARTITION BY s.PurchaseYear
    ORDER BY s.CustomerID
    RANGE BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
  ) AS CountByRange,
  SUM(s.PurchaseCount) OVER (
    PARTITION BY s.PurchaseYear
    ORDER BY s.CustomerID
    ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
  ) AS CountByRows
FROM PurchaseStatistics AS s
ORDER BY s.CustomerID, s.PurchaseYear, s.PurchaseMonth;
```

ORDER BY 조건에 s.CustomerID가 명시되어 있는데, 12개월에서 중복되므로 이 값은 유일하지 않다. 표 5-22는 가능한 결과를 보여 준다.

계속

표 5-22 RANGE와 ROWS의 차이를 보여 주는 결과

Customer ID	Purchase Year	Purchase Month	CountBy Range	CountBy Rows
1	2011	1	181	66
1	2011	2	181	78
1	2011	3	181	181
1	2011	4	181	39
1	2011	5	181	97
1	2011	6	181	153
1	2011	7	181	54
1	2011	8	181	107
1	2011	9	181	171
1	2011	10	181	11
1	2011	11	181	128
1	2011	12	181	142

ORDER BY 조건에 PurchaseMonth가 포함되어 있지 않기 때문에 PurchaseYear 값이 동일한 것 중에서 CustomerID 값이 같은 로우는 12개뿐이다. RANGE는 이들을 논리적으로 동일한 '그룹'으로 여겨 12개의 로우 합계가 모두 같다. 이에 반해 ROWS는 해당 그룹에 들어오는 로우의 누적 값을 반환하는데, 이 값은 정렬되어 있지 않다. 이것은 데이터베이스 엔진이 PurchaseMonth 값이 아닌 로우가 들어오는 순서대로 처리하기 때문인데, ORDER BY 조건에 PurchaseMonth가 명시되어 있지 않다. 이런 이유로 해당 윈도우에 들어오는 마지막 로우가 12월이 아니라 3월이 되어 합계가 181이 된다. 'BETTER WAY 37. 윈도우 함수 사용법을 알아 두자'에서 배웠듯이 ORDER BY는 결과 값을 극적으로 바꾸기 때문에 매우 중요하다. 따라서 윈도우 함수 표현식에서 PARTITION BY와 ORDER BY를 모두 사용할 때는 세심한 주의가 필요하다.

핵심 정리

- 윈도우 프레임의 경계를 기본 값이 아닌 값으로 변경할 때는 선택 사항일 때조차도 ORDER BY 조건을 명시해야 한다.
- 윈도우 프레임 크기를 임의로 정의해야 할 때는 ROWS를 명시해야 한다. 이렇게 하면 선행 또는 후행 로우로 얼마나 많은 로우를 이 윈도우 프레임에 포함할지 결정할 수 있다.
- RANGE를 사용할 때는 UNBOUNDED PRECEDING, CURRENT ROW, UNBOUNDED FOLLOWING만 쓸 수 있다.
- 로우의 논리적인 그룹을 만들 때는 RANGE를 사용하고, 물리적인 오프셋을 만들 때는 ROWS를 사용한다. ORDER BY 조건이 중복된 값을 반환하지 않는다면 이 둘은 동일한 결과를 반환한다.